


COMPUTATIONAL ADVERTISING

计算广告

互联网商业变现的市场与技术

刘鹏 王超 著



中国工信出版集团



人民邮电出版社
POSTS & TELECOM PRESS

计算广告 互联网商业变现的市场与技术

刘鹏 王超 著

人民邮电出版社

北京

图书在版编目 (CIP) 数据

计算广告：互联网商业变现的市场与技术/刘鹏，王超著.--北京：人民邮电出版社，2015.9

ISBN 978-7-115-39249-7

I. ①计... II. ①刘...②王... III. ①计算技术—应用—广告学—研究②数据处理
IV. ①F713.80-39②TP274

中国版本图书馆 CIP 数据核字 (2015) 第 163370 号

内容提要

计算广告是一项新兴的研究课题，它涉及大规模搜索和文本分析、信息获取、统计模型、机器学习、分类、优化以及微观经济学等诸多领域的知识。本书从实践出发，系统地介绍计算广告的产品、问题、系统和算法，并且从工业界的视角对这一领域具体技术的深入剖析。

本书立足于广告市场的根本问题，从计算广告各个阶段所遇到的市场挑战出发，以广告系统业务形态的需求和变化为主线，依次介绍合约广告系统、竞价广告系统、程序化交易市场等重要课题，并对计算广告涉及的关键技术和算法做深入的探讨。

无论是互联网公司商业化部门的产品技术人员，还是对个性化系统、大数据变现或交易有兴趣的产品技术人员，传统企业互联网化进程的决策者，传统广告业务的从业者，互联网创业者，计算机相关专业研究生，都会从阅读本书中受益匪浅。

◆著 刘鹏 王超

责任编辑 杨海玲

责任印制 张佳莹 焦志炜

◆人民邮电出版社出版发行 北京市丰台区成寿寺路 11 号

邮编 100164 电子邮件 315@ptpress.com.cn

网址 <http://www.ptpress.com.cn>

北京艺辉印刷有限公司印刷

◆开本：800×1000 1/16

印张：20.25

字数：388 千字 2015 年 9 月第 1 版

印数：1-4000 册 2015 年 9 月北京第 1 次印刷

定价：69.00 元

读者服务热线：(010) 81055410 印装质量热线：(010) 81055316

反盗版热线：(010) 81055315

对本书的点评

以下点评分领域以点评人的姓氏笔画为序排列。

互联网公司管理层

在线广告市场是比较复杂的体系，它贯穿了互联网生态链的各种角色。刘鹏的著作既从商业角度介绍了在线广告，也深入到了广告的技术和算法层面，还包括对于一个大规模竞价市场在市场设计方面的相关原理和优化机会。这本书不仅是了解在线广告市场的途径，也是了解互联网商业和盈利模式设计的窗口，同时对于互联网产品设计会有很好的参考作用。

——王华（@超凡 Derek），阿里巴巴副总裁，阿里妈妈负责人

这是一本非常系统、全面地介绍计算广告的书，一本在线广告专业人员必读的书，一本值得强烈推荐给想利用互联网力量的企业主和决策制定者和对大数据价值感兴趣的研究人员和工程师的书。虽然我亦曾亲眼目睹广告业在 20 世纪 90 年代开始的革命，一直积极参与在线广告的演变，但阅读完这本书，我对计算广告整个图景以及很多细微之处有了更多更深刻的理解。

——毛建昌，微软 Distinguished Engineer 和 Bing 广告工程负责人，前雅虎实验室广告科学副总裁

十多年的实践证明，互联网最有效的商业模式莫过于可以把流量直接变现的在线广告模式。从最初铺天盖地的横幅广告起步，到人群及兴趣精准定向的搜索广告与推荐引擎，直到与内容环境融为一体的原生广告，用户需求与口味的不断变迁促使着广告产品与技术持续不断地升级与发酵。本书最大的亮点在于，作者从中国互联网广告发展全过程亲历者的视角，极为系统地讲述了计算广告的产品设计思维与技术理论基础，涵盖从广告呈现到计价策略乃至算法实现并直接运用于互联网流量变现课题的方方面面。无论是产品经理还是工程师，如若准备投身于这一互联网最大的金矿领域，此书是手边必须常备的工具书与教材。

——刘子正（@刘子正），微博常务副总经理

本书内容全面且与时俱进，对核心技术的介绍深入浅出，是计算广告领域一本难得的好书。本书视野宽阔，涵盖了在线广告市场及核心技术的各个方面，除了主流技术以外，对一些其他著作很少涉及的方面，如广告创意优化、反欺诈、隐私保护等也进行了介绍。本书内容新颖，把近年涌现出的一些新的广告形式和技术，如实时竞价的广告交易、原生

广告等，都囊括其中。另外，本书行文流畅、逻辑清晰，对核心技术的介绍深入到位，包含了重要的算法细节以及理论探讨，对计算广告的从业者而言，是一本非常实用的参考书。

——刘铁岩（@刘铁岩），微软亚洲研究院首席研究员

在互联网深入改造传统行业的进程中，所谓“羊毛出在猪身上”的后向变现商业策略至关重要。市场上并不乏关于这一策略的推崇和讨论，不过本书从实战的角度出发，对其中关键的商业逻辑和产品结构作了全面的梳理，而这些对于商业化战略的落地至关重要。因此，我推荐所有正处在互联网化变革行业的从业者们阅读本书，结合各自的知识背景和行业问题，相信你们一定可以从本书中找到有指导意义的内容。

——陈彤（@老沉），小米内容运营和投资副总裁

刘鹏博士是我以前在微软时的同事，他博学睿智，融会文理，给我留下深刻印象。他将多年积累的相关经验与成果整理成国内第一部正式出版的计算广告著作，值得向大家强烈推荐。这本书将该领域的实际商业问题与技术解决方案结合起来，让读者对计算广告的理论与实践、应用与技术、系统与方法有全面深入的了解和认知。对于已经掌握了机器学习、数据挖掘技术的从业者、技术人员、教师和学生，如果想进入计算广告及其相关领域，这是一部极佳的指南。

——李航（@李航博士），华为诺亚方舟实验室主任

互联网业内人士都清楚流量的作用，流量之于互联网，正如血液之于人体。不同之处在于，互联网上的流量是趋利的，变现能力决定了流量的方向和价值。计算广告是流量变现最重要的方式之一。只有了解了互联网广告的精髓，才能真正懂得互联网上流量的奥秘，也才能懂得互联网的奥秘。本书作者对互联网广告的市场、产品和技术做了全面、深刻的剖析，为业内外人士理解并踏入这个领域提供了一条捷径。尽管本人从事互联网广告研发多年，也是第一次读到如此系统的著作，受益匪浅！

——沈抖（@沈抖），百度高级技术总监

我们的团队花了大量精力寻找和调研国内外的相关资料和文献，却一直苦于没有一套相对完整的知识体系来帮助我们的业务和技术人员加快学习、少走弯路。因此，我期待这样一本书的出现至少已经有两三年的时间。作为一门方兴未艾而发展迅猛的新兴产业，我相信刘鹏的这套科学且实际的知识体系，将对数字营销领域的同仁有非常大的指导价值。程序化营销、大数据应用是发展异常迅猛的产业，涉及大量的产品、工程以及算法，也涉及相当多的商业逻辑的深刻洞察。而刘鹏通过对产业内在逻辑的诠释和推演贯穿程序化营销产业的发展，对我们真正把握大数据给各个产业带来的深刻变化和影响，具有深刻的指导意义。

——杨炯纬（@杨炯纬），360 副总裁，聚效广告 CEO

如果说当年 **Yahoo!** 广告首席科学家 **Andrei Broder** 在斯坦福开设的课程第一次把计算广告学作为一门学科，那么这本《计算广告》堪称这门新兴学科的第一本教科书，因为这是首次全面系统地阐述计算广告学的著作，覆盖了商业逻辑、产品结构、关键技术、工程实践和应用实例。在内容结构编排上，本书由浅入深，从宏观背景到技术细节，从经典的搜索广告到最新的实时竞价，既适合作为从事在线广告的商务运营人员的参考书，也适合作为一线技术开发人员的实战指导。

——余凯（@余凯西二旗民工），百度研究院副院长，深度学习实验室主任

计算广告近年来特别热，全球大小互联网公司大量的算法工程师、系统工程师、数据科学家在从事与此相关的工作。正如刘鹏在书中指出的，流量变现和数据变现是很多互联网公司商业模式的核心。虽然学术界和工业界有大量与计算广告相关的文章，但或侧重于算法，或侧重于系统，抑或侧重于商业逻辑，却很少能像本书一样把这几个维度融会贯通地串在一起，既有连贯性、有广度，又有足够的深度。刘鹏过去几年中花了大量的精力在清华大学、北京大学以及一些在线教育平台分享他对计算广告的深刻理解，影响了不少人，我过去和现在的团队都有他的粉丝、他的学生。现在刘鹏又把他对计算广告的深刻理解集结成书，能影响到更多的人。为刘鹏点赞！

——张小沛（@Joyce 在路上），宜信 CTO，前 Hulu 全球副总裁

计算广告学纷繁复杂，刘鹏以一个科学的实践家的态度抽丝剥茧，全面、系统地阐述了其技术架构与产品生态，为入门者普及了概念，为从业者开阔了眼界。

——罗征，腾讯广点通总经理

互联网广告在近十余年里一直保持着爆炸式的发展，支撑着谷歌、脸书、阿里、百度等数个百亿、千亿级互联网公司。或许其发展过于迅猛，或许其涉及领域过于宽泛，以至于近几年来一直没有一本优秀的书能够系统、全面地对互联网广告加以介绍。这本书把这件早就应该有人去做的事情漂亮地完成了。从业务模式到技术架构，从算法模型到工程实现，从理论基础到实现细节，从历史背景到最新动态，这本书都做了翔实、系统的讲解。相信对于每一位置身于互联网广告业的朋友，不论其在这纷繁复杂的行业里承担什么样角色，这本书真值得一读。

——顾大伟（@小米大伟），小米广告负责人

很高兴看到刘鹏博士把自己在互联网广告领域的多年经验和智慧整理成书，其中既有他对商业产品的理解，也有算法和工程实现的总结。本书不仅第一次全面梳理了互联网广告产品形态，针对每个产品描述了相应的核心算法和系统实现，而且全面描述了以媒体和广告主为核心的生态圈，以及技术如何一步步促使生态圈演化，不断创造出更大的商业价值。对于互联网广告从业者来说，相信读后一定获益良多。

——贾志峰（@贾志峰 Michael），汽车之家技术副总裁

来自互联网创业者

如果你正从事或准备进入互联网广告行业，本书应该是你的职业生涯中必不可少的读物之一。无论在中国或是放眼世界，作者以更深、更广的视角向读者展示了当今互联网行业的市场与技术。在享受互联网大数据带来乐趣的同时，书中介绍的中西市场案例将助力中国互联网从业者（包括产品技术人员）开拓创新思维。本书为推动中国互联网发展赋予了更重要的意义。

——闫墨（@闫墨 AdMaster），AdMaster 创始人、CEO

今天，大数据浪潮正在席卷全球。数字技术正在改变我们的生活方式，同样也在驱动着商业、营销和广告业的未来。营销不再只是关于策略、创意和 idea 的，更和技术的发展紧紧地捆绑在一起。进入 2015 年后，我们看到全行业正在迎接大数据的风口，从数据的沉积分析和管理到数据的真正打通，这是一场时代的演进。刘鹏博士的这本书正是对这个变革时代营销技术变化的实录，他对最新数字广告技术方方面面的精到剖析，不仅是对广告知识体系的实时更新，更是对未来新的数字营销体系架构的有益探索。希望今天我们在勇于探索和开拓的也正是未来被写进历史的故事。

——吴明辉，秒针系统创始人、董事长兼 CEO

随着互联网的高速增长，广告开始往精细化发展，如何在有限的资源里获得最大化的广告综合收益是一个非常复杂、重要且有趣的问题，这也是计算广告研究的方向。刘鹏作为这个方向的专家，在本书中从计算广告问题的提出开始，介绍了计算广告的产品形态以及关键技术，非常适合互联网广告的从业者系统性地了解计算广告领域。

——周霖（@周霖-KCN），搜易贷联合创始人，前搜狐高级副总裁

这本书逻辑清晰，非常贴近实战，值得网络广告从业人员仔细阅读与思考。无论是媒体、广告代理还是广告主，谁能更好地获取数据、理解数据、应用数据，谁就能在日益激烈的市场竞争中脱颖而出。

——赵士路（@赵士路），WiseMedia 创始人、CEO

互联网和移动互联网广告生态圈正在发生翻天覆地的变化，广告形式、产品形态、市场格局及产业链模式不断推陈出新，让人目不暇接。同时，基于营销大数据的计算广告技术也日益成熟。刘鹏博士的这本书将两者有机结合，既能帮助从业人员了解互联网广告全貌及流量变现的现状，也能帮助技术人员掌握计算广告的核心技术，是一本兼顾商业产品逻辑和技术实践的难得一见的佳作。

——唐健，智云众创始人、CEO

互联网广告是一个千亿级的市场，如果把互联网比作一辆车的话，互联网广告就是汽油，因为大多数网站都是依靠广告盈利。刘鹏博士的这本书涉及大量的基础知识、概念和商业模式，是目前此领域比较全面的一本广告技术著作。书的内容深入浅出，讲述了搜索

广告、广告交易平台、广告基本算法以及开源系统等重要概念，也介绍了不少相关广告技术公司以及他们在互联网广告这个产业链上的各种典型产品，非常适合从业人员以及有兴趣进入这一阳光产业的同学学习。

——唐朝晖（@唐朝晖_adSage），艾德思奇创始人、CEO

过去 5 年是移动互联网发展最快的时期，开发者创造出如此多的应用和内容，用户行为习惯和数据积累发生如此惊人变化。在此过程中，在线广告作为最主要的变现形式，逐渐成为广大从业人员必须掌握的知识和技术。然而，由于此领域学习门槛较高，对于很多从业人员来说迷雾重重。大部分相关文章只是对于广告相关一些术语进行了罗列或介绍，无法让大家“知其然而知其所以然”。这本书的出版将弥补这一空白，它系统性地介绍在线广告的发展历史和逻辑，以及流行的程序化购买关键技术与算法。更为可贵的是，刘鹏在本书中融入了自己多年对于计算广告领域的理解和经验，使得整本书的思路和编排极为流畅。本书既适合想了解此领域的初学者或业务人员泛读，也适合专家以及产品人员对特定的知识点精读。本书将成为广大互联网从业人员必备的读物，特此重点推荐给大家。

——崔晓波（@崔晓波_TalkingData），TalkingData 创始人、CEO

来自媒体与行业专家

本质上讲，互联网经济与广告经济都属于信息经济的具体技术形态或产业形态，核心要素是数据，经济学特征则是“所有能够传播信息的商品，其售价都会趋向其边际成本”。因此，确定数据商业化与广告产品化之间转换的逻辑、方法和路径极为重要，计算广告恰恰是这样一种经过多年实践的有效体系。刘鹏先生所著的这本书对相关的技术、创新与商业作了极好的刻画、梳理与论述。

——马旗戟（@马旗戟），原尼尔森高级副总裁

这本书于我而言，是打开了一扇窗，让我看见了在巨大的互联网广告产业后面蕴含的数学模型和算法基础。计算广告学中蕴含的各种方法让我想到了管理方法论中很著名的一句话：“If you can't measure it, you can't manage it!”量化的方法使得计算广告学成为计算机科学与工程的一个崭新和重要的方向。非常感谢作者的知识分享。

——陈怀临（@湾区评论），弯曲评论创始人

我有两个身份，既是从 20 世纪开始工作的广告主，同时又是大学老师，但面对的却是一样的问题和困惑。营销方法尤其是广告形式推陈出新，众多科技层出不穷，受限于自身的学问背景，不可能全部都了解。所以有拜读本书内容的机会我特别欣喜，终于有由业内专家执笔且技术含量特别高、非常实用的书了。广告主可以从中了解不同的展现方式，利用书中的广告主在线营销决策过程择善而为。媒体也可以凭借类似的广告变现决策，揭示未来的发展方向。专业人员可以进一步了解背后的技术，找出最有针对性的广告投放，提升推广成果。因此，我非常推崇本书的实用价值及参考价值。

——杨仕名（@楊仕名），香港大学 SPACE 中国商业学院副总监，营销与传媒管理中心主任

广告带来的后向变现是互联网经济中核心的变现模式之一，也是互联网商业模式的重要根基，而本书对这一领域作了一次全面的总结。我们希望互联网企业、广告服务和技术公司，以及艾瑞这样的数据服务公司，以本书的出版为契机，认真探讨互联网商业模式上的分工协作，推动行业的变革与发展。

——杨伟庆（@杨伟庆），艾瑞咨询总裁

世界上有一种沟通是付费的，这就是广告的本质。然而，近几年互联网改变了整个广告生态的格局，目前世界上最叱咤风云的互联网公司几乎都依赖广告。刘鹏博士的这本书系统性地介绍了这种深层次的变化，以及整个产业链迸发出的各种技术手段与学问。此书由浅入深系统地介绍了几乎每个互联网广告的生态位置以及背后运作的机理，是我目前见过国内最系统的介绍计算广告的著作。此书对互联网、媒体、广告公司、市场营销人士，甚至消费者都是一本了解互联网广告的佳作。

——张迪（@广告技术流 adexchanger），Adexchanger.cn 创始人

有了互联网才有了计算广告学：计算广告学把传统的无法定向投放和无法度量的广告变得可以定向投放和可以量化度量效果。刘鹏博士在工作之余，把计算广告学的系统性和多年实战经验总结成书，对从事计算广告的工程师和想了解计算广告的工程师都非常有帮助。

——张栋（@张栋_机器学习），前 Google 研究员

对计算广告技术和商务人才的需求近两年迅速高涨，但计算广告是一个新兴交叉学科，一直缺乏全面系统的专著。这本书全面介绍了这一领域的商业背景知识、业务需求和详细的技术实现思路。本书一个重要特色是将该领域的商业挑战与技术的选择、应用、实现进行了融汇中西的系统化介绍，让不同知识背景的读者都能从中获得认识提升。此外，本书对于整个计算广告技术知识体系的梳理全面、准确，囊括了从业人士和学术研究需要关注和了解的主要知识点，对于已有一定基础和实践经验的读者也能从中温故知新和查漏补缺。此书的出版对于促进中国相关行业人才池的增长大有裨益。

——范秋华（@RTBChina），RTBChina 创始人

互联互通正领跑，眼球经济网民包。创收多多靠广告，变现书籍好难找。计算广告学走俏，廿年蔚然成林梢。理论实践兼顾到，刘鹏此书及时抛。入门登堂先介绍，市场规模大蛋糕。产品技术两面刀，块块切尝大与小。搜索推广竞价搞，合约展现包推销。程序交易争分秒，移动平台憋新招。信息流起人社交，原生广告置混淆。探索利用平衡高，点击建模测验校。背景逻辑打夯牢，核心技术窥其奥。照葫芦可画出瓢，立竿见影编码跑。十载面壁勤思考，刘鹏功成发大招。油翁多年练广告，情不自禁拇指挑！

——洪涛（@zhazhaba），打油诗人，前百度高级科学家

序一

2009 年 11 月，我在香港参加 CIKM'09，听 Andrei Broder 等几位学者讲了一个导学课——Introduction to Computational Advertising（计算广告导论），耳目一新，觉得在我们的大学中应该有这样一门课。

回来后了解了一下周围青年教师的情况，没有发现能够开这种课的人。后来，好像首先是在微博上，知道了刘鹏是这方面的专家。一联系，果然如此。与其探讨在北大开一次这种课的可能性，他欣然应允。时间定在 2013 年夏天，我安排实验室的青年教师彭波做助教，目的之一，就是希望通过助教工作学会计算广告这一套知识，然后独立在北大开出课来。

刘鹏的课进行得很顺利，彭波每次都参加，我也去听过一次。2014 年秋，彭波勇敢地开出课来了。课程结束后我问他感觉怎么样，他说内容太多，把握得还不好，而且没有教材，对老师学生都是个困难。

其实，最初我请刘鹏来上课的时候就谈到过教材的问题。他答应考虑，但因为他在公司里的工作很忙，所以需要比较长的时间。但他没有忘记！两年多过去了，一天他给我发邮件说书稿完成了，希望我能为他的书写个序，令我十分欣喜。

这本书不厚，但比较全面地覆盖了基于互联网服务的广告的市场背景、产品逻辑与关键技术，给出了一个宽阔的视野。作者基于多年的从业经验，从市场行为出发演绎对产品与技术的需求，而不是就技术讲技术，提高了本书的立意，因而也适合更广泛的读者群，包括计算机相关专业的研究生。应该说，这本书的风格不同于通常的教材，如果直接用于教学，对教师的要求会比较高，但不失为一本优秀的教学参考书。尤其是在其内容铺陈中展现出来的数据加工、利用与交易的思维主线，能让计算机专业的学生看到活生生的技术需求。而在互联网广告的背景下对数据的充分强调，让读者对大数据的意义有了一种更具体的体会。

国内大学中的计算机专业教育（尤其是高年级和研究生的）现在困难和问题还比较多。比较明显的一点就是，教学内容的时代感不够强。这一点在广度和深度上都有反应。跟不上业界的发展，一些重要的课程不能及时有效地开，我认为“计算广告”就是其中之一。这种情况和蓬勃发展的信息技术和产业是不相适应的。因此，我们欢迎业界中对技术和产业有比较透彻理解且对教育有情怀的专家参与到大大学教学活动中来，让我们的学生学到更多的真本事，适应产业发展的需要。刘鹏 2013 年在北大首开“计算广告”课程就是这样一种表率，他这本书的面世也是这个意义上的一种奉献，当予祝贺。

李晓明，北京大学计算机系教授

序二

所有互联网公司都对广告变现的地位和价值并不陌生。在每一个用户产品成长的各个阶段，除了认真解决需求痛点、优化用户体验，也应该不断地对流量和数据的价值进行评估，并积极探讨商业变现的战略与产品。而在各种商业化产品当中，以计算为导向的广告变现无疑是最为重要的。

在产品选型、开发和运营的初期阶段，如果能对产品未来产生的数据和流量价值有正确的评估，并了解如何利用广告产品将这些资产变现，对于判断该产品的成长空间和商业价值非常重要。另外，早期的产品推广会用到许多广告营销产品，而对于计算广告原理的深入了解也将有利于高效地做好营销。

当产品得到市场认可，获得了一定的用户规模以后，积极制定系统性的商业化战略，用合理的变现方式获得现金流，从而支撑产品的快速发展，则是每一个互联网公司成长过程中必须经历的关键步骤。如果能洞悉互联网广告市场的产品技术全貌，无疑对此阶段的决策大有帮助。

虽然广告技术在互联网行业至关重要，长期以来，却只有一些只鳞片爪的专题文章，对业界系统架构与算法的介绍，从世界范围来看，都非常缺乏系统性的整理和总结。这一方面是由于广告市场发展迅速，从搜索竞价到程序化交易，再到移动互联网下的原生广告趋势，日新月异的产品进化速度让整个工业界来不及停下脚步做小结；另一方面是广告产品的内在逻辑不像用户产品那样直觉，要进行全面透彻的整理和剖析，需要兼有丰富的实践经验和相当的理论抽象能力。也正由于缺乏系统性的资料，互联网工业界在这方面的人才培养也不够系统，导致在广告产品技术这样一个重要的领域，人才一直是短缺的。

刘鹏博士曾经与我在搜狐集团有过一段时间的同事经历。从简短的几次接触中，我知道他在对媒体的流量变现和需求方广告产品方面都有丰富的实践经验，并曾在 **Yahoo! Labs** 对计算广告领域进行过系统性的研究，是对这一领域做全面总结的合适人选。如今，终于看到他不吝时间和精力，将计算广告领域的产品技术和商业逻辑整理成书，这将是令整个互联网工业界受益之举。

带着期待读完本书，我的第一印象是，其内容全面而富有条理：本书既有计算广告全线产品的介绍，又有对其商业逻辑和原理的透彻解剖，还有对应的技术架构和关键算法的深入讨论。另外，除了受众定向、点击率预估、实时竞价等热点问题的讨论，还有详尽的周边产品和技术的介绍。相信认真读完此书的读者，一方面会对整个广告生态的全貌有全

局性的了解，不会只见树木，不见森林；另一方面又可以按图索骥，再碰到各种实际问题时在本书中找到具体思路甚至解决方案。

当然，本书的另外一项重要意义就是，它是计算广告领域第一本系统性的正式出版物。非常希望以此为契机，从合理配置资源的角度出发，整个互联网领域能够在流量和数据变现上逐渐走向标准化与分工协作。这也许会从一个侧面促进中国互联网企业摆脱恶性竞争的囚徒困境，走向合作共赢之路。

最后，祝贺此书的出版，并希望它能够给你些许启示。

王小川，搜狗公司 CEO

序三

广告营销处在历史转折点，技术对传媒的驱动和融合趋势让数字营销充满变数，这变化颇有乐趣却又让人不安。原因很简单，一方面，技术驱动下的数字生态百花齐放，程序化营销渐入佳境；另一方面，数字世界各式各样的广告技术概念让市场营销者感到困惑。

不可否认，营销行业有专业的技术型人才和数据科学家帮助我们实践和创新这些技术，似乎有了需要的一切。可想象一下，某个下午时光，当和我们的客户坐在一起，他可能会问起这样的问题：未来你们能帮我们做什么？

如果说技术代表营销的未来，那么技术到底是什么呢？技术为什么存在？技术可以帮助做些什么？我常想，要拨开这些技术迷雾，营销人具备的知识背景应该能跨越技术理解的盲点，能洞察到真正关键且清晰的归因，把这些问题答案清晰和简单地传递给我们的客户。所以我期待行业中有人能把广告技术的真实情况和作用讲出来，无论是 DSP、DMP 或是 RTB 这些商业产品概念，还是“预测模型”“机器学习”和“人群定向”之类的技术名词。

带着这个期待，我阅读了刘鹏博士这本广告技术专著。我想说，我的这些疑惑在阅读这本书的过程中都得到了解答或者找到了线索。

刘鹏博士在互联网领域，特别是广告变现产品领域有着非常丰富的从业经验。从雅虎全球研发中心到微软研究院，再到今天作为 360 首席商业架构师，他既主持过需求方营销产品和供给方变现产品的设计开发，又兼有从产品到系统和算法的全面把握能力，而这些经验都成了本书丰富实用内容的基础。

一本好的广告书不会大谈趋势，而是会从细节观察出发，探知商业逻辑；一本好的技术书不会大谈常识，而是剖析实践领域的真知灼见。刘鹏博士编写的《计算广告》就是这样一本跨越领域、兼而有之的作品。

很愿意分享两点阅读感受。第一是繁纷复杂的数字生态和技术说辞，刘鹏对此做了系统的梳理和介绍，即使高度专业的产品概念、逻辑及算法应用，非技术背景的读者也能对这些概念建立统一的认识。第二是概念之外，书中列举了国际国内经典的广告平台产品，分析其形态、技术、策略，描绘了商业和产品之间相互关联、相互促进的有趣演进。这些来自于作者多年从业实践和积累并给营销人带来“互联网+”的思考角度更难能可贵。而书中列举了很多详实的数据和图例，反映了刘鹏博士对技术和治学的严肃态度。

如果你需要了解在线广告的产品和技术，就应该马上行动，打开这本书，努力去学习和探索。

愿每位从事数字广告事业的营销人，都能读到此书。

李桂芬，安吉斯媒体集团大中华区首席执行官

前言

互联网的快速发展改变了整个世界。从门户网站到搜索引擎、从社交网络到电子商务，从免费 Wi-Fi 到应用市场，层出不穷的在线服务不仅方便了人们的生活，甚至颠覆了原有的产业。而且更为神奇的是，这些服务大多是免费的。在今天，“互联网思维”这个名词被越来越多互联网行业内的人们追捧和畏惧，而其中很多人的困惑都在于：这么多免费的服务是如何获得收入，乃至赚得盆盈钵满呢？实际上，如果把多样的互联网产品或服务看成各式硬币的正面，那么我们会发现，其中许多硬币的背面都有着一样的图案，这就是以广告为核心的后向变现体系。正面的免费服务是为了获得流量和数据，而背面的广告业务则是将这些流量和数据变成金钱，这就是互联网最关键的思维模式之一。



在能够获得充分的流量或高价值数据后，我们认为，所有能够传播信息的商品，其售价都会趋向其边际成本。这样的观点对许多传统行业商业模式的影响是深远的，也是我们认为大家应该在互联网时代深入了解广告、了解变现产品的原因。因此，本书的内容虽然以介绍互联网广告的产品和技术为核心，但并不是想让大家学会搭建一个广告系统。我们的核心目的，是让读者在清晰地了解互联网广告全貌的基础上，在遇到与后向变现相关的产品问题时，能够以合理的思维逻辑和背景知识来应对。实际上，在互联网时代，不论你身处哪个行业，只要用心留意，会发现这类问题可能比你想象得更为常见，也更为重要。对其中最重要的几类问题，我们来看看下面几个具体的例子。

（1）商业模式探索。例如，电影是一种边际成本很低，同时信息传播量又很大的典型商品。那么现在电影的票价为什么这么高？能否探索一种售价很低，而充分利用其信息传播能力的电影行业发行模式，获得更高的经济效益和社会效益？

（2）流量变现。例如，互联网电视厂商除了硬件销售的回报以外，还可以获得一部分用户流量。这些流量的性质和价值如何，应该以什么方式变现？

（3）数据变现。例如，室内导航技术是近年来快速发展的新型互联网应用。如果以向用户免费的方式运营室内导航产品，会得到什么有价值的数据资产，从而支撑相应的后向变现，又应该采用哪种具体的商业产品来支撑？

（4）商业产品建设和运营。例如，团购、游戏联运、返利购买、积分墙这些推广模式与一般的展示或搜索广告有什么内在联系？是否可以共用某些产品和技术平台？

这4类问题的典型性和价值不言而喻。不过，要回答这些问题，仅靠独立的深入思考是不够的，你还必须对当前互联网流量和数据变现市场的商业逻辑和产品现状有相当程度的了解，并在需要具体产品实施时有相应的方案可以参考和选择。而为读者提供这方面的帮助，正是本书希望能做到的。

从传统的视角看广告，会有人认为互联网服务中的广告破坏了用户体验，这实际上是一种观念上的误解。首先，互联网广告不再像线下广告那样，以宣教性的横幅为主，而是以各种自动决策的付费信息的方式存在，这其中既包括传统的创意形式，也包括游戏联运、团购、返利、原生广告等更加契合用户意图的新传播形式。虽然，从微观上看，部分不顾及媒体价值、盲目变现的广告产品确实存在这样的问题，但从宏观上看，恰恰是因为广告这一后向变现模式的存在，互联网产品的整体用户体验才达到了前所未有的高度。在传统的企业中，一般会根据产品线分设若干事业部，每个事业部在研发自己产品的同时还要对营收和利润负责。而在互联网企业或者按照互联网方式运营的企业当中，还存在另外一种组织方式，即面向用户的免费产品部门只负责优化产品体验，不对营收负责，而专门面向客户的商业产品部门通过广告等后向变现方式为企业创造营收。实践证明，在这样的组织方式下，用户产品部门往往能够心无旁骛，专心为了提高用户体验而努力。因此，我们会看到，比起传统软件企业，互联网企业的产品在把握用户需求、优化用户体验方面往往能够做得更加优秀。

因此，在互联网的世界里，广告不再只是广告公司的事，而是每一个互联网公司都要关心的事。从结果来看，在线广告实际上成为互联网最重要的发动机。从营收上看，它支撑着互联网业务的大半壁江山。当然，广告的概念本身在互联网业务中也已经发生了脱胎换骨的变化：首先，在互联网广告中，服务于中小商家、以直接销售为目的的广告取代品牌广告成为主流，这也创造了全新的巨大市场；其次，它的关键不再是创意、策略等人工服务，而是以数据支撑的流量规模化交易为典型特点。也就是说，机器和算法取代了人员与服务，成为在线广告最鲜明的特色。可以说，互联网广告的灵魂就在于数据与计算，因此，也就产生了“计算广告”这一名词以及后面复杂的产品与技术。

计算广告这个课题，逐渐成形于以 Google AdWords 为代表的竞价广告业务产生以后，并且在展示广告进入程序化交易阶段以后愈加成熟。而将其整理成一个新的研究方向，则要归功于时任 Yahoo! 广告首席科学家的 Andrei Broder。他在斯坦福开设的

“Computational Advertising”这门课，第一次全面而系统地介绍了在线广告中的计算挑战以及工业界实用的算法。既然有了计算广告的相关课程，为什么还要再整理这本计算广告的书籍呢？首先当然是因为这一领域变化太快，在“计算广告”这个词诞生后的几年里，它的内涵和外延都已经发生了重大的变化，而且这几年的变化使得这个领域逐渐完备起来。因此，有必要在此时对当下的计算广告领域做一个阶段性的小结。另外还有一个重要原因：那就是我们在几次计算广告的教学实践中发现，对于在校学生或者刚刚接触此领域的朋友们来说，最主要的理解障碍不在于算法和技术本身，而在于广告的商业逻辑和产品目标。以此为出发点，本书的组织方式将以广告产品为核心。在清楚地了解计算广告的产品逻辑与商业价值的基础上，我们再来有针对性地讨论其中的算法和架构问题。因此，商业逻辑驱动的在线广告产品和技术的升级将是本书最重要的一条主线。

另外，本书还有一条潜在的主线，即数据的加工、利用与交易。熟悉了计算广告业务和产品的读者会有认识，广告业务的收益只能来自于三个方面：数据、流量和品牌属性。其中后两点是媒体的专属，而大量的广告平台在做的事情，主要就是数据的加工与利用。不夸张地说，计算广告对于数据利用的广度和深度是空前的，而且产业的各环节也是比较完备的。在各行各业都在强调大数据思维与方法的今天，深入了解计算广告产品与技术具有特别强的范本意义。因此，本书在内容组织上特别强调数据这条线索，努力向读者解释清楚如何在广告产品进化过程中一步步地更有效地利用数据。

读者对象

既然在线广告不再只是广告公司的事，那么需要了解这一业务及其背后产品技术的人群也就相当广泛了。我们希望下面几类读者可以从本书中找到有价值的内容。

（1）互联网公司商业化部门的产品、技术和运营人员。对互联网公司来说，商业化产品中最重要就是广告产品，不过我们发现，囿于各公司具体的产品形态，仅仅从自己的业务中全貌地了解广告产品技术并不容易。因此，本书最主要面向的读者就是这些广告产品相关的人员，希望他们通过阅读此书，对互联网广告的全貌以及复杂的技术产品系列有整体的了解，避免只见树木不见森林。

（2）对个性化系统、大数据变现或交易有兴趣者。计算广告在各种个性化系统中具有典型性，又因为其商业逻辑的存在而相对复杂；此外，计算广告还催生了对大规模数据利用和变现的直接市场。因此，推荐等个性化系统的产品技术人员以及大数据相关的产品技术人员都非常有必要通过了解计算广告的产品和技术，对个性化系统架构、约束下的效果优化、大数据变现和交易等诸多问题在实际工业界的落地有一定的理解。

（3）传统企业互联网化进程的决策者。传统企业在互联网化的过程中需要借鉴的不仅仅是利用互联网的技术和产品，更重要的是按照互联网企业形成的高效运营和变现模式来改造传统业务。从这个意义上说，互联网企业以广告为基础的后向变现体系是整个互

联网化过程中至关重要的一环。因此，在这样的传统企业中，互联网化进程的决策者对广告的原理和市场必须有一定程度的了解。

（4）传统广告业务的从业者。传统广告业务与互联网广告业务既有密切的联系又存在着巨大的差别。以技术为导向、精准地面向受众的广告策略正深刻地影响这整个广告市场。并且随着互联网广告规模的迅速扩大，这样的策略越来越为广告主接受和青睐。因此，传统广告业务的从业者必须要顺应潮流，理解和运用计算广告的方法与策略，将线下资源与线上资源整合起来，才能更好地服务于广告主和媒体。

（5）互联网创业者。我们接触过不少互联网行业的创业者，对他们来说，找到用户产品的痛点并漂亮地解决问题往往并不是十分困难。不过，一个企业最终需要的是利润，而许多对变现逻辑和思考方法不熟悉的创业者往往面对产品得到的流量和数据不知所措，而商业化进程的缓慢也会大大拖慢用户产品的运营进度，甚至因此错过企业的黄金发展机会。从这个意义上说，了解一些流量与数据变现的思路无疑会对创业方向的选择、创业过程的加速、创业果实的收获都有巨大的帮助。

（6）计算机相关专业研究生。计算广告的人才在互联网行业相当稀缺，而目前学校对这样与工业界关系密切的实际问题在教育上是有些脱节的。我们整理此书的一个重要目的是希望为具有一定的计算机科学基础并且对工业界实际问题有兴趣的同学们提供一次指导旅行，让他们对思考和设计商业产品、运用技术解决产品问题形成正确的思考方法。

内容组织

前面说过，我们整理本书，并不是简单地为了介绍计算广告的产品和技术，更重要的目的是希望提供一个新的视角，让大家通过了解广告变现的内在逻辑，进而对互联网时代的用户产品如何将体验做到极致、将变现做到最高效有一个宏观的认识。在我们看来，如果不了解广告变现产品 and 市场，就谈不上真正透彻地了解互联网，也一定会在用户产品的设计和运营上有诸多掣肘。基于这样的目的，本书在内容上组织成三个部分。

（1）第一部分介绍在线广告领域的一些基本问题和背景知识。虽然内容比较容易理解，但这部分是全书的基础，特别是对很多相关概念和术语的集中介绍，请不要略过。

（2）第二部分主要面向产品、运营、销售等人员，以及互联网产品的宏观决策者，其内容重点在于介绍计算广告的市场结构、交易模式和主要产品。这部分内容将依在线广告产品发展的顺序展开，希望能帮助大家理解各种复杂的广告产品和交易机制产生的内在规律。

（3）第三部分主要面向系统工程师、算法工程师和架构师。与前一部分的广告产品相对应，这部分也以在线广告产品发展的顺序，重点阐释实现各种广告产品的关键技术挑战，并提供基础的解决方案。

一般来说，对于那些想运营一项在线广告业务，或者想了解如何在线广告对用户产品怎样变现的读者来说，可以重点阅读第一部分和第二部分，并且对其中的产品与商业逻辑要深入理解；对于那些重点关注工程实现和收入优化的读者来说，在了解了前面两部分之后，还要花一些精力深入阅读第三部分，特别是其中与自己关注的广告产品相关的技术章节。计算广告这个领域的复杂性在于，对于任何一项产品或技术都需要放在相应的商业背景下去判断其合理性；而想要了解商业产品上能达到的目标，还需要对技术的现状和难点有相当的认识。因此，我们推荐的阅读方式还是尽可能地通读全书，对其中确实不相关或者知识背景上无法理解的部分简单跳过就可以了。另外，除第 10 章外，其他各章结束后我们都准备了若干开放性的延伸思考问题。这些问题往往并没有确定的标准答案，只是为了帮助大家进一步深入思考该章中的关键或有趣的问题。

在讨论在线广告市场的产品技术过程中，会涉及大量的术语和专业名词。对于对变现业务不太熟悉的读者来说，这些术语会给阅读带来一定的障碍。为了帮助读者检索和查找术语的相关内容，我们在附录中对主要术语及缩写给出了索引，以方便大家的阅读。

由于篇幅限制，本书中有些内容的细节或背景知识无法全面展开，在这种情形下会给出相应的参考文献。但是由于本书并非学术著作，在引用文献时并不会保证完备性，因此当正文足以说明观点和方法时其原始文献不一定还会列出，请读者谅解。另外，在本书的第三部分中，为帮助读者理解，会对一些比较关键的算法给出相应的代码片段。不过本书中的代码都是示例性代码，目的仅仅是为了更清楚地描述逻辑，而并非可以直接编译执行的程序，其中一些特别容易理解实现的子函数调用也可能会略去其具体实现。

本书的内容主要是由刘鹏在清华大学的公开课，以及在北京大学、北京航空航天大学研究生课程的内容整理加工而成的，并且在整理时针对更广泛的读者群体做了内容本身和顺序上的调整。在两位作者中，刘鹏为主要执笔者，负责主体部分的写作和内容的整体组织，王超负责其中产品案例和算法示例代码的部分。由于作者的水平有限，再加上时间仓促，书中难免出现错漏之处，敬请读者多多批评指正。此外，本书撰写的过程中，我们邀请了一些业内的专家和从业者帮忙对内容进行把关，得到了他们的很多有益的建议，这些建议使本书更加完备和实用，我们在此一并表示感谢，并将其中部分专家对本书的评价附在书中。

目录

[封面](#)

[扉页](#)

[版权](#)

[对本书的点评](#)

[序一](#)

[序二](#)

[序三](#)

[前言](#)

[第一部分 计算广告关键技术](#)

[第1章 在线广告综述](#)

[1.1 大数据与广告的关系](#)

[1.2 广告的定义与目的](#)

[1.3 在线广告创意类型](#)

[1.4 在线广告简史](#)

[1.5 泛广告商业产品](#)

[1.6 延伸思考](#)

[第2章 计算广告基础](#)

[2.1 广告有效性原理](#)

[2.2 互联网广告的技术特点](#)

[2.3 计算广告的核心问题](#)

[2.3.1 广告收入的分解](#)

[2.3.2 结算方式与 eCPM 估计的关系](#)

[2.4 在线广告相关行业协会](#)

[2.4.1 交互广告局](#)

[2.4.2 美国广告代理协会](#)

[2.4.3 美国国家广告商协会](#)

[2.5 延伸思考](#)

[第二部分 在线广告产品逻辑](#)

[第3章 在线广告产品概览](#)

[3.1 商业产品的设计原则](#)

[3.2 需求方层级组织与接口](#)

[3.3 供给方管理接口](#)

[3.4 延伸思考](#)

[第4章 合约广告](#)

[4.1 广告位合约](#)

[4.2 受众定向](#)

[4.2.1 受众定向方法概览](#)

[4.2.2 受众定向标签体系](#)

[4.3 展示量合约](#)

[4.3.1 流量预测](#)

[4.3.2 流量塑形](#)

[4.3.3 在线分配](#)

[4.3.4 产品案例](#)

[4.4 延伸思考](#)

[第5章 搜索与竞价广告](#)

[5.1 搜索广告](#)

[5.1.1 搜索广告产品形态](#)

[5.1.2 搜索广告产品新形式](#)

[5.1.3 搜索广告产品策略](#)

[5.1.4 产品案例](#)

[5.2 位置拍卖与机制设计](#)

[5.2.1 定价问题](#)

[5.2.2 市场保留价](#)

[5.2.3 价格挤压](#)

[5.2.4 定价结果示例](#)

[5.3 广告网络](#)

[5.3.1 广告网络产品形态](#)

[5.3.2 广告网络产品策略](#)

[5.3.3 产品案例](#)

[5.4 竞价广告需求方产品](#)

[5.4.1 搜索引擎营销](#)

[5.4.2 媒体购买平台](#)

[5.4.3 产品案例](#)

[5.5 竞价广告与合约广告的比较](#)

[5.6 延伸思考](#)

[第 6 章 程序化交易广告](#)

[6.1 实时竞价](#)

[6.2 其他程序化交易方式](#)

[6.2.1 优选](#)

[6.2.2 私有市场](#)

[6.2.3 广告交易方式谱系](#)

[6.3 广告交易平台](#)

[6.4 需求方平台](#)

[6.4.1 需求方平台产品策略](#)

[6.4.2 出价策略](#)

[6.4.3 重定向](#)

[6.4.4 新客推荐](#)

[6.4.5 产品案例](#)

[6.5 供给方平台](#)

[6.5.1 供给方平台产品策略](#)

[6.5.2 产品案例](#)

[6.6 数据加工与交易](#)

[6.6.1 有价值的数据来源](#)

[6.6.2 三方数据划分](#)

[6.6.3 数据管理平台](#)

[6.6.4 数据交易平台](#)

[6.6.5 产品案例](#)

[6.7 在线广告产品交互关系](#)

[6.8 延伸思考](#)

[第 7 章 移动互联与原生广告](#)

[7.1 原生广告相关产品](#)

[7.1.1 信息流广告](#)

[7.1.2 搜索广告](#)

[7.1.3 软文广告](#)

[7.1.4 联盟](#)

[7.2 移动广告的现状与挑战](#)

[7.2.1 移动广告的特点](#)

[7.2.2 移动广告的创意形式](#)

[7.2.3 移动广告的挑战](#)

[7.3 原生广告平台](#)

[7.3.1 表现原生与意图原生](#)

[7.3.2 植入式原生广告](#)

[7.3.3 产品案例](#)

[7.4 原生广告与程序化交易](#)

[7.5 延伸思考](#)

[第8章 在线广告产品实践](#)

[8.1 媒体实战](#)

[8.1.1 变现方式和产品决策](#)

[8.1.2 数据支持方案决策](#)

[8.2 广告主实战](#)

[8.3 数据提供方实战](#)

[8.4 延伸思考](#)

[第三部分 计算广告关键技术](#)

[第9章 计算广告技术概览](#)

[9.1 个性化系统框架](#)

[9.2 各类广告系统优化目标](#)

[9.3 计算广告系统架构](#)

[9.3.1 广告投放引擎](#)

[9.3.2 数据高速公路](#)

[9.3.3 离线数据处理](#)

[9.3.4 在线数据处理](#)

[9.4 计算广告系统主要技术](#)

[9.5 用开源工具搭建计算广告系统](#)

[9.5.1 Web 服务器 Nginx](#)

[9.5.2 分布式配置和集群管理工具 ZooKeeper](#)

[9.5.3 全文搜索引擎 Lucene](#)

[9.5.4 跨语言通信接口 Thrift](#)

[9.5.5 数据高速公路 Flume](#)

[9.5.6 分布式数据处理平台 Hadoop](#)

[9.5.7 特征在线缓存 Redis](#)

[9.5.8 流计算平台 Storm](#)

[9.5.9 高效的迭代计算框架 Spark](#)

[9.6 延伸思考](#)

[第 10 章 基础知识准备](#)

[10.1 信息检索](#)

[10.1.1 倒排索引](#)

[10.1.2 向量空间模型](#)

[10.2 最优化方法](#)

[10.2.1 拉格朗日法与凸优化](#)

[10.2.2 下降单纯形法](#)

[10.2.3 梯度下降法](#)

[10.2.4 拟牛顿法](#)

[10.2.5 Trust-Region 法](#)

[10.3 统计机器学习](#)

[10.3.1 最大熵与指数族分布](#)

[10.3.2 混合模型和 EM 算法](#)

[10.3.3 贝叶斯学习](#)

[10.4 统计模型分布式优化框架](#)

[第 11 章 合约广告核心技术](#)

[11.1 广告排期系统](#)

[11.2 担保式投送系统](#)

[11.2.1 流量预测](#)

[11.2.2 频次控制](#)

[11.3 在线分配](#)

[11.3.1 在线分配问题](#)

[11.3.2 在线分配问题举例](#)

[11.3.3 极限性能研究](#)

[11.3.4 实用优化算法](#)

[11.4 延伸思考](#)

[第 12 章 受众定向核心技术](#)

[12.1 受众定向技术分类](#)

[12.2 上下文定向](#)

[12.2.1 半在线抓取系统](#)

[12.2.2 文本主题挖掘](#)

[12.3 行为定向](#)

[12.3.1 行为定向建模问题](#)

[12.3.2 行为定向特征生成](#)

[12.3.3 行为定向决策过程](#)

[12.3.4 行为定向的评测](#)

[12.4 人口属性预测](#)

[12.5 数据管理平台](#)

[12.6 延伸思考](#)

[第 13 章 竞价广告核心技术](#)

[13.1 竞价广告计价算法](#)

[13.2 搜索广告系统](#)

[13.2.1 查询扩展](#)

[13.2.2 广告放置](#)

[13.3 广告网络](#)

[13.4 广告检索](#)

[13.4.1 布尔表达式的检索](#)

[13.4.2 相关性检索](#)

[13.5 点击率预测](#)

[13.5.1 点击率预测模型](#)

[13.5.2 优化算法](#)

[13.5.3 点击率模型的校正](#)

[13.5.4 点击率模型的特征](#)

[13.5.5 点击率模型评测](#)

[13.5.6 智能频次控制](#)

[13.6 探索与利用](#)

[13.6.1 UCB 方法](#)

[13.6.2 考虑上下文的 bandit](#)

[13.7 延伸思考](#)

[第 14 章 程序化交易核心技术](#)

[14.1 广告交易平台](#)

[14.1.1 cookie 映射](#)

[14.1.2 询价优化](#)

[14.2 需求方平台](#)

[14.2.1 定制化用户标签](#)

[14.2.2 DSP 中的点击率预测](#)

[14.2.3 点击价值估计](#)

[14.2.4 出价策略](#)

[14.3 供给方平台](#)

[14.4 延伸思考](#)

[第 15 章 其他广告相关技术](#)

[15.1 创意优化](#)

[15.1.1 程序化创意](#)

[15.1.2 点击热力图](#)

[15.2 实验框架](#)

[15.3 流量保护和效果监测](#)

[15.3.1 反作弊](#)

[15.3.2 广告监测](#)

[15.3.3 广告安全](#)

[15.4 隐私保护和数据安全](#)

[15.4.1 隐私保护问题](#)

[15.4.2 程序化交易中的数据安全](#)

[15.5 延伸思考](#)

[第四部分 附录](#)

[附录 A 主要术语及缩写索引](#)

[参考文献](#)

第一部分 计算广告关键技术

第 1 章 在线广告综述

在线广告，也称为网络广告、互联网广告，顾名思义，指的是在线媒体上投放的广告。与传统广告不同的是，在线广告在其短短十几年的发展过程中，已经形成了以人群为投放目标、以产品为导向的技术型投放模式。在线广告不仅为广告主带来了以准确接触目标受众为方法论的全新的营销渠道，也为互联网免费产品和媒体提供商们找到了规模化变现的手段。可以说，不论你在做一款用户产品还是商业产品，不深入了解在线广告，就不太可能全面地了解互联网业务。因此，所有互联网行业的从业者们花一些时间把现代的在线广告原理和产品搞清楚，不仅是有益的，而且是必须的。

从另外一个角度，即数据的角度来看，在线广告开启了大规模、自动化地利用数据改善产品和提高收入的先河。可以不夸张地说，在过去相当长的一段时期内，大数据(big data)这一方法论在实践中唯一形成规模化营收的落地行业就是在线广告，只不过当年大数据这个词还不那么流行罢了。即便在今天，计算广告仍然是大数据应用中最成熟、市场规模最大的行业。因此，对大数据感兴趣的读者认真研究在线广告发展过程中遇到的技术挑战和产品问题，会对探索其他的大数据应用有莫大的帮助。

熟悉在线广告市场的朋友都知道，这一领域的产品形态和业务逻辑相当复杂。为了对在线广告有宏观上的把握，我们在本章中将从两个方面来探讨：一是它的内涵，即这种商业活动的定义与目的；二是它的外延，即在线广告发展的简要历史和发展过程中产生的关键产品形态。对其中的许多概念和观点，读者未必能够马上形成清晰的印象，然而随着内容的展开，读者能够剥茧抽丝般层层递进地加深理解，这正是本书希望做到的。另外，本章还有另外一个目的，就是尽可能集中地介绍互联网广告的产品和技术术语，以方便后面的讨论。

相比传统的线下广告，在线广告的产品和创意形式由于互联网媒体形态、交互方式等方面存在非常大的差异，也呈现出各种各样的表现形式。我们也将对其中比较常见的创意形式作简要介绍，希望读者能对在线广告的具体表现有直观的了解。

本章的内容与计算基本无关，目的在于让读者在进入计算广告领域之初就建立起一些重要观念。首先，广告不完全等同于搜索或推荐，它首先是一项商业活动，然后才是一项在互联网环境下需要技术优化的商业活动；其次，在这一商业活动中，广告主、媒体和用户的利益都需要被认真考虑和满足，这样才能达到整个市场的平衡和不断发展。在线广告市场所有产品和商业形式的演进，都是在这一主题下发生的。在商业逻辑的框架下思考和探索计算广告技术对理解本书中提到的产品、架构和算法非常关键。

1.1 大数据与广告的关系

近年来，大数据思维和技术渐成显学。然而，大数据这一概念至今为止并没有一个内涵上准确的界定。在参考文献[56]中，作者用 **Volume**（规模）、**Variety**（多样性）、**Velocity**（高速）和 **Value**（价值），即所谓的 4V 特征来描述大数据问题的特性，但并没有给出这类问题的界定标准。然而，从实际操作的角度来看什么是大数据问题或许要比理论上的定义简单一些：如果有的数据处理问题无法通过数据采样的方法来降低处理的复杂程度，就必须利用一些专门为海量数据处理而设计的计算和存储技术（如 **MapReduce**、**NoSQL** 数据库等）来实现。于是，这样的问题也就从工程上归为大数据问题，图 1-1 阐释了这一视角。




图 1-1 大数据问题的特性示意

在图 1-1 中，我们考察的是某一个有确定目标函数的数据处理问题。图中的三条曲线是三类有代表性的数据问题。

(1) C 类问题。从工程方便的角度来看，如果通过数据采样能够显著降低数据处理的复杂程度，同时解决问题的效果（即目标函数）没有太大的下降，那么显然应该这样做。这类问题可以用图 1-1 中的 C 曲线来示意。由于可以通过很低的采样率解决问题，并不需要大规模分布式的计算架构，用传统的数据方案就可以解决，因此，这类问题应该归为传统数据处理问题，而非大数据问题。一般的统计报表、报告等往往属于这类问题。

(2) A 类问题。另外有一些数据问题基本上不可能通过只处理一小部分数据来达到处理全量数据所能达到的效果，或者说随着数据采样率的降低，解决问题的收益会快速下降，这类问题是典型的大数据问题，用图 1-1 中的 A 曲线来示意。由于需要处理大规模的全量数据，传统的存储和计算架构都不再合适，必须寻找新的方案，这实际上是推动大数据技术发展的原动力。个性化推荐（personalized recommendation）和计算广告（computational advertising）需要用到每一个人的行为进行定制化推送，而无法只采样其中的一部分人来处理，因此可以认为是典型的大数据问题。大数据问题由于无法利用传统的计算架构和数据仓库来处理，因此才会产生 Hadoop 等新的基础设施和 NoSQL 数据存储等技术。

(3) B 类问题。当然，实践当中大数据问题和一般数据处理问题并不是泾渭分明的。有一些问题，其处理效果随着数据量的上升有一定提高，但当数据大到一定规模以后，再增加数据量价值就不大了，这类问题可以用图 1-1 中的 B 曲线来示意。一个典型的例子是文本主题模型（topic model）。我们用 1000 万文档往往会得到比 10 万文档更稳定、更有意义的主题，然而用 10 亿文档和用 1 亿文档差别可能就会不那么明显。在解决这类问题时，往往是选取一个有较大规模但并非全量的数据集来处理。针对这种中等规模问题上的复杂算法，也产生了像 Spark 这样更加灵活高效的计算框架。

很显然，从以上观点出发，计算广告是非常典型的大数据应用。实际上，在以往相当长的一段时期里，我们认为唯一得到充分商业化和规模化的大数据应用就是计算广告。计算广告为各行各业大数据的落地提供了非常有价值的借鉴范本，下面几点尤其值得了解和关注。

(1) 计算广告为规模化地将用户行为数据转化为可衡量的商业价值提供了完整产品线和解决方案，并且实际上创造了互联网行业大部分的营收。

(2) 在线广告孕育和孵化了较为成熟的数据加工和交易产业链，并对其中的用户隐私边界有深入探讨，这值得所有涉及用户数据的互联网应用学习和借鉴。

(3) 由于有了商业上的限制条件，计算广告的技术和产品逻辑比单纯的个性化系统更加复杂周密。因此，理解在线广告的产品和市场对于设计正确有效的商业产品大有益处。

由于以上这些原因，如果你是一位从事大数据或商业产品的产品经理、工程师或管理者，我们强烈建议你认真了解一下广告的产品和技术，相信你一定会有很大的收获，也会

快捷地了解到这一领域真正有挑战的问题是什么。本着这样的目的，我们在本书后续部分中将广告市场的产品和技术演进作为一条明的主线，而将这一市场对数据的利用程度作为一条暗的主线来展开。希望读者能够通过阅读本书，具体地了解数据是如何通过广告市场规模化地创造商业价值的。

1.2 广告的定义与目的

在了解计算广告之前，我们先从了解一般广告的目的开始。什么是广告？可以参考 William F. Arens 在《当代广告学》^[3]中给出的定义：

广告是由已确定的出资人通过各种媒介进行的有关产品（商品、服务和观点）的，通常是有偿的、有组织的、综合的、劝服性的非人员的信息传播活动。

这一定义中有两个关键点。首先，它指出了广告活动的两个主动参与方——出资人（**sponsor**）和媒体（**medium**）。在数字广告这样更加复杂的市场结构中，我们可以用一般性的术语来描述它们：需求方（**demand**）和供给方（**supply**）。这里的需求方可以是广告主（**advertiser**）、代表广告主利益的代理商（**agency**）或其他技术形态的采买方；这里的供给方可以是媒体，也可以是其他技术形态的变现平台。另外，要特别注意的是，广告还有一个被动的参与方，即受众（**audience**）。请大家从现在开始就牢牢建立起这样的概念：出资人、媒体和受众这三者的利益博弈关系是广告活动永远的主线，这一主线将贯穿于商业和产品形态的整个演化过程。另外，该定义还阐明了广告必须是有偿的、非人员的信息传播活动。这两点限制，前者使得广告的目标变得明确，后者使得这一目标可以采用计算的方式来优化，而这些都是计算广告产生的基础。

广告这一商业行为，其本质目的是什么呢？在不同的时代，广告主与媒体对这一问题存在着不同的认知。在传统媒体时代，供给方与需求方在市场地位上有相当的距离，不论你运营的是电视台、机场或杂志，都与大多数广告主需要的转化行为之间有相当大的差距。因此，这一阶段广告的目的是希望借助媒体的力量来快速接触大量用户，以达到宣传品牌形象、提升中长期购买率与利润空间的目的。这种目的的广告称为品牌广告（**brand awareness**）。当然，也有许多广告商希望能利用广告手段马上带来大量的购买或其他转化行为，这种目的的广告称为直接效果广告（**direct response**），有时也简称为效果广告。

在传统广告产品中，大量投送和优化效果广告的能力显然是缺乏的。这是因为，对短期效果的追求要求广告精准地送达目标人群，而这在传统媒体上缺乏有效的技术手段。我们能够想起的以效果为目的的传统广告恐怕只有在写字楼下散发的快餐传单，而数字媒体的出现使得效果广告空前蓬勃地发展起来。这主要有两方面的原因：一是数字媒体的特点

可以让我们低成本地投送个性化广告；二是一些在线服务，如搜索、电子商务，由于可以更清楚地了解用户的意图，也就使广告效果的优化更加容易。

互联网广告兼有品牌和效果两方面的功能。不过要说明的是，到目前为止，互联网广告行业的高速发展主要是由于效果广告市场带来的巨大红利。从表 1-1^[4]中可以看出，网络广告的市场规模发展迅猛；与此同时，传统广告渠道则增长乏力或快速下降。对比来看，网络广告的迅猛成长并没有直接带来电视广告的市场萎缩。这是因为网络广告的主要场景仍然集中在搜索引擎营销、效果类广告网络等直接效果类的广告活动上，而这部分相对于电视的品牌广告更多地是增量而非替代。另一方面，报纸广告则随着互联网的快速崛起而下降，这一方面是因为报纸占据的用户时间大幅被互联网抢走，另外也是由于报纸上一部分的分类信息广告与互联网效果类广告重叠较大。目前，随着数字媒体越来越多地占据了人们的时间以及在线视频等冲击力更强的媒体的普及，网络渠道也必将在品牌广告方面有更多的用武之地。

表 1-1 中美主要广告市场规模（单位：亿美元）

国家	广告类型	2007 年	2008 年	2009 年	2010 年	2011 年	2012 年	2013 年
中国	网络广告	17	27	33	52	83	122	179
	电视广告	97	114	127	153	182	207	212
美国	网络广告	212	234	226	260	317	366	428
	电视广告	719	394	359	401	685	721	745
	报纸广告	486	344	246	228	207	194	180

既然有品牌和效果这两种目标，究竟如何描述广告这种商业活动的根本目的呢，我们仍然借用《当代广告学》中的见解：

广告的根本目的是广告主通过媒体达到低成本的用户接触。

也就是说，按某种市场意图接触相应的人群，进而影响其中的潜在用户，使他们选择广告主产品的几率增加，或者对产品性价比的苛求程度降低，这才是广告的根本目的。至于短期内的转化效果，由于市场意图或媒体性质的不同，并不是直接可比。换句话说，如果仅仅以转化效果为目的来思考问题，可能会背离投放广告的正确方法论。举个例子，某感冒药广告商如果以短期效果为导向，那么最佳的策略是把广告投放给那些现在感冒的人，不过这显然是一个荒谬的决策；再比如，某汽车广告商为了提升自己的品牌形象，希望对自己竞品品牌的用户加强宣传，而对于这部分人群，广告的直接效果甚至有可能比随机投放还要差。认清这一概念，使得大家在遇到多种广告渠道的效果比较时能够避免偏颇的结论。关于这一点，有所谓整合营销（integrated marketing）的概念，即通过多种渠道的有

机配合来达到整体投放效果的最优，这并非本书讨论的重点，有兴趣的读者可以参考其他文献。

广告的“低成本”是与那些由市场或销售人员完成的劝服活动成本相对而言的，实际上是广告搭了媒体流量和影响力的便车。要确定是否真的成本较低，需要用到投入产出比（Return On Investment, ROI）这一评价指标，即某次广告活动的总产出与总投入的比例。在实际中，广告活动的总投入容易确定，但总产出的确定却不那么容易，特别是在投放以中长期收益为目标的品牌广告时。因此，绝对的 ROI 有时难以计算，不过通过各个渠道之间的对比，我们仍然可以评估广告的成本是否令人满意。

需要说明，在互联网环境中，广告的本质虽然没有变化，但是由于大量直接效果需求的产生，其表现形式越来越丰富和灵活了。不论是与线下类似的横幅、搜索竞价排名，还是软文，甚至是表面上与广告并不相干的游戏联运，其本质都是付费的信息推广，从产品和技术的角度来看都可以归在广告的范畴下。因此，对于互联网广告，我们有如下的认识：一切付费的信息、产品或服务的传播渠道，都是广告。

那么，在线广告主要有哪些表现形式呢？我们将在 1.3 节中介绍。

1.3 在线广告创意类型

在线广告除了产品有诸多形态，与用户接触的创意形式也有多种多样的选择，并且随着互联网产品的发展变得越来越丰富。诸多在线广告的创意类型在投送方式和用户交互方式等方面有不同的选择，下面我们对其中一些常见的类型进行简要介绍。

（1）横幅广告（banner ad）。这是展示广告中最传统也是最典型的形式。横幅广告一般是嵌入在页面中相对固定位置的图片，需要占据固定的版面，因此，这种广告一般要有底层的备选广告素材，以防没有合适的广告匹配时页面上开天窗。目前，横幅广告大多数也都不再是静止的图片，而是由 Flash 或其他技术方式实现的动态素材。图 1-2 中给出了横幅广告的一个示例。



图 1-2 横幅广告示例

（2）文字链广告（textual ad）。这种广告的素材形式是一段链接到广告主落地页的文字，在搜索广告中为主流形式，同时在展示广告中也被广泛采用。文字链广告有时像横幅广告那样占据固定的版面，有时也可以穿插在大量内容链接条目中。在后一种情形下，

广告投放引擎可以灵活决定是否投出该文字链广告，以及投出的条目数。典型的例子就是搜索广告，如图 1-3 所示。

我司代理各报类文字广告,价格优惠,电话:400-831-3770 www.bj-hhtc.cn
华恒天成专业文字广告,资深专业,专注于服务,创造品牌.电话:87765716.

图 1-3 文字链广告示例

(3) 富媒体广告 (rich media ad)。这类广告往往是利用视觉冲击力较强的表现形式，在不占用固定版面位置的情况下，向用户侵入式地投送广告素材。富媒体广告常见的形式有弹窗、对联、全屏等。它比较适合在高质量的媒体做一些品牌性质比较强的广告投放，但是对用户的使用体验往往影响也较大。富媒体广告与横幅广告不同，在未售出的情况下可以静默，因而没有防天窗的问题。一些门户网站的首页有时会为某个品牌广告主提供专门定制的、交互形式很复杂的富媒体广告，这样的广告一般不采用按人群投放的逻辑，也主要强调创意的冲击力和交互形式的特色。图 1-4 中给出了一个富媒体广告中的弹窗广告示例。



图 1-4 富媒体广告示例

(4) 视频广告 (video ad)。随着在线视频的快速发展，在视频流播放的间隙插入的广告也成为互联网广告的一种重要形式。根据插入位置的不同，视频广告又可以分为前插片、后插片、暂停等类型。视频广告由于载体的独特性质，其效果和广告创意比较类似于线下的电视广告。相应地，有关视频广告的效果评价，除了计算与横幅广告一样的点击率，还可以采用用户观看时长等更接近于用户印象的指标。

视频广告有两种最主要的形式：在视频内容播放之前的前插片广告以及视频播放暂停时的广告。图 1-5 中给出了这两种视频广告形式的示例。前插片广告一般采用短视频的形

式，创意的冲击力和表现力要远远强于普通的展示广告，因此价格往往也比较高；暂停广告则与普通的横幅广告区别不大。



图 1-5 视频广告示例：前插片广告（左）暂停广告（右）

（5）社交广告（social ad）。社交网络的兴起给广告的传播渠道和能力都赋予了新的空间。在社交网络环境下嵌入的广告可以通称为社交广告。社交广告中最典型的形式是插入在社交网络信息流中的广告，这种方式最早见于 Twitter，产品称为“Promoted Tweets”。这种方式力求在用户自然关注的交互过程中尽可能自然地插入广告，也被归于原生广告的范畴中。我们认为，“社交广告”与“社交网络中的广告”是两个不同的概念，如在社交网络页面上竞价售卖的文字链或横幅广告，其本质并不因为处于社交网络中有太大的变化。社交广告希望达到的效果是通过用户的扩散式传播获得更大的影响力和口碑，从这个意义上讲，在信息流的交互中挖掘价值前景光明。图 1-6 中给出了社交网络信息流广告的一个示例。




图 1-6 社交网络信息流广告

（6）移动广告（mobile ad）。移动互联网在近几年爆发式地增长，并且大有取代桌面互联网之势。严格来说，移动互联网上的广告形式与桌面电脑上的广告没有本质的区别，

不过由于移动设备上应用的大量普及，广告也由 Web 访问的页面上搬进了应用里。于是，也产生了在应用中插入广告的 SDK 和相应的广告网络。目前移动广告典型的形式有横幅、开屏、插屏、积分墙或推荐墙等。图 1-7 中给出了移动广告形式的一些示例，我们将在第 7 章中具体讨论与移动广告和原生广告相关的产品问题。

(7) 邮件定向营销广告（E-mail Direct Marketing，EDM）。这是通过电子邮件的方式向目标用户传递推广信息的一种网络营销手段。与上面各种广告形式都不同，EDM 是一种主动的广告形式，它不需要等到用户接触的机会出现时才被动地提供广告，而是可以随时向认为合适的用户发送推广信息。不过也正因为如此，EDM 非常容易变成垃圾邮件的主要来源。因此，对 EDM 的运营者而言，精准地把握用户兴趣、非常有节制地提供对用户用价值的相关信息是非常关键的。比起展示广告，EDM 中受众定向的利用更加直接，也更为重要。图 1-8 中给出了邮件营销广告的一些示例。另外，通过短信、iMessage 等方式投放的广告与邮件营销广告也非常相似。



图 1-7 移动广告形式示例

精品订阅	【139邮箱精品订阅】《意林》系列杂志5月里限时免费咯！读经典文摘，享...	5-23(四) 02:46	☆
海信	海信电视“节能补贴收官，以旧换新重现”，领取340元折旧券！	5-22(三) 03:19	☆

图 1-8 邮件定向营销广告（EDM）示例

当然，由于广告的本质是一切付费的信息、产品或服务的传播渠道，在线广告实际上的产品范畴远远不是上面介绍的这几种创意形式可以包罗的。除了上面这些以创意为载体的推广的狭义广告形式，还有很多的付费推广类商业产品也可以认为是广义的广告产品，其本质的产品技术框架与普通广告非常类似，我们将在 1.5 节进一步介绍这些泛广告产品。

1.4 在线广告简史

在讨论广告技术之前，我们先浏览一下在线广告发展的历程。因为广告市场的概念、技术和术语繁多，如果不是对这些有基本的了解，很难深入探讨具体的产品。

回到 20 世纪末，那时的在线媒体（如 AOL、Yahoo! 等网站）刚刚产生不久。他们已经取得了不错的流量规模，可是投资人当然希望这些媒体也能够给他们带来真金白银。要对这些线上流量进行变现，最直接的方法就是把网站的 HTML 页面当成杂志的版面，在里面插入广告位。供给方有了，那么需求方呢？线下的广告代理公司也就把这些网站当成一本本新的杂志，按原来的思路和逻辑进行采买。这种在互联网上展示广告创意的产品形式称为展示广告（display advertising），也叫显示广告。这一阶段的展示广告售卖模式称为合约广告（agreement-based advertising），即采用合同约定的方式确定某一广告位在某一时间段为某特定广告主所独占，并且根据双方的要求，确定广告创意和投放策略。当然，这样的采买模式还没有对计算的需求，因为此时唯一需要的就是把广告主的创意作为一个 HTML 的片段插入到媒体的页面中。然而，情况变化很快，互联网媒体为了营收的增长，希望逐年甚至逐季提高自己的广告位报价。在流量快速增长或者数字广告逐渐为广告主认知的阶段，提价是比较容易被市场接受的。可是当媒体的流量和品牌认知度都相对稳定以后，又有什么新的提高收入的办法呢？

互联网广告运营者们经过探索，很快就发现了在线广告不同于传统媒体广告的本质特点：我们可以对不同的受众呈现不同的广告创意！在今天看来再平常不过的这个观念，实际上是在线广告的效果和市场规模不断发展的核心驱动力。认识到这一点，媒体找到了一条能使广告位报价继续提高的思路。例如，可以把某广告位的男性受众和女性受众卖给不同的广告主，比如对男性受众展示某剃须刀品牌的广告，而对女性受众展示某化妆品品牌的广告。这样的广告投放方式称为定向广告（targeted advertising）。很显然，这样的广告系统已经对计算技术产生了两个具体需求：一是受众定向（audience targeting），即通过技术手段标定某个用户的性别、年龄或其他标签；二是广告投放（ad serving），即将广告投送由直接嵌入页面变为实时响应前端请求，并根据用户标签自动决策和返回合适的广告创意。由于从传统的品牌广告延伸而来，此时的定向广告仍然以合约的方式进行。媒体向广告主保证某个投放量，并在此基础上确定合同的总金额以及投放量未完成情况下的赔偿方案。这种担保式投送（Guaranteed Delivery, GD）的交易方式逐渐成为互联网合约式广告的主要商业模式。一般来说，这样的合约仍然主要面向品牌广告主，并且遵循按千次展示付费（Cost per Mille, CPM）的计费方式。

合约广告系统中有一个重要的计算问题，即在满足各合约目标受众量要求的同时尽可能为所有广告商分配到质更好的流量。这一问题有两个难点：一是如何有效地将流量分配

到各个合约互相交叉的人群覆盖上；二是要在在线的环境下实时地完成每一次展示决策。这个问题称为在线分配（online allocation）。如果将各合约的量看作约束条件，将某种度量下的质看作目标函数，可以利用带约束优化（constrained optimization）的数学框架来探索这一问题。为了得到在线环境下切实可行的解决方案，学术界和工业界的同仁在理论和工程方面进行了大量的研究，有一些高效且简便的实用方案已经为各媒体广泛采用。

需要注意，展示广告领域定向投放的最初动机是供给方为了拆分流量以获得更高的营收。如果一开始就提供非常精细的定向，反而会造成售卖率的下降。因此，最初的定向标签往往都设置在较粗的粒度上，最典型的是一些人口属性标签。受众定向显然更符合需求方的口味和利益——不要忘了，广告市场的钱全部是来自需求方的，他们的利益被满足得越好，市场的规模就会越大。因此，受众定向产生以后，市场向着精细化运作的方向快速发展。这一发展主要有两方面的趋势：一是定向标签变得越来越精准；二是广告主的数量不断膨胀。在这些趋势下，仍然按照合约的方式售卖广告会遇到越来越多的麻烦。首先，很难对这些细粒度标签组合的流量做准确预估；其次，当一次展示同时满足多个合约的时候，仅仅按照量约束下的在线分配策略进行决策有可能浪费掉了很多本来可以卖得更贵的流量。既然量的约束带来了这些麻烦，有没有可能抛弃量的保证而采用最唯利是图的策略来进行广告决策？这样的思路催生了计算广告历史上革命性的产品模式——竞价广告（auction-based advertising）。在这种模式下，供给方只向广告主保证质即单位流量的成本，但不再以合约的方式给出量的保证，换言之，对每一次展示都基本按照收益最高的原则来决策。

上面是从展示广告的发展看竞价产生的原因，实际历史的足迹却并非如此。竞价广告产生的最初场景是在互联网广告最主要的金矿——搜索广告（search ad）中。在以 Google 为代表的搜索引擎在技术成熟以后，迅速成为互联网新的入口。与门户网站不同，搜索引擎从一开始就没有被当作媒体来看待，因此搜索流量的变现也采用了与服务自然结合的付费搜索（paid search 或 sponsored search）模式。从广告的视角来看，也可以把付费搜索看作一种定向广告，即根据用户的即时兴趣定向投送的广告，而即时兴趣的标签就是关键词。很显然，这种定向广告从一开始就直接达到了非常精准的程度，也就很自然地采用了竞价的方式售卖。

搜索广告产生了巨大的收益以后，搜索引擎开始考虑将这样的变现方式推广到其他互联网媒体上：将用户的即时兴趣标签由搜索词换成正在浏览页面中的关键词，可以将这套竞价广告系统从搜索结果页照搬到媒体页面上，这就产生了上下文广告（contextual advertising）。上下文广告的初期，创意的形式也是与搜索广告一样的文字链接。许多产品讨论将它与展示广告分开对待，不过当我们把它与上一段中精细化定向的展示广告对比

来看时就知道，这样的区分实际上没有必要，或许从创意形式上把展示广告和文字链广告区别开更符合分类的逻辑。

从宏观市场上看，竞价广告与合约广告有很大的不同。没有了合约的保证，大量的广告主处在一个多方博弈的环境中。与直觉不同的是，在如何收取广告主费用这一点上，我们并非按照微观上最优的方案实施就可以达到整个市场最大的收益。关于定价机制的深入研究，产生了广义第二高价（**Generalized Second Price, GSP**）这一竞价重要的理论。

基于竞价机制和精准人群定向这两个核心功能，在线广告分化出了广告网络（**ad Network, ADN**）这种新的市场形态。它批量地运营媒体的广告位资源，按照人群或上下文标签售卖给需求方，并用竞价的方式决定流量分配。广告网络的结算以按点击付费（**Cost per Click, CPC**）的方式为主，这一点有数据和业务方面多层次的原因，在本书的后面会详细探讨。虽然我们不太能指望这种方式的千次展示收益（**Revenue per Mille, RPM**）可以达到合约式品牌广告的水平，但它使得大量中小互联网媒体有了切实可行的变现手段：这些媒体有一定的流量，但还不值得建立自己的销售团队面向品牌广告商售卖，直接把自己的广告库存（**inventory**）托管给 ADN，借助 ADN 的销售和代理团队为自己的流量变现。

ADN 既然只通过出价接口提供价格约定，那么由谁来保证量呢？自然会有需求方的某种产品来完成。当 ADN 产生以后，代理公司当然也要对广告采买方式做出调整，因为此时的流量采买发生了几点显著变化：一是更多地面向受众而非媒体或广告位进行采买，这当然是与受众定向的流行有直接关系；二是需求方的代理需要采用技术的手段保证广告主量的要求，并在此基础上帮助广告主优化效果。这又是一个与在线分配类似的带约束优化问题。但是实际上，这个问题有着本质的不同：由于只能在 ADN 定义好的定向标签组合上预先指定出价，而不能控制每一次展示的出价，因此，市场看起来像一个黑盒子，需求方只能靠选择合适的标签组合以及阶段性调整出价来间接控制效果。这种面向多个 ADN 或媒体按人群一站式采买广告并优化投入产出比的需求方产品，我们称为交易终端（**Trading Desk, TD**）。

在 ADN 中，核心的竞价逻辑是封闭的，这不能满足需求方越来越明确的利益要求。试想下面两个例子：（1）某电子商务网站需要通过一次广告投放来向它的忠实用户推广某产品；（2）某银行希望通过自己的信用卡用户在网络上找到类似的潜在用户群，并通过广告争取这批潜在用户。很显然，ADN 很难直接为这两个需求提供人群标签。定制化需求催生了一种开放的竞价逻辑，让需求方按自己的人群定义来挑选流量，这就是实时竞价（**Real Time Bidding, RTB**）。它是将拍卖的过程由广告主预先出价，变成每次展示时实时出价。只要把广告展示的上下文页面 URL 以及访客的用户标识等信息传给需求方，它就有充分的信息来完成定制化的人群选择和出价。于是，市场上产生了大量聚合各媒体的剩余流量并采用实时竞价方式为他们变现的产品形态——广告交易平台（**ad Exchange, ADX**）。

这个名称让我们很容易联想起股票交易所。事实上，如果我们把 ADN 的交易方式想象成场外交易市场（over-the-counter market），那么 ADX 与股票交易所确实有着类似的作用。

通过实时竞价的方式，按照定制化的人群标签购买广告，这样的产品就是需求方平台（Demand Side Platform, DSP）。由于实时竞价主要采用按展示次数计费的方式（本书后面部分会具体讨论其原因），DSP 需要尽可能准确地估计每一次展示带来的期望价值。在这一点上，DSP 比 TD 要方便多了，因为充分的环境信息使得深入的计算和估计成为可能。基于 DSP 的广告采买非常类似于股票市场上的程序交易，我们把这样的广告采买方式也叫作程序化交易（programmatic trade）。除了 RTB 以外，还有其他几种程序购买的交易方式，如优选（preferred deals）以及私有交易市场（Private Market Place, PMP）等。可以预见，在线广告中程序化交易的作用和地位将会不断加强，这是由数字广告的本质特点以及广告主利益最大化的趋势所决定的。

初次接触在线广告的读者可能对这部分中提到的大量概念和商业逻辑感到无所适从。不过没关系，上面所有用楷体字标出的关键概念在本书后面章节出现时会进行详细讨论。而我们写这一段的目的也仅仅是让大家对本书讨论的范畴有一个全局性的认识，从而在后面章节中接触到某个具体问题不会只见树木，不见森林。

由于在线广告存在着较为复杂的市场结构，LUMA Partners 对北美市场的主要代表公司进行非常全面的总结，并绘制成了图 1-9 中的“display LUMAscape”^[2]。这一图谱的骨架与上面我们介绍的在线广告简史有着非常紧密的联系，因此也是本书在广告产品方面重要的提纲。基本上可以说，这一图谱是从两端向中间逐渐发展和形成的：首先是合约阶段，广告主通过代理公司从媒体方采买广告，而媒体方的广告投放机则负责完成和优化各个广告主的合约；然后，市场进化出了竞价售卖方式，从而在靠近供给方产生了 ADN 这样的产品形态，而需求方的代理公司为了适应这一市场变化，孵化除了对应的媒介采买平台（media buying platform）；最后，当市场产生了实时竞价方式交易时，供给方进化出了 ADX，而需求方则需要用 DSP 与其对接来出价和投送广告。图中的下半部分，多是一些对这一骨干市场结构起支持作用的产品或者在细分领域的特异化产品。我们在后面介绍到相关部分时，将会给出相应的介绍。




图 1-9 LUMA 总结的展示广告市场结构和代表公司图谱

图 1-9 中的个别术语与本书略有区别（如媒介采买平台），我们会在书中用相近似的概念 TD 来代替，请大家留意。

总结一下，在在线广告发展的历史上，定向技术和交易形式的进化是一条主线。从最初的固定位置合约交易发展到进行受众定向、按展示量结算的合约交易，再到竞价交易方式，并最终发展成开放的实时竞价交易市场。这条主线的核心驱动力是让越来越多的数据源为广告决策提供支持，从而提升广告的效果。除了这条交易形态的主线，互联网广告产品还有另外一条发展线路，即产品展现逻辑上的发展：在展示广告的最初阶段，广告位作为与内容相对独立的单元来决策和运营，并且完全以优化收入为目标；但同时，人们从搜索广告和社交网络信息流广告中得到了启发——将内容与广告对立起来未必是一个好的选择。搜索广告和社交网络信息流广告这两种广告产品正是由于与内容的展现和触发逻辑有着高度的一致性，才使得它们的效果突出。沿着这样的思路，将内容与广告以某种方式统一决策或排序的广告产品——原生广告（Native AD）在近年来得到了工业界越来越多的关注。如何将原生的决策方式与前面介绍的广告市场已经非常成熟的规模化交易逻辑相结合是目前互联网广告产品发展的热点。需要特别说明的是，原生广告的思路在移动设备这样

屏幕尺寸受限的环境下将会成为一个非常有前景的发展方向，这方面的进展我们将在第 7 章中具体讨论。

1.5 泛广告商业产品

下面要讨论的这些泛广告商业产品的本质都是付费推广。虽然这些付费推广模式的表现方式更加多样化，用户的感知程度和参与程度也大不相同，但是产品和销售模式却与狭义广告基本相同。希望读者在看完此书以后，能够认识到这些商业产品本质上也是在线广告，能够以统一的视角来理解和规划这些变现方式。



图 1-10 团购产品示例

(1) 团购。团购本质上是一种按照效果付费的泛广告产品，其特殊性在于广告主除了付推广费用外，还向用户让利以获得转化。团购推广的主要广告主是一些本地化的店铺，主要目的是为了获得新客户。如图 1-10 所示，对团购平台来说，团购商品在一定环境下的排序与广告是一样的问题。不过团购销售很少采用竞价的方式，而多是预先约定价格。另外，团购的广告库中是付费信息而非创意，这有利于发展原生广告的推广方式，参见第 7 章。

(2) 游戏联运。游戏联运根据用户的最终游戏内消费在推广渠道和游戏开发商之间分成的商业产品，这仍然是一种按效果付费的泛广告产品。在页游和手游的推广中，联运是一种非常常见的发行模式，读者在各种产品中看到的图 1-11 所示的游戏下载专区，其背后的商业模式往往都是联运。实际上，在中国的各大 Android 应用市场中，游戏联运的收入远远超过其他类型的广告收入。如果将联运收入也算在广告收入中的话，互联网总体收入的广告占比还会提高不少。不同的联运渠道分成比例可能相差很大，经过我们调研，在 Apple Store 这样典型的国外市场中，渠道的分成比例一般为 30%，但是在中国，有些强势

的联运渠道分成比例甚至可以达到 90%以上。游戏联运也完全可以按照广告产品思路来设计和运营，另外其广告库同样具有易于原生化的特点。



图 1-11 游戏联运产品示例

(3) 固定位导航。这主要包括网址导航站的位置入口（如图 1-12 所示）、应用分发平台的推荐位置等付费推广位置。一般来说，这种产品的销售都采用按时间付费的固定位模式，而不是动态的竞价决策模式。这是因为广告主除了引流以外，往往更加关注这些入口位置的橱窗效应。这种广告的销售和运营模式与按天购买的合约广告相同。

(4) 返利购买。返利购买是电商行业常见的一种推广模式，它与团购有些类似，也是采用折扣或积分的方式激励用户购买。显然，这种方式可以获得非常高的 ROI，但是也会带来一些老用户转而由返利网下单，因此实际的效果远没有那么好，特别是在获取新客户方面的价值值得考量。

需要特别说明，当一个公司同时运营普通广告和上述一种或多种泛广告产品时，它们之间甚至是和用户产品之间，经常会出现争夺广告位或其他入口资源的问题。面对这样的问题，最合理的分配方式是通过它们之间的竞价来决策，这是非常重要的内部流量货币化的运营理念。



图 1-12 网址导航产品示例

1.6 延伸思考

1.考虑到品牌广告和直接效果广告的目的性差异，两者在创意设计、投放策略、媒介选择等方面应该有什么区别？

2.请你从自己熟悉的领域中找出几个泛广告产品的例子，并探讨其与典型广告产品的区别。

第2章 计算广告基础

从现在开始，我们开始接触在线广告中与“计算”有关的问题。在线广告中计算到底是为了解决什么问题，以及解决这些问题需要什么样的业务描述框架，将是本章重点关注的内容。

我们将先对传统广告中发展起来的广告有效性理论做简要的回顾。通过把广告产生效果的过程分解为若干阶段，并讨论其中各阶段关键的影响因素，可以对在线广告情形下受众定向、创意优化及其他有价值的技术点有感性的认识。虽然这部分与具体的计算技术无关，却对计算广告中的一些根本原理有深入的揭示，希望读者有所了解。

在互联网广告中，计算之所以可以发挥巨大的作用，与它的一些根本技术特点有很大关系，这是本章的出发点。总的来说，可衡量的效果以及相应的计算优化是在线广告区别于线下广告的主要特点。在这些特色的基础上，我们对 Andrei Broder 提出的计算广告核心挑战稍做推广，得到贯穿本书的计算广告核心问题，即利润优化问题的概念性框架。

在大多数广告产品中，可以通过计算优化的主要是收入部分。而千次展示期望收入（expected Cost Per Mille, eCPM）正是计算广告中最为核心的量化指标之一。与广告的信息传达过程相关，eCPM 又可以分解为点击率和点击价值的乘积，这两个指标是各种广告产品在计算过程中经常碰到的，也是产品运营需要深入理解和重点关注的。

同时，这样的收入分解方法还对在线广告产品市场结构和计费方式的理解很有帮助。大家将会看到，在线广告多种多样的计费方式实际上反映着市场结构的分工不同。具体来说，供给方和需求方如何分工估计点击率和点击价值，与整个市场的资源优化配置有关。对若干常见计费方式的深入理解，对于把握计算广告领域的核心问题，以及评估每个问题在特定情形下的难度有很重要的指导意义。

本章的最后，还介绍了若干广告和在线广告领域中重要的行业协会。了解这些协会在广告业务中代表的利益方以及他们对整个在线广告市场产品和技术形态的推动作用，对于有志从事广告技术和业务的读者来说也是必要的。

2.1 广告有效性原理

为了探讨用技术手段优化广告投放效果，我们先看看广告从产生用户接触开始是如何产生最终效果的。这一问题是广告领域一个传统重要的研究课题，我们直接借鉴了前人的研究成果，按照方便计算广告讨论的原则，用一个三段式信息传播模型来解剖广告由物理上产生到最终产生转化行为的全过程，这一模型如图 2-1 所示。

图 2-1 所示这一有效性模型把广告的信息接收过程分为选择（selection）、解释（interpretation）与态度（attitude）三个大阶段，或者进一步分解为曝光（exposure）、关注（attention）、理解（comprehension）、接受（acceptance）、保持（retention）与决策（decision）6 个子阶段。下面我们分别来讨论每个阶段的意义和关键点。




图 2-1 广告效果产生过程示意

（1）曝光（exposure）阶段。这一阶段指的是广告物理上展现出来的过程，此阶段的有效程度往往与广告位的物理属性有关，并没有太多可以通过技术优化的空间。实际的广告实践中，曝光的有效性对最终结果的影响往往远远高于其他技术性因素，所以才会有传统广告中“位置为王”的说法。像纽约时代广场那组著名的广告牌（见图 2-2 中左图）以及北京东三环北端京信大厦外立面正对着东三环北路的广告牌（见图 2-2 中右图）就有非常好的曝光效果。在互联网广告中，位置的影响有时会更加显著，因此如何从算法上消除由此带来的点击率预估偏差，是一个非常重要的实际问题。



图 2-2 曝光效果突出的广告位示例（左：纽约时代广场 右：北京东三环京信大厦）

（2）关注（attention）阶段。这一阶段指的是受众从物理上接触到广告到意识上注意到它的过程。对广告而言，曝光并不一定意味着关注。举个例子，有一天我的一位好友在浏览社交网站时，他的小儿子在旁边喊道：“爸爸，快看网页上的恐龙！”而这位朋友找了一分多钟都没有找到恐龙。实际上，恐龙就在网页上端最醒目的广告位上。这个例子说明，强曝光并不能等同于用户实际有效的关注。那么如何使得关注阶段的效率提高呢？有几个重要的原则。首先，尽量不要打断用户的任务。这一点是上下文相关的广告投送的原理基

基础，也是当今讨论原生广告产品的出发点之一。上面的例子也可以用这个原则来解释，当用户明确辨识出某个固定不变的广告位，并且不再认为它与自己当浏览网页的任务有关联时，他会下意识地屏蔽其中的内容。其次，明确传达向用户推送此广告的原因，这一点是受众定向广告创意优化的重要方向。另外，内容符合用户的兴趣或需求，这是行为定向的原理基础。

（3）理解（**comprehension**）阶段。用户关注到了广告的内容也并不意味着他一定能够理解广告传达的信息。再举一个例子，笔者有一次试玩了一款网页游戏，然后被某游戏广告定向到，并多次看到某宣传“四维城战新模式”的游戏广告。应该说这样的定向是精准的，我也非常认真地关注了广告的内容，不过这些内容我确实不能直观理解，也就谈不上后续的转化。理解阶段有哪些原则呢？首先，广告内容要在用户能理解的具体兴趣范围内，这说明了真正精准的受众定向有多么必要。其次，要注意设定与关注程度相匹配的理解门槛。例如，在电视广告中，可以用有一定情节的短故事来宣传品牌；在路牌广告中，创意制作原则是将若干主要市场诉求都表达出来；而对于互联网广告，由于用户的关注程度非常低，我们应该集中强调一个主要诉求以吸引用户的注意力。

（4）接受（**acceptance**）阶段。受众理解了广告传达的信息，并不一定表示他认可这些信息。广告领域有一句名言：“我知道有一半的广告预算浪费了。”实际的情况还有可能更糟，如果表达的信息不适当，甚至有可能有三分之一的广告展示起到负面效果！在使用幽默、性感这样非常规的广告手段时，要特别注意这一点。广告的上下文环境对于广告的接受程度有着很大的影响，同一个品牌广告出现在某游戏社区上和门户网站首页上，用户会倾向于认为后者更具说服力，这也就是优质媒体的品牌价值。在定向广告越来越普遍的今天，如何让合适的广告出现在合适的媒体上，即广告安全（**ad safety**）的问题，正在引起大家越来越多的关注。

（5）保持（**retention**）阶段。对于不仅仅追求短期转化的广告商，当然希望广告传达的信息给用户留下长久的记忆，以影响他长时间的选择，因此品牌广告商在创意设计上下了大量的精力提高此阶段效果。我们想想那些充满艺术性或浪漫气质的电视汽车广告，可以对此有直观的认识。

（6）决策（**decision**）阶段。成功广告的最终作用是带来用户的转化行为，虽然这一阶段已经离开了广告的业务范围，但好的广告还是能够为转化率的提高做好铺垫。特别是对于电商或团购业务，在创意上强调哪些信息以打动那些价格敏感的消费者是有相当的学问的。

定性地讲，越靠前的阶段，其效果的改善对点击率的贡献越大；而越靠后的阶段，其效果的改善对转化率的贡献越大。但是以上各个阶段的划分绝非孤立的和绝对的，而某一项具体的广告策略或技术也往往会对几个阶段的效果同时发生影响。虽然这样的有关广告

有效性模型的讨论多见于传统广告的研究中，然而其规律显然也对在线广告的产品方向有很强的指导作用。

2.2 互联网广告的技术特点

从前面的讨论中，大家一定已经发现了不少在线广告不同于传统广告的特点。在这些不同点当中，有一些对我们正确理解在线广告市场并探究合适的效果优化方案有着非常重要的指导意义。

(1) 技术和计算导向。数字媒体的特点使在线广告可以进行精细的受众定向，而技术又使得广告决策和交易朝着计算驱动的方向发展。实际上，受众定向这一思想在线下广告中也曾经被尝试过，比如试图把信用卡纸质账单背面的广告按照信用卡用户的年龄和性别做一些定制化，不过由于非数字的媒体上这么做的成本太高，因而无法规模化。在数字媒体上进行受众定向，其成本可以控制得非常低，这也直接催生了在线广告的计算革命。除了受众定向，由于在线广告存在着独特的竞价交易方式，因而广告效果精确的预估和优化能力也是非常重要的。

(2) 效果的可衡量性。在线广告刚刚产生之时，大家对这种广告最多的称道之处是它可以以展示和点击日志的形式直接记录广告效果，并且可以利用这些日志优化广告效果。不过，点击率这一指标从是否在绝对意义上能够反映广告效果是值得探讨的。从 1998 年到今天，横幅展示广告的点击率从 10% 一路降至 0.1%，难道这说明广告的效果下降了两个数量级吗？快速增长的市场规模显然给出了否定的回答。我们认为，在不同的产品或时代中，点击率绝对值的比较并没有那么重要，而在一个特定时期不同广告和算法表现出来的差异才是更有意义的。从这一点来看，可衡量性仍然可以认为是在线广告的一个重要特点。

(3) 创意和投放方式的标准化。标准化的驱动力来自于受众定向与程序购买。既然需求方关心的是人群而非广告位，创意尺寸的统一化与一些关键接口的标准化非常关键。这些接口标准中，比较典型的有视频广告的 VAST 标准^[40]和实时竞价的 OpenRTB 标准^[41]等。实践表明，有越来越多的广告产品和平台愿意根据这些市场标准来设计自己的规范和接口，因为这样大家可以充分利用整个市场的流动性，更快地创造更多的价值。

(4) 媒体概念的多样化。随着 Web 2.0 和移动互联的普及，赋予了更多交互功能的互联网媒体与线下媒体已经有了本质差别。随着交互功能的不同，这些媒体与转化行为的距离也就不同。举个例子，对在线购物行业而言，门户网站、垂直网站、搜索引擎、电商网站、返利网，在转化链条上一个比一个更靠近购买行为。我们从直觉上就可以知道，越接近转化的媒体上的广告带来的流量一定可以达到越高的 ROI，不过离“引导潜在用户”

这样的广告目的也就越远。因此我们在从需求方看在线广告时，应该注重各种性质媒体的配合关系，并从整合营销的角度去审视和优化整体的效果。试想，如果一家电商只用返利网作为线上广告渠道，ROI 一定可以做到很高，可是这样的营销能给他带来大量潜在用户吗？^[3]

（5）数据驱动的投放决策。与工业革命时期机器化的根本驱动力——电力相类比，互联网化的根本驱动力可以认为是数据的深入加工和利用。这一点在大数据概念被广泛认知的今天已经成为老生常谈。前面提到的在线广告的计算技术在很大程度上也要依赖于对于数据的大规模利用。广泛收集用户的行为数据和广告反馈数据，利用云计算的基础设施对用户打上合适的标签，同样根据数据在多个广告竞争同一次展示时作出决策，再将投放的结果统计数据反馈给广告操作人员以调整投放策略，这已经成为在线广告的基本投放逻辑。因此可以认为，现代的在线广告系统就是一个大数据处理平台，而且其对数据处理的规模和响应速度的要求都相当高。可以说，从来没有任何传统广告形式像在线广告那样，需要大规模地收集并利用数据，而这正是在线广告最吸引人之处。

2.3 计算广告的核心问题

Andrei Broder 在提出计算广告这一概念的同时也给出了该课题的核心研究挑战（注意是“核心挑战”而非“定义”）。对于这一核心挑战，他的表述是“Find the best match between a given user in a given context and a suitable advertisement”^[1]。我们结合近年来市场的发展以及实际业务中的一些体会，对此表述稍作加工，给出如下计算广告的核心问题：

计算广告的核心问题，是为一系列用户与环境的组合找到最合适的广告投放策略以优化整体广告活动的利润。

与 Andrei Broder 的表述相比较，我们主要进行的两方面的微调。首先，强调广告问题优化的是一组展示上的效果，而非孤立的某一次展示上的效果。这是由于广告活动中普遍存在着量的约束，在这一约束下进行利润优化，其最优解往往与每次展示独立决策时有很大的不同。其次，描述中去掉了“given”的字眼。这是由于在某些广告产品中，系统并不一定能拿到确定的用户或上下文唯一标识，但这并不意味着完全无法进行计算优化。同样地，我们也强调优化的结果是“广告投放策略”而不一定是具体的广告，这也是因为有些产品的策略并不是直接决定最后的展示。相信读完本书后面的部分，大家就能更深入地体会这些调整的原因。

上面的计算广告核心挑战需要转化为数学上可以优化的目标才能利用计算技术来解决。把它用下面的最优化问题来表达：

$$\max \sum_{i=1}^T (r_i - q_i) \quad (2.1)$$

这里的 i 代表从第 1 次到第 T 次之间的某一次广告展示。我们优化的目标就是在这 T 次展示上的总收入 (r) 与总成本 (q) 的差, 即广告活动的利润。当某次广告活动的预算一定, 即 $\sum_{i=1}^T q_i$ 是一个常数时, 很容易验证优化公式 2.1 与优化另一个广告中更常见的目标投入产出比, 即 $ROI = \sum_i r_i / \sum_i q_i$ 也是一致的。进一步考虑收入与成本具体依赖的因素, 上面的优化问题可以写成:

$$\max_{a_1, \dots, T} \sum_{i=1}^T \{r(a_i, u_i, c_i) - q(a_i, u_i, c_i)\} \quad (2.2)$$

表达式中的 a 、 u 、 c 三个变量, 分别代表广告、用户与环境, 即广告活动的三个参与主体, 显然, 广告展示的收入或成本与这三个因素都有关系。实际上, 对除了 DSP 以外的大多数广告产品来说, 要么是自营或包断资源, 要么按以收定支的方式与媒体分成, 其成本也对应为常数或正比于收入, 在这种情形下, 成本部分可以从上面的优化公式中去掉。

注意, 这里有一个隐含的假设, 即整体的收入或成本可以被分解到每次展示上。显然, 这一假设并不是十分合理的, 但是考虑到实际线上决策时, 必须对每次展示马上完成计算, 所以, 从实用出发我们仍然采用这一假设。在实际的系统中会采用频次控制、点击反馈等方法来对付多次展示之间效果相关性的问题。

在具体的广告产品中, 优化公式 2.2 可能会省略掉一些内容或参数, 或者增加一些约束条件, 构成该广告产品独特的优化问题。在后面我们谈到若干广告产品的关键技术时, 也会给出其具体形式。

2.3.1 广告收入的分解

下面, 我们再来进一步分解广告收入, 以便引出关于在线广告市场计费方式的重要分析。对一个广告市场中具体的产品形态, 我们往往能够主动优化的是收入而非成本, 因此, 可以主要关注收入优化的部分。在一次广告展示产生后, 有可能发生哪些后续行为呢? 参见图 2-3: 当用户在媒体页面的广告位上看到广告以后, 如果产生兴趣, 首先产生的是点击行为, 广告点击与广告展现的比率称为点击率 (Click Through Rate, CTR); 点击行为成功以后, 将会打开广告主的落地页 (landing page), 落地页成功打开次数与点击次数的比例称为到达率, 这是在广告主网站上发生的; 如果用户从落地页开始, 进一步完成下单等操作, 则称为转化, 转化次数与到达次数的比例称为转化率 (Conversion Rate, CVR), 这是在广告主网站上或线下发生的。



图 2-3 在线广告产生效果的步骤

按照媒体网站和广告主网站上的行为段对回报 r 进行分解，是实践中比较合理且容易操作的方式：

$$eCPM = r(a, u, c) = \mu(a, u, c) \cdot \nu(a, u, c) \quad (2.3)$$

在后文中，我们都沿用这样的符号表示：用 μ 表示点击率，用 ν 表示点击价值（click value），即单次点击为广告产品带来的收益。其中前一部分描述的是发生在媒体上的行为，后一部分描述的是发生在广告主网站上的行为。而这两部分的乘积定量地表示了某次或若干次展示的期望 CPM 值，就是我们前面提到的 $eCPM$ ^[4]。请大家特别关注 $eCPM$ 这个指标，因为它是计算广告中最常被提及，也是最关键的定量评估收益的指标，本书的计算问题大都是围绕它展开的。在对多个检索候选进行排序时，是根据 $eCPM$ 还是 CTR 排序也是区别广告产品和用户产品的重要策略特征。进一步，如果我们将所有的点击价值都等同起来，那么根据 $eCPM$ 排序和根据 CTR 排序实际上将得到一样的结果。因此，可以认为根据 CTR 排序是根据 $eCPM$ 排序的一种特例，这也使得将内容与广告统一排序的原生广告成为可能。

$eCPM$ 一般指的是估计的千次展示收益，它有两个很相近的概念：如果讨论的是千次展示收入，往往用 RPM；如果讨论的是千次展示成本，往往用 CPM。这三个术语有时在实用中的区别并不明显，请大家注意。

根据图 2-3 所示的流程，点击价值还可以进一步分解为到达率、转化率和客单价的乘积。由于这部分的深入解剖与行业密切相关，而且更多地属于站内运营而非广告的范畴，因此在本书中将只在 14.2.3 节进行简要的讨论。

2.3.2 结算方式与 $eCPM$ 估计的关系

对于大多数广告产品来说，需要计算给定 (a, u, c) 三元组的 $eCPM$ 以进行决策。可是由于广告市场的协作关系复杂，并非每个广告产品都可以对 $eCPM$ 中的两个步骤做出较准确的估计。根据 $eCPM$ 的分解决定哪部分由谁来估计是广告市场各种计费模式产生的根

本原因，也是广告市场中商业逻辑与产品架构衔接的关键一环。下面，我们来逐一分析下市场上主要的几种广告计费模式。

(1) CPM 结算，即按照千次展示结算。这种方式是供给方与需求方约定好千次展示的计费标准，至于这些展示是否能够带来相应的收益，由需求方来估计和控制其中的风险。对于品牌广告，由于目标是较长时期内的利益，很难通过对短期数据进行分析的方式直接计算点击价值，而点击率也因为对于用户接触的核心要求变得不是唯一重要的因素。在这种情况下，由需求方根据其市场策略与预算控制流量的单价并按 CPM 方式结算是比较合理的交易模式。实际上，在大多数互联网品牌广告，特别是视频广告中，CPM 都是主流的结算方式。

(2) CPC 结算，即按点击结算。这种方式最早产生于搜索广告，并很快为大多数效果类广告产品所普遍采用。在这种方式结算方式下，点击率的估计是由交给供给方（或者中间市场）完成的。点击价值的估计则由需求方完成，并通过点击出价的方式向市场通知自己的估价^[4]。这样的分工对于互联网广告，特别是以效果为导向的互联网广告而言，有着清晰的合理性：供给方通过其收集的大量用户行为数据可以相对准确地估计点击率；而转化效果是广告网站内的行为，当然他们自己的数据分析体系也就能更准确地对其作出评估。因此，以 CPC 方式结算，在效果类广告市场中具有接近垄断的地位。

(3) CPS (cost per sale) /CPA (cost per action) /ROI 结算，即按照销售订单数、转化行为数或投入产出比来结算。这些都是按照转化付费的一些变种。这是一种比较极端的结算方式，即需求方只按照最后的转化收益来结算，从而在最大程度上规避了风险。在这种结算方式下，供给方或中间市场除了估计点击率还要对点击价值作出估计，这样才能合理地决定流量分配。这里存在两个很明显的问题。一是转化行为为用户在广告网站内的行为，并非供给方能够直接监测和控制，因此无法进行准确的估计和优化。只有那些转化流程和用户体验类似的广告商组成的广告平台按转化付费才比较可行，典型的例子就是淘宝客广告。二是实际执行中，存在广告主故意扣单以降低转化率，从而低成本赚取大量品牌曝光的可能。因此，我们认为这种方式主要适合于一些垂直广告网络(vertical ad network)。另外在 DSP 中，由于需要完全代表广告主利益出价和优化，因此也会出现一些跟广告主之间按照 CPS 计费的情形。总体而言，对于那些与广告主收益直接挂钩的需求方广告产品来说，CPS 在一定条件下是可行的；但是对于普通的中间市场广告产品来说，CPS 并不是一种趋势性的结算方式。而 CPA 广告在移动应用下载的场景下，由于转化流程统一在 Apple Store 或 Google Play 中，且存在较完善的第三方转化监测，因而市场较为成熟。

(4) CPT (cost per time) 结算，这是针对大品牌广告主特定的广告活动，将某个广告位以独占式方式交给某广告主，并按独占的时间段收取费用的方式。严格来说，这是一种销售方式而非一种计费模式，因为价格是双方事先约定，无需计量。这种方式主要适用

于一些强曝光属性，有一定定制性的广告位。在一般的展示广告中，这种方式在欧美市场市场并不经常采用，但在中国的门户网站广告中，CPT 仍然是一种主流模式。CPT 这样独占式的售卖虽然有一些额外的品牌效果和橱窗效应产生，但是非常不利于受众定向和程序交易的发展，因而从长期的角度来看，其比例会有下降的趋势。

表 2-1 展示了以上几种结算方式概要的对比。综合来看可以认为，对于效果广告，CPC 计费方式最有利于发挥供给方和需求方的长处，因而在市场上被广泛接受；对于品牌广告，由于效果和目的有时不便于直接衡量，可以考虑按照 CPM 的方式计费；而 CPS 的计费方式只在一些特定的环境下才比较合理。

表 2-1 在线广告结算方式比较

结算方式	点击率估计	点击价值估计	优缺点	适用场景
CPT	需求方		可以充分发挥橱窗效应 无法利用受众定向技术	高曝光的品牌广告
CPM	需求方		可以利用受众定向选择目标人群 合约售卖下，受众划分不能过细	1. 有受众选择需求的品牌广告 2. 实时竞价广告交易
CPC	供给方	需求方	可以非常精细地划分受众人群 比较合理的供给方和需求方分工	竞价广告网络
CPS/CPA/ROI	供给方		需求方无任何风险 供给方运营难度较大	1. 效果类广告联盟 2. 效果类 DSP

既然广告有计费的需求，也就同时产生了效果监测的需求。在 CPM 类品牌广告中，由于曝光在媒体上产生，广告主往往会委托第三方的广告监测公司对曝光量、点击量等指标作技术核实，并以此作为结算的依据。在 CPC 或 CPS 结算的广告交易中，由于计费的指标，即点击或转化在广告主的网站上产生，所以并不需要特别的监测服务。因此，可以认为广告监测主要服务的对象是品牌广告主。随着 CPM 广告定向方式越来越复杂，广告监测也从简单的展示和点击记数到频次、人口属性等信息的验证和计量。关于这方面的问题和技术，我们将在第 15 章中再作介绍。

2.4 在线广告相关行业协会

由于供给方和需求方的博弈关系，需要一些行业协会来约束和规范市场。关注这些行业协会的立场与使命对更清晰地认识广告的商业逻辑大有帮助。以最重要的北美市场为例，主要有三个行业协会需要了解。

2.4.1 交互广告局



交互广告局（Interactive Advertising Bureau, IAB, <http://www.iab.net>）成立于 20 世纪末，是在线广告领域最重要的行业协会，其使命是致力于推动在线广告市场的发展。IAB 主要是站在供给方的长远利益上来研究和影响市场。换句话说，IAB 主要关注的是在线广告供给方的利益。正如 IAB 在自己网站标题上声明的那样，这一组织存在的使命是“dedicated to the growth of interactive advertising market”，即致力于交互广告市场的壮大。而这个方向的受益者主要是各在线媒体与广告技术公司。因此，IAB 的典型会员是 Google、Facebook、Yahoo!、Microsoft 这样的广告供给方以及 AudienceScience、MediaMath 这样的广告技术公司。广告技术公司和产品的发展是为了更好地服务广告主和提升在线广告效果，以利于更多的预算进入在线广告领域。从具体工作上看，IAB 与互联网大量媒体和广告平台合作，制定了一系列意义重大的标准和规范，这些都极大地促进了在线广告行业的健康发展。其中包括如下几个重要的规范。

（1）横幅广告创意尺寸标准。2001 年 IAB 公布的标准仅仅支持 7 种创意尺寸，即 120×600（摩天大楼）、160×600（宽摩天大楼）、180×150（长方形）、300×250（中级长方形）、336×280（大长方形）、240×400（竖长方形）、250×250（正方形弹出）。创意尺寸的统一化，对于在线广告市场淡化广告位概念、推广受众定向有着非常根本的促进作用。中国市场与此对比，由于广告位尺寸非常复杂，因而各个网站之间的壁垒较高，非常不利于定向广告和程序采买的发展。

（2）视频广告标准 VAST（digital video ad serving template）。由于视频广告创意和展示形式比较复杂，消耗资源也较多，IAB 制定了一套统一的 XML Schema 用于向在线视频媒体投放视频流内的广告，并对其用户进行规范化的描述，这一标准实际上减少了进入视频广告领域的技术障碍，使得视频广告市场规模快速发展成为可能。

（3）通用实时竞价接口标准 OpenRTB。实时竞价的技术我们将在第 6 章中介绍，简单来说，这种采买方式是为了方便需求方按照自己的受众划分高精度地采买流量。假设各个广告交易平台的实时竞价接口不同，将意味着需求方需要付出几倍的技术成本以完成广泛的市场对接。于是，IAB 制定了统一的 OpenRTB 标准，将横幅广告、视频广告、移动广告情形下的实时竞价接口做了统一的规范。

2.4.2 美国广告代理协会



美国广告代理协会（American Association of Advertising Agencies, 4A）并不是一个专门从事互联网广告的组织，而是线上线下各种广告，特别是品牌广告的代理商在美国的行业协会。4A 公司向其会员代理公司约定，至少要向广告主收取一定比例的服务费用，这一方面是为了避免行业内的恶性竞争，另一方面也是确保广告代理公司能够站在广告主的利益角度考虑问题，而后一点对于市场的长期健康发展是有帮助的。4A 公司的典型代表有奥美（Ogilvy&Mather）、智威汤逊（JWT）、麦肯（McCann）等。值得注意的是，由于 4A 是一个美国协会，因此严格意义上的 4A 公司都是美国公司，不过对于另外一些国际影响力较强、业务方式和准则与其类似的非美国广告代理公司，我们也往往都将其归为广义 4A 公司的行列，典型的例子如日本的电通（Dentsu）公司。

2.4.3 美国国家广告商协会



美国国家广告商协会（Association of National Advertisers, ANA）是一个广告主的协会，也是最彻底地代表需求方利益的组织。其会员多是 AT&T、宝洁（P&G）以及 NBA 等这些拥有大量广告预算的广告主。ANA 对广告主利益的维护可以从一件小事中得到体现：在微软宣布考虑在 IE10 支持限制第三方 cookie 滥用的“do not track (DNT)”协议时，是 ANA 明确声明对这样的计划表示反对，因为这样将会使得在线广告市场精确投送广告的能力受到很大影响，而这显然是与广告主的利益相违背的。

2.5 延伸思考

1.CPA/ROI 的结算方式看似对广告主有利，实际也催生了一些变形的推广方式。请考察你接触到的 CPA/ROI 渠道，并研究其与 CPM 或 CPC 渠道的关键差异。

2.对广告产品而言，优化利润与优化 ROI 有什么区别？

3.在社交网络中发生的传播营销过程与典型的展示、点击、转化流程有很大不同，请对此建立一个合理的模型，并分析其中的关键量化指标。

注 释

[1].数据来源于 IAB (<http://www.iab.net>)、艾瑞 (<http://www.iresearch.cn>) 等机构的市场调研报告。

[2].资料来源于 <http://www.lumapartners.com/introducing-the-marketing-technology-lumascape/>。

[3].2012 年年底，淘宝发布声明，宣布终止与以现金形式返利的淘宝客网站的合作，这正反映了市场对此问题的认知正在趋向一致和理性。

[4].由于 CPM 是千次展示的收益，因此 eCPM 实际上还要乘以 1000 才能与其相比较，为了表达简单起见，我们在本书中略去 1000 这一固定系数。

[5].当然需求方不会完全按照其点击价值来出价，而是会寻求更低的价格以获得套利空间。因此，如何在市场机制上避免广告主积极地调整出价，以促进市场竞争的激烈程度，是竞价体系设计的关键。我们将在第 5 章中讨论这一问题。

第二部分 在线广告产品逻辑

第 3 章 在线广告产品概览

在线广告不同于传统线下广告，其产品形式（这里说的并非创意形式）相当丰富。在 1.4 节中，我们对在线广告整个发展历程有了初步了解，如果从产品的视角将这一过程提炼出来，可以用图 3-1 来示意。




图 3-1 在线广告产品进化示意

我们将图 3-1 中的产品分为 4 个部分，这些将在后面几章中分别介绍。

（1）合约广告产品：它由线下广告的交易形式衍生而来，又可以分为按照时段售卖的 CPT 广告和按照约定展示量售卖的 CPM 广告。这类广告产品主要服务于后续效果不宜直接衡量的品牌类广告主，在门户网站和视频网站较为常见。

（2）竞价广告产品：其最重要的形式是搜索广告，其产品形式为对搜索关键词的竞价。这种广告在拓展到站外展示广告流量时，演进成了对页面关键词或者用户标签竞价的的产品形式，也就是 ADN。竞价广告的商业逻辑与合约广告完全不同，也是解决效果类广告需求的关键产品形式。

（3）程序化交易广告产品：竞价广告的进一步发展催生了实时竞价的交易形式。实时竞价使得需求方可以更灵活地划分和选择自己的目标受众，也使得更广泛的数据使用和

交易迅速发展起来。以实时竞价为核心的一系列交易方式逐渐演变为机器之间以程序化的方式完成广告交易决策，因此，这类产品称为程序化交易广告产品。

（4）原生广告产品：广告的产品体系除了自身的演进，另一个重要课题是如何处理与非商业化内容的关系，让广告与内容尽可能以“原生”的方式共存。搜索广告和社交网络信息流广告对此作了非常有价值的探索，不过这样的原生广告在规模化和交易化方面也遇到了很多的问题。然而，随着近年来移动设备对于原生广告的强烈渴求，像标准 ADN 那样的原生广告平台正在快速发展中。

对于每一种广告的产品形态来说，都可能会有三个主要的组成部分：面向需求方的接口、面向供给方的接口、中间的投放系统及匹配策略。根据产品的不同，其中接口的形式可以是面向人工操作的界面，也可以是机器间通信的接口。这些广告中的产品环节，都属于商业产品的范畴，我们将先对这类产品设计的主要原则以及需求方和供给方界面的一般情形进行介绍，为后面几章中按上述的四个部分分别介绍广告产品做准备。

3.1 商业产品的设计原则

商业产品指的是面向商业客户而非一般用户的产品，其中最典型的代表就是互联网广告产品。其他的一些面向客户的互联网产品，如客户关系管理（Customer Relation Management, CRM）、网站分析（Web Analytics, WA）以及后面要提到的数据管理平台（Data Management Platform, DMP）等，也属于商业产品的范畴。商业产品的设计和运营有着一定的共性原则，我们有必要在这里提一下。

互联网是一个产品驱动的行业。熟悉产品设计的读者应该了解，用户产品演进的根本驱动力是人们追求方便的天性。因此，用户产品的设计原则总是朝着更简单、更直观、更快捷的方向努力。而相应的产品设计重点也集中在关键功能的突出、操作过程的流畅等方面。

然而，如果有机会参与商业产品的设计和运营，你就会发现，其中关注的重点和运营的方式有相当大的区别。有时候良好的用户体验，并不一定能带来一款商业产品良好的口碑或市场上的成功，这是为什么呢？简单来说，商业产品一般都有一个明确的商业目标，而商业产品的使用者选用一款产品的动力也是为了优化这个商业目标。例如，广告，其使用者不论是媒体、代理或广告主，都是为了优化自己的利润。因此，对这类产品的选择标准是客观的，也是可衡量的。Google AdWords 之所以为大量的中小广告主广泛采用，主要原因并不是因为 AdWords 的使用便捷性远超同类产品，而是因为其推广效果有目共睹。因此，商业产品的任何一项功能改进，只要能带来其对应商业目标的提升机会，即使在使用流程上引入一些不便，也是可以接受的。这样的产品原则带来的结果正如图 1-9 所示，

整个广告市场的交易环节越来越复杂，使用门槛也越来越高，这与用户产品简化的大趋势是非常不同的。

在优化既定商业目标这一商业产品的总体原则下，我们在商业产品运营过程中有一些需要注意的关键点。

（1）相对于产品功能，要特别关注产品中的策略部分。策略本身是商业产品非常关键的环节，以广告为例，竞价中的机制设计、冷启动时的数据探索、受众定向的标签体系都是产品策略需要考虑的内容。策略上看似简单的调整往往能带来广告系统收入上巨大的变化。与一般产品不同，这些策略的制定既需要对于广告市场深入的了解，又需要许多扎实的基础知识。对于刚开始进入广告产品领域的读者，将关注点集中在这些“看不见的产品特征”上是需要下大工夫体会和实践的。

（2）要特别关注数据，让运营和产品优化形成闭环。由于商业产品的目标是确定和可优化的，所有产品特征和策略的成功与否要严格根据数据的反馈来判断。同时，新产品功能的规划也要在洞察历史数据和其他用户产品数据的基础上进行。从数据分析开始，以数据结束，这样的闭环式迭代是最适合商业产品的开发模式。

（3）当然，在所有与使用者打交道的产品界面上，用户产品追求便捷性的设计原则依然非常重要。不过在商业产品中，实现功能以外过于新奇、炫酷的产品外观和交互模式是应当避免的。

由于本书探讨的是计算广告这一典型的商业产品，我们也会将重点放在广告投放、交易、策略、数据使用和交易等产品环节上，而对于广告系统与需求方或供给方的界面接口，将只在下面作简要的介绍。

3.2 需求方层级组织与接口

由于广告市场的复杂性，一个广告系统的需求方有可能是广告主、代理公司、TD 或者 DSP。无论面对哪种需求方，一般来说，我们都需要一个操作界面让其对预算、广告投放条件和其他策略做设置。

一般来说，需求方提供的广告是分层次管理的。在市场上大多数的产品中，广告的层次分为广告主、广告（推广）计划（campaign）、广告（推广）组（ad group）、广告创意（creative）等几个层级，参见图 3-2。其中广告主层级管理一个广告主的通用信息，而其他三个层级则与具体的投放管理相关，我们来分别介绍一下。




图 3-2 广告层级关系示意

(1) 广告计划概念上对应于广告主的一次投放合同，其中包括了预算、时间范围等基本信息，参见图 3-3 中的示例。除了这些信息以外，图中还有另外的一些相关设置，例如，(a) 在有多个广告产品可供选择时，要在广告计划中确定投放的是哪个产品，如图中的“选择投放网络”部分；(b) 预算的分配策略 (pacing)，即图中的“预算分配控制”部分。对于大多数广告计划，较为均匀地分配预算可能比较合理，但是对于游戏开服、移动应用冲榜等类型的推广，预算的集中花费则很重要。

设置推广计划

* 推广计划名称：

加载现有计划的设置：

选择推广计划

* 选择投放网络：

精选网络

标准展示广告 - 在PC端的流量中投放您的展示广告

关键词文字链广告 - 针对搜索过特定关键词的人群投放文字链广告

商品推荐广告 - 您的产品库没有符合条件的商品 [了解详情](#)

预算和时间

--预算--

* 每日预算：

☒ 不限预算

不限预算时,每日投放量没有上限,设置预算后,当消费达到预算后即不再投放。

* 预算分配控制：

☒ 标准：将每日预算均匀地分配到整个投放日程中

☐ 加速：尽可能地将每日预算花费出去

--时间--

* 开始时间：

2014-09-17

结束时间：

为空表示不限结束时间。

* 按小时投放：

全日程展示广告 (当前排期时区: GMT+08:00)

自定义

图 3-3 广告计划设置示意

(2) 广告组对应于一个具体的广告投放策略，主要是设定受众定向条件和出价，参见图 3-4 中的示例。广告组最重要的功能是设置各种各样的定向条件，因而是广告效果优化的关键层级。另外，对媒体的选择也可以认为是一种定向条件。值得注意的是出价——在后面我们将要介绍的竞价类广告产品中，出价是由广告主自行设置，而非预先约定。而对于出价与能获得流量的规模和质量的关系，广告主很难有直觉上的认识。因此，从产品的角度来说，往往需要给出一些有意义的提示，如根据当前出价做的流量预估，或者如图 3-4 中所示比较直接的“建议出价”。

基本设置：

* 推广组名称：

建议您根据媒体、人群或活动内容来命名，以便于调整投放和报表查看。

加载现有推广组：

选择推广组

哪些用户可以看到我的广告

--地域定向--

国家/地区：中国大陆 修改

地区选择：☒ 不限 ☐ 选择省份 ☐ 选择一二线城市

排除地区：

请输入拼音或中文

--人群定向--

指定关键词：已添加关键词数量：0/5000 修改

用户在哪里看到我的广告

-- 媒体定向 --

选择媒体：☒ 精选资源 ☐ 指定广告位

高级设置

出价（按第二高价和创意质量度计费，将不会高于您的实际出价）

默认出价(¥)：

CNY/ ☒ CPC ☐ CPM

建议出价(¥)：0.10-1.15

(推广组的出价将作为每个关键词的默认出价，您也可以在关键词列表中单独修改每个关键词的出价)

图 3-4 广告组设置示意

（3）广告创意则是最终展示出来的素材，可能在同一个组策略下有不同尺寸的创意存在，参见图 3-5 中的示例。对于文字链类型的创意，基本素材包括标题、描述等内容；而对于图片类型的创意，则直接上传图片素材。另外广告创意的必要设置还应包括展示和点击的监测地址等。为了方便广告投放人员直观地看到创意的展示效果，往往还会提供创意预览功能（如图 3-5 右侧的“预览区”）。

关于需求方设置管理的细节功能，在不同的产品中可能会有较大的差别，但是这样的 4 层级组织方式是比较通用的。除了业务管理的便捷性，这样的层级结构还为数据统计和建模提供了天然的、合理的层级结构，让新创意的冷启动问题变得容易一些。在后文介绍

各类广告产品时，我们会重点关注其商业逻辑和产品策略，而对于界面上投放管理的功能不再展开讨论。

关键词创意

* 标题：

360合并创意.png

不超出50个字符，超出不显示

{}

点击插入通配符

* 描述：

不超出80个字符，超出不显示

{}

点击插入通配符

* 点击地址：

http://e.360.cn/

点击地址和显示地址应为同一个网站域名下的网址

* 显示地址：

不超出50个字符，超出不显示

显示URL的设置不会影响网民对网站的实际访问

提交

回到上一步

预览区（以下预览效果仅提供示意，实际

360合并创意.png

聚效以最全面的网站资源实现全面覆盖，
众人群划分实现精选受众

http://ju.mediaiv.com

图 3-5 广告创意设置示意

对于投放规模很大的广告主或代理，所有的操作都通过类似上面的界面人工完成是非常低效的。对于这样的情形，广告平台一般会提供与界面功能相对应的 API 接口，以便大的需求方用编程的方式进行批量投放和优化。不过，需求方也有可能大量滥用 API 来做一些组合或测试投放，这会使得投放系统的压力大增，因此在实际运营中要对带宽或操作次数作一定的限制。

3.3 供给方管理接口

在目前的主流广告交易逻辑中，供给方即媒体对业务的控制比起需求方来要弱很多。供给端的资源组织主要分媒体和广告位两个层次。其中媒体可以是网站，也可以是移动应用开发者。

媒体的操作比广告主方要简单，一般来说，添加、删除广告位以及查看各广告位的运营数据是主要的功能需求。这一接口的功能性示例见图 3-6（广告位名称已经被隐去）。

广告位名称	状态	尺寸	创建日期	显示数	点击数	点击率	收入
	启用	65x65	2014-11-28	238,602,848	199,153	0.0835%	¥ 68,692.58
	启用	65x65	2014-11-28	0	0	0.0000%	¥ 0.00
	启用	65x65	2014-11-28	376,409,825	704,798	0.1872%	¥ 242,941.18
	启用	63x63	2014-11-28	1,331,921,299	944,687	0.0709%	¥ 321,429.39
	启用	64x64	2014-09-25	960,408,949	4,094,441	0.4263%	¥ 1,261,196.91
	启用	64x64	2014-07-18	127,600	104	0.0815%	¥ 34.76
	启用	64x64	2014-06-10	237,264	185	0.0780%	¥ 61.19
	启用	64x64	2014-06-10	295,444	266	0.0900%	¥ 91.78
	启用	64x64	2014-06-10	362,509	352	0.0971%	¥ 111.33
	启用	64x64	2014-06-10	435,934	447	0.1025%	¥ 147.65
	启用	64x64	2014-06-10	530,349	526	0.0992%	¥ 169.06

图 3-6 媒体广告位管理示意

对于其中的某个具体广告位，根据产品功能的不同，需要的操作功能也不同。但一般来说，设定广告位尺寸、取广告投放代码或 SDK 以及设定该广告位对广告类型的要求是一些通用的需求。在广告管家或 SSP 之类的供给方产品中，往往还会有精细的流量分配功能。需要注意的是，广告平台会维护各个广告位对应的域名或应用名，以防其他域名的流量盗用广告位代码。

上面介绍的这种比较简单的供给方管理接口主要用于一般的 ADN 或 ADX，而在媒体需要深度参与的原生广告中，这样简单的对接方式不再适用，关于这部分内容参见第 7 章。

3.4 延伸思考

- 1.请研究你熟悉的某一个商业产品，并探讨其与用户产品在设计和运营方面的不同之处。
- 2.如果向需求方提供 API 来替代一般的 UI 投放方式，会对广告产品的运营产生什么样的影响？

第 4 章 合约广告

从本章开始，我们将对在线广告一些主要的产品形态和相应的商业逻辑展开讨论。先从按照合约的方式售卖的广告产品开始，这部分产品在整体产品演进过程的位置如图 4-1 所示。




图 4-1 合约广告产品

互联网广告业务的初始阶段，拥有流量的媒体与需要广告资源的代理商是市场的主要参与者。线下广告的商业逻辑也被照搬到了线上，由广告代理公司和媒体签订协议，确保某些广告位在某时间段为指定的广告商所占有，同时广告商按整体合同支付广告费用。这种按 CPT 结算的广告位合约方式对技术的依赖性较小，只需要用到简单的广告排期系统。

合约式广告的重点是按 CPM 计费的展示量合约广告。这种方式仍然以合同的方式确定一次广告活动的投放总量和展示单价，但是售卖的对象已经由“广告位”进化到了“广告位+人群”。这可以说是在线广告发展史上的一个重要里程碑，而数据也被直接应用在广告的商业活动中。从供给方产品和技术复杂程度来看，CPM 合约甚至比以后的竞价系统更加复杂，其复杂性主要来源于多个合约对投放系统提出的量的约束。

在展示量合约广告中，需求方的产品技术并没有太大发展。这是因为所有广告投放的执行要求都以合约的形式交由供给方来完成了，需求方并没有技术上优化的空间。而正是由于需求方对深入优化效果的需求进一步发展，才产生了按照竞价方式来售卖的广告系统，希望大家通过本章中合约广告的讨论，能够理解这种交易形态进化的内在动力。

4.1 广告位合约

广告位合约是最早产生的在线广告售卖方式。它是指媒体和广告主约定在某一时间段内、在某些广告位上固定投送该广告主的广告，相应的结算方式为 CPT。这是一种典型的线下媒体广告投放模式，在互联网广告早期也很自然地被采用。这种方式的缺点非常明显，即无法做到按受众类型投放广告，因而也无法进行深入的效果优化。可以说，广告位并不是目前互联网广告的主流模式。

不过，这种方式在一些特定的场景下也有一定的好处：首先，在一些强曝光属性的广告位^[2]上采用这种独占式的广告投放，往往可以有效地给用户带来品牌冲击；而在其他一些横幅位置长期独占式的购买有利于形成“橱窗效应”，塑造不断攀升的品牌价值和转化效果；还有一点，这种销售模式由于可以向广告主提供一些额外的附加服务，比如同一个页面上的竞品互斥，使得高溢价的流量变现成为可能。

随着受众定向技术的发展，广告位独占式售卖的执行方式也发生了很大的变化。即使某个广告位全部投放一个广告主的创意，也并不意味着一定要投放同样的一款创意，而受众定向在其中也可以起到很重要的作用。例如，某汽车生产商广告主旗下可能有多个系列的产品，如小型车、紧凑型车、豪华车、SUV 等，而这些车型的潜在购买人群其实也有很大的区别，如果能够对这些系列的受众分别投送相应的创意，就可以取得更好的效果。另外，即使在受众上无法区分的情形下，也可以利用频次控制的方式向同一用户递进式地展示一系列创意，以达到更好的效果。这些与受众定向结合的广告位独占式售卖实际上与其他非独占式的售卖在系统实现上没有本质区别了。

广告位合约还有一种变形的形式，即按照广告位的轮播售卖。在这种方式中，同一个用户对同一个广告位的一系列访问，被依次标上一组循环的轮播顺序号，如 {1, 2, 3}。将其中具有同样顺序号的展示作为一个虚拟的广告位，售卖给广告主。需要注意的是，对某一个用户而言，第一次展示的顺序号不应该设为 1，而是应该按相等概率从所有轮播顺序号中随机选取一个，并从此开始累加和循环。这样做是为了保证各个轮播分配到的流量一致。这种轮播的售卖方式在广告位独占式售卖库存不够而广告主又需要确定的展现规则保证时，被较广泛地采用，特别是在中国门户网站的品牌广告中。

在 CPT 售卖的情形下，供给方和需求方的计算需求和技术成分都不太高。广告主的营销需求往往是 4A 或其他代理公司进行媒介采买（media buy）。而对于广告质和量两方面的要求，也都是根据代理公司人员对媒体广告位的历史经验以及对广告主业务的了解通过人工优化的方式来满足。对于供给方，即媒体而言，往往会使用一种在合同确定以后自动地执行合同的广告管理工具，或者称为广告排期系统。

广告排期系统的代表性产品有 DoubleClick 的 DFP 以及中国市场上好耶（Allyes）的类似产品，还有免费给中小网站使用的百度广告管家等。当然，排期等基础功能都是这些产品早期的形态，随着受众定向、实时竞价等广告投放方式越来越普及，这些产品的功能也

都逐渐演进，从简单的广告排期管理逐渐拓展出其他售卖方式下媒体需要的功能，如果结合了动态分配和 RTB 等功能，也就接近于供给方平台了。

4.2 受众定向

从我们马上将要谈到的展示量合约开始，大多数广告产品的基础是按照受众售卖。因此，受众定向是其非常重要的支持技术。当然，受众定向本身的重要性和应用范围远远超过合约广告领域，而在各种竞价广告产品中也尤其重要。因此，我们先对受众定向这一核心的广告产品策略进行整体介绍。

随着在线广告技术和业务的发展，产生了各种各样的受众定向方法，这些方法的综合应用使得广告的精准程度越来越高。在考察某种定向方法时，主要有两个方面的性能需要关注：一是定向的效果，即符合该定向方式的流量上高出平均 eCPM 的水平；二是定向的规模，即这部分流量占整体广告库存流量的比例。当然，效果好、覆盖率又高的定向方法是我们追求的目标，不过往往难以两全。因此，广告系统有必要同时提供多种定向方法的支持，以达到整体流量上质的最优化。

4.2.1 受众定向方法概览

我们先来看一些市场上比较流行的定向方式。按照其有效性和在广告信息接受过程中起作用的阶段，对照第 1 章中的广告有效性模型，我们把这些定向方式按照粗略的定性评估表示成图 4-2。

在图 4-2 中，水平方向表示的是定向技术在广告信息接收过程中大致起作用的阶段，而垂直方向为定性的效果评价。对受众定向的一些典型方法，我们举例说明如下。

（1）地域定向（geo-targeting）。这是一种很直觉也很早就被广泛使用的定向方式。由于很多广告主的业务有区域特性，地域定向的作用相当重要，也是所有在线广告系统都必须支持的定向方式。地域定向也可以认为是一种上下文定向，不过其计算简单，仅仅需要简单的查表就可以完成。地域定向是一种不可或缺的流量选择手段。举个例子，假设某电商网站只在北京运营和送货，那么其效果广告一般来说应该定向在北京的区域内，否则一个其他省的顾客点击广告进入购物环节后，如果发现无法结算，将会是非常差的用户体验。




图 4-2 常见受众定向方法一览

(2) 人口属性定向 (demographical targeting)。人口属性定向虽然在效果上未必特别突出，但是由于在传统广告的话语体系中大量使用这类标签来表达受众，因此它特别为品牌广告主所熟悉。在在线广告的品牌合约中也经常会有对人口属性的要求。人口属性的主要标签包括年龄、性别、教育程度、收入水平等。人口属性有一点与兴趣标签不同，那就是它是可以监测的，即可以用采样加调研的方法来判断一次人口属性定向广告活动受众中有多少比例是正确的。因此，在按 CPM 结算的广告中，人口属性比其他定向标签为广告主接受的程度更高。

需要说明的是，除非有特别的专门数据来源，如实名制 SNS 的注册信息或在线购物的消费记录等，一般情况下要进行准确的人口属性定向并不容易。在人口属性数据覆盖率不足的情况下，如果要按照这种定向进行 CPM 售卖，我们可以用已知人口属性的用户作为训练集，构造分类器对人口属性进行自动标注。一般来说，采用分类器的方法确定人口属性准确程度有限。在单纯效果类的广告活动中，预测人口属性的必要性不太高，因为预测出来的人口属性也是根据用户其他行为特征得到的，并不能提供额外的信息量。

(3) 频道定向 (channel targeting)。频道定向是完全按照供应方的内容分类体系将库存按照频道划分，对各频道的流量投送不同的广告。这种定向方式比较适用于那些离转化需求比较近的垂直类媒体，如汽车、母婴、购物导航等。对于内容覆盖面比较宽的媒体，这种方式取得的效果是有限的。举一个极端的例子，如果我们把某网站的军事频道作为一个定向标签，那么很难找到直接匹配的广告需求。

(4) 上下文定向 (contextual targeting)。将频道定向这种方法加以推广，可以根据网页的具体内容来匹配相关的广告，这就是上下文定向。上下文定向的粒度可以是关键词、主题，也可以是根据广告主需求确定的分类。上下文定向的效果在不同类别的内容上有很大的区别，但是这种方式有一个非常大的好处，那就是覆盖率比较高。对大多数广告展示，不论对当前访问用户的信息了解有多少，往往都可以根据当前浏览的页面推测用户的即时兴趣，从而推送相关广告。由于覆盖率高，上下文定向也是 ADN 中首选的定向方法之一。

(5) 行为定向 (behaviorial targeting)。行为定向是展示广告中非常重要的一种定向方式，其框架是根据用户的历史访问行为了解用户兴趣，从而投送相关广告。行为定向之所以重要是因为它提供了一种一般性的思路，使得在互联网上收集到的用户行为数据可以产生变现的价值。因此，行为定向的框架、算法和评价指标也就奠定了在线广告数据驱动的本质特征，并催生了相关的数据加工和交易的衍生业务。如果把上下文定向看成是根据用户单次访问行为的定向，那么行为定向可以认为是一系列上下文定向的融合结果。因此，上下文定向是行为定向的基础，而且对各种类型的上下文定向都可以有相对应的行为定向方式。例如，地域定向是根据用户当前访问的 IP 来确定地理区域，相应地，也可以根据用户过去一段时间内的访问中最频繁的地理位置来定向，这种方式实际上得到的更接近于用户的经常居住地，业界有人称其为“where-on-earth”定向。

(6) 精确位置定向 (hyper-local targeting)。在移动设备上投放广告时，我们有可能获得非常精准的地理位置。例如，利用蜂窝信息或者 GPS，地理定位的精度完全可以达到街区的粒度，如果进一步利用 Wi-Fi、蓝牙等设备的室内定位技术，精度可以进一步达到数米级。这就使得基于精确地理位置的广告成为可能，也使得大量区域性非常强的小广告主（如餐饮、美容等）有机会投放精准定位的广告，这已经与传统意义上的地域定向有了质的变化，也成为移动广告最重要的机会之一。在桌面环境中，也有数据提供商（如 Experian）可以提供根据 IP 信息得出的电脑精确定位，在这些数据的支持下，桌面在线广告也可以进行精确位置定向。

(7) 重定向 (retargeting)。这是一种最简单的定制化标签，其原理是对某个广告主过去一段时间的访客投放广告以提升效果。显然，某个广告主的访客是其独有的信息，因此这属于定制化标签。重定向被公认为精准程度最高、效果最突出的定向方式，不过其人群覆盖量往往较小。这是因为，重定向的覆盖投放量是由广告主固有用户的数量和与媒体的重合比例共同决定的。关于重定向的原理，我们将在第 6 章中具体介绍。

(8) 新客推荐定向 (look-alike targeting)。由于重定向的量太小，而且无法满足广告主接触潜在用户的需求，因此不能仅仅依靠它来投送广告。新客推荐定向的思路是根据广告主提供的种子访客信息，结合广告平台更丰富的数据，为广告主找到行为上相似的潜在客户。这一方法的目的是希望在同等用户覆盖比率的情况下，达到比一些通用的兴趣标签更好的效果，这也从实质上体现了广告主数据的核心价值。新客推荐只能说是一种大致的思路，而非具体的方法，其基本原理我们也将第 6 章中介绍。

(9) 团购 (group-purchase)。这并不是定向广告技术，却与其有一定的关联，因此我们在这里一并说明。根据我们的观点，团购也是一种变相的广告形式，这种广告有两个显著的特点：首先是一般都针对区域性的广告主，因此地域定向或者直接按照地域分类组织是必要的功能；另外，团购主要是利用价格工具，直接降低用户在决策阶段的门槛，

使得价格敏感的用户转化效果有明显的提升，当然，这一手段也是要付出成本的。用类似的手段在创意上直接显示打折或降价的促销信息也被其他的电商类广告广泛使用。

4.2.2 受众定向标签体系

在一些反映用户兴趣类的受众定向方法（如行为定向、上下文定向等）中，我们需要一个标签体系，将每个用户映射到其中的一个或几个标签上去。如何规划合理的标签体系对广告产品的运营影响非常大，因此，这是产品策略中特别关键的一环。一般来说，这样的标签体系有两种组织方式：一种是按照某个分类法（taxonomy）制定一个层次标签体系，其中上层的标签是下一层的父节点，在人群覆盖上是包含关系。一些面向品牌广告的受众定向往往采用这种结构化较强的标签体系。需要指出，这一体系中的标签是根据需求方的逻辑而制定，某些在媒体方意义很大的分类标签，如军事等，由于没有明确的需求对应，不宜出现在标签体系中。

另外一种兴趣标签的组织方式，是根据广告主的具体需求设置相应的标签，所有的标签并不能为同一个分类体系中所描述，也不存在明确的父子关系。这种半结构化或非结构化的标签体系往往包含一些比较精准的标签的集合，因而主要适用于多种目标，特别是效果目标并存的广告主的精准流量选择要求。

选择结构化兴趣标签体系还是非结构化的兴趣标签体系更多地是商业上的决策，主要需要考虑下面两种情形。

（1）当标签作为广告投放的直接标的时（包括 CPM 广告及竞价广告中直接可被广告主选择的人群），这些标签既要能够为广告主所理解，又要方便广告主的选择。因此，在这种情形下，结构化的层级标签体系往往是较合理的产品方案，特别是在 CPM 广告中，标签的划分不能过细（原因将在 4.3.3 节中讨论）。这种结构化标签体系的一个典型代表是表 4-1 所示的 Yahoo! 行为定向标签体系。从表 4-1 可以看出，这样的标签体系非常易于理解和操作，在面向品牌广告主售卖时较为适用。

表 4-1 Yahoo! GD 受众定向标签体系

一级标签	二级标签
Finance	Bank Accounts, Credit Cards, Investment, Insurance, Loans, Real Estate, ...
Service	Local, Wireless, Gas & Electric, ...
Travel	Europe, Americas, Air, Lodging, Rail, ...
Tech	Hardware, Software, Consumer, Mobile, ...
Entertainment	Games, Movies, Television, Gambling, ...
Autos	Econ/Mid/Luxury, Salon/Coupe/SUV, ...
FMCG	Personal care, ...
Retail	Apparel, Gifts, Home, ...
Other	Health, Parenting, Moving, ...

(2) 当标签仅仅是投放系统需要的中间变量，作为 CTR 预测或者其他模块的变量输入时，那么结构化的标签体系其实是没有必要的，应该完全按照效果驱动的方式来规划或挖掘标签，而各个标签之间也不太需要层次关系的约束。这样的标签体系，比较典型的代表是 Bluekai 的标签体系，由于其面向的对象是追求效果或特殊人群定位的广告主，因而组织上的规整性也就让位于效果的精准性了。关于 Bluekai 标签体系的更多介绍，参见 6.6.5 节。

还有一种特殊的标签形式，即关键词。直接按照搜索或浏览内容的关键词划分人群和投放广告，往往可以达到比较精准的效果。关键词这种标签体系是无层级关系、完全非结构化的，它虽然很容易理解，但并不太容易操作。不过由于搜索广告在整个在线广告中的重要地位，选择和优化投放关键词这样一项专门技术已经发展得相当充分，因此这种标签也是实践中常用的。

4.3 展示量合约

在今天，广告位合约的方式并非互联网广告的主流，哪怕是以品牌为目的的投放。实际上，互联网主流的品牌广告投放方式是按照 CPM 结算的展示量合约。展示量合约指的是约定某种受众条件下的展示量，然后按照事先约定好的单位展示量价格来结算。这种合约还有一个名称，就是担保式投送即 GD，其中的“担保”指的就是量的约定。实际执行中，在未能完成合约中的投放量时，可能要求媒体承担一定的赔偿。

很多情况下，我们也会把展示量合约通俗地称为“CPM 广告”。实际上，CPM 广告还包括另一种按 CPM 结算，但是不约定展示量的售卖方式，如广告交易市场中的广告售卖。

而那样的非保量 CPM 实际上属于竞价广告而非合约广告，其商业逻辑差别较大。因此，这里我们采用展示量合约的说法。

我们从供给方和需求方两方面来看这种售卖方式出现的合理性。媒体从按固定广告位售卖变为按 CPM 售卖，初衷是为了在受众定向的基础上提高单位流量的变现能力，可是面向的仍然是原来的品牌广告主。广告主按广告位采买时，比较容易预估自己拿到的流量，可是按照人群定向的方式采买，流量有诸多不确定的因素。因此，需求方希望在合约中加入对量的保证，才能放心地采买。

展示量合约虽然以人群为显式标的进行售卖，但是请注意一个非常重要的事实：

展示量合约并没有摆脱广告位这一标的物。

这是由于在 CPM 这种结算方式下，无法将多个差别很大的广告位打包成同一售卖标的，因为这些广告位的曝光有效性可能差别巨大，合理的 CPM 也相应地大幅变动。实践中的展示量合约往往是以一些曝光量很大的广告位为基础，再切分人群售卖，最典型的例子是视频网站的贴片位置或者门户网站首页的广告位。对实时竞价有所了解的读者可能有疑问，广告交易市场里的广告位五花八门，为什么可以按照 CPM 结算呢？这个问题我们在后面谈到实际竞价的产品逻辑时再进行讨论。

虽然从交易模式上来看，展示量合约仍然是比较传统的交易模式，但是从技术层面上看，这种模式的出现实际上已经反映了互联网广告计算驱动的本质：分析得到用户和上下文的属性，并由服务端根据这些属性及广告库情况动态决定广告候选。这一商业模式的出现，需要有一系列技术手段的支持，这些手段主要包括受众定向、流量预测和担保式投放等。其中受众定向是在线广告非常重要的核心问题，被各种广告产品广泛使用，我们已经在上一节进行了介绍。下面讨论一下流量预测和在线分配的产品策略问题。

4.3.1 流量预测

展示量合约售卖的是某特定人群上的广告曝光次数，而人群不同于确定的广告位，因此必须在合约中约定投放的量。于是，在产品策略上就产生了流量预测(traffic forecasting)这一问题。流量预测在广告产品中包括以下三个主要用途。

(1) 售前指导。在展示量合约广告中，由于要约定曝光总数，事先尽可能准确地预测各人群标签的流量变得非常关键。如果流量严重低估，会出现资源售卖量不足的情形；如果流量严重高估，则会出现一部分合约不能达成的状况。这都会直接影响整个系统的收入。

(2) 在线流量分配。同样是在展示量合约广告中，由于合约之间在人群选择上会有很多交集，当一次曝光同时满足两个以上合约的要求时，怎样决策将它分配给哪个合约以

达到整体满足所有合约的目的，这是下文将要讨论的在线分配问题。各种在线分配算法都要依赖流量预估的结果，以达到高效和准确的目标。

(3) 出价指导。在竞价广告中，由于没有了量的保证，广告主往往需要根据自己预计的出价先了解一下可能获得多少流量，以判断自己的出价是否合理。与前面的应用不太一样，这里的流量预测还多了出价这样一个因素。

综上所述，广告里一般的流量预测问题，可以描述成对流量 $t(u, b)$ 这个函数的估计，其中第一个参数 u 是给定的人群标签或人群标签的组合，第二个参数 b 是出价。在展示量合约中，由于没有竞价，可以看成是上述问题在 $b \rightarrow \infty$ 情形下的特例。与流量预测有关的技术将在第 11 章中介绍。

4.3.2 流量塑形

流量预测对于展示量合约非常重要，不过在本质上还是被动地统计流量情况。在有些情形下，我们可以主动地影响流量，以利于合约的达成。这一产品策略问题称为流量塑形 (traffic shaping)。

流量塑形的典型场景是综合性门户网站上售卖的展示量合约广告。我们知道，门户网站各子频道的流量严重依赖于首页关键位置链接的导流。假如在车展期间，汽车频道上的展示广告需求旺盛，那么首页上的链接应该更多地给汽车频道导流以利于收入的增加。这样的想法相当直接，在实践中也被广泛使用。不过，从商业产品的要求来看，要系统化、高效率地达到流量塑形的目标，需要用户产品与广告产品的需求情况打通，然后按照一定的准则，在不伤害用户体验的情形下，尽可能提高商业变现的效率。本书不对这方面具体的产品技术进行详细的介绍。

值得注意的是，流量塑形问题已经涉及用户产品与商业产品的内在联系，这与后面讨论的原生广告有千丝万缕的联系，我们将在第 7 章中详细讨论。

4.3.3 在线分配

展示量合约这种保量合约都面临一个问题：各个合约要求的人群很可能大量交叠，如何设计分配策略，使得各个合约都尽可能被满足。为了描述这一策略问题，我们将其简化为一个二部图 (bipartite graph) 匹配的问题。二部图的一方是表示广告库存的供给节点，每个节点代表的是所有人群标签都相同的广告流量集合；二部图的另一方是表示广告合约的需求节点，每个节点代表的是一个广告合约的人群标签条件。




图 4-3 在线分配中的二部图匹配问题示意

供给节点、需求节点和在线分配二部图的示例见图 4-3。在图 4-3 中，下方的 6 个节点为供给节点，而上面的三个节点为需求节点。如果某供给节点的受众标签能够满足某需求节点的要求，我们就在相应的两个节点间建立一条连接边。供给节点中的各个条件之间都是“与”的关系，因此各个供给节点之间的流量是无重合的；需求节点中的各个条件也是“与”的关系。（如果广告投放中设置的是“或”的关系，则可以转化为多个需求节点。）显然，需求节点之间可能会抢夺同一个供给节点的流量。

如果系统允许在一天结束后才分配今天的流量，我们可以很容易地设计策略：根据每个供给节点的流量和各需求节点的约束，解上面的分配问题，得到每个供给节点应该分配多少比例的流量给某个需求节点。不过在实际情况中，我们不可能等到流量情况全部已知后再做决策，而是需要在每一次曝光时实时做出分配决策，因此，这一策略问题称为在线分配。在线分配需要根据历史数据和某种策略离线得到一个分配方案，线上则照此方案执行。

如果可选的标签数量很少，比如只开放年龄和性别，那么供给节点的数量就不多；如果合约的数量也不太多，那么需求节点的数量也不多。在这种情形下，我们仍然可以借鉴上面的离线方法进行在线分配：根据流量预测的结果得到代替实际流量，再解上面的分配问题，得到每个供给节点应该分配多少比例的流量给某个需求节点，而线上的系统则根据解得的分配比例来执行。不过，实际的在线分配技术比这个要复杂很多，我们将在第 11 章中具体讨论。

随着标签数量的增加，供给节点的数量会以指数速度上升，而每一个供给节点的流量当然也就迅速收缩。当节点的流量过小时，对其进行相对准确的预测就变得相当困难，这时上面所说的方案就会变得完全不可行。因此，展示量合约这类广告产品在人群标签非常丰富和精准时是无法有效地运作的，而这正是竞价广告产品的原动力之一。

4.3.4 产品案例

广告位合约产品多见于中国门户网站首页等曝光资源，由于其逻辑较为简单，我们不再举例说明。展示量合约有两种典型的产品场景：一是用于视频广告资源；二是北美主要门户网站的品牌性广告位。我们简要介绍 Yahoo! GD 市场，供大家了解。

Yahoo! GD 市场



Yahoo! 的展示广告分为两个产品体系：GD 和非担保式投送（Non-Guaranteed Delivery, NGD）。前者是面向品牌的合约广告，而后者包括了广告网络、程序化交易等多种产品。应该说，从是否满足高价值品牌广告为视角来划分广告产品，这是一种相对陈旧的视角，这也导致了 Yahoo! 在程序化交易方面的产品进展一直不快。

我们重点来看一下 Yahoo! GD。在这个市场中，Yahoo! 为品牌广告主提供合约式的采买接口，并且提供了基础的定向功能来划分人群。在 Yahoo! GD 中的人群标签包括地域、人口属性（主要是年龄和性别）以及行为定向标签。其行为定向标签分为多个层次，其中前两层的一部分标签如表 1-1 所示。

在这个行为定向标签体系中，一共有数千个标签，不过实际售卖中，产生过销售合约的不过一百多个。这非常典型地反映了合约广告的尴尬：大量精准的标签在合约量的束缚下基本无法售卖。因此，大家要特别注意，一个广告产品声称自己的标签体系多么复杂，有多少标签种类，实际上没有太大的实际意义，这些标签的人群规模会更有说服力。

应该说，Yahoo! GD 市场是显示量合约广告最早产生也比较完备的产品体系之一。在实时竞价产生之前，Yahoo! GD 市场提供的简单标签已经能满足大部分需求了。有关展示量合约广告的一些关键产品策略和技术方案都来自于这一产品，因此值得大家深入了解。并且，在今天视频广告快速发展的环境下，这一市场中的方法论和解决方案很多情形下都可以直接被采用。

4.4 延伸思考

1.除了广告位合约和展示量合约，是否可以设计一种点击量合约的交易模式，它会遇到什么样的挑战？

2.在展示量合约中售卖的受众往往有监测上的要求，那么对于行为定向这样的不易监测的用户标签而言，有什么产品思路提高其市场接受程度？

第5章 搜索与竞价广告

随着搜索业务变现的要求，以及精准受众定向技术的发展，在搜索广告和展示广告中都产生了竞价这种新的交易模式。对比前面的合约广告可知，竞价交易模式的本质是将量的约束从交易过程中去除，仅仅采用“价高者得”的简单决策方案来投放每一次广告。竞价顺应了定向广告向精细化发展的趋势要求，也为大量无法用合约售卖的剩余流量找到了可能的变现渠道，使得大量中小广告主参与在线广告的可能性和积极性大大增强，也使得在线广告的商业环境与传统广告产生了本质区别。

本章将集中介绍竞价类广告产品，特别是搜索广告和广告网络，并重点讨论其中关键的产品策略。这部分产品在整体产品演进过程中的位置如图 5-1 所示。但是，实时竞价相关的产品由于在数据利用和商业逻辑上与广告网络区别较大，我们将在第 6 章中进行介绍。




图 5-1 竞价广告产品

搜索广告在竞价广告乃至整个在线广告中都有着旗舰产品的地位。除了它的变现能力和市场规模方面的优势，更重要的是，一些在计算广告中非常核心的产品策略和技术方案都来源于搜索广告。因此，对搜索广告的深入理解对于理清整个竞价广告市场非常关键。我们在本章中对搜索广告的讨论将着重介绍其对整个广告市场的引领点，而其中最关键的一项，就是竞价广告产品的产生和相应的机制设计理论。如何设计合理的市场规则和定价策略，使得竞价市场的竞争更加合理充分，对于整体收益有相当大的影响。这方面有关宏观市场上的讨论在竞价时代显得非常重要，也成为在线广告领域得到深入研究的问题，我们在本章中会用单独一节来讨论其问题框架和一些实用方法。

在竞价广告的交易逻辑下，展示广告领域也产生了广告网络这种批量采购各种媒体剩余流量，然后主要按照点击付费的方式售卖给广告主的产品形式。这种产品形态的产生对

于提高整个展示广告市场的流动性发挥了很大作用。广告网络中竞价的标的物有两种：一是上下文页面中的关键词，这是直接从搜索广告衍生而来的；二是根据用户行为加工的兴趣标签，这是从展示广告的定向逻辑发展而来的。广告网络的竞价环境与搜索广告有所不同，各种上下文或用户标签的有效性差别巨大，另外各种广告位的差别也会很大。因此，除了完全依照 eCPM 估计排序广告外，冷启动问题以及各种复杂环境下点击率的归一化非常重要。这些实际上使得广告网络的效果优化比搜索广告更有挑战性。

对应于竞价广告的产生，需求方的产品和技术也在发生变化。其中关键的变化有两点：一是由面向广告位采买变成面向人群的跨网络采买；二是帮助广告主在竞价环境中完成量的保证，这一点是竞价市场不再直接保证的。能达到这些需求方目的的产品我们叫作媒体采买平台。在媒体采买平台里，在量的约束下完成 ROI 的优化的问题依然存在，并且变得比在线分配问题更加困难，这也成为高端的采买平台提供的服务之一。当然，搜索广告的媒体采买和 ROI 优化同样十分重要，这项专门的服务称为搜索引擎营销（Search Engine Marketing，SEM）。

5.1 搜索广告

提起竞价广告，不能不先从搜索广告说起。搜索广告一直是整个在线广告市场中市场份额最大的类型，更重要的是，像竞价、类搜索的广告投放架构都是从搜索广告发展起来的。因此，我们非常有必要深入地了解搜索广告，并从这里入手了解整个竞价广告市场。

对搜索广告这个产品，不同搜索引擎提供商有不同的称呼，如 paid search、search ad、sponsored search 等。这些词汇概念上非常相似，但也略有差别，个人比较倾向于采用“sponsored search”（付费搜索）这样的说法，而“paid search”（付费搜索）有时会让读者对是谁付费产生误解。至于“search ad”（搜索广告）实际上还应包括搜索引擎中的其他广告形式。有关搜索广告更多的背景和概念，大家可以进一步参考参考文献[42，53]。

从市场规模来看，搜索广告占整个在线广告市场的一半以上。表 5-1 列出了中国市场综合搜索引擎广告和垂直搜索引擎广告（如淘宝直通车）等的收入占比数据^[3]。

表 5-1 中国搜索广告市场规模

	2012Q4	2013Q1	2013Q2	2013Q3	2013Q4	2014Q1	2014Q2	2014Q3
在线广告整体规模（亿元）	223.1	192.8	256.6	306.2	344.4	295.3	381.5	422.2
搜索引擎广告占比（%）	32.5	33.8	31.8	31.3	29.8	34.4	33.9	34.1
垂直搜索广告占比（%）	24.4	24.9	27.3	29.4	31.9	27.1	26.2	24.6

搜索广告是比较典型的竞价广告产品，其特点是广告主就某标的物（在这里是关键词）的广告展示机会展开拍卖式的竞争，并根据竞争结果依次占据该广告展示的若干位置。这与第4章中的展示量合约是截然不同的：首先，量的保证不复存在，广告主需要自行调整效果与量的平衡；其次，价格的约定也被去掉，每个广告主都可以随时调整各关键词上的出价。下面介绍搜索广告的具体产品形式。

5.1.1 搜索广告产品形态

搜索广告是以上下文查询词为粒度进行受众定向，并按照竞价方式售卖和CPC结算的广告产品。通常，搜索广告展示在搜索结果页，如图5-2所示。搜索广告创意的展示区域一般来说分为北（north）、东（east）、南（south）三个部分。北区和东区的所有位置构成同一次关键词拍卖的位置集合，竞价时位置的排序为 $\{\text{north}_1, \text{north}_2, \dots, \text{east}_1, \text{east}_2, \dots\}$ ，这基本上是根据各个位置点击率的高低排列的。同时，并不需要在这些位置上全出广告，这与横幅广告有显著的区别。南区的广告，不同的搜索引擎有不同的产品处理方法，有的直接照搬北区广告，有的则直接照搬东区的前几条。

搜索广告最基本的形式是与自然检索结果一致的文字链，一般会加底色和角上的“推广”“推广链接”“Ads”等字样，以区别于自然结果，这样做的目的是让那些对广告没有兴趣的人尽量少减少误点击，从而降低广告主的无效消费和提升用户体验。

搜索广告竞价的标的物是竞价关键词（bid term），用户输入的查询（query）通过与关键词相匹配来确定是否可以触发该条广告。匹配的方式及可以采取简单的精确匹配，也可以有更多的扩展方式，查询扩展也是搜索广告的一项比较关键的产品策略。

本章中讨论的搜索广告主要以通用搜索引擎为蓝本。实际上，很多垂直类搜索，特别是电子商务类搜索也有很强的广告变现能力，但产品形态可能会有所不同，大家可以有选择性地与下面讨论的问题来对照。

在互联网广告的整体产品谱系当中，搜索广告有着特殊重要的地位，具有以下鲜明的产品和技术特点。

（1）搜索广告的变现能力，即eCPM远远高于一般的展示广告，其市场重要程度也就得以彰显。因此，与搜索广告的一些独特问题和算法的研究，受到了高度的重视。而搜索广告高变现能力最关键的产品原因就是用户主动输入的查询直接反映了用户的意图。

（2）搜索广告的受众定向标签，即是上下文的搜索查询。由于搜索词非常强地表征着用户的意图，搜索广告可以进行非常精准的定向。相对这样的上下文信息，根据用户历史行为得到的兴趣标签的重要性大打折扣，这一方面是因为其信号远不如搜索词强烈，另

一方面是因为用户这样明确意图的任务是决不能被打断的（参见第2章广告有效性原理部分）。因此，搜索广告里的eCPM由一般情形下的 $r(a, u, c)$ 退化成了 $r(a, c)$ 。

信用卡

百度一下

信用卡首选招商银行信用卡,积分可兑星巴克,1分钟办卡!



立即办卡

招商银行信用卡中心-官方24小时快速办理信用卡通道,信用卡积分可兑星巴克/DQ!
积分永久有效-办卡送1500积分-赠品牌双肩包-官方申请通道
ccclub.cmbchina.com

推广链接

信用卡哪家比较好,上班族族...

宜人贷p2p借贷平台,针对上班族,打工工资4000元即可申请,0抵押0担保,额度高达50万。
cps.yirendai.com

信用卡选平安,轻松借钱不用...

信用卡首选平安直通贷款,活动时间有限,利率8折任你抢!0抵押0担保0风险!
1010-0000.pingan.com

中信银行信用卡中心小额贷款

中信信用卡中心0抵押贷款,月入3000即可办理,贷款流程简单,放款快,专人上门服务。
www.ecitic.com

信用卡申请,贷款平台,融360

融360贷款平台,超多信贷机构超多信贷员,信用卡申请
www.rong360.com

无需信用卡,1小时快速借贷!!

信用卡,拍拍贷新型个人网络借款方式,无抵押贷款。
www.ppdai.com

更多信用卡的百度推广结果>>

关于信用卡百度为您推荐更多优质结果,放心搜索,有V有保障。

信用卡

小额信用卡办理

什么信用卡最好申请

信用卡小额贷款

想在此推广您的产品吗?

咨询热线: 400-800-8888
e.baidu.com

信用卡怎么申请,信用卡查看,信用卡官方申请,百度财富

发卡行: 不限 平安 兴业 民生 建设 招行 中信 交通 中行 农行 花旗 华夏 光大 浦发 工商 广发



招商银行bankcard

预借现金随时随地可取



招商银行YOUNG卡

100%的取现额度



平安标准卡

新开送100购享3折



平安淘宝联名卡炫

新开送100购享3折

查看更多相关信用卡>>

caifu.baidu.com

信用卡 百度百科



信用卡(英语:Credit Card),又叫贷记卡。是一种非现金交易付款的方式,是简单的信贷服务。信用卡一般是长85.60毫米、宽53.98毫米、厚1毫米的具有消费信用的特制载体塑料卡片。是银行向个人和单位发行的,凭此向特约单位购物、消费和向银行存取现金,其形式是一张正面印有发卡银行名称、有效期、号码...

产品起源 产品种类 主要特点 特点对比 申请流程 更多>>

baike.baidu.com/ 2014-10-15

信用卡论坛-我爱卡会员社区-中国最大最权威的信用卡论坛

信用卡论坛-我爱卡会员社区-中国最大的信用卡论坛,讲述申卡历程,谈谈用卡体会,解答用卡疑惑,信用生活-从我爱卡开始
bbs.51credit.com/ 2014-10-12

南区

信用卡首选招商银行信用卡,积分可兑星巴克,1分钟办卡!

招商银行信用卡中心-官方24小时快速办理信用卡通道,信用卡积分可兑星巴克/DQ!

推广链接

信用卡哪家比较好,上班族族...

宜人贷p2p借贷平台,针对上班族,打工工资4000元即可申请,0抵押0担保,额度高达50万。
cps.yirendai.com

信用卡选平安,轻松借钱不用...

信用卡首选平安直通贷款,活动时间有限,利率8折任你抢!0抵押0担保0风险!
1010-0000.pingan.com

中信银行信用卡中心小额贷款

中信信用卡中心0抵押贷款,月入3000即可办理,贷款流程简单,放款快,专人上门服务。
www.ecitic.com

信用卡申请,贷款平台,融360

融360贷款平台,超多信贷机构超多信贷员,信用卡申请
www.rong360.com

无需信用卡,1小时快速借贷!!

信用卡,拍拍贷新型个人网络借款方式,无抵押贷款。
www.ppdai.com

更多信用卡的百度推广结果>>

关于信用卡百度为您推荐更多优质结果,放心搜索,有V有保障。

信用卡

小额信用卡办理

什么信用卡最好申请

信用卡小额贷款

想在此推广您的产品吗?

咨询热线: 400-800-8888
e.baidu.com

平安信用卡,在线办卡送100,方便快捷!

平安信用卡,办卡成功立送100元,超长50天免息期,积分还可换油卡电话卡。

图 5-2 搜索广告竞价位置示例

(3) 搜索广告的展示形式与自然结果的展示形式非常接近，往往仅仅在底色和文字链接中有不太引人注目的提示。这样的产品设计使得它有原生广告的意味，也进一步提高了广告效果。但另一方面，这样的广告结果对相关性的要求远远超过展示广告，因此在根据查询匹配广告时需要非常精细的策略和技术。

(4) 从搜索广告发展起来的竞价交易模式已经逐渐发展成为互联网广告最主流的交易模式。这一模式从根本上改变了广告的运营方法，并为其效果的快速提高释放出巨大的生产力。

5.1.2 搜索广告产品新形式

搜索广告的产品技术重点与前面介绍的合约广告差别很大，与竞价的展示广告网络也有一定的差别。从产品设计的角度看，搜索广告有以下三方面的探索趋势。

- (1) 丰富文字链创意的展示形式让其更富表现力以提高点击率。
- (2) 利用东区对相关性要求稍低的特点设计一些拓展广告产品。
- (3) 优化广告与自然结果的关系在保证相关性和广告效果的前提下提高收入。

图 5-3 中给出了搜索广告产品新形式的一些示例，下面分别具体说明。



图 5-3 搜索广告新产品示例

1.超越文字链的创意

显然，蓝色超链接肯定不是搜索广告的产品终点。随着搜索结果本身向着展示更丰富、获取内容更直接、行业性不断加强的方向发展，搜索广告也在探索一些能传递更多价值的展现形式，以同时提升用户体验和变现效率。这方面的探索有两个重点方向。

(1) 在通用广告链接上增加更多有表现力的信息点。如图 5-3 中第 2 部分所示，除了标题、摘要这些文字链广告创意的标准内容以外，还增加了广告主的 Logo、主要内容链接、联系电话等内容。实践证明，这些都会提高广告的直接效果和品牌价值。更重要的是，这样的发展方向与行业基本无关，可以规模化复制，因此在搜索广告中已经被广泛采用。

(2) 直接展示结构化的广告内容摘要，甚至提供一些可直接访问的功能，这样可以减少用户跳转的成本，提高推广效率。如图 5-3 中第 1 部分所示，广告产品直接展示了旅游网站的一些主要内容链接，并直接在结果中提供了订机票和酒店的快捷入口。这样的商

业化结果往往直接来源于搜索的直接到达产品，如百度的阿拉丁、360 的 OneBox 等，但由于结果是付费的，因此也应该归为广告或商业化内容。需要指出，这种内容为了照顾用户体验的一致性，往往不能完全采用搜索广告的竞价方式来运营，一般的运营方式是就某个行业进行阶段性的线下竞价。

上面的这种发展方向为提升搜索广告效果提供了新的空间，然而尚未成为搜索广告的主流。原因在于这种模式需要分行业设计产品和运营方案，规模化程度有限；另外如果直接对接单品，会产生与个性化重定向一样的商品库对接等复杂的工程问题，这部分我们在后面介绍 DSP 时再进行讨论。

2. 弱相关广告形式

搜索引擎右侧的产品原则跟左侧相比有一点点区别，那就是在合理和可解释的范围内可以增加一点相关性要求稍低的泛化内容，因此为这部分的广告产品设计也提供了新的空间。我们用两个例子来介绍这方面的探索。

(1) 图 5-3 中的第 3 部分是一种在搜索广告中常见的带有一定品牌意味的广告形式。它是以广告主对应的一组导航类搜索关键词，在用户搜索这些词时展示该广告主的品牌宣传性创意。这样的产品可以提升广告主用户对品牌的认知程度和后续黏性。

(2) 图 5-3 中的第 4 部分是一些搜索引擎提供的同类推荐功能，在此例中，为相关的旅游类网站。显然，这部分的列表和排序可以按照竞价广告的逻辑来运营。通过这一广告产品可以为搜索引擎提供一些离决策稍远、以接触潜在用户为目的的广告。如图中的例子，携程的用户可能不一定用过同城网，但是在此处看到以后或许会尝试并对其发生兴趣。当然，这样的产品绝对不能在搜索左侧的结果中展示，因为那样会引起用户对结果相关性的质疑。

3. 原生广告探索

搜索广告从一开始就具有原生广告的特点：它的商业化结果与自然结果一样，由用户的主动意图触发，并且展示形式上与自然结果相差不大。实际上，有相当比例的用户是完全无法区分自然结果和广告结果的。因此，探索搜索广告与内容的自然结合，以越来越“原生”的方式投放广告，也是产品的重要方向。

与其他搜索引擎不同，百度的搜索广告从一开始就是混排在自然结果中的竞价排名方式，而类似于图 5-2 的标准形式是后来才逐渐发展起来的，但这种混排的形式实际上一直存在于百度的广告产品中，并且对营收仍然发挥着重要的作用。这种混排虽然褒贬不一，而且在一部分查询上实际上降低了结果的质量，但是可以说是搜索广告原生化的一种探索。

另外一个原生化的趋势，在有些直接面向商品的信息类搜索中，像图 5-4 中那样提供结构化内容结果时，在其中混入商业化结果，并进行统一排序。与只提供自然结果相比，

这可以增强变现能力；与只提供广告结果相比，这可以避免需求不足带来的结果质量下降。这样的广告，也可以称为“商品直达式广告”。



图 5-4 商品直达式搜索广告示例

我们认为，搜索广告实际上是比信息流广告更加重要的原生广告起源，而且搜索广告的一些重要特点可以被借鉴到原生广告平台的产品之中，这一点在第 7 章介绍原生广告时再讨论。

5.1.3 搜索广告产品策略

除了产品形式上的创新，搜索广告的投放和优化策略也是产品的重要一环。要了解产品策略方面的关键点，我们先来看一下搜索广告决策的基本过程。

如图 5-5 所示，搜索广告的整个决策过程可以分为查询扩展、检索、排序、放置、定价等几个阶段。查询扩展是搜索广告独有的策略，目的是给广告主自动地拓展相关的查询词，扩大采买流量；广告检索和将候选广告根据 eCPM 排序是广告系统较为通用的核心流程（本章后面介绍广告网络时再讨论）；而定价是竞价广告非常核心的策略（在下一节机制设计中将重点介绍）。




图 5-5 搜索广告决策过程示意

需要说明，在搜索广告中，排序的依据，即 eCPM，可以简单地表示成 $r(a, c) = \mu(a, c) \cdot \text{bid}_{\text{CPC}}(a)$ 。不过在实际产品中，点击率 μ 这一项会被质量度（quality score）所替代，而后者除了考虑点击率，还需要综合诸如落地页质量等其他因素，得到更全面的对广告质量的评价，其目的是为了避免广告主的恶意行为、促进市场长期发展等。而在本书中，为了说明基本概念和算法，将主要考虑点击率的作用。

1. 查询扩展

查询扩展是搜索广告的一项关键策略。对广告主来说，从浩若烟海的关键词中找到符合自己需求的组合绝非易事。因此，搜索引擎会提供一些将广告中的关键词匹配到更多相关查询的服务，常见的几种匹配方式如下。

（1）精确匹配，即不对广告主提供的关键词做任何形式的扩展，保证忠实按照广告主意图精准执行。精确匹配的执行方式是首先将用户输入的查询分词，例如，“英语培训”这个查询，可以分成{英语，培训}这个词集合，当这个词集合与广告主设定的关键词集合完全一致时，就触发了精确匹配。以“英语培训”这个关键词为例，在精确匹配方式下，可能触发广告的有“英语培训、培训英语”这两个查询。

（2）短语匹配。当用户的查询完全包含广告主关键词及关键词（包括关键词的同义词）的插入或颠倒形态时，就认为匹配成功，可以触发相应的广告候选。仍以“英语培训”这个关键词为例，在短语匹配方式下，可能触发广告的搜索有“英语培训、英语培训暑期班、哪个英语培训机构好、英语的培训、英语相关培训、英文培训”等。但像“英语歌曲、电脑培训”这样的词就不会触发。这种方式是用较精细的概念匹配较宽泛的概念，因此一般来说还是比较精准的。

（3）广泛匹配。当用户的查询词与广告主的关键词高度相关时，即使广告主并未提交这些查询词，也可能被匹配。仍以关键词“英语培训”为例，在广泛匹配方式下，可能会触发“外语学习班、四级证书”这样的查询。广泛匹配的逻辑并没有清晰的定义，一般来说，都是用数据挖掘的算法自动获得。因此，虽然打开广泛匹配可以获得较多的流量，但是流量的精准性往往会打一定的折扣。

（4）否定匹配。由于短语匹配和广泛匹配都是系统自动完成，难免会出现一些匹配不精准的结果。因此，需要同时向广告主提供否定匹配的功能，即明确指出哪些词是不能被匹配的，这样可以灵活地关停一些低效的流量。

短语匹配和广泛匹配都属于典型的拓词方式，将其与否定匹配相结合，广告主可以比较自由地在流量和质量之间找到平衡点。然而由于媒体与广告主利益的不一致性，搜索引擎提供的拓词方式未必是对广告主最佳的，我们后面介绍 SEM 产品时会讨论这一点。

2. 广告放置

当广告候选完成排序以后，需要分别确定北区和东区的广告条数，这个环节称为广告放置（ad placement）。由于这两个区域构成一个统一的竞价队列，实际上是要分别设定进入北区和进入东区的条件，其中最关键的是进入北区的条件。

北区是黄金的广告展示位置，对于搜索广告的收入至关重要。一般来说，通用搜索引擎的广告收入中绝大部分都来自于北区，因此北区广告的平均条数与收入直接相关。但同时由于北区广告直接压低了自然结果的位置，必然会对用户体验产生一定的影响。因此，要达到商业利益与用户体验较好的平衡，我们在关注收入指标时也要特别关注北区广告的数量和质量。往往在考察一项新算法对 RPM 的影响时，我们也应同时关注整个搜索引擎的北区广告平均条数（North Foot Print, NFP, 或 Average Show Number, ASN），而在 NFP 显著变化时，对应的 RPM 变化往往没有太大的参考价值。

确定一条广告能否进入北区要考虑两个关键因素：一是该广告相关性是否足够；二是该广告的 RPM 是否足够。前者是为了确保用户体验，后者是为了高效地利用展示位置。另外，一般来说北区还会设定一个广告条数的上限。根据整体 NFP 的约束和收入的目标，我们可以很容易通过数据模拟的方法确定相关性和 RPM 的最优阈值，这些我们将在第 13 章中再进行讨论。

前面说过，搜索广告的决策一般来说不太考虑用户 u 的影响，但是在确定北区广告条数这个问题上是个例外，这就是个性化的广告放置。由于个人偏好、对广告了解程度的不同，不同的用户对广告的容忍度和点击率呈现出明显的差别：有一部分用户总是会跳过广告，直接从自然结果开始浏览；但也有一部分用户或者对广告不太分辨、或者对其接受程度高，会将广告与自然结果一样看待，因此产生大量点击。很显然，对前一类用户，应该降低北区广告条数，这样在不显著减少收入的情况下可以换来更好的用户体验；而对后一类用户，应该在有符合条件的广告时，尽可能用足北区的位置。

[5.1.4 产品案例](#)

1. Google AdWords



AdWords 是 Google 推出的关键词竞价广告产品，每年为 Google 创造百亿级美元的营收。在产品的最初阶段，AdWords 是以搜索词为定向条件，按当时最流行的 CPM 方式售卖，可惜销售结果不理想。后来采用了 Overture 的 CPC 售卖方式，并创造性地在 CPC

的售卖方式中引入了点击率的概念，通过广告的点击率表达广告的相关性，取得了非常高的营收。

Overture 发明 CPC 售卖方式的时候广告的投放方式很简单，只是以广告主的出价排序，出价最高的广告赢得曝光的机会。Google 发现了此模式的缺陷：出价最高的广告赢得了很多曝光，但如果没人点击，平台还是没有收入。因此，Google 将策略改变为在投放过程中预估每条广告的点击率，然后按点击率和出价的乘积对广告排序，这也就形成了现在竞价广告普遍采用的根据 eCPM 决策的逻辑。

在引入点击率来表达相关性后，在 CPC 模式下形成了一个对广告主、用户、平台都有利的生态。在此生态下，广告主可以通过选择关键字来定向目标受众，并通过改善广告创意提高点击率的方式降低出价。Google 通过给用户投放点击率高和出价高的广告提高收益。因为给用户每次投放都是点击率高的“个性化”广告，所以用户在使用搜索引擎时看到了更多相关付费信息，降低了广告对用户的干扰。

相关性提高后，广告主就会以更低的出价赢取更多的点击，所以广告主就有动力通过更精准的关键词条件和更好的广告创意去提高广告的点击率。整个系统的营收也就相应增长了。2013 年，Google 财报中 Google Websites 的收益达到了 374 亿美元^[4]，而这主要来自于 Google AdWords 这一款搜索广告产品。

需要说明，为了简化概念，这里介绍的 AdWords 是其过去的产品范畴。目前，Google 已经将其展示广告网络、移动广告网络的需求方入口统一在 AdWords 产品下，目的是为广告主提供一个统一市场（universal marketplace），方便统一的效果跟踪优化，这实际上也是广告产品面向需求方接口的一个重要趋势。

2. 淘宝直通车



相比于 AdWords 这种通用搜索引擎的广告产品，淘宝直通车是 C2C 电子商务公司淘宝专门服务于卖家的广告产品。如图 5-6 所示，淘宝直通车广告主要出现在淘宝站内搜索结果页上。但是由于商品搜索的结果展示与通用搜索引擎有很大区别，相应的广告展示也有很大不同。在图 5-6 中，广告只出现在页面的东区和南区。

淘宝直通车的前身是雅虎直通车，卖家可以在雅虎搜索和雅虎网站上投放广告，2008 年改名为淘宝直通车。开始的广告排名规则非常简单，即出价高的广告主赢得投放机会。之后淘宝也完善了广告策略，开始采用与 AdWords 一样的 eCPM 排序方式。相比之前的广告排名规则，由于投放的广告相对来说点击率都比较高，使得卖家的转化率提升，而淘宝也因为宝贝整体的点击率提升获得更多的营收，形成共赢的局面。

与通用搜索引擎的广告主来自各行各业不同的是，淘宝直通车的广告主来自于淘宝平台上的卖家群体。淘宝与它的广告主之间基本是共生的关系，这使得淘宝对其广告主有更大的影响力，并在如下的几个方面有显著的优势。

(1) 广告主可以推广单品，并且直接复用商品的图片、描述等信息，而不需要针对广告渠道制作创意，这使得大量中小卖家使用直通车的额外成本很低。

(2) 站内搜索由于与用户购买意图强相关，因此广告的效果较好。



图 5-6 淘宝直通车广告示例

(3) 由于淘宝对其广告主全部转化流程的了解，使得淘宝直通车在利用后续数据优化广告系统，如转化预估、商品上下架同步等方面，都有着一般搜索广告难以达到的深入程度。

因此，虽然淘宝直通车仅仅是一个垂直搜索引擎的广告系统，生态体系却支撑了阿里巴巴这一中国最大互联网公司大部分的营收和利润，也是淘宝变现的主要途径之一。这个例子告诉我们，在一些高商业价值的垂直搜索引擎（如电商、房产、汽车、应用下载）之中，利用搜索广告的产品体系进行变现是需要最优先考虑的流量变现方式。

5.2 位置拍卖与机制设计

以搜索广告为代表的竞价广告实际上是像拍卖那样销售广告展示机会。也就是说，系统根据广告主的出价以及由此计算出的 eCPM 决定谁可以得到某次展示的广告位。在竞价广告初始阶段，出价是广告主阶段性调整的；而到了广告实时交易阶段，广告主可以对每次展示实时调整出价^[4]。但是从拍卖市场的宏观角度看，这两种竞价没有本质差别。

让我们先来看看怎样描述竞价广告问题，并从宏观市场的角度了解一些重要结论。如图 5-7 所示，假设有一组广告位可以被占用，将这些广告位按照其经验价值排名，分别记为 $s=1, 2, \dots, S$ （对横幅广告而言，这里的 S 一般为 1）。在某次广告请求中，有一组广告 $a=1, 2, \dots, A$ 出价参与拍卖，每个广告的出价记为 b_a ，系统将前 S 个高出价的广告依次放到前面排序好的 S 个广告位上，这样的问题称为位置拍卖（position auction）。根据前文的讨论，当某个广告 a 被放在 s 位置上时，其期望收益即 eCPM 为 $r_{as}=\mu_s v_a$ 。这里我们作了一些假设，比如，点击率 μ 仅与位置 s 有关，而点击价值 v 仅与广告 a 有关，这些假设在搜索广告给定某具体关键词的情形下可以说基本合理，对于展示广告的情形虽然非常近似，但并不太影响对竞价问题宏观市场的讨论。




图 5-7 位置拍卖问题示例

如何设计这样的位置拍卖问题中的一些重要机制往往对整个竞价市场的收益、稳定性、公平性等有着巨大的影响，这一类问题称为机制设计问题。在广告中常见的机制设计问题包括定价、市场保留价、价格挤压等。

5.2.1 定价问题

围绕位置拍卖最重要的机制设计是所谓的定价（Pricing）问题，它探讨的是在一次位置拍卖中给定各参与者的出价以及他们的期望收益，如何对最后获得某个位置的广告主收取合适的费用。

讨论定价问题乍听起来有些多余，有人会说按照广告主自己的出价收取不就可以了吗？为了解释研究此问题的动机，我们先来看看下面的例子：假设有某个单位位置（ $S=1$ ）的广告机会在竞拍，开始有两个广告主参与，甲出价 1 元，乙出价 2 元，当然乙赢得了此次竞价，如果按照其出价来收费，市场就向他收取 2 元的费用。在广告市场里，这一拍卖机会还会重复出现（对应于不断产生的展示），因此广告主可以也存在调整出价的机会，假设乙在发现自己 2 元钱能拿到流量以后，自然就会想到，是不是可以调低出价，用更低的成本拿到流量？乙将一直不断尝试，直到把出价调低到 1.01 元，发现继续调低就拿不到位置了。于是系统稳定在甲出价 1 元，乙出价 1.01 元。此时假设又有一个广告主丙加入竞争，并希望赢下此广告位，那么以此类推，他在不断调整后将会出价 1.02 元，市场的收入也就是 1.02 元。我们有可能通过调整定价策略来影响系统的总收益吗？答案是肯定的。比如我们在甲出 1 元，乙出 2 元参与竞价时，并不对获胜的乙收 2 元，而是收取其下一名即甲的出价 1 元，那么甲就没有动力调低其出价了。那么当丙加入时，就需要出价 2 元以上才可以赢得竞价，市场的收入也就变成了 2 元（不论丙出价多少，我们都按其下一位即乙的出价来收费）。这个简单的例子告诉我们，在广告这样的参与者可以针对同一个标的物不断调整出价的拍卖环境中，通过聪明的定价策略完全可能为整个市场创造更高的收益和更好的市场稳定性。

在定价问题上，我们在微观上的直觉未必可以推广到宏观市场。从整个市场的角度来看，我们重点需要研究的是市场处于稳定状态下的收益和其他特性。而所谓稳定，指的是整个竞价系统处于纳什均衡（Nash equilibrium）状态，也即每个广告主都通过出价得到了最符合自己利益的位置。对某一次位置竞价来说，其对称纳什均衡（symmetric Nash equilibrium）状态可以表示为下式：

$$\begin{aligned}\mu_s(\nu_s - q_s) &\geq \mu_t(\nu_s - q_t), \forall t > s \\ \mu_s(\nu_s - q_s) &\geq \mu_t(\nu_s - q_{t-1}), \forall t < s\end{aligned}\tag{5.1}$$

注意这里的下标意义有所调整，这里的 v_s 指的是排在 s 位置上的广告的点击价值，并非 s 位置带来的点击价值，而 q_s 指的是市场向排在 s 位置上的广告收取的费用，即定价，也就是广告主的单次投入。这一均衡状态的意义很容易理解：对于最终位置排名竞价结果中的每一条广告，其收益都比排在其他位置上要高。显然，在这样的状态下，每个广告主都达到了自己最优的状态，整个系统也就随之稳定下来。

在公式 5.1 中，市场方能够调整的策略只有 q_s 的确定方式，也就是定价策略。随着定价策略的不同，市场达到稳定状态时的宏观收益情况和稳定的程度都有所不同。因此，有关竞价市场宏观性质的研究主要目的是寻找更好的定价策略以优化整体收益。由于位置竞价问题纳什均衡状态的数学分析与本书的产品和技术重点有一定差距，因此不再介绍这方面的内容，有兴趣的读者可以阅读参考文献[72]。

在线广告竞价市场最常见的定价策略是 GSP 方案；另外有一种 VCG（Vickrey-Clarke-Groves）定价策略，虽然理论上比 GSP 更合理，但是由于原理较复杂，向广告主解释起来有难度，因此在实际系统中采用的并不多。下面我们分别介绍这两种定价策略。

1. 广义第二高价（GSP）

先来看看什么叫第二高价（second price）^[74]。所谓第二高价，指的是在只有一个位置的拍卖中，向赢得该位置的广告主收取其下一位广告主的出价，这样的拍卖也叫作 Vickrey 拍卖。在搜索广告这种有多个位置的拍卖过程中，很容易直觉地将第二高价策略推广成下面的策略：对赢得每一个位置的广告主，都按照他下一位的广告位置出价来收取费用，这就是广义第二高价^[30]。

第二高价和广义第二高价的直觉合理性在上面已经有所解释。但是实际上，第二高价是单位位置拍卖时的最优定价策略，然而广义第二高价却不是多位置拍卖时的最优定价策略（最优策略是下面要介绍的 VCG 定价）。虽然并非理论上最优，广义第二高价却有着实现简单、容易向广告主解释等诸多操作中的优点，因此在实际的竞价广告系统中是最主流的定价策略。

如果是按照 CPM 结算，那么广义第二高价可以非常直接地应用。然而在 CPC 结算的竞价广告系统中，广告主的出价是针对点击的，而竞价是针对 eCPM 的，因此要对两者换算一下以实现 CPC 情形下的广义第二高价^[30]，其定价公式如下：

$$q_s = \mu_{s+1} b_{s+1} / \mu_s + \Delta \quad (5.2)$$

如果将等式两边同时乘以 μ_s ，可以看出广义第二高价实际上仍然是 eCPM 上的第二高价。

读者可以自行验证，不论是 CPM 还是 CPC 结算，在广义第二高价的情形下，对某广告主的定价是一定不会大于其出价的。实际上，这种定价策略也同样适用于 CPS 结算的竞价市场，并且只需要将公式 5.2 中的 μ 换成 μ_v 即可。公式 5.2 最后的 Δ ，一般为广告系统结算货币的最小单位，如 1 美分，这是一种历史惯例，也在某种程度上让广告主心理上感觉更加公平。

2.VCG

VCG 定价^[74, 24, 37] 是 Vickrey、Clarke 和 Groves 在研究竞价系统均衡状态时得到的一种理论上较为优越的定价策略。其基本思想是：对于赢得了某个位置的广告主，其所付出的成本应该等于他占据这个位置给其他市场参与者带来的价值损害。在这一原则下，VCG 的定价策略可以表示为公式 5.3。

$$q_s = \sum_{t>s} (\mu_{t-1} - \mu_t) \nu_t \quad (5.3)$$

这种定价策略直觉上的合理性很容易理解。理论分析表明，VCG 定价策略的优越性体现在如下几个方面：首先，在这种定价策略的稳定状态下，整个市场是 truth-telling 的。所谓 truth-telling，可以理解为每个广告主都找到了自己的最优状态。其次，相对于其他的定价策略，这种定价向广告主收取的费用是最少的。在单广告位拍卖的情形下，VCG 定价策略就退化为第二高价策略。

虽然有以上诸多的优点，VCG 定价在竞价广告中却并不是一种主流的方式。这主要是由于这种定价方式的逻辑过于复杂，比较难以向广告主解释清楚；另外在广告主和媒体存在博弈关系的情形下，媒体是否正确地计算了“给其他市场参与者带来的价值损害”也很难验证。不过这种定价方法也有其市场空间，有些广告厂商，如 Facebook，在实际的竞价广告系统中就采用了这一定价机制。

5.2.2 市场保留价

为了控制广告的质量和保持一定的出售单价，竞价广告市场往往要设置一个赢得拍卖位置的最低价格，这一价格我们称为市场保留价（Market Reserve Price, MRP），俗称“起价”或“底价”。广告主的出价只有在高于市场保留价时才能获得竞价机会，同时在赢得某个拍卖位置后，如果根据定价策略算出的付费低于市场保留价（以广义第二高价为例，很容易验证这种情况是可能发生的），也需要调整到市场保留价的水平上。

确定 MRP 是竞价广告重要的产品策略，MRP 定得过低或过高都不利于整个市场的收益最大化。一般来说，当竞争较充分、广告主深度足够时，MRP 可以设置得比较高；反之则应适当降低。市场保留价的设置有两种方法，一是对整个竞价市场采用同样的保留价格，

二是根据不同标的物（如搜索广告里的关键词）的特性设置不同的保留价格。如果按照后一种方法设置，显然应该对那些竞争程度较激烈的关键词设置比较高的 MRP。

在搜索广告的实践中还有一点：北区和东区的广告虽然共享一个竞价队列，但为了保证北区黄金位置得到较好的变现，我们往往会对北区单独设一个较高的 MRP。

关于如何计算最优的市场保留价也有一些理论研究和实践方法。简单来说，一个特定关键词的最优起价仅与竞价和质量度的分布有关，通过拟合其被保留价截断的分布为核心，可以通过理论上的计算公式来解出最优起价。自付费搜索的商业模式成型以来，搜索引擎便在不断尝试调整关键词竞拍的起价，在市场可以接受的前提下提升自身的收益水平。在 2001 年，Yahoo! 将其起价统一设置为 5 美分，2008 年，Yahoo! 结合理论的推导结果，对部分雅虎搜索关键词进行动态调价，不同价值的关键词被调整为不同的起价。此次调价后，根据持续观测，起价提升在 2008 年第三季度对收入的影响为+13%。而 Google 并没有公开自己的起价计算方法与过程，但是一般认为其起价的制定策略是业界较为先进的，早在 Yahoo! 实行动态起价之前，研究人员即发现 Google 的起价也是动态的。

无论是调整市场整体的 MRP，还是在不同流量划分上动态设置 MRP，其基本原理都是根据竞价广告主的 eCPM 分布，找到一个使得填充率没有明显下降的 CPM 底价，然后再根据质量度倒算其 CPC 底价。实际上，由于考虑质量度，动态底价可以同时与 (a, u, c) 这三个参数都有关系，做到完全的动态。有关动态市场保留价的原理和具体算法可以进一步参考参考文献[64]。

5.2.3 价格挤压

在 CPC 结算的广告产品中，eCPM 可以表示成点击率和出价的乘积，即 $r = \mu \cdot v = \mu \cdot \text{bid}_{\text{CPC}}$ 。但是在竞价的机制设计中，有时会对此公式做一些微调，把它变成下面的形式：

$$r = \mu^{\kappa} \cdot \text{bid}_{\text{CPC}} \quad (5.4)$$

其中的 κ 为一个大于 0 的实数。可以考虑两种极端情况来理解 κ 的作用：当 $\kappa \rightarrow \infty$ 时，相当于只根据点击率来排序而不考虑出价的作用；反之，当 $\kappa \rightarrow 0$ 时，则相当于只根据出价来排序。因此，随着 κ 的增大，相当于我们在挤压出价在整个竞价体系中的作用，因此我们把这个因子叫做价格挤压（squashing）因子。

价格挤压因子的作用主要是能够根据市场情况更主动地影响竞价体系向着需要的方向发展。比如说，如果发现市场上存在大量的出价较高但品质不高的广告主，则可以通过调高 κ 来强调质量和用户反馈的影响；如果发现市场的竞价激烈程度不够，则可以通过降低 κ 来鼓励竞争，如果存在短期的财务压力，这样就可以短期使得整体营收有所上升；如果为了鼓励广告主提高广告质量和相关性，则可以通过提高 κ 来降低出价的影响。

5.2.4 定价结果示例

我们用一个具体的例子来直观地说明上述的综合竞价和定价过程：假设有一组广告竞争一个有多个位置的搜索广告展示机会，其出价和系统对其对其点击率^[4]的预估如表 5-2 中的第 2 列和第 3 列所示，那么计算出的 eCPM 以及在按照 GSP 定价策略并取不同 κ 值时向每个广告主收取的费用如表 5-2 的后面几列所示^[4]。从表 5-2 的例子中可以看出，经过 GSP 的 CPC 定价并不是降序的，并且存在低于 MRP（如第 3 位的广告）的情形，这时需要将其强制设为 MRP；另外， κ 会对排序和计价都有明显的影响。

表 5-2 GSP 广告竞价过程示例（单位：元 MRP=0.25）

出价	点击率 (%)	排序/定价 ($\kappa = 1.0$)	排序/定价 ($\kappa = 2.5$)	排序/定价 ($\kappa = 0.5$)
0.80	1.6	1/0.50	1/0.25	2/0.25
2.00	0.4	2/0.75	3/0.70	1/1.60
0.30	1.0	3/0.25	2/0.25	3/0.28
0.40	0.5	4/0.25	4/0.25	4/0.25

希望进一步了解具体实现过程的读者，可以参考 13.1 节中的示例代码。至于按 VCG 定价策略向每个广告主收取的费用，读者可以自行探讨。

5.3 广告网络

竞价广告产品在搜索广告逐渐成熟的同时也在展示广告领域得到了广泛应用。对展示广告而言，合约式的售卖方式必然无法消耗所有的库存，实际销售中为了控制售卖比例以获得更高的品牌溢价空间，未通过合约售卖的广告流量很多。这部分流量我们称为剩余流量（remnant inventory）。竞价交易模式的产生为这部分流量提供了变现的机会，催生了广告网络这一产品。广告网络的产品功能是批量聚合各媒体的剩余流量，按照人群或上下文标签的流量切割方式售卖给广告主。

对于一些中小网站而言，甚至完全没有按合约售卖的流量，而是将所有的广告位都交给广告网络来变现，图 5-8 中给出了一个网页上所有广告网络位置的示例，其中所有用线框标出的部分都是交由广告网络来变现的。



图 5-8 广告网络广告示例

5.3.1 广告网络产品形态

一般来说，广告网络中的投放决策过程对媒体而言类似于一个黑盒子：只需要在广告位的剩余流量上调用广告网络的投放代码或 SDK，而不用关心每次展示的投放结果。在实际运营中，广告网络既有竞价的售卖方式，也有合约的售卖方式。不过我们这里重点讨论的是其竞价部分。

竞价广告网络的产品逻辑如图 5-9 所示。这里的产品关键，一是售卖的标的主要是人群，而广告位被淡化了。（根据上一章的讨论知道，合约广告是很难淡化广告位标的的。）另外，当流量满足多个广告活动要求时，简单地采用竞价模式而不用考虑量的合约。




图 5-9 广告网络广告示例

根据人群划分模式的不同，广告网络产品其实有两个来源：一方面来源于搜索引擎发展出来的上下文广告产品，即根据页面中提取的关键词来投放广告；另一方面来源于展示

广告的兴趣标签向精细化发展后。无论上下文还是兴趣，都可以看成是对受众的划分方式，因而它们都统一在广告网络这一产品中。

竞价广告网络有下面几个关键的产品特点。

(1) 竞价方式不向广告主做量的约定，而是根据变现能力，即 **eCPM**，来决定每次展示分配给哪个广告主。因此，与合约式的广告系统不同，广告网络大大降低了为保证合约而设计复杂的在线分配算法的必要性，使得其中的计算技术可以把精力集中在对 **eCPM** 的估计上。

(2) 由于是按人群售卖，广告网络会极力淡化媒体和广告位的概念。由于淡化了媒体的概念，广告网络中很难拿到品牌溢价高的广告位，一般来说也不适合广告主的品牌类需求。

(3) 从商业角度来看，广告网络的销售模式与合约的方式相比也有两点优势：首先是无需再满足广告主品牌独占的要求，这使得让国美和苏宁同时参与同一个人群的竞价、提高市场流动性成为可能，而在合约广告中，这一点是很难做到的；其次，由于广告网络根据实际消耗来结算，一般来说财务上采用广告主先充值的方式，这区别于合约广告投放结束后计算的方式，结果使得广告网络运营方的现金流状况大为改善。

广告网络存在 **CPM**、**CPC** 和 **CPS** 等不同的结算方式，不过最主流的方式是 **CPC**。我们有必要从计算的角度分析一下 **CPC** 结算的合理性：首先，从需求方来看，既然是各种媒体的不同广告位聚合在一起售卖，广告主无法知道每个媒体上广告的具体位置。而位置对于广告的曝光效果影响巨大，因此实际上广告主根本无法评估每次展示的出价，而在点击上出价，这个问题就没那么严重了。另外从供给方来看，由于淡化了广告位的概念，并且聚合了多个媒体的流量，广告网络可以接触到同一个用户比较丰富的网络行为，并且知道每次展示所在的媒体与广告位位置，所以比广告主更容易估计点击率。根据第 1 章中的讨论，由广告网络负责估计点击率，需求方根据对点击价值的估计来出价，是最合理的市场分工。

但是，对于一些有特殊业务需求或者特殊数据来源的媒体或媒体组合来说，有时候希望能够直接从广告网络的广告库中挑选广告，并能够创造比广告网络自动挑选更多的价值。因此，某些广告网络也会对一部分合作供给方开放广告库供其自行挑选，广告网络的这种运营模式可以称为联盟（**affiliate**）模式。

5.3.2 广告网络产品策略

广告网络中的广告决策过程与搜索广告相比，整个流程要简单一些，如图 5-10 所示，分为检索、排序、定价等几个阶段。虽然流程相对简单，但是广告网络在广告检索和排序两个环节上面临的问题比搜索更加通用，因此在产品策略方面也存在着不小的挑战。




图 5-10 竞价广告网络广告决策过程示意

1.广告检索

广告与搜索面对的文档其实不同，它往往是一个用布尔表达式表达的投放条件，而不是可以简单看成一个词的集合。搜索那样的面向词集合的检索方案对布尔表达式来说不是最有效的。在搜索广告条件下，这一问题并不突出，但是在展示广告网络中，这样的差别就值得重视了。

搜索广告检索与搜索基本一致，用常规的倒排索引技术就可以解决。展示广告网络与搜索广告不同，由于用户意图不明确，我们往往要将更多的关键字、兴趣标签同时用于检索过程，而实践也证明，使用更多的标签对于提高效果是有直接帮助的。将很多的标签同时用于一次检索也与搜索中的短查询情形差别很大，这可以描述为一个相关性检索问题，需要探索专门的方法。

以上两个问题主要都与具体的算法有关，我们在介绍广告技术时再详细讨论。

2.广告排序

我们都知道，竞价广告中排序的准则是 eCPM，而在 CPC 结算的情形下，对 eCPM 的估计转化为对点击率的估计问题。应该说，在搜索广告和展示广告网络这样的竞价广告产品中，点击率预测的问题才开始面临真正的挑战。

与广告位较规整、点击率较高的搜索广告相比，广告网络中的 CTR 预测有两方面的困难。首先，点击数据更加稀疏，而且需要同时考虑上下文和用户量方面的信息，这使得各种新广告、新策略的冷启动问题非常突出。如何设计好一个合理可行的冷启动策略，对展示广告网络来说至关重要。其次，广告网络中由于广告位的差别巨大，点击率的变动范围很大，这使得稳健地估计点击率变得相对困难。我们在后面讨论点击率预估技术时将主要以展示广告的复杂情形为场景展开讨论，并将其与搜索广告的特例对比。

5.3.3 产品案例

实际的广告网络有两种不同的业务方向，一种是广泛承接各种广告库存并面向所有品类的广告主进行服务，称为水平广告网络；另一种则专门服务于某一种类型的广告主，如电商、游戏等，并寻找相关的媒体资源来搭建网络，称为垂直广告网络。下面分别举例介绍这两种类型的广告网络。

1.Google Display Network

Google Display Network

AdSense 是 Google 进入展示广告领域的第一个广告产品，与 AdWords 只有通过采用关键词来定向人群不同，AdSense 定向人群的方式更加多样化，可以通过一系列关键词或主题来确定相关的网页，或者通过人群兴趣、性别等人群、历史访问信息等属性来定向人群，也可以通过这些定向条件的组合精确地选择想到达的网页和人群。相比 AdWords，广告主可以有机会接触更多的网页和流量。

除了定向人群方面的不同，在广告竞价环节，AdSense 和 AdWords 的流程基本一致，也是根据 eCPM 对广告排序。从 AdSense 的定向环节和竞价环节的不同和相似我们可以发现，相比 AdWords 的生态圈中只有 Google、广告主以及用户而言，AdSense 多了网站（媒体）这一参与方。在 AdSense 的生态圈中，媒体方会通过调整广告位置和格式、给页面补充合适的关键字以吸引更多同类广告等方式提高点击率。广告主方则会通过选择合适的定向条件和出价提高点击率。在这种机制下，用户会看到更多相关广告，而平台方也会有比较好的收益。

在 AdSense 之后，Google 又于 2008 年收购了展示广告领域的巨头 DoubleClick。在整合旗下 Utunbe、Google Finance 以及 AdSense 等一些广告资源基础上，推出了 GDN(Google Display Network) 这一展示广告领域最重要的产品之一。由原来 AdSense 这种为搜索广告的衍生产品存在的地位，进化到独立的 GDN，表现出 Google 对展示广告领域的重视和独立发展的决心。GDN 的下游包括 DoubleClick Adx 和一些 TD，平台会将它竞价比较低的流量导给 DoubleClick Adx 进行实时竞价，使得一些长尾流量可能会以比较高的价格卖出，而 TD 则会从多个 ADX 中买流量并优化 ROI。目前，GDN 是世界上最大的展示广告网络，可以到达 90% 的互联网用户和超过 200 万的网站。

在 Google 2013 年的财报中，Google Network Members' Websites 的收益达到了 131 亿美元。

2. 淘宝客



淘宝客是阿里巴巴集团旗下的广告产品之一，它通过淘宝联盟获得广告，利用淘宝和天猫网以外的网站为阿里巴巴平台上的卖家带来流量和转化，并且根据转化的比例给网站一定的佣金。加入淘宝客网络的媒体主要是为淘宝等商家带来流量，因此阿里妈妈把它们称为“淘宝客”。淘宝客的投放方式是淘宝客网站通过 API 拿到相关的广告，并自行决定在某个页面或对某种用户展示什么样的商品，这是一种联盟的方式。

直觉上，由于淘宝掌握的用户数据和运算能力远远超过一个个孤立的淘宝客网站，让淘宝负责广告决策，应该可以达到更好的 eCPM，不过由于一些购物导航或购物分享类型的个人博客或网站可以利用软文的形式非常有针对性和全面地介绍和宣传某种产品，其效果远远高于普通的在线广告。因此，这种将广告库开放并由淘宝客网站自行选择广告的方式，其变现能力在充分优化后也相当可观。不过由于后一种方式无法规模化，并且通常只在转化流程相当完善的情形下才有意义，因此并不见得适用于一般的广告网络，但在电商垂直广告网络中是不错的方式。

由于广告库开放，淘宝客的供给方操作方式很多样：既有返利网站、独立博客等媒体，也有以论坛、微博、邮件、QQ 群等作为推广方式的个人，还有的通过自己开通淘宝客来输入购买商品链接以赚取佣金，目的在于获得一定的折扣。

2012 年 12 月 21 日，阿里巴巴宣布重启“阿里妈妈”品牌，放弃“淘宝联盟”。

5.4 竞价广告需求方产品

搜索广告和竞价广告网络虽然效果差别很大，但从产品本质上看，属于同一范畴。竞价广告市场的产生对需求方的技术也提出了新的要求：原来通过直接与媒体签订保量合约的采买方式变成通过竞价为广告主完成量与质需求的采买产品。具体地说，这样的产品需要具备一项基本功能，即按照广告主预算跨媒体一站式采买人群的功能。另外，还可以具备一项高级功能，即机器决策的 ROI 优化功能。

这样的需求可以分解为两个基本问题：一是如何挑选合适的目标人群，二是如何对各个目标人群给出合适的出价。由于竞价广告平台的决策过程对于需求方来说是个黑盒子，要解决好这两个问题其实并不容易。

5.4.1 搜索引擎营销

搜索广告对应的需求方产品，即通过竞价采买搜索引擎关键词来做推广，这就是搜索引擎营销，即 SEM。上面说的两个基本问题在 SEM 中具体表现为关键词选择和出价。对 SEM 来说，各个标签即关键词的流量是互相不重叠的，这与展示广告受众定向标签之间可以进行复杂的布尔运算不同，实际上比人群标签优化要直接一些。

关键词选择和出价两个问题都有相当的难度。首先来看关键词选择，如果广告主提供一些种子词，那么这个问题看起来非常类似于 5.1.3 节中的查询扩展问题，但又有相当大的区别：搜索引擎进行查询扩展的目的是为了提高自己的营收；而需求方进行关键词选择的目的是为了提高自己的广告主采买流量的 ROI。这两个目标显然有着很大的区别，因此广告主

更信赖代表需求方利益的 SEM 公司。不过 SEM 公司由于数据来源的问题，需要长期的数据积累才能做到较好的效果。同时，对于大量长尾的小型广告主，往往比较难于积累起足够的数据用于优化，因此这类 SEM 公司服务的对象主要是中型以上的广告主。

出价的问题，传统的认识是广告主根据到达率、自己网站的转化率和客单价来估计点击价值，并以此点击价值为参考来出价。不过这忽略了一个问题，那就是各个关键词的转化率、客单价和市场竞争水平都有很大的区别，因此只有在不同关键词上做不同的出价才能更深入地优化整体采买的 ROI。由于搜索广告的定向粒度很细，可以看出关键词选择和出价都是规模很大的优化问题，而且由于广告网络半封闭的竞价机制，数据的反馈和调整都不够及时，因此这一优化问题技术挑战是比较大的。

5.4.2 媒体购买平台

面向展示广告网络的一站式采买平台称为媒介采买平台，与之类似的概念还有交易终端（Trading Desk, TD），可以认为是同一类的产品。

从市场发展来看，许多媒体采买平台都是 4A 或其他代理公司为了适应市场技术形态的变化，收购或者孵化出来的子公司，这从图 1-9 中两部分产品之间的连线就可以看出来。在竞价广告市场上，广告主量的需求仍然是存在的，因此保量的合约并不是消失了，而是由代理与媒体之间下沉到了广告主与媒体采买平台之间。

虽然概念类似，但是媒体采买平台的难点与 SEM 有所不同。媒体采买平台的技术挑战主要在于 ROI 的优化部分，要合理地选择需要的受众定向条件，并在每个人群上优化出价，以保证量的要求和优化收益是一个复杂的组合优化问题。由于无法具体控制每一次展示，其困难程度要高于后面实时竞价的情况下的效果优化。这种面向广告网络中非 RTB 流量的 ROI 优化也成为广告技术产品的一个重要方向。

5.4.3 产品案例

对于非实时的竞价广告产品，需求方的优化比较困难，因此主要在投资回报比较高的 SEM 中得到了充分发展。我们举一个 SEM 产品的例子供大家参考。

EfficientFrontier



EF（EfficientFrontier）开始是一家专门从事 SEM 优化的广告技术公司，后来也涉足展示广告网络的优化领域。2011 年，EF 被 Adobe 旗下的 Omniture 以 4 亿美元的价格所收购，其产品成为 Adobe Digital Market Suite 中的一部分，称为 Adobe AdLens。收购时，

EF 每年管理着 6 亿美元以上的搜索引擎广告预算以及超过 4000 万的搜索关键词，平均每日为每个客户投放 40000 个以上的竞价。

从 EF 这家公司的名称就可以大致了解到其技术方向，他们的业务是通过关键词选择和出价为搜索广告主提供大量关键词情形下的 ROI 优化。EF 采用是金融领域的投资组合（portfolio selection）理论^[55]方法来解决这两个问题，而 **efficient frontier** 也是这一金融领域中的术语。这一问题是通过计算的方法确定一个投资组合中各个品种的投资比例，以达到期望收益最优情况下风险最小的理论。在各个投资期望收益水平下，相应的最小组合风险对应的曲线就称为 **efficient frontier**。




图 5-11 SEM 中的 **efficient frontier** 示意

如果将搜索广告里的标的物，即关键词，类比于股票，那么在一定预算的限制下分配各个关键词上的投入以求达到整体 ROI 的最优，从框架上看非常类似于上述的投资组合问题。因此，EF 公司按照这一思路，将量化金融里的投资组合理论与计算广告技术结合起来，创造性地发展出了大规模的关键词出价优化技术。图 5-11 中给出了 **efficient frontier** 的一个示例，图中每个点代表一个广告投放设置，即关键词组合及其出价，而每一个组合也就对应了一个收入和成本。将各成本对应的最高收入的投放设置连接起来，就构成了 **efficient frontier** 曲线。找到这条 **efficient frontier** 曲线后，给定广告主的预算，就可以找到最佳的投放策略。在可选的关键词数量很大时，投放设置的集合规模非常大，再加上搜索引擎非实时的数据反馈，可以想见此优化问题的困难程度。

广告主优化广告投放收益的问题其实比优化股票收益还要复杂。因为广告主的收益就是 ROI，而无论是估计点击率还是估计点击价值，都严重依赖于数据。因此，这方面数据的积累实际上才是 EF 最核心的竞争力。为了获得更多的数据来强化其竞争力，它被 Adobe 旗下的 Omniture 收购了也符合逻辑，因为 Omniture 是专门提供网站分析工具的公司，积累了大量的网站行为数据，这对于优化 ROI 来说非常有价值。

除了 SEM，Adobe AdLens 也开展了 Facebook 等展示广告优化业务，因为其技术对于展示广告、搜索广告来说具有通用性——从广告网络的产品角度看，二者的本质是相通的。

5.5 竞价广告与合约广告的比较

在了解了竞价、合约这两类主要的广告交易方式后，我们来简要对比一下它们的优缺点。

从供给方或广告市场方来看，合约广告和竞价广告的对比可以类比于计划经济和市场经济的区别。在合约广告的情况下，所有量的保证和质的优化都是由媒体方的广告投放机来统一完成，而在竞价广告的情况下，市场只负责制定竞价和收费的规则，而各广告主量的保证完全采用市场竞争的方式来完成。在这种情况下，市场方需要仔细设计宏观竞争机制，但是不一定需要实现像合约广告那样的交易级别的计划调度。

从需求端来看，合约广告的采买方式对广告主来说缺乏透明性，唯一能做的就是在合约的层面预先约定好一些最关心的利益条款，但是很难进行深入的优化。不过，合约的采买方式也有一定的好处，特别是对量的保证可以有预先的约定，这对于品牌性质较强的广告活动来说比较有意义的。

在竞价广告中，供给方和广告主的约定比较松散：首先，供给方不再向广告主承诺广告投放量；与此相对应，点击单价由广告主自行决定。这样的交易逻辑使得广告合同由首先确保量的结构变成了首先确保单位成本的结构。这实际上是非常革命性的变化，它使得广告市场产生了以下三个有利于大幅提高广告效果的发展趋势。

（1）非常精细的受众定向可以被无障碍地使用在交易中，而这是展示量合约广告很难做到的。由于这一点，市场的效率得到了巨大提升。

（2）大量的中小广告主逐渐成为参与竞价的主体，这使得市场的规模得到了快速扩张。

（3）与合约广告相比，竞价广告中数据的价值得以彰显，整个市场开始以数据为核心来组织和运营广告产品。

5.6 延伸思考

1. 搜索广告南区的产品策略在不同搜索引擎中差别很大，请从用户产品的角度出发，谈谈你认为合理的策略。

2.在网址导航类产品的销售中，往往采取按月线下竞价然后签订广告位合约的模式，这属于合约广告还是竞价广告？

3.广告网络的运营的关键是提高市场的流动性，即广告主参与竞价的积极性。为了提高市场流动性，投放功能、受众定向等环节有哪些产品思路？

第 6 章 程序化交易广告

在线广告发展到竞价阶段，可以说基本的计算格局已经建立，大多数重要的产品和技术问题也都浮出水面并得到研究。然而，随着需求方优化效果的要求进一步加强，广告网络在产品形态上已经无法完全满足需要，而市场的发展方向是向需求方彻底开放。具体而言，除了允许广告主按照已经定义好的用户划分来购买，还要进一步提供广告主自行选择流量和在每次展示上独立出价的功能。这样的功能，必然要求询价、出价和竞价在展示时进行，这也就产生了以实时竞价即 RTB 为核心的程序化交易市场。程序化交易产品在整体产品演进过程中的位置如图 6-1 所示。




图 6-1 程序化交易广告产品

RTB 的产生，使得广告市场向着透明的比价平台的方向发展，这样的平台就是广告交易平台，即 ADX，其主要特征即是用 RTB 的方式实时得到广告候选，并按照其出价简单完成投放决策。与广告交易平台对应的采买方，我们称为需求方平台即 DSP。在这样的交易市场中，需求方对于流量的选择和控制能力达到了极致，因此其技术和算法的挑战也相当大，而供给方则变成了简单的比较平台。

从需求方来看，定制化的用户划分能力使得广告主可以像优化自己的推荐系统那样优化广告购买，唯一的区别是这个推荐系统是放在站外的。出价需求的存在和广告主预算范围内的套利要求 DSP 具备点击率预测、点击价值估计、流量预测、站外推荐等多方面的运算能力。除了站外推荐，广告市场新的发展趋势是根据广告主提供的种子用户，利用海量的媒体数据为广告主找到行为相似的潜在用户。这样的一些定向方式都是针对 (a, u) 组合的定制化用户划分，它们使得在线广告的受众定向精准程度达到了前所未有的水平。

在需求方的利益得到了充分的保证以后，媒体的变现手段也发生了相应的变化。到现在为止，媒体至少有四种常用的广告变现选择：担保式投送的合约售卖方式、自营广告网

络、托管给其他广告网络、通过 RTB 变现。如何动态地选择这四种模式中变现价值最高的那种，以最大化媒体收益，这是供给方面临的市场需求。在这样的需求驱动下，产生了供给方平台这样的完全优化媒体利益的产品。

除了看得见的交易模式的改变以外，RTB 的产生和发展实际上还催生了另外一个更加重要的市场：数据加工和交易市场。开放的交易模式使得广告主可以自由地使用各种数据指导投放，而 RTB 过程又为附带的数据传送提供了天然的基础设施。因此，在程序化交易时代，数据加工和交易规模化地发展了起来。作为数据加工与交易的两个关键产品：数据交易平台（data exchange）和数据管理平台 DMP 分别从第三方数据和第一方数据入手，为市场提供了有价值的数据源或数据加工服务。了解在广告中的数据交易逻辑，对于各行业大数据变现的落地都有十分重要的指导意义。

在线广告市场进入到这个阶段以后，程序化交易的方式已经成为举足轻重的力量，它使得整个在线广告市场越来越向着数据驱动、计算导向的方式前进。我们在本章中也对程序化交易的若干种主要方式以及对应的供应方和需求方产品做了一下小结，并与合约导向的优先销售方式进行了对比。

6.1 实时竞价

我们先来直观地解释一下为什么广告交易会向实时竞价的方向发展。竞价广告网络中的受众定向虽然可以很精准，但是还是会有一些完成不了的场景。例如，某广告主希望对自己的流失用户进行一次广告促销，或某广告主希望广告平台帮助找到与其用户类似的潜在用户。很显然，无论怎样选择在广告网络中的人群标签，都不可能直接完成上述的任务。实际上，这两个任务有一个共同的特点，即我们在加工人群标签的过程中需要利用到广告主的数据。这样的标签称为定制化用户标签（customized audience segmentation）。

利用定制化标签的投放在广告网络中并非完全无法解决：对于最常见的重定向标签，采用由广告网络在广告主网站布设代码的方式也可以收集人群和投放广告；而对于一般的定制化标签，也可以采用由广告主上传用户 ID（cookie 或移动设备 ID）集合的方案，由广告网络来决策和投放，如 Facebook 的广告网络就提供这样的功能。不过，这样的方案仍然存在着很多问题。

（1）定制化标签可能的选择是与广告主的量级成正比的，将这些标签集中地由广告平台加工使用，显然是一个低效的解决方案。

（2）除了定制化的人群库，需求方往往还对频次、时间、地域等诸多因素有综合决策的需求，而简单地上传用户 ID 集合显然无法达到这样的目的。

（3）简单的人群库交互无法做到精细的出价和预算控制。

因此，采用广告网络这样的封闭式竞价方案是无法规模化和精细化地针对定制化标签进行投放的。什么样的解决方案才能够规模化呢？其实很简单，只要把竞价过程开放，在广告展示时由需求方来判断是否需要并出价，就可以解决上面的问题，这样的思路就产生了实时竞价。因此，我们认为：

用定制化标签指导广告投放是实时竞价的关键产品目标。

实时竞价的交易方式不仅仅解放了相关的效果类广告需求，也为品牌广告创造了全新的机会。我们知道，品牌广告的核心在于其人群触及策略，但无论在展示量合约广告还是竞价广告网络中，人群的定义方式都是由广告平台决定，需求方基本没有加工的自由。然而，在实时竞价交易中，服务于品牌广告主的 DSP 可以根据市场上采买的各种数据为某个特定的广告主加工特有的人群，完成更加符合其市场策略的人群触及。因此，我们会发现，品牌广告的预算基本上没有进入竞价广告网络，但是现在却有向实时竞价转移的倾向。表 6-1 中给出了美国整体 RTB 市场的规模和增长数据^[4]，从该数据可以看出，RTB 已经成为展示广告市场非常重要的一部分，并且仍在高速成长中。

表 6-1 美国 RTB 市场增长情况

年度	2010	2011	2012	2013	2014e	2015e	2017e
交易额（百万美元）	986	1948	3363	4561	5967	7420	8493
比上年增加	149%	98%	73%	36%	31%	28%	14%
占展示广告比例	8%	13%	19%	22%	25%	28%	29%

实时竞价流程

实时竞价的接口可以分成两个过程，即预先进行的将 ADX 与 DSP 的用户标识对应起来的 cookie 映射（cookie mapping）过程和线上广告请求时的竞价和投放过程，如图 6-2 所示。下面我们分别介绍这两个过程。




图 6-2 实时竞价（RTB）过程示意

（1）cookie 映射。当供给和需求双方都可以得到同样的用户标识时，实时竞价并不是总需要此映射过程。但是，当双方能够得到的用户表示不同，特别是在 Web 环境下根据 cookie 投放广告时，需要一个预先的映射过程。cookie 映射一般是由 DSP 在广告主网站上

发起，这样做的原因是，一般情况下 DSP 负责的是加工广告主定制受众标签，因而不需要对所有用户都建立对应关系。这一过程又可以细分为以下两个步骤。

步骤 1.1：从广告主网站向 DSP 服务器发起 cookie 映射请求。

步骤 1.2：DSP 与 ADX 服务器之间通信完成 cookie 映射。由于 cookie 映射这项专门技术的应用范围不仅仅限于 RTB，我们将在第 14 章介绍实时竞价技术时对其进行更具体的讨论。

(2) 广告请求 (ad call)。以 Web 投放环境为例，RTB 的广告请求可以分为以下三个步骤。

步骤 2.1：用户浏览媒体网站。

步骤 2.2：媒体网站通过 JavaScript 或 SDK 向 ADX 发起广告请求。

步骤 2.3：ADX 向各 DSP 传送 URL 和本域名 cookie，发起询价请求。DSP 根据预先做好的 cookie 映射查出对应的己方 cookie，决策是否参与竞价，如果参与，则返回自己的出价。在等待一个固定的时间片后，ADX 选出出价最高的 DSP 返回给媒体网站。

步骤 2.4：媒体网站从胜出的 DSP 拿到广告创意并展示。

其中步骤 2.2 和步骤 2.3 可以合并为一步，即 DSP 同时返回出价和广告创意地址，由 ADX 返回给媒体。这样做的好处是减少了一次服务器往返，用户看到的广告延迟也会减少。缺点是 ADX 可以获得 DSP 某个广告商的相关受众，因而存在信息泄露风险，不太符合 ADX 中立市场的地位。实际产品中，这两种方式都有采用。在应用内广告等非 Web 的环境下，有时供给方和需求方采用同样的用户标识，这时 DSP 进行用户对应的操作可以略去。

实时竞价的交易方式虽然给予了广告主最大的流量选择空间，也对系统提出了更高的要求，并且带来了下面一些实际问题。

(1) 每次展示都有 ADX 服务器与多个 DSP 服务器的参与，这使得服务器与带宽成本大大增加。读者可以简单计算下，假设每个广告请求包的大小是 1 KB，每秒产生 5000 个广告请求，在将每个广告请求都发给 10 个 DSP 的情形下，需要的带宽就将达到 400 Mbit/s，而这样的数字对于 ADX 来说只是一个不大的规模。

(2) 在询价过程中，ADX 要等待一个约定好的时间片（一般情况下为 100 ms），这使得用户看到的广告延迟增加，对 CTR 有负面影响。

(3) 原理上 DSP 可以以极低的出价参与竞价，这样虽不能获得流量，却可以低成本得到在媒体网站上的用户行为数据，这里存在着潜在的信息泄露风险。

RTB 的接口有两个对接方：在 ADX 方实现的部分称为 RTBD (RTB for Demand)；在 DSP 方实现的部分称为 RTBS (RTB for Supply)。在各个 ADX 中，RTB 接口的细节和具体参数有很大的不同，显然这对于广告主从不同的 ADX 中统一采买流量是不利的。为了

解决这一问题，IAB 经过充分市场调研与企业合作，制定了 OpenRTB^[41]的接口标准，这一标准涵盖了视频、无线、文字、横幅等多种广告形式下的 RTB 问题，并已经为一些 ADX 所采用。

需要特别说明一点，实时竞价中的“实时”这一限定，特指的是需求方实时地，也就是在每一次展示时参与广告竞价，而供给方对不同广告实时比价的过程在前面讲到的一般竞价广告中也存在。因此，不要把搜索广告、广告网络等也理解成实时竞价产品。

6.2 其他程序化交易方式

在实时竞价产生以后，广告交易越来越多地依赖机器间在线的协商而非事先约定或人工操作完成，这样的交易方式称为程序化交易。程序化交易的核心目的是让需求方能够自由地选择流量和出价。除了实时竞价以外，市场上还存在若干其他的程序化交易方式，我们来看一下。

6.2.1 优选

优选比实时竞价产生要早，可以看成是只有一个需求方的程序化交易，其交易过程如图 6-3 所示。




图 6-3 优选交易过程示意

优选方式允许单个需求方按照自己的意愿来挑选流量，但是又可以避免复杂的竞价过程。这个过程主要有以下五个步骤。

（1）用户浏览媒体网站。

（2）媒体网站通过 JavaScript 代码或 SDK 向供给方广告投放机发起广告请求；这里的供给方广告投放机有时是媒体自己的广告投放机，有时则是 ADX 的广告投放机。

（3）供给方广告投放机向需求方的广告投放机发起请求，询问是否需要此次广告展示机会。

(4) 需求方广告投放机根据自己的逻辑判断, 如果需要此次展示机会, 则返回相应的广告创意。

(5) 需求方如果不需要此次展示机会, 则通知媒体广告投放机, 由供给方广告投放机从自有广告库中选择合适的创意返回。

优选过程同样可以使得需求方自由地挑选流量, 因此也是一种程序化交易方式。由于只有一个需求方参与, 媒体可以比较容易地对广告的质量和来源进行控制。这种交易一般按照 CPM 方式结算, 由于没有了多方竞价, 又有选择流量的便利, 往往要约定一个比市场价格更高的 CPM 单价。与 RTB 相比, 优选的一个缺点是决策过程可能存在比较多的服务器往返: 在极端情况下, 需要三次服务器的往返才能得到最后的广告。这有可能使得用户看到的广告延迟增大, 从而影响广告效果。

6.2.2 私有市场

除了实时竞价这种公开的市场拍卖机制以外, 有时媒体为了保证广告主的质量, 希望将拍卖限制在一些被邀请需求方的小范围内。这种程序化交易叫作私有市场。私有市场中的在线交易过程与公开的实时竞价一致, 在此不再赘述。

私有市场可以说兼顾了优选与实时竞价的好处: 首先, 私有市场与优选一样, 是一种邀请制而非公开的交易方式, 因此广告主的质量可以由少量被邀请需求方很好地控制, 这有利于确保媒体的价值不受伤害; 其次, 在被邀请需求方之间仍然保留了竞价关系, 有利于提升媒体的变现能力。当然, 与实时竞价相比, 这两点主要都是对媒体有利, 因此往往是大型优质媒体在考虑程序化交易时的选择。另外, 这也将使得更多的优质媒体加入到程序化交易市场, 反过来可以促进品牌广告投放的程序化进程。

从 2014 年开始, 私有市场在整个程序化交易市场中得到了越来越多的重视, 以 DoubleClick Adx 为代表的主流 ADX 都在大力加强私有市场的产品和服务。可以预见, 随着私有市场与公开市场的充分发展与融合, 程序化交易能在效果与品牌、媒体利益与广告主利益的平衡方面变得越来越成熟。

随着优选、私有市场为代表的一些交易方式的产生, 程序化交易的产品边界变得有些模糊, 甚至令人困惑。IAB 在其报告中, 根据库存类型、价格模式这两个关键产品特征, 把市场上与程序化交易相关的交易方式分成四类, 如表 6-2 所示, 以便大家遇到相关的市场术语时能够了解其本质。需要说明的是, 以我们的观点来看, 表中 **programmatic direct** 这类担保投送优化 (**automated guaranteed**) 交易方式实际上仅仅是完成了固定库存上的受众定向和效果优化, 与传统需求方的广告投放服务很接近, 而并没有机器决策的流量选择过程, 是否应该归在程序化交易之中, 还值得商榷。

表 6-2 IAB 总结的程序化相关交易方式

交易方式	库存类型	价格模式	参与方式	市场术语举例
担保投送优化 (automated guaranteed)	预留	定价	一对一	programmatic direct , programmatic premium
非预留定价交易 (unreserved fixed rate)	非预留	定价	一对一	preferred deals , private access, first right of refusal
邀请制竞价交易 (invitation-only auction)	非预留	竞价	一对少量	private marketplace , private auction, closed auction, private access
公开竞价交易 (open auction)	非预留	竞价	一对多个	RTB (Real-Time Bidding) , open exchange, open marketplace

6.2.3 广告交易方式谱系

我们已经介绍了在线广告市场上主流的交易方式，现在对它们做一个小结，如图 6-4 所示。

	程序化交易			半程序化交易	优先销售
供给方	RTBD	PMP	优选	网络优化	CPM CPT
中间平台	广告交易平台			广告网络	广告投放机
需求方	RTBS	PMP	优选	交易终端	

图 6-4 在线广告主要交易方式一览

按时间段和广告位独占式的售卖以及展示量合约的售卖是销售与客户之间将广告投放的关键要求约定下来的交易方式，在其中人的因素起了相当大的作用，不过这种售卖一般来说由于能满足一些品牌性需求，溢价能力也比较好，在高质量的媒体上属于优先考虑的售卖方式，我们把它们称为优先销售（premium sale）。从技术层面来说，优先销售整体对计算的要求不算特别深入，而且主要的技术集中在供给方（如在线分配、受众定向）。

在竞价广告网络的市场形态下，对供给方而言，可以通过将广告位直接托管给 ADN 的方式变现，也可以同时使用给多个广告联盟，按照一些准则或计算结果灵活地对不同的流量分割选择不同的 ADN，这称为网络优化（network optimization），我们在下文中的供给方平台中还会讨论。对需求方而言，则存在选择合适的人群标签并合理出价，以优化整

体 ROI 的程序交易要求。这样的交易方式虽然已经比较依赖计算，但是双方的决策并非实时完成，效率还没有达到最高。我们把这种交易方式称为半程序化交易。

在实时竞价的环境中，程序交易的过程变得更加简单直接，供应方的 RTBD 接口和需求方的 RTBS 接口通过 ADX 直接对接，并完成精细的流量采买。除了这两种市场上常见的程序交易结构，上面介绍的优选和私有市场等方式也越来越多地在市场上呈现。我们在图 6-4 中列出了包括优先销售和程序化交易等各种在线广告主要的交易方式，供大家参考。

6.3 广告交易平台

广告交易平台，即 ADX，是程序化交易时代的关键产品，它负责将媒体流量以拍卖的方式售卖给 DSP，可以类比于证券市场中的交易所。最早的 ADX 产品 RightMedia 的初衷是在纽约的一些广告代理公司之间交换剩余流量。因此，早期的 RightMedia 并不采用 RTB，而是采用类似于私有市场和托管交易的方式。但是，这种私有市场并不能满足大量长尾媒体流量交换的需求，因为剩余流量只有按照需求方最精确的定向方式来交换，才能获得最高的价值。所以当公开 RTB 产生以后，迅速成为 ADX 的标配甚至最主要的功能。

ADX 的产品策略较为简单，由于所有的广告竞价都是实时进行，因此不需要保存广告库，因而也不需要广告检索流程，排序过程也非常简单。广告交易平台中需要注意的产品策略，主要是如何解决给多个 DSP 发广告请求带来的带宽和机器成本的上升。这一问题，我们称为询价优化（call out optimization）。询价优化的具体技术方案，我们将在后文的技术部分再做介绍。

ADX 一般为 CPM 结算方式，这一点要特别说明一下。我们前文提到过，展示量合约一般按照 CPM 结算，但是无法把多个广告位放进同一合约；而广告网络由于广告位复杂，一般只能按照 CPC 结算。那么为什么在情况与广告网络类似的广告交易市场中可以按照 CPM 结算呢？这里的逻辑在于，实时竞价中广告决策是由 DSP 完成的，而且对每次展示都可以得到广告位信息。因此，虽然各个广告位的点击率差别很大，DSP 还是可以自行精细估计点击率，并实时计算出当前展示的合理 eCPM。并且，由于第一方数据在程序化交易中的广泛使用，DSP 对于人群在特定广告上产生的效果往往能够估计得更加精细。因此，按照 CPM 结算，将 eCPM 整体的估计都交给需求方是比较合适的市场分工。

产品案例

从早期以托管和私有交易为主的模式，到后来以公开交易为主的模式，ADX 的产品演进很快，我们将以 RightMedia 和 DoubleClick Adx 为例进行介绍。

1.RightMedia

The logo for RightMedia, featuring the word "right" in a bold, lowercase sans-serif font, followed by "media" in a lighter, lowercase sans-serif font.

RightMedia 是美国最大的网络广告交易平台之一。2007 年，展示广告占美国整个在线广告市场份额的四分之三。Yahoo! 斥资 6.8 亿美元收购 RightMedia（同年 Google 以 31 亿美元收购 DoubleClick）。收购以后，Yahoo! 对 RightMedia 做了一项重要的改变，将其变成了私有的网络广告交易所，不再为小网站提供广告位拍卖的服务。

优质媒体希望进入网络广告交易来消化直销的品牌广告剩下的广告库存，但是又不希望失去流量的控制权。而一般的公开交易平台面向大大小小的网站提供交易服务，广告质量参差不齐，会影响媒体的品牌价值。因此，Yahoo! 非常重视让优质媒体进入广告生态圈的策略，希望把 RightMedia 打造成针对高端媒体的私有广告交易平台。

虽然能建立广告主关系，公开交易的 RTB 市场上的竞价对优质媒体有时有失公允：在信息对称，也就是受众的信息完全被 DSP 知晓的情况下，DSP 的出价才会完全合理；而在信息不对称，例如，数据来源不充分的情形下，一个高端用户访问了优质媒体，DSP 可能并不知晓，其出价对于优质媒体来说也会偏低。如果优质媒体接入了公开交易的 ADX，不仅媒体品牌将被淡化，ADX 的品牌价值被提高，媒体也将会失去控制权。

综上考虑，优质媒体会首选提供 PMP 交易的平台，这样既能控制流量又能选择控制 DSP 和建立广告主关系，从而建立媒体品牌。事实上，PMP 也一直是 SSP 优化媒体利益的显著特性。只是近年来随着 ADX 逐渐融合了 SSP 的特性，这两类交易模式在产品上也逐渐融合。

由于近年来基于公开 RTB 的 ADX 发展迅猛，RightMedia 的业务也面临着很大的挑战，并且其交易架构和算法都存在着一些不尽合理之处。Yahoo! 已经决定在 2015 年将 RightMedia 这一产品下线，代之以全新的广告交易产品。

2.DoubleClick ADX



2007 年，Google 以 31 亿美元的价格收购了 DoubleClick。在此基础上，发布了其广告交易平台产品 DoubleClick ADX，并将 AdWords 和 AdSense 接入。其中，AdSense 是作为一个广告网络从供给端接入的，而 AdWords 则作为需求方接入。Google Adwords 的广告主可以直接进入 ADX 的平台并拥有更多的媒体资源，而 AdSense 的发布商们也将拥有更广泛优质的广告主资源。DoubleClick 作为一个 ADX，连接了众多广告网络和 DSP，当一次广告展示发生时，AdSense 和 AdWords 只是作为其中两个参与者而已，AdWords 赢得的展示并不一定在 AdSense 上展示，在 AdSense 上展示的广告也不一定是来自 AdWords 的。

DoubleClick 提供的是一个完全透明，理论上任何 DSP 都可以对任何流量竞价的公开交易市场。媒体一般会允许一些或所有需求方通过这种方式接入他们的流量。通常不会与需求方产生直接交流，媒体主可以在完全未知的情况下参与公开市场流量竞拍。

DoubleClick 的公开透明的 RTB 模式吸取了 RightMedia 由于历史问题带来的一些设计不足，在其 ADX 的拓扑结构设计上有其独到之处。RightMedia 在拓扑结构设计上，任意两个媒体间换量需要双方签订合同，即在会进行换量的媒体间连边，伴随着换量媒体的增多，节点之间的连接是任意的，没有规律，带来了设计上的复杂性。DoubleClick 采用了星型的拓扑结构，媒体直接换量需要先经过 Google，直接和 Google 签订合同，这么做一方面降低了 ADX 模式的复杂性，一方面将单纯的分成收益拆分成了两份合同里的收入和成本，也增加了 Google 的现金流。

DoubleClick Adx 每天管理着全球数百亿次广告展示的实时竞价，在中国市场也是重要的 ADX 之一。

6.4 需求方平台

与 ADX 相对应，以 RTB 方式购买广告的产品形态就是需求方平台，即 DSP。这一产品的核心特征有两个：一个是 RTB 方式的流量购买，另一个是需要支持需求方定制化的用户划分。这两个核心特征其实是同一问题的两个方面：为了能够按需求方定制化的用户划分采买广告，需要市场开放竞价接口；而如果仅仅根据供给方定义的用户划分来采买，那么像广告网络那样的非实时竞价就够了。

什么是定制化^[4]的用户划分呢？从受众定向的角度看，那些形如 $t(a, u)$ 的定向方式，即与广告主相关的定向方式，就是定制化用户划分。可以通过两个例子来直观地理解一下。第一个例子，假设某电商网站准备进行一次面向其老客户的广告投放，这里的“老客户”就是一种定制化用户划分，显然只有该电商自己才能找到这个用户群，而任何媒体或广告网络无论数据能力有多强，也无法加工出这样的标签。第二个例子，某银行希望通过广告接触到自己信用卡的潜在客户。要找到这些潜在客户，我们需要以银行现有的客户作为基础，分析其行为和人口属性有哪些特征，然后再根据这些特征去拓展可能的潜在客户。这一过程既需要需求方的数据，又需要媒体或第三方数据，而其加工出的人群仍然是与广告主相关的，因此也属于定制化用户划分。

由于可以细分到每次展示的粒度来决策和出价，这使得需求方向一个推荐系统那样精细化地执行广告活动，也使得推荐和广告这两项重要的互联网技术找到了完美的契合点。

6.4.1 需求方平台产品策略

DSP 的广告决策过程（如图 6-5 所示）与广告网络非常相似，同样先要经过检索、排序、定价几个阶段，主要的差别是完成广告选择后，又增加了出价的步骤。而出价正是 DSP 的关键产品策略之一，因为在实时竞价环境中，出价直接决定着 DSP 的流量基本单位成本，当然也就决定着利润。




图 6-5 需求方平台广告决策过程示意

DSP 与广告网络另一个不同的产品策略问题体现在受众定向的方式上。在广告网络中，主流的定向方式都是根据第三方数据加工的标签；但是在 DSP 中，以第一方数据为核心，结合第三方或第三方数据的定制化标签，即 $t(a, u)$ 的定向方式，是其关注的重点。在各种定制化标签中，重定向和 look-alike（新客推荐）的方法具有一定的普适性，是 DSP 需要特别重视的产品策略。

下面我们来讨论下 DSP 中这两个关键的产品策略。

6.4.2 出价策略

在广告网络中，我们估计 eCPM 的目的是为了对广告排序，而绝对的 eCPM 值并不需要太精确。但是在 DSP 中，由于每次展示都要按 CPM 向 ADX 报价，因此准确地估计 eCPM 非常关键，这也成为 DSP 出价策略的基础。

DSP 直觉的出价策略比较简单：只要 eCPM 估计足够精准，并按照此值出价即可。由于 ADX 一般也是按照 GSP 来计费，这样的策略是可以确保有利润空间的。如果没有预算的限制，那么这样的出价策略就是最优策略了。

为什么预算的限制使得情况有变化了呢？图 6-6 中的曲线是某实时竞价市场的成交价在一天内随时间变化的曲线（bid landscape）^[25]。可以发现，由于市场中各 DSP 的广告主、预算及出价的变化，这一曲线不但不平滑，甚至是变化非常剧烈。在这样的市场中，假设我们的 eCPM 是某高于市场水平的固定值，可以比较两种出价策略。图 6-6 中的策略 A，由于 eCPM 高于市场水平，可以对所有询价按 eCPM 出价，这样可以获得所有流量，直至当日预算消耗完。图 6-6 中的策略 B，我们选择一些市价较低的流量出价，获得这些流量，直至当日预算消耗完。很显然，采用策略 B 我们付出的成本要显著低于策略 A，当然也就能获得更高的利润。




图 6-6 DSP 不同出价策略

在上面的例子中，DSP 优化的出价策略可以定性地描述为：首先，通过历史的观察和预测得到市价的曲线；然后，将一天的预算分配到那些市价较低的流量上。当然，实际情况要更加复杂，因为 eCPM 也会随着时间而变化，例如游戏广告在休闲时间的 eCPM 显著高于上班时间。于是我们希望获得的并不是市价较低的流量，而是 eCPM 与市价的比例较大的流量。因此，DSP 的出价策略要基于两条曲线，即 eCPM 和市价随时间变化的曲线。

当然，除了时间轴上找合适的出价区间，也可以将此策略拓展到更多的维度上。例如，一般来说女性用户流量的商业价值较高，市场价也可能会比较高，如果 DSP 广告在男女用户的 eCPM 上差别不大，甚至在男性用户上更高（如游戏），那么就应该尽量多投放男性流量，以获得更高的利润。不过，加入更多维度使得问题变得复杂了很多，而且其他因素对市场价的影响没有时间那么大，因此，做好时间轴上的出价策略是实践中最关键的。

6.4.3 重定向

重定向是在线广告中最早产生，也最广泛使用的一种定制化标签。它的概念很简单，即把那些曾经对广告主服务发生明确兴趣的用户找出来，向他们投放该广告主的广告。在不同的广告类型上，重定向主要有两种目的。

（1）用于品牌广告。当用户已经选择过某品牌的服务或产品后，如果在比较高质量的媒体上看到该品牌的广告，他会进一步肯定自己决策的正确性，从而对该品牌的认知度也大大加强。这种用途下，应当以宣传品牌而不是具体产品为主要诉求。

（2）用于效果广告。当用户曾经考虑过某种产品，但没有完成最终转化，通过在线广告将这个用户找回，点击率和转化率都会明显高于平均水平。如果用户已经选择了该产品，那么可以利用推荐技术为他推送相关的产品广告。

重定向可以从信息来源和使用信息的精细程度上区分为网站重定向、个性化重定向和搜索重定向，我们将分别说明。

1. 网站重定向与个性化重定向

网站重定向（**site retargeting**），即将在一段时间内到达过广告主网站的用户作为重定向集合。这样的重定向流量其 **eCPM** 一般来说要比无定向流量高出一个数量级，因此需要尽可能扩大投放量。在媒体上采买这种重定向流量时，能够得到的量有两个主要影响因素，一是广告主网站本身的独立访客量水平，二是这些访客与媒体的重合程度。前一个因素没有办法通过广告手段扩大，而后一个因素则要求尽可能多地通过各种渠道采买重定向流量，显然 **DSP** 是合适的方式。

个性化重定向（**personalized retargeting**）是网站重定向的一种特例。对重定向流量进行深入加工，按照品类和购买阶段等因素进行创意上的深度个性化，就是个性化重定向。具体来说，个性化重定向可以在两个方面深入挖掘：一是对于处于不同购买阶段的用户，采用合适的创意推动他尽快完成转化行为，这里的购买阶段包括浏览、搜索、加入购物车等；二是对于已经有过一些购买记录的用户，使用推荐技术向其展示相关的商品以提升二次购买率。从这两层意义上看，这一方法与推荐有非常多的共通之处：以广告产品的视角看，我们称之为个性化重定向；而从推荐产品的视角看，则可以认为是一种站外推荐（**off-site recommendation**），换句话说，是将原来广告主网站上的推荐模块搬到了站外。

在图 6-7 中，我们给出了个性化重定向广告的一个示例。该广告投放的对象是某个京东商城的用户。该用户很可能在京东商城关注过某种手机商品以及有关 **PHP** 编程的技术书籍。因此，广告系统根据他的个性化购物兴趣，结合京东商城的商品库存，为其推荐了相关的手机和技术书籍。可以想见，这样的广告其点击率和转化率都会比较高。



图 6-7 个性化重定向广告示例

个性化重定向与传统的受众定向方式有较大的差别，其产品有以下三个关键点。

（1）动态创意。个性化重定向的核心是用推荐的思路实时决定展示什么商品。由于广告主的商品数量往往相当大，因此显然不可能为所有的商品组合预先准备好创意。因此，动态创意是个性化重定向最重要的支持技术，这也是在线广告朝着彻底个性化、动态化方向发展迈出的重要一步。

（2）推荐引擎。个性化重定向可以看作是站外推荐。不过与站内推荐相比，它有一些不同之处。首先，站内商品页上的推荐主要根据上下文信息来进行，而站外推荐则是根据用户信息来进行；另外，站内推荐由于是发生在某个特定的购买环节上的，因而往往不需要根据用户的购买阶段来调整创意，而站外推荐这么做则非常必要。

(3) 广告主商品库存实时接口。对于站外的商品推荐，如果用户在点击某单品到达广告主网站时，发现该商品已经售完或下架或者是价格与创意上的宣传不符，会对该广告主的品牌形象有较严重的伤害。为了尽可能避免这种情况的发生，个性化重定向服务需要提供准实时的商品库接口，让广告主可以及时地将库存和价格信息同步过来。

2. 搜索重定向

搜索重定向 (search retargeting)，即将搜索过与广告主直接相关的关键词的用户群作为重定向集合。这样的方式也可以获得很精准的用户群，其绝对量也要高于网站重定向，不过对于非主要搜索引擎提供商来说，依靠搜索重定向能覆盖的人群比例未必会高于网站重定向。

既然搜索重定向使用的是搜索引擎的第二方数据，那么为什么也归为定制化标签呢？这要从如何获得搜索重定向中用的词表说起。给一次广告活动确定合适的搜索重定向词表，一般来说有以下三种思路。

(1) 人工根据经验确定词表。

(2) 如果该广告主同时也在做 SEM，可以直接采用对应投放的关键词表。

(3) 基于广告主流量统计的方法，即统计广告主网站流量中从搜索引擎来的流量，将其中频度较高的关键词作为搜索重定向词表。

其中，最后一种策略在实践中表现出来两方面的优势：首先，由于是根据实际流量数据统计得到，效果往往比其他方法更好；其次，通过在广告主网站布置代码等手段得到第一方数据后，整个过程可以自动化，简便易行。因此，我们建议的首选搜索重定向策略，是第三种策略，而这种策略需要依赖于第一方数据，因此也是一种定制化标签。

6.4.4 新客推荐

重定向的方式虽然精准，但是量受到极大的限制。而且对于大部分广告主来说，除了对老用户精耕细作，他们更希望能有办法接触到那些“有可能”对自己产品发生兴趣的潜在用户。对于那些快速成长期的电商或者是网站流量并不大的线下业务广告商（如银行、汽车），这方面的需求尤其强烈。

“有可能对自己产品发生兴趣”这样的用户标签，从目的上来说很明确，但从做法上来说比较模糊。很容易想到的思路是这样：由广告主根据自己的第一方数据提供一部分种子用户，再由拥有更丰富数据的第二方数据的广告平台分析这些用户网络行为的特征，并根据这些特征找到具有相似特征的拓展人群。很显然，这也是一种定制化用户标签。这样的标签加工策略称为新客推荐，即 look-alike。

从推荐的角度来看 look-alike，可以认为这是一种“新客推荐”的方式，重点在于向没有关注广告主产品的潜在用户进行推广。当然，既然是推荐，就不是漫无目的的撒网式推广。另外，这样的推荐技术，考虑的是没有广告主站内行为情况下的推荐，是原有狭义推荐问题的扩展。

look-alike 是一种合理的受众定向产品思路，但是要在一定的数据支持下才有可能产生价值，并且由于它涉及第一方数据和第三方数据的获取与加工，在技术上是有一定的挑战的。读者在遇到这类产品时，要特别注意从数据和技术方案合理性的角度判断其真正价值。不客气地说，在中国市场，look-alike 这个词已经一定程度上变成了效果不明、原理解释不清的定向方式的遮羞布，而几乎所有的广告产品都声称自己有此项能力，这实在可以称为中国的“look-alike 乱象”。

6.4.5 产品案例

定制化用户划分和 RTB 技术的产生催生了许多以技术方式优化广告采买的 DSP 公司。这些公司当中，有些以 CPM 采买并优化 ROI 的套利模式为主；有的则以透明的采买和效果优化功能性服务为主，我们将对这两种类型的 DSP 分别举例说明。

1.Criteo



Criteo 是一家总部位于法国的广告技术公司。从其历史业务来看，Criteo 除了实时竞价，还采用优选方式采买流量。不同于其他的需求方平台，Criteo 的重点产品是按照个性化重定向方式采买广告。其核心技术也就是前面介绍的三项：动态创意、推荐引擎和广告主商品库存实时接口。图 6-8 中给出了 Criteo 个性化重定向创意的几个例子。


Nowości			Zobacz wszystkie < >	
				
Polar damski Lady Polaris Hi-Tec 449.99 zł 97.00 zł	Koszulka termoaktywna damska Extreme W02 Spaio 144.90 zł	Skarpety narciarskie dziecięce Thermolite Junior Spaio 31.90 zł		

图 6-8 Criteo 个性化重定向广告示例

Criteo 按照 RTB 或优选的方式，以 CPM 方式与媒体结算，但是与广告主之间的结算完全采用 CPC 方式，从而实现套利，并且也很容易被效果类广告主接受。在个性化重定向的方案框架内，Criteo 还提供了 user、category、data 和 banner 四个维度上比较灵活的优化功能，即广告主可以根据不同的用户细分、商品种类、具体数据和创意类型设置不同的点击出价，从而达到非常精细的 ROI 管理和优化的目的。这样的显示广告运营和投送方式，其精细程度与搜索广告有相似之处：都是在非常精准的流量细分上以效果为导向投放广告，并且能够在非常精细的粒度上控制出价。不过这种方式对于展示广告来说有一些先天的缺点：个性化重定向不同于搜索广告，需要预先在广告主网站布置跟踪代码，这使得新广告主加入的进程变得大为复杂。因此，专门从事个性化重定向的公司初期会面临需求不足的问题，并且需要运营商大量的努力和效果上良好的记录才能逐步改善，而 Criteo 也同样经历了这一过程。伴随着 Criteo 海外业务的拓展，最近几年，Criteo 收入增长良好，2012 年收入 3.4 亿美元，2013 年营收 5.6 亿美元，增速达到了 60%。

2. InviteMedia



InviteMedia 原是一家独立的 DSP 公司，2010 年 6 月以约 7 000 万美元的价格被 Google 收购，现已整合进 DoubleClick 的广告系列产品，并改名为 DoubleClick Bid Manager。虽然 Google 在广告产品中全线布局，但 InviteMedia 被整合后仍然保持相对独立，和代表媒体利益的 DoubleClick Adx 之间仍然是相互博弈的关系。

InviteMedia 是广告交易市场上的先行者之一，其业务是提供比较透明的 RTB 采买功能，如设定一些规则和优化目标，帮广告主把相关 ADX 接入进来并从中收取固定比例的佣金，希望借此方式快速拓展广告主端的影响力。当然，随着业务发展，现在也正在提供越来越深入的采买 ROI 优化服务。同时伴随着 2013 年 InviteMedia 将域名切换到 DoubleClick 的域名 dc.com，InviteMedia 不再需要和 DoubleClick Adx 进行 cookie 映射，减少了因 cookie 映射带来的损失，从而提升了采买的效率和最终投放的效果。

3. 聚效



聚效是从 MediaV 独立出来的广告技术平台产品，是国内规模最大的效果类 DSP 之一。严格来说，聚效是一个 ADN 和 DSP 混合的产品，也有人把这类产品称为 DSPAN。其流量中既有通过 RTB 方式获得的部分，也有自营的广告网络，聚效将这两部分流量按照统一的人群划分，并按 CPC 竞价的方式售卖给广告主。不过目前，聚效也在进行内部流量 RTB

化的改造，预计将来会演变成由一个 ADX 承接其广告网络流量，而需求方则完全以 DSP 为接口的模式。

作为国内最早的自助式 DSP 之一，聚效在电商等效果类行业有众多的用户，这些用户既包括淘宝网店，也包括知名的电商平台。这些广告主都按照 CPC 进行出价和结算，聚效的 DSP 引擎会预估每一次流量的点击率或转化率，实时将该出价转换成 CPM 报价。

聚效对接国内的主流公开 ADX，包括 Google ADX、TANX、腾果等，同时，聚效也对接了新浪、搜狐、优酷、土豆、网易、58 同城等大型网站的私有流量。因此，就产品形态上而言，聚效是一个兼具公开交易和私有交易功能的 DSP，也能够为不同诉求的广告主提供相应的流量和服务。同时，除了服务大型电商以外，聚效还服务了数万家的中小广告主，并通过算法和数据能力为其精准地找到用户，这成为其核心竞争力。

6.5 供给方平台

我们再来看看在程序化交易产生以后，供给方的综合性收益优化方案。对于媒体而言，无需把全部流量的变现都放在一种交易方式上。媒体既可以通过直接销售来高溢价地售卖品牌广告，也可以综合使用各种程序交易方式以追求更高的 eCPM。

参照 6.2 节中的广告交易方式谱系，媒体的统一变现平台需要这样的逻辑。当广告请求到达时，首先检查优先销售的订单有无需求，这包括 CPT 和 CPM 的合约。如果有需求，按照优先级和在线分配的方案完成投放；如果没有这类销售合约，则进入竞价流程。竞价时，从自运营广告主库中找出 eCPM 较高的，并估算可供调用的若干广告网络的 eCPM，在这两者之间找到较高的广告候选，再以此作为 MRP，通过 RTB 接口向接入的各 DSP 实时询价。可以看出，在这样的逻辑中，广告请求是被分配到自运营广告库，还是其他广告网络，或者是 DSP，是根据他们的收益在线动态决定的，这样的方案称为动态分配（dynamic allocation）。对应的产品形态就叫作供给方平台（Supply Side Platform，SSP）。

6.5.1 供给方平台产品策略

SSP 中多种广告源动态分配的决策过程如图 6-9 所示。

Admeld

Admeld 的创始人 Michael Barrett 曾经在美国在线（AOL）和福克斯集团（Fox）担任要职，所以 Admeld 的产品从一开始就在为门户网站设计广告管理功能，优化媒体利益。他们早期的客户包括了 AOL、FOX 等在美国具有相当流量的大型门户型网站。从 2008 年起，一直在网络优化、PMP 等方向上引领 SSP 相关技术和产品形态的发展。

早年 Admeld 在为媒体做收益管理时，接入的主要流量并不只是来自于 ADX 里的 RTB 流量，主要是来自于各大 ADN，比如在北美市场就接入了 50 多家 ADN，换句话说媒体只要加一段 Admeld 的代码，就可以对接所有的这些 ADN，这极大地方便了剩余流量的变现和优化。在对这 50 多家广告网络做网络优化时，如前所述，由于对广告网络自己的定向方式和广告库不是特别清楚时，反而是使用广告位和时间段这样的基本划分比较稳健，所以主要在广告位维度、时间维度、广告返回率以及分成比例等少数维度上进行 eCPM 估计和流量切分。

Admeld 也会从 DMP 购买用户数据，这一方面为了自己能更进一步深入地估计各广告网络的 eCPM，另一方面也方便参与竞价的各 DSP 了解流量质量，从而刺激 DSP 的竞价价格和市场的流动性。

2011 年被 Google 以 4 亿美元收购后，Admeld 整合了 DoubleClick 的 DoubleClick for Publishers（DFP）广告管理系统中。Google 收购后能获得到一些他们难以取得的顶级内容供应商的流量以及良好的媒体关系，而 Admeld 的 SSP 相关技术也被整合进 DFP 中，完善了 Google 的广告生态链。

2. Rubicon



Rubicon 是第一家上市的专注于供给方的 SSP 公司，默多克的新闻集团拥有其 20% 的股份，新闻集团旗下的数字媒体均通过其变现，所以 Rubicon 拥有强大的媒体资源支撑其业务。在上市的招股书中，Rubicon 是这样描述其客户群的：拥有超过和 500 家数字媒体的良好关系，包括 comScore 排名前 100 位的媒体中的 40%。

伴随着产业链上下游的整合，Rubicon 也逐渐淡去了 SSP 的标签，其重点宣传的产品包括 SSP 产品 Seller Cloud、ADX 产品 Advertising Automation Cloud、DSP 产品 Buyer Cloud，这些产品覆盖了产业链的上下游。在 ADX 的环节，Rubicon 每天发出近 40 亿次的询价请求，宣称与 Google 是目前最大的两家 ADX。

6.6 数据加工与交易

通过前面的讨论我们知道，要提高定向的精准程度与人群覆盖率，技术远不是唯一重要的因素。那么什么才是决定性的呢？是数据的来源与质量。这是正确认识精准广告业务非常重要的观点。为了强调这一观点，我们以大家更容易理解的石油加工工业为例与之做类比，如图 6-10 所示。在石油工业中，从油田挖掘出的原油是整个行业的原材料，炼油厂的作用是把这一原材料加工成汽油等燃料，再输送给加油站这样的销售终端。在精准广告中，可以把用户的行为类比于石油工业中的原材料，日志收集和清洗系统的作用就相当于油田的挖掘设备。而受众定向的平台就可以类比于炼油厂，它把原油，即清洗过的日志，加工成用户标签，而这些用户标签就像汽油一样，是可以被销售和使用。而传统广告中起关键作用的广告位在这里仅仅变成了加油站，负责完成产品消费的过程而已。




图 6-10 数据驱动的计算广告与石油加工对比

如何正确认识技术在精准广告业务中的作用呢？从上面的类比可以看出，技术的地位相当于挖掘设备和炼油设备，当然有着无可置疑的重要性。技术能力的高低直接影响着数据采集和变现的有效性。不过从另一个角度说，技术的作用也不能被过分夸大。巧妇难为无米之炊，没有高质量的原材料，即用户数据，再高明的技术也没有用武之地。

6.6.1 有价值的数据来源

既然数据本身有这样根本性的作用，甚至从某种意义上说是精准广告市场的核心，那么围绕数据本身的加工与交易就与广告的投放技术一样令人瞩目。有哪些数据是对精准广告业务有直接贡献的呢？我们可以重点关注下面的几类。

（1）用户标识。对广告而言，如何确定哪些行为来自于同一个用户是非常关键的问题。用户标识对于行为定向的重要性往往容易被忽视。实际上，稳定精确的用户身份就像

是一串 0 前面的那个 1 一样，对准确界定受众和利用数据至关重要。无论能拿到多少行为数据，如果无法把它们与投放系统联系起来，这些数据都无法发挥作用。

对于浏览器行为，我们最常使用的用户标识是 **cookie**，但是由于存在同时使用多个浏览器、**cookie** 过期或用户主动清除 **cookie** 的情况，这种用户标识的长期一致性并不算太好。不过好在广告来说，起关键作用的还是用户近期内的行为，所以用 **cookie** 作为用户标识还是有效且为业界广泛采用的基础方案。如果运营广告业务的域名同时提供其他有永久身份的服务，如电子邮件、SNS 等，那么可以用这些永久身份找回过期或被清除的 **cookie**，这样用户身份的一致性就会改善。当然，如果广告业务域名和用永久身份服务的域名不同，也不是完全没有办法，在后者同意的前提下，可以采用 **cookie** 映射的方法来对应彼此的用户身份，这一技术的细节将在后文谈到广告交易的技术时再讨论。

在移动互联的情形下，iOS 与 Android 在应用内广告使用的用户 ID 有所不同：前者是苹果公司设计的广告专用用户标识符（Identifier for Advertising, IDFA），其性质与 **cookie** 类似；而后者没有专门的广告用户 ID，一般采用 Android ID 或 IMEI（international mobile equipment identity）号等标识信息。

由于高质量的用户标识本身就是一种非常有价值的信息，因此也是可以在市场交换和售卖的。

（2）用户行为。业界通常认为，转化（conversion）、预转化（pre-conversion）、搜索广告点击（sponsored search click）、展示广告点击（ad click）、搜索点击（search click）、搜索（search）、分享（share）、页面浏览（page view）、广告浏览（ad view）等在线行为是可以被广泛采集并且对于受众定向或广告决策有明确作用。按照对效果广告的有效性分类，这些行为可以分为决策行为、主动行为、半主动行为和被动行为。

决策行为主要包括转化和预转化。这些都是在广告主的网站中发生的行为，往往对应着非常明确的用户兴趣。例如在电商网站上，转化就对应着最后的下单，而预转化对应下单前的搜索、浏览、比价、加入购物车等多种准备工作。这类行为的价值是最高的，但是也是供给方或广告平台最难得到的。根据广告主端的数据进行重定向或者个性化重定向是对于此类行为最直接的利用。在行为定向中，这类数据虽然量不大，但却不能忽视。

主动行为主要包括广告点击、搜索和搜索点击。这一组行为都是用户在网络上在明确意图支配下主动产生的行为，因而也有比较丰富的信息量。其中的广告点击行为一般来说量不大，并不能作为定向的主要数据来源。而搜索行为是能够大量获得的最主要的主动行为，需要特别注意挖掘利用。

半主动行为主要包括分享和网页浏览。这两类行为都是用户在目的比较弱的网上冲浪过程中产生的，因此，其所涉及的兴趣领域对把握用户信息有价值，但是非常细节的内容其精准程度有限。半主动行为的指导意义虽然有限，但是其数据量却是各种行为中最大的。

被动行为主要是指广告浏览。广告浏览严格来说不能算作定向的行为依据，但是由于其频次与相应类别的广告点击负相关，因而在行为定向的建模中也可以使用。

(3) 人口属性。人口属性本身是常用的一种定向标签，因此其数据来源很重要。一般来说，只有一些能够与用户实名身份绑定的服务可以得到此信息。我们也可以利用网络行为数据进行人口属性标签的预测，但是这样做的准确程度一般都有限，而且仍然需要一些标定的数据用于训练。对于某些人口属性，可能一些特别的信息比较容易给出准确的判定，例如用语音服务记录的声音信号，可以将男女区分得相当准确。

(4) 地理位置。地理位置信息随着能获得的精度不同其用途也会有相当大的差异。如果只能根据 IP 进行映射，我们往往只能拿到精确到城市级别的地理位置，当然这对于很多广告投放来说已经有相当的价值。而在移动互联环境下，GPS 或蜂窝可以提供的定位往往可以准确到几百米的范围，这就使得 hyper-local 的区域广告商投放定向广告成为可能。这样的广告定向，对于餐饮等受地理位置限制极大的线下业务广告商是非常有价值的。

(5) 社交关系。社交网络上的关系反映了人与人之间的联系，也隐含了一种联系人之间“兴趣相似”的合理推测。因此，社交关系可以用于用户兴趣的平滑。当广告系统观察到某个人的行为不足，无法进行精准的行为定向时，可以考虑借鉴其社交网络朋友的行为和兴趣。比如一个人在微博上的好友有很多都是足球爱好者，那么可以猜测他也是一名足球爱好者。虽然这样的猜测未必准确，但只要统计上合理，就会对广告投放效果有帮助。需要注意，这样的平滑只适用于那些长期稳定的兴趣，对于短时的购买兴趣不太适用。从这个意义上来看，强关系类型的 SNS 比弱关系的 SNS 有优势，关注人群比被关注人群的信息意义更大。

关于以上各类行为数据对广告效果的意义，有两条基本的规律：首先，随着用户主动意图的提升，相应的行为数据信息价值也随之增大；其次，越接近转化的行为，对效果广告的精准指导作用越强。把握这两条规律有助于大家判断各种各样的行为数据的价值。不过读者不要忘记，广告的根本目的是“低成本地接触潜在用户”。如果仅仅从转化效果上判断行为数据的作用，会发现靠近转化的行为更精准，实际上是因为这部分人群已经更加接近于决策的最终阶段，也就是说越发不是“潜在用户”。因此，在行为定向这个问题上，不能单纯追求 ROI 或者转化效果，而是要根据广告主的具体的人群接触目标来平衡效果和覆盖率。

6.6.2 三方数据划分

广告中用到的用户数据，根据其来源的不同可以分为第一方数据、第二方数据和第三方数据，如图 6-11 所示。一般我们说的第一方和第三方分别是指广告主和广告平台，而

不直接参与广告交易的其他数据提供方统称为第三方。在广告网络中，主要使用第二方数据指导广告投放；而在实时竞价环境下，不仅第一方数据可以被利用，大量第三方数据的加工和交易也逐渐发展起来。虽然，一般情况下第一方数据的量较小，却是所有数据的灵魂。以第一方数据为基础，用好第二方数据和第三方数据，是实时竞价时代重要的方法论。




图 6-11 三方数据示意

6.6.3 数据管理平台

第一方数据的收集和加工是广告市场上非常重要的环节。不过对于没有这方面技术积累的广告主而言，专门设团队进行数据加工是没有必要的。因此，市场上也产生了专从事此业务的产品，称为数据管理平台即 DMP。DMP 有下面几个核心的产品功能。

(1) 它可以为网站（可以是媒体也可以是广告主网站）提供受众定向功能，并将得到的用户标签应用于网站业务。在这一过程中，除了加工一些通用标签，DMP 还需要能够比较灵活地按照网站定义的用户标签来加工受众人群。

(2) 如果媒体网站授权，DMP 可以提供接口对加工出来的用户标签进行变现，并与网站进行分成。

(3) 广告主网站可以通过 DMP 与广告采买渠道进行更方便的数据对接。这一点可以通过下面的应用来理解。假如某广告主需要通过外部广告平台做重定向，那么需要将自己的用户集合通过某种技术方式通知广告平台。如果每个广告平台都采用在广告主网站上加跟踪代码的方式来收集用户，有两个弊端，一是多个广告平台同时加代码，有可能使页面变得太重；二是访客的积累可能长达数周的时间，这使得广告平台重定向的效率降低。如果由 DMP 唯一负责广告主网站的用户积累和划分，并通过数据接口的方式传送给广告平台，那么可以很大程度上解决上述问题。

在北美的在线广告市场上，有不少以 DMP 类似业务为主要方向的公司。比较有代表性的是 AudienceScience。

6.6.4 数据交易平台

数据交易平台（data exchange）的主要产品功能是聚合各种来源的在线的用户行为数据，加工成有价值的用户标签，然后在广告市场上通过售卖这些标签来变现。数据交易平台与数据管理平台的产品边界并不是泾渭分明。一般来说，数据交易平台除了聚合成型的用户标签，也都会提供聚合原始行为数据自行加工标签的功能，也就是兼具 DMP 的产品功能。不过，数据交易平台往往是按照自己的逻辑而非媒体的需求来制定标签体系和加工数据，因此，可以认为 DMP 是站在第一方数据的角度提供产品，而数据交易平台主要是站在第三方数据的角度提供产品。

关于数据交易的方式如图 6-11 所示，一般是通过 ADX 或 SSP 作为中转来完成。数据交易平台提供的各种用户标签作为 ADX 的一个辅助产品提供给各 DSP。标签一般按照 CPM 计价，DSP 如果选择购买某种标签，则在广告询价的过程中，ADX 将本次请求的用户标签传给 DSP，最终按照 DSP 实际成交的展示量乘以 CPM 价格作为其购买数据的附加费用。以广告交易为载体进行数据交易是比较合理的产品方案，这种方案有一些具体的好处：首先，在广告请求上附加用户标签，不会带来额外的服务开销；其次，所有的 DSP、数据提供方都只需要与 ADX 进行 cookie 映射，这样以 ADX 为中心的星型拓扑结构比起 DSP 与数据提供方直接进行 cookie 映射的拓扑结构显然要方便得多。

6.6.5 产品案例

数据管理和交易产品在程序化交易市场已经比较普及，但是在中国市场中还没有形成规模。究其原因，恐怕与中国存在着大量作弊和流量劫持（参见 15.3 节）等灰色低成本渠道不无关系。因此，我们将主要关注国际市场中比较成熟的数据类产品，并以 BlueKai 和 AudienceScience 为代表。

1.BlueKai



我们先介绍一下 BlueKai 这家公司的发展历程：2007 年年末，展示广告占 200 亿美元在线广告市场的 75%。同年，在雅虎 6.8 亿美元投资了 RightMedia，Google 以 31 亿美元收购了 DoubleClick 的背景下，BlueKai 的 CEO Omar Tawakol 预见到未来展示广告的客户需要将广告精准投放到特定的消费群体，于 2008 年建立了一个名为 Data Exchange 的数据库，一方面让中小网站提供流量、会员资料等信息，另一方面将这些信息加工后销售给中小广告主。2009 年 BlueKai 启动了分析服务，帮助用户区分受众购买行为。2011 年，BlueKai 收购 Tracksimple，加强了自己的数据分析能力，从而为广告主提供一站式的包括数据分析、数据购买的 SaaS 服务。近年来，作为 Data Exchange 和 DMP 的领头羊，BlueKai

开创和推动了一个独立 DMP 时代，活跃用户数超过 3 亿，前 20 位的广告网络、门户网站中有 80% 在使用 BlueKai 的数据。

BlueKai 作为一个独立 DMP，不像其他 DMP 公司开始整合 DSP 业务，而是一直不提供媒体的竞价采购服务。BlueKai 认为，这样可以保持 DMP 的中立性，可以使 BlueKai 的 DMP 与多家 DSP 对接合作。2014 年 2 月，BlueKai 被 Oracle 以 4 亿美元收购。作为 BlueKai 的收购方，Oracle 没有媒体购买的业务，主要是一些企业级的市场营销管理服务，因此与 BlueKai 的独立 DMP 的市场定位相符合。作为独立的 DMP，BlueKai 收入规模并不大，2013 年总收入仅 6400 万美元左右。

BlueKai 的主要业务模式是聚合大量中小媒体的有价值行为数据，使用受众定向技术为用户打上标签，并对外售卖标签以获取收入。BlueKai 通过数据交易获得的收入，其中很大比例还将返还给数据提供方。BlueKai 的重点放在汽车网站、旅游网站和各种购物网站上，因为这些网站背后代表着某一个同质性较高的族群，与这些主题网站相关的广告主，如航空公司、汽车厂商等，也非常需要精准营销。比如有一家售卖服装的小网店，它有自己的搜索行为和购买行为，但它的数量不大，不值得用这些数据去分析变现，BlueKai 就会与这些中小网站合作，通过汇聚众多中小网站的用户资料和行为数据，加工成受众定向标签，通过 Data Exchange 对外售卖。比如某些 DSP 想知道用户身上有什么标签，而它又没有用户信息，就可以向 BlueKai 购买或分成，BlueKai 再向网站分成。

BlueKai 同时提供面向媒体、数据提供商和广告主的一系列产品，包括 DMP、数据交换平台（BlueKai Data Exchange）以及数据分析系统。这几项产品都围绕一个商业目标展开，那就是帮助有数据变现需求的参与者能够自由、灵活地通过技术对接的方式与广告主进行交易。对于媒体或者其他拥有数据者，可以通过 BlueKai Data Exchange 将自己的数据公开式地出售给市场上的需求方，同时可以比较自主地控制定价；对于广告主，可以通过 BlueKai 提供的 DMP 产品和第三方数据标签，与自己的第一方数据结合起来，对自己的人群进行更灵活的划分，并按此购买广告。BlueKai 在其中所扮演的核心价值在于，尽管单看每一个媒体的信息都不具有太大的价值，但当达到一定规模之后，BlueKai 按照自己的受众定向技术对这些数据进行重新分类，就能让其蕴含的商业价值得以显现。

通过这种数据交换方式，广告市场上最有价值的数据资源被盘活利用了。数据拥有者不需要直接涉足复杂的广告业务，也可以对数据进行变现；而数据需求者也可以方便地找到数据购买来源，以快速提高自己广告投放的效果。BlueKai 也注意到了隐私的问题，它提供了一个接口，用户可以看到自己的资料被谁使用，也可以选择“捐给慈善机构”。而实际上这不过是一种规避风险的方式，基本上不会影响到 BlueKai 和中小网站原本的收入。有关隐私方面的问题，读者可以进一步参考 15.4 节。

Bluekai 提供大量细分的类别，它有着开放体系上的标签，如“对宝洁洗发水感兴趣的人”“想去日本旅游的人”，这些非常精细类目对于要做效果广告的广告主来说非常有意义，所以它的售价也很高。根据广告主使用目的和数据来源的不同，这些标签又分成如下的几种：Intent、B2B、Past Purchases、Geo/Demo、Interest/LifeStyle、Branded、Estimated Financial/Economic。这是一个比较典型的半开放的标签体系，其中的 Intent 部分非常类似于前文中的兴趣定向体系，这部分是由 BlueKai 根据通过 Data Exchange 收集的用户行为加工的。而其他部分，有的是由其他数据提供商直接提供，比如由 Bizo 提供的 B2B 标签；也有的是根据多家的数据融合决策而成，比如 Demo/Geo 标签实际上融合了 Bizo、DataLogix、Expedia 等多家数据提供商的数据源。

之所以说 BlueKai 的标签体系是开放式的，是因为它会根据数据的来源和市场需求不断拓展和调整标签的类别和内容，力求能够满足尽可能多的广告主的特质化需求。表 6-3 中列出了 BlueKai 主要的几种标签、覆盖用户量和主要数据来源。

表 6-3 BlueKai 标签体系主要类别

类别	描述	数据来源	用户规模
Intent	最近输入词表现出某种产品或服务需求的用户	BlueKai Intent	160+MM
B2B	职业上接近某种需求的用户	Bizo	90MM
Past Purchase	根据以往消费习惯判断可能购买某产品的用户	Addthis, Alliant	65+MM
Geo/Demo	地理上或人口属性上接近某标签的用户	Bizo, Datalogix, Expedia	
Interest/LifeStyle	可能喜欢某种商品或某种生活风格的用户	Forbes, i360, IXI, ...	103+MM
Qualified Demo	多数据源上达成共识验证一致的人口属性	多数据源	90+MM
Estimated Financial	根据对用户财务状况的估计作出的分类	V12	

2. AudienceScience



AudienceScience 是广告市场上首先明确提出受众定向这一概念的公司，并且长期专注于这方面的数据加工和算法建设。它的核心业务包括以下两方面。

(1) 主要提供面向 publish 的数据加工服务。比如《纽约时报》(New York Times) 自己有很多用户，也有很多在线数据，但很显然它的核心业务不是做广告，也不是做数据加工，它更愿意把数据交给 AudienceScience，AudienceScience 帮它加工一些有意义的用户标签，比如财经类用户、体育类用户。New York Times 的 BI 系统可以用这些标签分析哪些用户对哪些内容感兴趣，应该如何优化内容。

(2) AudienceScience 还直接运营一个效果广告网络，帮助广告主进行投放管理和优化，这里就用到了它分析得到的用户标签。

就其数据聚合和收入分成的模式来说，AudienceScience 与 BlueKai 有很多相似之处。两者主要的区别是，AudienceScience 并不通过售卖标签来获得收入，而是仅供委托他们优化效果的广告商使用，即通过运营一个自有的广告网络来变现，使用标签创造的营收按照一定比例跟提供数据的媒体分成。这样做的原因是 AudienceScience 认为数据加工业务在扣除媒体分成以后利润空间太小，而自营广告网络有可能获得更大的套利空间。

AudienceScience 其具体的商业流程是：网站（可以是广告主或媒体网站）先把自己的流量托管给 AudienceScience，并付给 AudienceScience 一定的技术服务费，AudienceScience 把数据加工成标签，首先提供给网站用以优化它的流量和用户体验。同时，它在自己的广告网络中对这些数据进行变现，变现的数据过来又可以与媒体分成。

随着近年来 RTB 模式的发展，AudienceScience 也逐渐从自营广告网络向整合的 DMP/DSP 的方向发展，因为不同于 BlueKai 是作为第三方的数据提供者，AudienceScience 加工用户标签的目的主要就是为了更好地服务自己的广告主，其为了优化广告主需求方的利益，融合了 DMP 的数据来指导 DSP 的投放效果也是自然的选择。

6.7 在线广告产品交互关系

本章系统性地讨论了在线广告的各种交易方式。在实际的广告市场中，这些交易方式又是怎样通过具体的产品联系起来的呢？图 6-12 示意性地表示了在线广告市场各种产品的交互关系。从媒体角度来看，有以下三种产品可以帮助其变现流量。

(1) 可以将广告位托管给广告网络，由广告网络决策广告投放，从赚取分成，如图 6-12 中的“媒体₁”。

(2) 可以将广告位对接到广告交易平台，以实时竞价的方式变现，如图 6-12 中的“媒体₂”。

(3) 也可以将广告位托管给 SSP，这样可以同时对接多个广告网络和 PMP 接口，并按照动态分配的逻辑选择变现最高的需求方（这一产品的具体情况我们在后文介绍），如图 6-12 中的“媒体₃”。




图 6-12 在线广告市场产品交互关系示意

对于广告网络来说，有以下两种需求方对接方式。

(1) 可以直接与需求方产品 TD 对接，通过后者将广告流量售卖给广告主，也可以让广告主自行投放。

(2) 将其剩余流量再导入广告交易市场，以实时竞价的方式变现，此种方式中的广告网络充当了广告交易市场的供给方。

SSP 是彻底代表媒体利益的产品，因此，它将广告网络、广告交易市场和 DSP 等都视为提供预算的需求方，并通过统一的网络优化功能来管理收入和确保媒体的用户体验。

广告交易平台是相对比较中立的，在供给方和需求方之间提供公开、公平的流量交换能力的平台产品。广告交易平台的流量可以来自于媒体、广告网络或 SSP，而需求方主要对接 DSP 进行变现，某些情况下也可以让某些广告网络以优先或者打底的方式接入。

从需求端来看，无论是广告主还是代理公司，主要通过两类产品来采买流量：一是面向实时竞价的 DSP 产品，二是面向非实时竞价的 ATD 产品。采用什么样的产品是由供给方的产品接口确定的。一般来说，实时竞价比较适合于采买定制化的人群，并进行深入的流量优化；非实时竞价则适合于简单、低成本的一些通用人群的采买。

6.8 延伸思考

1. 在搜索广告中引入程序化交易方式，是否是一个有前景的产品方向？
2. 重定向的广告效果往往显著高于其他定向方式，不过这部分是由于其人群选择的特殊性，应如何公允地评价一次重定向广告投放的实际增量效果？
3. 数据的交易与广告的交易有什么不同特点，应如何借鉴广告竞价的模式发展数据的竞价交易？

4.在与广告相关的数据交易中，数据采取限量或不限量的供应策略，会对流量和数据的市场价格产生什么影响？

第 7 章 移动互联与原生广告

通过前面几章的产品介绍，我们了解了计算广告从合约到竞价再到程序化交易的产品演进路线。可以说，进入程序化交易时代以后，互联网广告产业多方参与、规模化利用流量和数据的整个产品体系已经逐渐完善。广告从依附于媒体的简单变现功能已经进化成了独立的业务体系，在互联网行业中的地位举足轻重。但是从另外一个方面来看，广告毕竟是离不开用户产品的。目前的广告交易体系越来越倾向于直接使用第一方数据和第三方数据作指导，在独立的交易环境中完成投放，而广告与媒体内容的关系则在一定程度上被边缘化了。应该说，这并不是一个好的趋势，与内容基本独立的广告交易必然会在效果和用户体验方面碰到天花板。将内容与广告决策深度融合的原生广告产品是本章讨论的重点，这部分产品在整体产品演进过程中的位置如图 7-1 所示。




图 7-1 原生广告产品

需要说明的是，迄今为止，原生广告没有一个清晰的定义。实际上，从软文、搜索广告到社交网络中的信息流广告都有一些原生广告的意味，但也都只反映了原生广告的一个侧面。应该说所有将商业化内容与非商业化内容统一生产或混合排序的产品都可以认为与原生广告有关系，这样的产品方向经常被称为内容即广告（**content as ad**）。我们也会介绍几种常见的原生广告初级产品。

必须指出的是，原生广告得到充分的重视是在移动互联网时代到来以后。这是因为在屏幕较小的移动设备环境下，独立地展示和运营广告与内容遇到了巨大的挑战。于是，业界开始探讨将原生广告部分代替一般展示广告，提高移动环境下广告的变现能力。实际上，第一个真正由第三方提供的平台化的原生广告产品也产生于移动互联网。因此，从移动广告的角度出发，我们更能深切地理解原生广告产生的关键诉求以及它所面临的主要产品挑战。

不过，与内容结合的原生广告如何能够规模化、交易化运营是产品面临的一个棘手的挑战。根据现在市场上的产品探索，我们总结了一些原生广告交易化运营的关键点以及将会面临的主要挑战。虽然原生的时代尚未到来，我们仍希望与大家一起展望这样的产品形态可能会对互联网广告，特别是移动互联网广告，乃至整个移动互联网生态带来的变革性影响。

7.1 原生广告相关产品

在探讨原生广告的产品关键之前，我们先来看一下市场上早已出现的几种内容与广告深度结合的广告产品，目的是对这个问题形成一些感性认识。

7.1.1 信息流广告

信息流广告起源于社交网络。2010 年 4 月，Twitter 发布了“Promoted Tweets”产品，在其信息流中插入商业化的内容，如图 7-2 所示。这样的信息流广告后来也被其他的社交网络（如 Facebook、微博、QQ 空间等）广泛采用。信息流广告由于自然地出现在用户内容消费的主路径上，而且展示形式与内容非常接近，因此吸引的关注比较有效，这也使得其效果比一般展示广告有较大的提升。正是从这种信息流广告开始，大家开始意识到，内容与广告的有机融合对于提升广告效果十分有效，这也催生了对于原生广告系统性的探讨。




图 7-2 “Promoted Tweets”信息流广告示例

如今，信息流广告也出现在一些非社交类的媒体上，如 Yahoo! 新首页、今日头条等。这些适合于信息流广告的媒体都有一个共同特点，即信息流中的各条内容相关性并不强。在这种情形下，插入一条商业化内容在形式上不会显得太突兀，用户体验也会较好。如果

在一些垂直媒体的信息流中提供广告，则需要考虑上下文的影响，以达到原生的目的。实际上，在社交网站上投放信息流广告时，如果考虑与周围内容的相关性也会提升一些效果。

社交网络信息流中的内容是根据产生时间排序的，因此无法将内容与广告按同一准则排序，一般是将广告直接放在固定的位置上。

7.1.2 搜索广告

在竞价广告产品中，我们重点介绍了搜索广告，现在可以换一个视角再作解读。

搜索广告的展示形式与自然搜索结果基本一致，也可以看成是存在于同一个信息流当中。因此，它的高变现能力也部分地源于这种类原生的产品形式。另外，搜索广告的一个特点，即用一个明确的查询来触发广告，对我们探索原生广告也很有启发：要想真正做到“内容即广告”，显然在广告决策过程中要明确考虑用户当前的任务和意图，并直接根据这些来触发广告。

搜索广告与内容的混合方式有两种，一种是将广告在固定的位置上展现，另一种是将广告与内容混合排列在一起。当然，在实际的搜索引擎中，广告与内容也是来源于不同的服务，前者按照 eCPM 排序，后者按照相关性排序，两者混合的规则也是一些固定的逻辑，并没有实现按同一准则的统一排序。应该说，如果按照内容即广告的思路前进，那么在搜索引擎中，内容与广告按照同一准则的统一排序将会是一个有价值的发展方向。

7.1.3 软文广告

在这种广告类型中，内容本身就是为了委婉地宣传某种产品而生产的。很多网站的内容营销实际上指的就是这种软文广告。这种方式也从一个独特的角度体现了“原生”的意义：较高质量的软文往往让读者可以像接受普通文章一样接受其内容，因而宣传效果也会比较好。<http://news.pedaily.cn/201410/20141021372531.shtml> 给出了一条典型的软文“揭秘单品餐饮的暴利账本：一道冒菜如何年入 2 亿？”请大家参考。不过这种软文广告的生产和传播过程很难被标准化，往往只适用于比较大的品牌广告主，不是产品化交易的对象，因此并不是我们重点讨论的广告产品。

虽然软文本身离广告产品较远，不过也给我们提供了重要的启发：在内容的生产过程中，应该同时考虑到商业化的可能。虽然整篇的软文生产很难做到规模化，但是如果将内容中一些相对标准化的片段变成商业化信息如何呢？显然，这个方向是值得探索的。

7.1.4 联盟

在前面介绍广告网络时，我们提到了一种联盟（affiliate）模式，即由媒体从广告库中自由选择要推广的对象，并按照自己控制的展现方式进行推广。虽然说这是比较原始的广告产品形式，但也对原生的思路有一定启发：只有给媒体一定的选择广告的权限，才能比较容易地做到广告与内容在主题上的和谐，也才会产生像淘宝客那样可以将广告自由地嵌入博客和各种网站。

不过还是要说明，这样简单的联盟方式并不是我们理想中的原生广告形式。因为在这种方式下，数据基本上无法发挥作用，而且也并没有一个强大的第三方平台专业化地负责广告的运营和投放，因此其市场相对原始，规模化程度也有限。

7.2 移动广告的现状与挑战

移动互联网的快速发展对所有在线服务都产生了颠覆式的推动，在线广告行业当然也不例外。移动互联网广告的产品和交易形式可以视为 PC 互联网广告的自然延伸：无论是 PC 上展示广告网络的方式还是搜索竞价排名的方式都在移动流量被变现的一开始就被移植到了移动环境下。我们前面讨论的在线广告市场的大多数交易机制和产品形态在移动广告世界仍然是适用和存在的。不过，移动广告也存在着自己非常鲜明的特点，这些特点使得这一市场同时存在着巨大的机会和挑战，特别是存在着广告原生化的巨大动力。因此，我们将以移动广告为典型的场景，分析原生广告的关键产品方向。

7.2.1 移动广告的特点

由于移动互联网越来越显著的重要性，业界对移动广告产品逐渐产生了独立的思考 and 认识。在认清了移动设备的一些独特属性，特别是可以对人的行为模式进行全方位、全天候分析这一特点后，我们会发现，移动广告面临着前所未有的巨大市场机遇。

移动广告的库存将随着移动设备的爆发式增长而迅猛成长，这一点带来的流量红利当然是最大的机遇。不过，我们更关注的是从产品本身来看，移动广告究竟给我们带来了哪些新的机会呢？我们认为至少有以下两点。

（1）情境广告的可能性。从用户行为分析角度来看，移动设备与 PC 最大的不同是可以对用户行为模式进行全天候的监测和分析。移动设备的特点是一直跟用户在一起，并且从地理位置、生活状态、需求意图等各方面都能对用户有深入的理解。因此，在移动环境下，受众定向完全有可能做到从情境和意图出发，而不是仅仅根据兴趣推送商品。举个例子，根据简单的地理位置分析就可以判断用户是在家还是在上班，如果是在上班，那么就不应该向其推送游戏广告。

(2) 大量潜在的本地化广告主。广告发展到今天，可以说没有任何主流的渠道可以帮助本地化小商家做推广。电视、路牌这种品牌性媒体自不必说，就是在线广告在 PC 时代往往也只能定位到城市级别，这样的地域定向对于一个小区的理发店来说显然是粒度太粗了。而在移动环境下，GPS、蜂窝、Wi-Fi 等多种精确定位的手段使得基于精确地理位置的本地化广告变得可行。当然，精确地理位置也需要结合移动特点，用情境化的方式使用。例如，我们检测到一个用户早上沿着地铁线移动，并于八点半左右在国贸出站，那么很有可能他是一位正在赶时间的上班族，因此可以向他推送地铁站口麦当劳的早餐套餐。

7.2.2 移动广告的创意形式

上面说到，移动广告就其交易形态而言，与 PC 广告并无本质区别。但在广告的展现和转化路径上体现出比较独特的一面，这也使得移动广告在 PC 广告创意形式的基础上衍生出一些新的形式，如插屏广告和积分墙等。这些新的创意形式，一方面为传统的横幅广告提供了符合移动设备特点的补充，另一方面也使得大家开始专门探讨和设计面向移动的创意方案。就目前市场来看，移动展示广告主要的创意形式有横幅、插屏、开屏、锁屏、推荐墙、积分墙等，示例如图 7-3 所示。



图 7-3 移动广告形式示例

1. 横幅与插屏

横幅（如图 7-3 所示）是移动应用中产生比较早的广告创意形式，也是直接从 PC 广告的形式传承下来的。虽然形式上类似，但在移动广告中，横幅这种形式会有一些问题。首先，移动横幅广告的点击率远远高于 PC 横幅广告，经常会达到 2%~3%，当然其中有很大比例是误点击。横幅的误点在移动设备上会严重打乱用户的任务，因此对用户体验的

伤害也较大。其次，广告主观察到的转化率很差，这一方面是由于大量的误点击不会产生任何效果，另一方面是由于广告主的后续转化体系在移动上不够成熟，当然这并不是横幅独有的问题，我们后面还会提到。

图 7-3 中示例的插屏广告与视频中的暂停广告非常类似，往往也是出现在游戏或其他应用暂停时。这种广告同样有着点击率虚高、转化相对较差等特点，而且可能比横幅更加严重。

虽然横幅和插屏有这些问题，但是由于广告网络、广告交易平台等成熟交易体系的存在，这种标准化程度较高的形式最容易形成规模。因此，到目前为止，横幅和插屏广告仍然是移动展示广告最主要的形式之一，并且主要以竞价方式售卖为主。另一方面，正是由于这些广告形式在移动设备上面临的新挑战，才让业界认真思考移动广告更加有效的产品形式。

2. 开屏与锁屏

开屏是在一个应用打开时在加载页面展示的全屏广告，读者在新浪微博、网易新闻等应用加载时经常可以看到。开屏可以说是移动广告形式比较好的探索之一，因为用户在等待应用打开时还没有明确的任务，因此不会对广告很反感。另外，全屏的展示形式让这种广告的品牌价值较高，因此在实际售卖时往往以合约方式为主。

与开屏类似，还有一种锁屏广告，他是在用户的移动设备被锁定时展示的广告，其特性与开屏广告很相似，对用户体验的影响也较小。

3. 推荐墙与积分墙

由于移动设备中应用生态体系的存在，尚有相当比例的移动广告预算是以推广应用下载为目标的。因此，也产生了一些专门针对此类推广需求的广告形式。最直接的下载类广告形式是推荐墙（offer wall），如图 7-3 所示。从技术上说，这可以类比于上一章提到的站外推荐。不过，推荐墙并没有成为移动应用推荐类广告最主要的形式。

实践中更常见的是一种叫“积分墙”的产品。积分墙同样是向用户推送应用下载类广告，不同的是在用户下载并激活该应用后会得到一定的积分。这些积分往往可以兑换游戏币、电话卡等虚拟物品，以此刺激用户的下载行为。积分墙很容易让我们联想起返利网这种推广形式。这样的形式虽然直观的点击和激活都很好，但是后续的转化行为往往不能得到保证。不过，在特殊场景下，积分墙这种推广方式也有下列特殊的价值。

（1）应用冲榜。当开发者开发的新应用上线时，往往需要短时间内的大量下载冲高在 Apple Store、Google Play 等这类应用商店里的排名，因此积分墙是一个很好的渠道。不过在中国，由于 Android 市场非常割裂，因此积分墙主要流行于 iOS。而 Apple 从 2013 年开始也明确表示会打击这类用积分推广影响榜单的方法，因此其前景并不乐观。

(2) 游戏开服。在线手机游戏增加新的服务器时，需要短时间内大量玩家进入以形成社区环境，因此也常常选择积分墙。

7.2.3 移动广告的挑战

虽然移动广告前景广阔，但由于与 PC 环境巨大的差异，很多在广告产品中业已形成的经验和规律在移动环境下也遇到了不小的挑战。在这些挑战里，下面的三点尤其值得关注。

(1) 应用生态造成的行为数据割裂。在目前的移动互联网环境中，并没有形成 PC 时代那样的以 Web 为核心的生态，取而代之的是以应用为主的生态体系，这有些像 PC 早些年的情形。

应用与 Web 相比，虽然在用户体验的流畅性、功能丰富性方面有一定的优势，但也带来了商业产品的挑战：各应用之间相对独立，没有 Web 环境下超链接那样的组织体系，因此数据的来源也相对割裂，整合起来比较困难。虽然理论上说，移动环境对用户的了解更加深入，但实际操作中数据的获取更加困难。Web 生态下常用的数据交换接口，如 JavaScript 跟踪代码之类，在应用生态中需要用更加复杂的 SDK 来解决，可行性往往大打折扣。

(2) 许多 PC 时代广告主移动化程度还不够，无法充分消化广告带来的流量。虽然原理上讲，将一个 PC 的广告投放迁移到移动上非常简单，但在实际操作中会遇到后续转化流程上巨大的麻烦。

首先，是落地页展示和交互模式的巨大差别。在图 7-4 中，我们对比了一个成熟广告主的 PC 端与移动端落地页。很显然，如果将 PC 端的落地页直接照搬到移动投放中，交互体验会非常差，效果当然也不会好。这还仅仅是落地页，如果涉及后续转化流程的多个页面，可以想见广告活动的移动化不仅仅是个系统工程，而且很可能是要等待广告主自身业务移动化的进程。就目前而言，移动端业务交互较完善的中小广告主的比例仍然不算高。



图 7-4 同一广告在 PC 端的落地页（左）和移动端的落地页（右）

有人会有疑问，既然移动环境为应用生态所主导，为什么广告主不能把落地页做成应用，再用广告推广此应用呢？对于中大型的广告主，如果业务是用户粘性较高、周期性访问的，这样的策略应该更加合适。但对于大量中小广告主或者那些业务本身在线上交互较浅的广告主而言，指望用户下载应用来完成广告转化的过程是不现实的。试想，你会为了了解一次 4S 店组织的试驾活动而专门下载此 4S 店开发的应用吗？

为了让广告主后续的转化流程更符合移动环境的用户使用习惯，移动广告的落地页也产生了一些新模式，比如点击广告直接拨打广告主服务电话或者发送短信，这也都是为了让后续的转化流程更加顺畅。

（3）移动广告的产品形态需要一次革命。上面谈到的传统横幅广告在移动环境下遇到的问题，实际上反映了产品形态的深层次问题。在传统的在线广告产品形态中，广告位总是和内容放在不同的单元中，以相对独立的产品运营。但到了移动环境下，由于屏幕的尺寸减小了很多，如果被广告位再占据一块空间，那么变现与用户体验的矛盾就显得非常突出了。

那么，移动广告产品形态的变革有哪些方向呢？显然，前面介绍的原生广告是个值得探索的方向。原生广告的目的就是要解决广告与内容对立的现象，希望广告也能在用户正常的内容消费中和谐地存在。如果这样的产品能够发展起来，那么也就不存在广告与内容争抢版面并严重损害用户体验的问题了。正是基于此，我们才将移动广告和原生广告这两个并非并列关系的问题在这一章中一起讨论。在我们看来，只有原生化才是移动广告的未来。

与上面我们介绍的那些原生广告产品相比，移动广告对原生化提出了一些新的要求，最重要的一点，在上面的那些原生广告例子中，运营原生广告的都是媒体本身，显然，这样的方式只有大中型媒体才有能力做。于是，如何以独立广告平台的身份提供原生广告，像普通展示广告那样进行交易的市场，将是原生广告面对规模化以及大量中小媒体的需求时必然碰到的问题，这也是我们下一节要展望的产品重点。

7.3 原生广告平台

我们从原生现有的产品状态和共同特点出发，来看看市场真正需要的原生广告平台的产品特征。注意，下面我们讨论的基础是由独立广告平台，而不是媒体本身提供广告。

7.3.1 表现原生与意图原生

从 7.1 节提到的几种原生广告产品中可以发现，“原生”这一概念实际上有两种不同的诉求：一种诉求是将广告的展示风格和样式变得与内容相一致，从而做到产品形式上的“原生”；另一种诉求是将广告的投放决策逻辑与内容生产相一致，从而做到用户意图上的“原生”。我们把这两种原生分别称为表现原生与意图原生。

表现上的原生性需要媒体来控制广告展示形式。从信息流广告、搜索广告这些例子中可以总结出原生广告的最重要也最直觉的产品原则，即内容与广告的展示形式要尽可能一致。从广告有效性原理来看，这样做有助于用户自然地给予广告更多的关注。而在独立原生广告平台的情形下，要做到广告与内容表现上的和谐，只能由媒体来设计和控制展示样式。

意图上的原生性需要媒体明确提供广告需求。如果进一步比较搜索广告和社交网络信息流广告，会发现前者的效果要远远好于后者。究其原因，是因为搜索广告的投放决策是基本完全按照内容结果的展示原则进行的，也就是说，我们在以投放内容的方式匹配广告。根据这一点，可以得到原生广告的另一产品原则，即应该用媒体提供的广告需求来筛选广告。

在 7.1 节介绍的原生广告产品中，社交网络信息流广告侧重于表现的原生性，而搜索广告在表现和意图两个方面都是原生的。大体而言，对于那些用户直接意图比较模糊的用户产品，如社交网络、新闻列表等，表现原生的广告产品就足够了；而对于用户直接提供明确意图的用户产品，如搜索，则最好要做到意图上的原生性。除了这两类产品，互联网上还有大量的用户产品在实际上有比较明确的用户意图，但是并未以查询等方式直接提供，并且表现形式上也不是规整的信息流模式，联盟或软文适用于这样场景的原生广告形式，

这实际上也是兼顾了表现和意图上的原生性。但是，联盟和软文并不能像其他广告产品那样以计算的方式来优化效果，并且通过广告市场规模化地交易，因此在这方面存在着探索空间。

比较理想的原生广告平台应该能兼顾表现原生和意图原生的要求，并且仍然可以以第三方平台的形式规模化地运营，而这样的设想在移动广告的推动下也已经形成了一定的产品趋势，我们将在下一节中来介绍。

7.3.2 植入式原生广告

在一个第三方运营的原生广告平台中，媒体应该提供哪些合理且有指导性的广告需求呢？简单来说，一是要判断用户当前的意图，二是要确定根据用户的意图提供什么信息。例如，在一篇旅游博客上，媒体运营方可以很容易地判断读者一般是为了了解该目的地的旅游信息，进而可以向广告平台请求同一目的地的酒店作为广告。我们相信，通过这种方式，可以真正挖掘一家媒体的商业价值。这并不同于传统的展示广告中的上下文定向，因为在上下文定向中，是广告平台，而非媒体采用比较粗浅的自然语言处理方法获得页面的主题。对于用户的意图，这种面向全行业的自动化往往行不通，而如果有了媒体的主动参与，用户意图提取起来就容易得多了。

广告平台提供的是结构化的付费内容。由于媒体控制广告展示，广告平台返回的就不能是成型的图片或文字链创意，而必须是一些结构化的信息作为媒体拼装创意的素材。因此，原生广告平台的广告库的结构不是简单的广告投放和创意信息，而是各行业结构化的付费内容，这一点将会显著改变广告业态的结构。

如果按照上面的逻辑来设计和运营一个原生广告平台，实际上可以称为一个“植入式广告”的投放系统，这样的系统逻辑是在内容的行文中自然地植入付费信息。我们仍然以上面提到的旅游网站为例，用图 7-5 中的概念性示例看一下整个投放决策过程。

图中的广告请求发生在某拉萨旅行游记的网页上。在这样的内容中，除了游记本身，编辑很自然地会推荐拉萨的酒店，以方便读者。然而我们知道，酒店信息是高度商业化的内容，有没有可能以付费内容的方式从第三方广告平台获得呢？这显然是可行的。




图 7-5 植入式原生广告投放过程示意

(1) 首先，网站的运营者给出用户的意图，并用一个结构化查询“类型=酒店；地点=拉萨”来表示。这里的“类型”限定的是需要什么样的付费内容，而“地点”则是与此类型相关的查询条件。

(2) 广告投放机收到此查询后，会去酒店库中检索符合条件的酒店。在得到候选后，广告投放机仍然要根据 eCPM 对各个候选排序，而在此排序过程中，人群标签仍然可以使用，比如收入水平较高的用户可能对高星级的酒店点击率较高。

(3) 排序完成以后，将结构化的酒店信息拼装渲染装入页面的过程由媒体来控制。媒体可以自由地根据自己页面的风格、色调、字体等从酒店信息中选取需要的字段，加工成最终展示出来的创意，而这样的创意是可以做到与内容无缝融合的。在实际产品中，如果将每一次的广告渲染都交由媒体处理，既对媒体提出过高的技术要求，又不利于点击监测、反作弊等环节的实施。因此，我们可以采用一种等价的方法：由媒体按照广告平台的格式提供渲染模板，在广告平台审核通过后，每次展示按照此模板来拼装渲染，最后返回的与普通广告一样，仍然是一段 HTML 片段。

以植入式广告的逻辑来运营原生广告，是希望在内容生产的过程中，当某些片段商业价值较高时，将这些内容按照严格的条件交由广告平台来生产。这样做，不仅可以避免现有的展示广告产品对用户体验的打扰和伤害，而且有可能将展示广告变成类搜索广告，真正为媒体创造高价值的变现能力。

不过，不要指望这样的产品能在一夜之间变成主流，因为这样的广告体系与现有体系差别是巨大的。它可能将会面临以下两方面的挑战。

(1) 媒体参与让广告多了一个自由度，运营难度大大增加。在前面介绍的各种广告产品中，媒体对于除了品牌广告部分的交易，基本上都可以简单地加投放代码或 SDK 来完成。这虽然带来了引发原生广告讨论的许多问题，但也极大地方便了媒体的流量变现需求。但是无论是“原生”还是“植入式”，从字面就可以理解，没有媒体一定程度的参与是不可能的。如果媒体以图 7-5 所示的方式参与广告交易过程，从生成用户意图查询到渲染模板的设计，需要做不少的工作。所以，尽管原生广告对于媒体用户体验和变现能力都有帮助，但要想让中小型媒体参与到这样的交易过程中，需要一个较长的市场培育和产品教育过程。

(2) 大量分行业、结构化广告信息的建立需要时间。原生广告处理的信息从原来的广告创意变成了结构化的付费内容。然而，即使是目前比较大的广告平台，实际上也还没有成规模地积累起这样的付费内容库，它们有的都只是广告创意。唯一已经积累起一些付费内容库的产品是 DSP 中的个性化重定向，其单品库主要集中在电商行业。而大量的非商业化行业，如新闻、视频等，实际上也存在付费推广自己内容的需求，而这部分的内容库都需要市场慢慢积累。

7.3.3 产品案例

以独立广告平台方式运营的原生广告产品在市场上还处于刚刚萌芽的阶段，我们以 2014 年 InMobi 发布的产品为例进行介绍。另外，有关分行业结构化信息作为付费内容的引入，我们将介绍一家名为 OutBrain 的创业公司。

1. InMobi 原生广告



作为一家总部在印度的广告技术公司，InMobi 在创立之初就把握了移动互联网广告的全球化的特点，大力开阔全球市场，首先避开竞争激烈的北美、欧洲市场，InMobi 把视角对准印度周边的新型市场，如印度尼西亚、马来西亚、沙特阿拉伯等，等有了一定实力站稳脚跟后 InMobi 再进入北美市场、欧洲等市场，经过不断的全球化拓展的努力，InMobi 成为仅次于 Google Admob 的全球第二大移动广告平台，覆盖到全球 165 个国家和地区的 7.59 亿消费者。InMobi 在 2012 年的营收为 6000 万美元，2013 年就增长到了 1.04 亿美元，发展势头相当迅猛。

在发展移动广告平台的过程中，InMobi 发现应用比网站更加重视用户体验，而沿用 PC 端的传统横幅广告显然会影响 App 的用户体验。对移动端来说提升用户体验就可以提升流量变现能力，由于移动端的环境限制相对于 PC 端更重要，InMobi 在洞察到这一点后，在 2014 年年初推出了原生广告平台。原生广告能够完全融入应用本身的内容、场景和交互方式，不会打断用户与移动 App 的交互和体验，用户也不会有突兀的感觉，因而可以最大限度地维护用户体验。

InMobi 原生广告的示例如图 7-6 所示。在即时通信、应用搜索、桌面或新闻等各类应用中，都可以以本场定制化的形式展示 InMobi 提供的应用下载类或品牌类付费信息，并且根据供给方的需要对信息进行裁剪和排列。



图 7-6 InMobi 原生广告示例

在推出了原生广告后，InMobi 广告流量变现能力相对传统的横幅广告提升了 5 倍以上。更重要的是，一些高端的应用更加愿意尝试这种广告形式，这将会给移动广告市场带来深远的正面影响。当然，目前的原生广告在部署过程中还远远不能达到自动化，仍然需要 InMobi 工程师的参与，因此市场推广进程并不快，也需要更加方便快捷的媒体解决方案。

2.OutBrain



OutBrain 是一家以色列的创业公司，它提供的是网络推荐引擎服务，CNN 等媒体都是它的客户。它会依据读者的兴趣，采用基于行为定向的推荐技术，在文章末尾呈现一系列的推荐阅读。对这些内容媒体而言，它提高了页面浏览量和读者互动度。同时，它也在推荐内容中以付费内容这一原生广告的形式直接推介广告主的内容而不是广告创意。在

comScore 2013 年的调查中，有超过在 10 万家媒体采用了 OutBrain，每月产生的推荐请求总量超过 1500 亿。

从原生广告的角度来看，OutBrain 实际上迈出了重要的一步，那就是从投放广告创意变成了投放付费内容。这样的变化使得效果广告达到了以单品为核心的推广模式，从而与品牌广告彻底差异化，而这样的单品库也正是我们上面讨论的原生广告的基础设施之一。另外，这种模式为过去一些无法投送广告的内容类媒体创造了有效的营销渠道，从而拓展了整个广告市场的服务对象。当然，这样的运营方式的难点在于如何从新闻品类拓展到其他更广泛的品类。

7.4 原生广告与程序化交易

在讨论到原生广告后，本书的话题似乎来了个 180°的大转弯：从受众购买、程序化的市场趋势变成了在媒体深度参与下将广告融合到内容中。读者不免会产生这样的疑问：这两条道路是不是通往同一个方向呢？原生广告与程序化交易的产品结合点在哪里呢？

要回答这些问题，请大家先观察和思考一个现象：搜索广告是否有程序化交易的可能呢？显然，我们没有见到过这种产品场景。不过在 Facebook 的信息流广告中却有按照广告主上传的人群库投放的方式，这虽然不是程序化交易，但目的却很类似，而且也很容易改造成 RTB 的交易方式。本书前面提到，搜索广告和信息流广告都是原生广告的特殊形式，那么为什么在程序化交易这一点上两种形式的接受程度不同呢？

实际上，关键问题就是原生广告的触发是否根据用户意图进行。在明确提供用户意图的原生广告中，完全开放地进行 RTB，很难控制付费结果的相关性。例如，对搜索而言，能够做到良好相关性的只有 Google 这样的大平台，而引入大量 DSP 参与竞价，就很难保证结果质量。因此，在这种情形下，采用单个技术能力较强原生广告网络（也可以自营）的方式比较可行。而如果是像社交网络信息流这样的原生广告环境，由于用户意图并不明确，也不要求广告依此触发，完全可以考虑用程序化交易的方式来运营，而且我们认为这也是原生广告未来的发展趋势之一。

7.5 延伸思考

1.对于大型广告主和中小广告主，移动互联网营销相比 PC 互联网营销来说，发生了什么有利或不利的变化？

2.移动设备与 PC 的跨屏营销主要需求场景有哪些？

- 3.游戏联运是移动上常见的泛广告产品，同时游戏也是移动广告的主要广告主类型之一。如果某公司同时运营移动广告网络和游戏联运产品，这两者应该如何分工协作？
- 4.请探讨 CPM/CPC/CPA 等计费模式在原生广告中的适用场景。

第 8 章 在线广告产品实践

根据前面对计算广告产品和业务模式的讨论，从广告和泛广告变现的角度来看，在互联网市场上主要有三种资产能够变成钱，分别是数据、流量和品牌属性。后两项是媒体的专属，而第一项既可能来自于媒体，也可能来自于第三方的数据拥有者。在当今越来越复杂的广告交易和数据变现市场中，如果从实际需求的角度来看，不外乎有下面三类问题。

（1）媒体如何利用合适的广告产品更好地变现？媒体利用广告手段来变现，要兼顾短期收益和长期品牌价值提升的双重目的，如何合理地利用自有销售渠道以及各种供给方的广告产品以平衡这两方面的目的，是此问题的主要关注点。同时，媒体往往也拥有一定量的数据，将数据变现和流域流量变现结合在一起，也是媒体需要考虑的。

（2）广告主应选择何种广告平台，结合什么样的数据来完成高效的营销？广告主对于广告市场的可参与程度比媒体要深入，根据营销活动阶段与目的不同，需要谨慎选择合适的需求方产品，并通过第一方数据与第三方数据的帮助来优化营销效果。

（3）拥有数据的第三方组织如何利用广告市场将自己的数据变成钱？数据变现的问题在广告交易中得到了相当程度的发展，不过仍然处在比较初级的阶段。高价值数据的所有者如果想在广告市场变现，也有深入参与和简单参与两种方案，而且特别需要根据数据和广告主行业的特点来加工数据。

本章并不会谈到新的产品，主要是从广告市场几种主要角色的视角出发，帮助大家直观地了解如何结合业务需求选择和使用广告产品。无论您是用户产品的运营者、在线商品服务的提供者，还是其他数据的拥有者，了解这些实战环节都会对您按照互联网规律运营好自己的产品有帮助。

8.1 媒体实战

这里所说的媒体指的是一切拥有流量的 Web 网站、WAP 网站、HTML5 网站、PC 或移动应用程序等。媒体的变现渠道无非是面向终端用户和面向客户两种，而除广告以外的面向客户的很多形式（如游戏联运、免流量下载等）的产品本质与广告是一致的。如果用广告形式变现，前提是其交互界面可以加入广告位，或者一些内容中可以以原生的方式混入付费内容。除了面向客户的广告变现，媒体还有其他面向用户的变现手段，利用应用直接收费或者内置订阅或付费等，这些本书不详细讨论。

媒体利用广告市场的目的无非是获得收入。不过在获得收入的同时，一定要特别注意广告产品给用户体验带来的负面影响，这一立场是与广告市场其他参与方不同的。坚持利

用高质量的广告变现有利于媒体长期保持和提升自己的品牌价值，从而在优先销售的广告上获得更高的品牌溢价。不过对大量中小媒体而言，很难在品牌销售上找到切入点，因此重点关注的是即时的单位流量变现能力，即 RPM。

媒体选择合适的广告产品主要考虑以下几方面因素：是综合性媒体还是垂直媒体？媒体的品牌价值如何？媒体的流量是否足够大？媒体是否有高价值的数据？根据这几方面因素，媒体在进行商业变现时的决策逻辑如图 8-1 所示。下面我们将介绍此决策过程中的关键点。




图 8-1 媒体利用广告变现决策过程示意

8.1.1 变现方式和产品决策

在移动互联和广告实效化充分发展的今天，我们建议媒体首先要考虑的变现方式是原生广告。如果你的内容中有内容流、列表等适合做原生广告的形式或者其他一些可以商业化的内容段落，那么就可以考虑用原生的方式加入付费内容。原生广告的变现产品落地有两种选择。

(1) 如果流量充分，可以自行运营原生广告平台（如站内的搜索或新闻应用的内容），特别是当站内搜索有足够的流量时，在搜索结果中插入原生的付费结果是最需要重视的变现方式。这些做法对广告主的质量、相关程度都可以最好地控制。

(2) 如果流量不充分，那么合理的方案是与其他原生广告平台或相关行业的搜索广告提供商合作，不过如第 7 章中介绍的，原生广告平台在产品 and 市场落地方面还处于比较初级的阶段，实际操作难度会比较大。

总之，原生广告从趋势来看应该给予很高的重视程度，但对中小媒体而言目前还并不是一个可以规模化变现的市场。

如果采用一般广告形式变现，首先要判断的是媒体是否具有比较有价值的品牌属性。如果是这样，首先应该考虑通过合约的方式售卖品牌广告：在一些强曝光的广告位（如门户首页的特型广告位）上，应该采用 CPT 结算的广告位合约；而在其他一些通用的横幅位置上，我们推荐采用按照 CPM 结算的展示量合约，而且售卖的标的应该是定向以后的人群标签。当然，在今天中国市场中，后一种也是以 CPT 方式为主，不过我们仍然认为其有向 CPM 定向广告演进的动力。首先考虑合约广告，是因为其品牌溢价的能力，这往往使得它会比一般的竞价广告有更高的 RPM 水平。同时，一旦建立了品牌广告销售体系，在采用其他竞价广告时，需要特别注意是否会对品牌广告有制度和价格上的冲击。

一般来说，为了维持价格水平，媒体的合约广告售卖率不会很高。合约广告未能变现的剩余流量就需要采用其他竞价广告了。在行业垂直媒体和综合媒体上，竞价广告的策略方式有所不同。如果是汽车、房产、电商这类行业垂直媒体，考虑到用户明确的意图和媒体价值的提升，一般来说只能运营一个行业垂直的广告网络；如果是综合类媒体或者视频、音乐这类非商业行业的垂直媒体，那么可以采用对行业无限制的水平广告网络，在对广告质量高或媒体流量足够大时，可以考虑自建广告网络，否则更便捷的方式是将流量卖给市场上较大的广告网络。

除了广告网络，当然还需要考虑新的程序化交易模式。程序化交易主要有两种选择：公开的交易市场和私有的交易市场。这两种市场的选择逻辑与前面的广告网络类似：当对广告主类型、质量有较高要求时，最好采用私有交易的模式，控制好 DSP 的准入门槛和制度，特别是当媒体主要依赖品牌广告时，与品牌售卖政策有冲突的行业性 DSP 要避免接入；而当对广告主质量没有特殊要求时，可以选择公开交易的市场。不过，程序化交易其实并非简单的广告网络升级，特别是在私有交易市场中，原有的品牌售卖需求也可以在更高层次上得到满足，并且通过竞价的模式提高收益。因此，拥抱程序化交易，提升品牌售卖的效率，是高质量媒体在当今必须考虑的方向之一。

当媒体同时通过销售品牌广告、多个广告网络、程序化交易市场等产品形式进行变现时，可以使用统一的 SSP 来分配流量。不过由于市场上广告网络数量的减少和程序化交易的快速发展，SSP 正在变得与广告交易市场越来越同质化。

8.1.2 数据支持方案决策

媒体在确定了利用广告变现的产品形式和交易方式以后，还需要考虑这些产品需要的数据支持，而且这一点从某种意义上更加关键。选择什么广告变现方案需要数据支持呢？根据图 8-1 所示，当有 CPM 定向广告、自营广告网络或私有交易存在时，需要考虑这一问题。

在按 CPM 售卖的定向展示量合约广告中，媒体需要提供人群的分类体系供广告主来购买，这一点往往需要数据支持，否则就只能提供地域定向了。由于面向品牌广告主，人口属性定向比较重要，因此需要有相关的数据来源，或者在没有直接数据来源时利用行为数据建立人口属性预测的模型。除了人口属性，根据行为的兴趣分类也经常用于 CPM 定向广告。

在自营广告网络或私有程序化交易中，提供受众标签的目的是让广告主或 DSP 有足够的流量选择能力，从而提高整个市场的流动性。因此，在这两种情形下，媒体也需要获得受众标签的能力。另外，在这两种情形下，由于市场是竞价交易的方式，标签的粒度可以很细，品类上也可以很丰富，其目的都是为了驱动直接效果类广告。

获得这些人口属性或兴趣标签需要一个数据管理和受众定向的平台。如果媒体自身拥有的相关数据比较充分，另外又有合适的产品技术团队，出于数据安全灵活性和快速迭代的考虑，可以自建受众定向平台支持业务。不过，对于大量的中型以下媒体，要么是没有充足的相关数据，要么是不值得投入一个专门的团队，在这种情形下，不妨直接选择第三方的 DMP 产品，将数据委托其加工，同时从 DMP 获得更充足的通过第三方数据加工的、更为精准的受众标签。

8.2 广告主实战

广告主指的是所有以付费方式推广自己的品牌、产品或内容的组织。在互联网的环境下，广告主的营销目的差异化很大，因此也需要合理地选择广告市场中合适的产品，否则很有可能与其营销目标背道而驰。

广告主对营销方式的选择，主要要考虑几方面的因素：是推广品牌还是直接销售？是否有自己的第一方数据可以用于营销？对新客和老客的营销重点如何？根据这几方面的因素，广告主选择在线广告产品时的决策逻辑如图 8-2 所示。下面我们将介绍此决策过程中的关键点。




图 8-2 广告主在线营销决策过程示意

影响广告主在线营销推广方案的第一要素是推广的目的。根据品牌 and 效果这两大类不同的推广目的，应该选择的推广产品和策略也大相径庭。

如果推广的目的为直接转化，也就是直接效果广告，那么先根据是否利用广告主自己的第一方数据做渠道来进行选择。在没有或不用第一方数据的情形下，可选的效果类推广渠道主要有搜索广告、展示广告网络这类按 **CPC** 结算的渠道以及垂直行业入口、返利网这类主要按 **CPS** 结算的渠道。一般来说，展示广告网络用于效果营销时的效果，与搜索广告相比还有不小的差距，因此主要还是作为搜索的辅助渠道在预算充足、**ROI** 要求不是很严格的情况下采用。当然，在搜索广告流量不容易获得时，投放网络有助于扩大人群的触及，对总体营销规模的扩大有帮助。当需要高 **ROI** 的营销渠道时，搜索广告几乎是必不可少的选择，也是效果营销领域最受重视的渠道。不过搜索广告大量关键词选择、管理和出价是非常复杂的优化过程，除像京东、携程这样的大型广告主之外，一般都是通过专门的搜索引擎营销公司来投放。不过，搜索广告一般是按照 **CPC** 结算的，在实际效果优化方面有比较多的工作要做。除了搜索广告，我们要特别建议的是：

对于直接效果类推广需求，需要特别重视垂直的行业入口渠道。

这里的垂直的行业入口指的是用户在本行业相关需求主要的流量来源。例如，对于应用下载行业的应用市场和线下预装渠道、对于手游行业的联运渠道、对于淘内电商的聚划算渠道、对于线下商户的团购渠道等。实际上，这样的垂直行业入口是直接效果类推广非常关键的渠道，也是首要的选择之一，因此我们在图 8-2 中重点标示出来。在返利网也可以达到很高的 **ROI** 水平，有时甚至还会高于搜索广告，不过由于存在大量广告主老用户经过返利网下单的情形，其实际效果，特别是在获取新客方面的效果并不很理想。

如果广告有一些有价值的第一方数据来源，并且有一定的技术实力将其加工利用，那么除了上面的搜索广告、展示广告网络等渠道外，还可以考虑利用 **DSP** 进行精准的、定制

化的人群选择和投放。这里应该选择的 DSP 类型是那些效果类的、按照 CPC 或者 CPS/CPA 结算的 DSP。在通过 DSP 投放时，对于 CRM 或老客再营销类需求可以采用重定向的策略；对于新客的拓展和营销，可以采用 look-alike 的策略；而对于那些有丰富单品、流量较充足的大型在线服务提供商来说，还可以与 DSP 进行深度的数据和商品库对接，采用个性化重定向的方式在广告渠道商直接展示动态的单品创意。利用第一方数据的精准定向，从效果的角度来看，有时可以做到与搜索引擎相比肩的水平，不过，这样的营销对于广告主来说有一定的技术门槛，因此在中小广告主中并不十分实用。

如果营销的目的是品牌推广而非直接转化，那么应该考虑一些以用户接触为主的合约广告产品。我们在第 4 章中介绍过，这类产品有按 CPT 结算的广告位合约和按 CPM 结算的展示量合约。如果广告宣传的是“双十一”促销这样的阶段性主题活动，那么一些强曝光位置上的 CPT 广告是重要的选择；如果是一般性的品牌推广，并且结合有特定的人群策略，那么采买受众定向的 CPM 广告比较合理，不过有时，广告主确定的推广策略不一定能为媒体提供的受众标签所表达，在这种情形下，可以通过 DSP 按照自己的人群划分在 ADX 中投放品牌广告。这种以服务品牌广告为主的 DSP 与前面说的效果类 DSP 有所不同，它一般采用 CPM 跟广告主结算，并向广告主收取一定比例的服务费用。

在当今以产品技术为核心的互联网广告市场中，广告主的营销也不是仅靠媒体采买和价格谈判完成的。对于大中型的广告主来说，在上面各种营销产品的使用过程中，有两种情况需要自建相关的技术平台。首先，在使用搜索引擎营销时，需要一个专门的选词、出价及优化 ROI 的产品，尽管产品服务本身可以从市场上购买，但是与广告主自身数据的对接以及行业相关策略的制定还是需要大量细致的产品技术工作。实际上，对于大型电商这样的广告主来说，SEM 往往是其内部非常重要的产品。其次，当定制化标签的投放量很大时，广告主可以自建 DSP 来投放广告，相比于采买其他 DSP 的服务，这样做在数据整合、效果优化方面都会有一定的优势，当然，如果 DSP 广告量不是很大，这样做的必要性不大。

8.3 数据提供方实战

在线广告交易使得那些拥有数据、但是既不是广告主又不是媒体的组织也可以参与到其中。这种数据提供方的例子有很多。例如，手机游戏流量分析产品可以收集到与游戏相关的许多数据；汽车牌照摇号网站可以收集到近期可能购车的非常精准的人群数据；电信运营商可以从信道上得到用户的网站访问或搜索行为数据。这些数据在谨慎地考虑用户隐私保护以后是可以服务于广告投放，从而获得收益的。因此，了解通过广告市场来变现这些数据对于各种类型的互联网企业都非常有价值。

一个组织拥有数据并不等于数据值得变现。在考虑数据变现之前，需要先对数据的价值有合理的评估。评估的基本方式是“用户数×平均用户价值”。这里的用户数，就是该组织在一段时间内能够收集到数据的用户总量；而平均用户价值，就是单个用户可以获得的广告价值，它主要被 RPM 水平、单个用户被广告有效触及的展示次数这两个因素的影响。其中 RPM 反映了数据的价值密度，而广告触及次数则需要通过扩大媒体接触来实现。

如果确认拥有的数据有商业价值，那么就可以考虑如何变现了。数据提供方变现决策的选择如图 8-3 所示。一般来说，对于那些数据量有限、不太值得自行加工的数据拥有者来说，可以委托其他 DMP 加工数据，并将得到的标签通过数据交易平台在广告交易的过程中售卖，对于大量的中小互联网服务提供商来说，这是一个简单易行的数据变现方案。不过，选择通用的 DMP 往往很难发掘其中独特的价值，因此如果拥有大量高价值的数据，还需要考虑其他的变现方案。

大量数据通过广告市场的变现可以通过直接运营广告产品进行，也可以通过将数据售卖给需求方进行。关于这一点，需要首先根据团队能力、媒体来源与销售计划等诸方面的可行性认真评估。当不具备开发和运营一个完整广告产品的能力时，还是应该采用直接出售数据的方案。需要特别指出，成功运营一个广告产品决不是简单地搭建一个广告系统就够了，而是需要技术、产品与商业模式上的贯通与执行。为了变现数据运营广告产品，也有两种选择：当拥有的数据集中在某个人群覆盖率有限但价值很高的垂直行业（如汽车、医疗等）时，因为只有一小部分的媒体流量可以被数据所指导，选择供给端的产品（如 SSP、ADN、ADX 等）是不合适的，正确的方案是搭建一个 DSP，并且选择那些数据可以覆盖的流量出价以变现数据；而如果拥有的数据是适用于许多行业的，而且能够覆盖到相当多的人群，那么也可以考虑运营一个广告网络来变现数据。




图 8-3 数据提供方变现决策过程示意

8.4 延伸思考

1. 对于一个直接效果类广告产品，应如何看待收入、利润、活跃客户数这些指标？其中哪个指标最能反映该产品的成熟程度？

2. 对媒体而言，短期广告收入和长期品牌价值存在着一定的矛盾。为媒体变现服务的供给方广告平台应如何看待此问题，并如何优化媒体的长期收益？

注 释

[1]. 注意，这里的 API 接口并不是需求方平台即 DSP 使用的实时竞价接口。

[2]. 如门户网站首页的一些特型广告位。

[3]. 数据来源于艾瑞咨询，参见 <http://news.iresearch.cn/zt/241445.shtml>。

[4]. 注意这是基于 Google 全球市场的统计，这甚至接近了表 1-1 中美国市场总的在线广告收入规模。

[5]. 实时竞价将在第 6 章中介绍。

[6]. 这里的点击率考虑了广告而未考虑位置和其他因素的影响，因此仅仅是示意性的。

[7]. 计算中忽略了公式 5.2 中计价时多加的 Δ 。

[8]. 数据来源：<http://www.eMarketer.com>。

[9]. 本书用“定制化”（customized）一词来表示对不同客户的不同结果，而用“个性化”（personalized）一词来表示对不同用户的不同结果。

第三部分 计算广告关键技术

第 9 章 计算广告技术概览

对在线广告产品的介绍到上一章就告一段落了。读者可能会有一种感受，在计算广告中，无论我们讨论的是产品还是策略，都与技术的关系十分密切。这是因为这个市场本质上是计算驱动的，而计算背后的能源正是大规模的数据。从这一章开始，我们将从系统架构和数据处理算法的角度重新审视各种广告产品，希望能对需要在实际工作中具体搭建流量变现或数据变现系统的读者有所帮助。

有很多大数据驱动的产品，就其技术架构而言往往都落地成个性化系统，即根据用户、上下文的一些信息动态决定返回什么内容的系统。计算广告也是一个典型的个性化系统。不过由于复杂的市场交易结构、多样的数据来源以及预算带来的约束，计算广告是目前工业界遇到的个性化系统中比较复杂的，也是相对成熟的。因此，无论您在从事什么类型的大数据业务，我们都建议您从计算广告系统中了解一些关键技术挑战，并掌握相应的基本设计原则。

个性化系统与搜索系统都是互联网时代具有挑战性的大规模计算问题。由于数据规模的要求，它们一般都采用检索（retrieval）加排序（ranking）这样类搜索的系统架构，因而这两种系统有非常多的相似之处。个性化系统与搜索系统的主要差别在于大量的用户特征的使用。由于需要对每一个用户进行刻画，这一过程需要用到大规模的分布式数据处理平台，如 Hadoop；另外，由于个性化特征的效果与其生成的实时性关系很大，为了尽可能实时地利用线上数据，我们还会用到流计算平台来加工短时的个性化特征。将离线的分布式计算平台和在线的流计算平台相结合已经成为这样的系统生成个性化特征的常用方案。

虽然计算广告系统是一种典型的个性化系统，不过由于其业务的特殊性，在具体模块设置上会比一般的个性化系统更加复杂。为了方便后面各广告产品的系统架构和算法介绍，本章会给出一个示意性的广告系统统一架构。虽然这一架构中的模块在不同的广告产品中有取舍和变形，它仍然对于从宏观上把握广告系统的全貌以及各种产品在技术方面的内在联系有一定的价值。后面章节有关各种广告产品的架构讨论都会在这个统一架构的基础上进行。

在互联网时代，搭建这样一个五脏俱全的广告系统实际上并没有看起来那么复杂。这里最关键的方法是要充分利用开源社区的成熟工具快速搭建系统框架，把底层通信、资源分配、集群管理、跨语言调度等与核心业务逻辑无关、但又有较高技术难度的部分用成熟方案来解决，这样广告系统的开发者就可以重点关注业务逻辑和核心算法了。在本章中，我们也将对选择哪些成熟的开源工具快速搭建广告系统框架做一些介绍。

9.1 个性化系统框架

计算广告是根据个体用户信息投送个性化内容的典型系统之一，类似的系统还有推荐系统、个人征信系统以及室内导航系统等。我们发现，大多数以大数据为核心驱动力的产品往往都需要一个这样的个性化系统，而不同产品的个性化系统之间存在着许多共同点。在介绍计算广告系统的架构之前，我们先来了解一般的个性化系统是如何构成的。

如图 9-1 所示，一般的个性化系统由四个主体部分构成：用于实时响应请求，完成决策的在线投放（online serving）引擎；离线的分布式计算（distributed computing）数据处理平台；用于在线实时反馈的流计算（stream computing）平台；连接和转运以上三部分数据流的数据高速公路（data highway）。这几部分互相配合，完成个性化系统的数据挖掘和在线决策任务。




图 9-1 个性化系统一般框架

这几部分的协作流程是：在线投放系统的日志接入数据高速公路，再由数据高速公路快速转运到离线数据处理平台和在线流计算平台；离线数据处理平台周期性地以批处理方式加工过去一段时间的数据，得到人群标签和其他模型参数，存放在高速缓存中，供在线投放系统决策时使用；与此相对应，在线流计算平台则负责处理最近一小段时间的数据，得到准实时的用户标签和其他模型参数，也存放在高速缓存中，供在线投放系统决策时使用，这些是对离线处理结果的及时补充和调整。可以看出，整个系统形成了一个闭环的决

策流程，而这个闭环在搭建完成后，基本依靠机器的运算来运转，人的作用只是进行策略上的调整和控制。实践证明，这样的闭环系统是有效全量利用大数据的关键。

还有一点需要强调，由于个性化需要的是对用户尽可能准确的理解，因此除了个性化系统本身的日志，一般都还会用到其他的业务线数据或采买得到的数据，这些数据都会进入数据高速公路以及后续的加工流程中。因此，在同一个企业中，我们会在不同的业务之间尽可能共享离线和在线的两个计算平台以及所有的用户行为数据。

各种个性化系统之间有上述的共性，不过由于其数据来源、产品形态、优化目标的不同，系统架构的细节也会呈现出很大的差别。我们以最典型的两种个性化系统，即计算广告和个性化推荐以及不需要深度个性化的搜索系统为例，比较这几个 **Web-Scale** 问题在不同方面的区别，如表 9-1 所示。而这些区别，是决定它们系统架构不同的关键原因。

表 9-1 Web-Scale 技术问题比较

	搜索	搜索广告	展示广告	个性化推荐
主要准则	相关性	利润		用户兴趣
其他目标	垂直领域决定	质量、安全性		多样性、新鲜度
索引规模	十亿级	百万级、千万级	百万级	百万级、亿级
个性化	较少的个性化需求		亿级规模用户上的个性化	
检索信号	较明确		较分散	

9.2 各类广告系统优化目标

广告系统的优化目标是提高广告产品的利润，也就是第 2 章中提到的计算广告核心挑战：

$$\begin{aligned}
 \hat{\mathbf{a}}_{1,\dots,T} &= \max_{\mathbf{a}_{1,\dots,T}} \sum_{i=1}^T \{r(a_i, u_i, c_i) - q(a_i, u_i, c_i)\} \\
 &= \max_{\mathbf{a}_{1,\dots,T}} \sum_{i=1}^T \{\mu(a_i, u_i, c_i) \cdot \nu(a_i, u_i) - q(a_i, u_i, c_i)\}
 \end{aligned} \tag{9.1}$$

任何一个具体的计算广告系统，都是为了优化上面的目标而设计的。对应于上一节的个性化系统一般框架，在广告系统中，每次展示的 $\mathbf{r}$ 是由在线的投放引擎来决策的，而离线数据处理平台和流计算平台所做的都是为了准备 $\mathbf{a}_i$, $\mathbf{u}_i$, $\mathbf{c}_i$ 这三个变量或其组合的一些特征。

在不同的广告产品中，上述优化目标会具体表现为不同的形式，并且有时会有额外的约束。表 9-2 中列出了主要广告产品中优化目标各部分的具体表达。

在展示量合约的 GD 系统中，只要各合约达成，系统的收益是确定的，因此这一系统的主要优化在于满足各合约带来的约束，而成本由于是媒体静态产生，与广告优化过程无关，可以认为是常数；ADN 需要估计点击率 $\mu(a, u, c)$ ，并与广告主出的点击单价 $\text{bid}_{\text{CPC}}(a)$ 相乘得到期望收入，而成本是与收入成正比的媒体分成；ADX 直接用广告主出的展示单价 $\text{bid}_{\text{CPM}}(a)$ 作为期望收入，成本也是与收入成正比的媒体分成；只有在 DSP 中，点击率 $\mu(a, u, c)$ 、点击价值 $v(a, u)$ 和成本 $q(a, u, c)$ 都可能是需要预估和优化的，因此算法的挑战较大。

表 9-2 主要广告产品优化目标分解

广告投放	产出 (r)		投入 (q)	约束
	点击率 (μ)	点击价值 (ν)		
GD	常数		常数	合约的展示量要求
ADN	$\mu(a, u, c)$	$\text{bid}_{\text{CPC}}(a)$	$\propto r$	无
ADX	$\text{bid}_{\text{CPM}}(a)$		$\propto r$	带宽、服务成本
DSP	$\mu(a, u, c)$	$\nu(a, u)$	$q(a, u, c)$	预算限制

9.3 计算广告系统架构

根据广告的核心优化问题和上面个性化系统的一般框架，我们抽象出一个完整的广告系统可能具备的各个模块以及这些模块之间的协作关系，用图 9-2 中的架构框架来描述。这一架构图将是后面讨论各种广告产品系统结构的统一基础。我们在下面分几个部分介绍该架构中的功能模块。

需要说明，并不是每一个广告系统都需要以上所有的功能模块。这样的架构图和模块划分是为了方便本书后面在各种广告系统之间进行架构上的对比。另外，这样的架构主要是根据竞价广告系统的骨架来进行的，对于其他类型的广告系统，虽然概念上也可以套用，但是术语和习惯表达上会有一些不同。大家要注意的最关键之处是，在一个完整的广告系统架构中，数据的记录、交易、流转、建模和使用，因为这些是广告系统最核心的驱动力，也从本质上决定了广告产品的变现能力和利润空间。因此，我们将广告系统归于大数据产品之列。

在实践中，广告系统的建立应该是循序渐进的。一般来说，对一个刚起步的广告产品，有广告投放机和相应的日志系统，实现简单的定向投放逻辑，就可以开始使用。随着对广告效果深入优化的需求，需要建立起完整的广告排序和用户行为反馈模型；而当中小广告主大量增加时，就需要实现广告的倒排索引和相应的检索功能。因此，在一个新的广告产品开始运营和逐步完善的过程中，要特别注意根据当前阶段的实际需求决定哪些模块是必要的，哪些可以暂时省略，以避免过度设计和不必要的投入。

9.3.1 广告投放引擎

广告系统中必不可少的部分是一个实时响应广告请求，并决策广告的投放引擎，这与我们在个性化系统框架中介绍的个性化投放引擎一致。一般来说，广告系统的投放引擎采用类搜索的架构，即检索加排序的两阶段决策过程。另外，广告投放引擎还有一个独特模块，就是要从全局优化的角度对整体收益进行管理。广告投放引擎主要有以下几个模块。




图 9-2 在线广告系统一般性架构示意

(1) 广告投放机 (ad server)。这是接受广告前端 Web 服务器发来的请求，完成广告投放决策并返回最后页面片段的主逻辑。广告投放机的主要任务是与其他各个功能模块打交道，并将它们串联起来完成在线广告投放决策。一般来说，为了扩展性的考虑，我们都采用类搜索的投放机架构，即先通过倒排索引从大量的广告候选中得到少量符合条件的或相关的候选，再在这个小的候选集上应用复杂而精确的排序方法找到综合收益最高的若干个广告。对广告投放机来说，最重要的指标是每秒查询数 (Query per Second, QPS) 以及广告决策的延迟 (latency)。

(2) 广告检索 (ad retrieval)。这部分的主要功能在线时根据用户标签 (user attributes) 与页面标签 (page attributes) 从广告索引 (ad index) 中查找符合条件的广告候选。实际

上，倒排索引技术的重要性体现在所有 Web 规模的技术挑战上，也同样是大规模计算广告系统的基础。广告检索得到的候选将被送入广告排序模块。

(3) 广告排序 (ad ranking)。这部分是在线高效地计算广告 eCPM，并进行排序的模块。eCPM 的计算主要依赖于点击率估计，这需要用到离线计算得到的 CTR 模型和特征 (CTR Model&Features)，有时还会用到流计算得到的实时点击率特征 (real-time features)。在需要估计点击价值的广告产品 (如按效果结算的 DSP) 中，还需要一个点击价值估计的模型。

(4) 收益管理 (yield management)。我们用这部分来统一代表在各种广告系统中将局部广告排序的结果进一步调整，以全局收益最优为目的做调整的功能，如 GD 系统中的在线分配、DSP 中的出价策略等。这部分一般都需要用到离线计算好的某种分配计划来完成在线时的决策。

(5) 广告请求接口。实际系统中，根据前端接口形式的不同，广告请求可能来自于基于 HTTP 的 Web 服务器，也可能来自于移动 App 内的 SDK，或者其他类型的 API 接口。不论哪种接口，只要能够提供用户唯一的身份标识 ID 以及其他一些上下文信息，从逻辑上讲与标准的 HTTP 请求就没有本质区别，因此我们都用 Web 服务器来表示。

程序化交易市场中的广告请求接口与上面有所不同，它包括作为需求方时使用的 RTBS 以及作为供给方时使用的 RTBD。这一接口可以采用 IAB 建议的 OpenRTB 协议或者其他主要 ADX 规定的接口形式。

(6) 定制化用户划分 (customized audience segmentation)。由于广告是媒体替广告主完成用户接触，那么有时需要根据广告主的逻辑来划分用户群，这部分也是具有鲜明广告特色的模块。这个部分指的是从广告主处收集用户信息的产品接口，而收集到的数据如果需要较复杂的加工，也将经过数据高速公路导入受众定向模块来完成。

9.3.2 数据高速公路

数据高速公路完成的功能是将在线投放的数据准实时传输到离线分布式计算平台与流计算平台上，供后续处理和建模使用，它非常类似于人体的循环系统。由于在进行受众定向建模时需要用到广告系统以外的其他用户产品日志或者第三方提供的数据，因此，数据高速公路也担负着收集这些数据源的任务。

9.3.3 离线数据处理

计算广告最具挑战的算法问题大多都集中在离线数据处理的部分。离线数据处理有两个输出目标：一是统计日志得到报表、dashboard 等，供决策人进行决策时作为参考；二

是利用数据挖掘、机器学习技术进行受众定向、点击率预估、分配策略规划等，为在线的机器决策提供支持。为了对大规模数据进行分布式的处理加工，我们一般会选用 Hadoop 这样的分布式存储和 MapReduce 计算框架。离线数据处理有下面几个主要模块。

(1) 用户会话日志生成。从各个渠道收集的日志需要先整理成以用户 ID 为键的统一存储格式，这样的日志称为用户会话日志 (session log)。这样整理的目的是为了后续受众定向过程更加简单高效^[4]。

(2) 行为定向 (behaviorial targeting)。这部分功能完成挖掘用户日志，根据日志中的行为给用户打上结构化标签库 (structural label base) 中的某些标签，并将结果存储在用户标签的在线缓存中，供广告投放机使用。这部分是计算广告的原材料加工厂，也因此在整个系统中具有非常关键的地位。

(3) 上下文定向 (contextual targeting)。这部分包括半在线页面抓取 (near-Line page Fetcher) 和上下文页面标签的缓存，与行为定向互相配合，负责给上下文页面打上标签，用于在线的广告投放中。这里的抓取系统比搜索系统要简单，但也有不太一样的需求，后面会详细介绍。

(4) 点击率建模 (click modeling)。它的功能是在分布式计算平台上训练得到点击率的模型参数和相应特征 (click model&features)，加载到缓存中供线上投放系统决策时使用。

(5) 分配规划 (planning)。这部分为在线的收益管理模块提供服务，它根据广告系统全局优化的具体需求，利用离线日志数据进行规划，得到适合线上执行的分配方案 (allocation plan)。

(6) 商业智能 (business intelligence, BI) 系统。这部分包括 Extract-Transform-Load (ETL) 过程、dashboard 和 cube，这些是所有以人为最终接口的数据处理和分析流程的总括，担负着对外信息交流的任务。由于实际的广告运营不可能完全通过机器的决策来进行，其间必然需要有经验的运营者根据数据反馈对一些系统设置及时调整。因此，实现一个功能强大、交互便利的 BI 系统是非常重要的。

(7) 广告管理系统。这部分是广告操作者，即客户执行 (Account Execute, AE) 与广告系统的接口。AE 通过广告管理系统定制和调整广告投放，并且与数据仓库交互，获得投放统计数据以支持决策。一般来说，广告系统中只有这部分是面向用户的产品。根据对操作对象开放程度的不同，这一系统有时又有开放自助的需求，在这种情况下，还需要包含相应的财务结算功能。对这部分，读者可以从很多自助式广告产品中看到，我们在第 3 章中已经进行了简单介绍。

9.3.4 在线数据处理

在线数据处理基本上可以认为是离线数据处理的镜像功能，它是为了满足广告系统对实时数据反馈的要求，解决那些离线分布式计算平台无法快速响应的计算问题。为了组织下面一些在线时前后有依赖关系的数据流加工过程，我们经常选用流式管理平台作为基础设施。在线数据处理主要包括以下模块。

(1) 在线反作弊 (anti-spam)。实时判断流量来源中是否有作弊流量，并且将这部分流量从后续的计价和统计中去除掉，是广告业务非常重要的部分。此模块是所有后续在线数据处理必须经过的前置模块。

(2) 计费 (billing)。这部分同样是计算广告关键的业务功能之一。对于那些经过扣费预算耗尽的广告，系统必须马上通知广告索引系统将其下线。当然，扣费也必须在扣除了作弊流量的基础上进行。

(3) 在线行为反馈，包括实时受众定向 (real-time targeting) 和实时点击反馈 (realtime click feedback) 等部分。这部分是将短小时内发生的用户行为和广告日志及时地加工成实时用户标签以及实时的点击率模型特征。对于在线广告系统，这部分对于效果提升的意义重大：在很多情形下，把系统信息反馈调整做得更快比把模型预测做得更准确效果更加显著。

(4) 实时索引 (real-time indexing)。这部分的主要功能是实时接受广告投放数据，建立倒排索引。广告的索引由于涉及预算调整等商业环节，因此必须在投放管理者调整以后非常快速地在线上广告索引中生效。

9.4 计算广告系统主要技术

了解了计算广告的优化目标和系统架构，我们再来看看这一系统会用到哪些关键的技术。实际上，上一节介绍的广告系统架构也是由这些技术问题决定的，而这些也给我们提示了实践中需要重点关注并优化的方向。

从算法优化的角度看，主要有下面的一些问题，解决这些问题需要广泛用到机器学习、数据挖掘等一些相关学科的技术。

(1) 公式 2.2 中的特征提取，即对 (a, u, c) 打标签以方便后续建模和市场售卖的问题，是计算广告中非常核心的受众定向问题（参见第 12 章）。

(2) 如果不考虑全局最优，计算广告系统主要靠 eCPM 估计，特别是点击率预测（参见 13.5 节）来完成每一次展示时的局部优化。

(3) 如果考虑到量的约束和投放时即时决策的要求，则产生了在线分配的问题（参见 11.3 节）。

(4) 为了在多方博弈的市场中达到动态平衡时的收益最大化，则需要对市场的机制设计 (mechanism design)（参见 5.2 节）深入研究，进而确定合理的定价策略。

(5) 为了更全面地采样整个 (a, u, c) 的空间以便更准确地估计点击率, 需要用到强化学习 (reinforcement learning) 中的探索与利用 (explore and exploit, E&E) (参见 13.6 节) 方法。

(6) 在实时竞价快速发展的今天, 个性化推荐 (personalized recommendation) 技术也被广泛使用在效果类 DSP 的个性化重定向中 (参见 14.2 节)。

从系统架构的角度看, 大规模广告决策和投放有如下一些特点: 首先是服务压力大, 这是由于广告的投放量往往数倍于页面浏览的 PV, 这使得广告成为互联网流量规模最大的产品之一; 其次, 因为用户对广告产品接受是被动的, 广告展现延迟的增加往往会带来广告效果的显著下降, 因此广告系统的决策延迟是非常关键的指标; 从另一方面看, 也正因为广告是被动的用户产品, 其决策结果的逻辑性不直接, 因此广告系统在用户标签的数据一致性方面要求是比较低的, 也往往并不需要持久化的存储, 这为系统设计提供了一定的灵活性。计算广告在系统架构方面涉及以下一些技术问题。

(1) 由于广告主的预算、定向条件等信息在设置后需要快速在线上生效, 需要用实时索引技术服务于广告候选的检索。

(2) 需要用 NoSQL 数据库为投放时提供用户、上下文标签和其他特征。

(3) 广泛使用 Hadoop 这样的 MapReduce 分布式计算平台进行大规模数据挖掘和建模, 也用到流计算平台实现短时用户行为和点击反馈。

(4) 在广告交易市场中实现高并发、快速响应的实时竞价接口, 这是一项广告中用到的独特技术。

上述这些技术与大数据、分布式计算等领域中的一些通用技术有紧密的联系, 但也有很多结合广告产品特点的独特需求。我们将会在介绍具体的广告产品时, 结合相应的上下文具体讨论。

有关这些技术需要了解的一些基础知识将在下一章简要介绍。当然, 本书并不是专门讨论机器学习或信息检索的教程, 因此大家不要期望在这里能系统地学习到这些领域的知识。我们的目标是从商业的需求出发, 解剖问题的本质, 并给出代表性的解决方案。同时, 在用到其他工业界已经成熟的技术时, 会尽量给出建议的参考方案, 以方便大家进一步深入了解。

9.5 用开源工具搭建计算广告系统

上面的广告系统架构模块众多、交互复杂, 从头搭建并不容易。在大型互联网公司中, 这样的广告系统可以精雕细琢, 其中的很多模块也都可以进行专门开发。不过, 对于初创企业和变现业务方向尚需探索的企业来说, 需要根据最小值原型 (Minimum Value

Prototype, MVP) 的原则, 低成本、短平快地搭建系统, 然后在实际业务中进行快速迭代。幸运的是, 开源社区为搭建广告系统提供了很多不错的工具, 利用这些工具可以相当方便地搭建起一个广告系统基础骨架。一般来说, 我们可以利用成熟开源工具解决底层通信、数据传输、负载分配等基础问题, 从而将精力重点放在与业务逻辑相关的开发上。

图 9-3 标示出了计算广告系统中经常用到的一些开源工具, 为了方便读者在实际工作中的需要, 我们将简要介绍一些主要工具在广告系统中的用法。

9.5.1 Web 服务器 Nginx



我们先从在线投放时用到的 Web 服务器说起。由于广告系统有高并发、低延迟的性能要求, Nginx (<http://www.nginx.org>) 在多数情形下都是广告系统首选的 Web 服务器解决方案。

Nginx 是一款开源服务器软件, 兼有 HTTP 服务器和反向代理服务器的功能。其主要特点在于高性能、高并发和低内存消耗, 并且具有负载均衡、高速缓存、访问控制、带宽控制以及高效整合各种应用的能力, 这些特性使得 Nginx 非常适合计算广告这种并发很高的互联网服务。

Nginx 还提供了 fastCGI 这一与各种编程语言之间的通信接口, 开发者可以很方便地将服务器的功能逻辑用 fastCGI 插件的形式实现, 而无需关注响应 HTTP 请求的细节。在广告系统中, 用 Nginx 作为前端 Web 服务器, 而将广告投放机的功能用 C/C++ 语言实现成 fastCGI 插件, 是一个开发成本较低、性能又很不错的方案。实际上, 这一方案已经实现了一个基本的广告投放机, 从事最简单的广告投放业务, 而其他模块和功能则可以根据需求逐步开发。

有关 Nginx 更详细的介绍和使用方法可以参考参考文献 [70]。其他的相关开源工具还有 Apache (<http://httpd.apache.org>) 等。




图 9-3 计算广告系统用到的开源工具示意

9.5.2 分布式配置和集群管理工具 ZooKeeper



由于广告系统的流量很大，单台广告投放机往往不能满足需要。在使用多台服务器的时候，会遇到很多诸如配置文件更新、集群上下线管理等分布式环境下的同步问题。ZooKeeper (<http://zookeeper.apache.org>) 是解决这些问题非常有用的开源工具。

ZooKeeper 是为分布式应用建立更高层次的同步（synchronization）、配置管理（con-figuration maintenance）、群组（groups）以及名称服务（naming）的通用工具。它的基础原理是参考文献 [49] 中的 Paxos 算法，而这一算法最早的工业界应用是 Google 开发的 Chubby^[17]。在编程上，ZooKeeper 的设计很简单。所使用的数据模型非常类似于文件系统的目录树结构，简单来说，有点类似于 Windows 中注册表的结构，有名称、树节点、键/值对等，可以看作一个树形结构的数据库，可以分布在不同的机器上做名称管理。由于 ZooKeeper 并不传递计算数据而是传递节点的运行状态，所以运行负载很低。

对广告投放机进行集群管理是 ZooKeeper 在广告系统中的典型应用之一：由于某台服务器宕机或者新机器上线，Nginx 的负载均衡方案需要及时作出调整。显然，人工地维护响应时间较长，不可避免地会带来一些流量上的损失。利用 ZooKeeper 的 Ephemeral 类型节点可以很方便地实现此功能，这方面的参考资料很多，本书不具体介绍。

由于在广泛使用的 Hadoop、HBase、Storm、Flume 等开源产品中都需要用到 ZooKeeper 进行分布式同步，如果把上述开源产品看作各种小动物，ZooKeeper 这一命名可以说非常形象。有关 ZooKeeper 更详细的介绍和使用方法可以参考参考文献[44]。

9.5.3 全文检索引擎 Lucene



大多数广告业务在初始运营阶段并不见得需要一个真正的倒排检索引擎，不过当广告业务开始面向长尾广告主，广告库规模较大时，采用“倒排检索”加“排序”这样的两段式决策过程是必要的（参见 10.1.1 节）。然而，实现一个功能全面、效率较高的倒排索引并不是一件简单的事，并且由于其与核心业务逻辑关系并不大，也可以用开源方案来实现。

在开源工具中，Lucene (<http://lucene.apache.org>) 是比较常用的基于 Java 的全文检索工具包。Lucene 并不是一个完整的搜索引擎，但是针对计算广告系统的需要，它可以方便地实现全文索引和检索功能。Lucene 能够为文本类型的数据建立索引，其主要功能是替文档中的每个关键词建立索引。另外，Lucene 还提供一组解读、过滤、分析文档，编排和使用索引的 API。我们选用 Lucene，除了它的高效和简单外，还因为它允许用户对其中的关键环节自定义功能逻辑。不过一些特殊的检索算法，如第 13 章中要介绍的相关性检索，在 Lucene 中并不能直接支持，还需要在深入理解源代码的基础上改动或者另行开发。有关 Lucene 更详细的介绍和使用方法可以参考参考文献[57]。

在需要比较强的索引扩展性的情形下，还可以考虑使用 Elasticsearch (<http://www.elasticsearch.org>)，这是一个基于 Lucene 构建的开源、分布式、RESTful 搜索引擎。设计场景主要是在云计算的环境中，能够实现稳定可靠的实时搜索，并具有良好的水平扩展性。

9.5.4 跨语言通信接口 Thrift



图 9-2 中的各个模块之间广泛地存在数据交换，不过由于各模块需求的不同，有时我们会选用不同的开发语言来分别实现它们；或者由于开源工具的不同，最方便的使用语言也不同。为了方便在不同语言的模块之间实现调用接口，避免应用开发者过多地将精力放在底层通信上，开源社区涌现了若干个跨语言通信接口工具。我们以 Thrift 为例来介绍。

Thrift (<http://thrift.apache.org>) 被描述为 “scalable cross-language services implementation” (可扩展的跨语言服务实现) [67], 它有自己的跨机器的通信框架, 还提供了一套代码生成工具, 可以生成多种编程语言的通信过程代码。Thrift 有一种描述对象和服务的界面定义语言 (Interface Definition Language, IDL), 它提供了一种网络协议, 使用这些对象和服务定义的进程之间基于这种网络协议彼此进行通信。Thrift 根据 IDL 的描述可以生成绝大多数流行语言 (如 C++、Java、Python、PHP、Ruby、Erlang、Perl、Haskell、C#、Cocoa、JavaScript 等) 的代码框架。因此, 服务器端实现语言不会影响到客户端, 这给复杂的计算广告技术平台不同系统之间的通信提供了很大的便利。

此外, Thrift 还提供了实践中非常有用的版本兼容性功能, 即服务器端能在不影响现有的客户端的情况下增加数据结构、字段、服务方法和函数参数。这一特性使得大型工程中模块间的依赖性大为减弱, 也能够显著降低开发成本。因此, 我们建议在计算广告的系统模块之间尽可能采用 Thrift 这类工具封装接口。

有关 Thrift 的设计原理和更多细节可以参考 [67]。其他的相关开源工具还有 ProtoBuf (<http://code.google.com/p/protobuf>)、Avro (<http://avro.apache.org>) 等。

9.5.5 数据高速公路 Flume



计算广告这样的个性化系统由于并发很高, 产生的日志量也非常大。在这类系统中, 应该避免对数据做单点的集中式读写, 而是尽量应该让数据的处理形成环形的流动, 即由数据高速公路将线上日志准实时地送至离线或在线处理平台, 再将处理结果存放在缓存中供线上决策使用。在这样的架构中, 一个分布式、高吞吐率的数据传送通道至关重要。

在这类数据传输工具中, Flume (<http://flume.apache.org>) 是比较常用的开源解决方案之一。Flume 是 Cloudera 提供的一个高可用的、高可靠的、分布式的海量日志采集、聚合和传输的系统, 它支持在日志系统中定制各类数据发送方, 用于分布式地收集和汇总日志数据。Flume 提供了从控制台 (console)、RPC (thrift-RPC)、文本 (text)、Tail 操作 (UNIX tail)、日志系统 (syslog, 支持 TCP 和 UDP 两种模式) 以及命令执行 (exec) 等数据源上收集数据的能力。同时, Flume 还提供了对数据进行简单处理并输出到各种数据接收方的能力。如果广告投放机采用 syslog 方式记录投放、点击等日志, 可以很方便地通过配置 Flume 将日志传送到 Hadoop 上。

其他的相关开源工具还有 Scribe (<https://github.com/facebook/scribe>) 等。

9.5.6 分布式数据处理平台 Hadoop



图 9-2 中的离线数据处理部分需要一个能够存储和加工海量数据的基础设施，实际上这也是大多数大数据系统都需要的平台。在开源的这类平台工具中，Hadoop（<http://hadoop.apache.org>）几乎是工业界的标准选择。Hadoop 的核心架构主要包括 HDFS（Hadoop Dis-tributed File System，Hadoop 分布式文件系统）、Hadoop MapReduce 和 HBase，其中 HDFS 是 GFS（Google File System）^[34]的开源实现，MapReduce 是 Google MapReduce^[26]的开源实现，而 HBase 则是 Google BigTable^[20]的开源实现。

HDFS 是一种易于横向扩展的分布式文件系统，提供大规模数据文件存储服务，支持 PB 级数据规模。它可以运行在上万台的通用商业服务器集群上，提供副本容错机制，为海量用户提供性能优秀的存取服务。计算广告系统里的海量日志文件等就是通过 Flume 之类的数据高速公路传送，最终存储在 HDFS 上，为各种离线计算任务提供服务。

Hadoop MapReduce 是一种分布式计算框架，顾名思义，它由两个部分组成：Map 和 Reduce。Map 是将一个作业分解成多个任务，而 Reduce 是将分解后多任务处理的结果汇总起来。在程序设计中，一项工作往往可以被拆分成为多个任务，任务之间的关系可以分为两种：一种是不相关的任务，可以并行执行；另一种是任务之间有相互依赖，先后顺序不能够颠倒，这种任务是无法并行处理的。MapReduce 适用于第一种类型，庞大的集群可以看作是硬件资源池，将任务并行拆分，然后交由每一个空闲硬件资源去处理，能够极大地提高计算效率，同时这种资源无关性对于计算集群的横向扩展提供了最好的设计保证。为了降低 MapReduce 编程的复杂性，人们还开发了 Hive、Pig^[33, 63]等开源工具产品，使用类似于 SQL 的脚本语言发起各种数据计算任务。

在广告系统中，Hadoop 主要承担着离线数据的存储和计算需求，可以说是计算广告系统进行大规模数据处理不可或缺的基础平台。无论是受众定向、点击率预测还是基础的报表生成，都需要在 Hadoop 上进行大规模的数据处理。因此，关于 Hadoop 的原理和应用必须深入掌握。有关 Hadoop 更详细的介绍和学习资料可以参考参考文献[77]。

9.5.7 特征在线缓存 Redis



无论是离线计算的受众定向标签还是点击率模型参数或特征，由于规模比较大，一般来说都无法直接存放在在线广告投放机的内存中，而是要用独立的缓存服务。在线用到的特征缓存有两个显著的特点，首先是往往只需要存储简单的键/值对，其次是大多数情形下需要支持高并发的随机读和不太频繁的批量写。在这样的需求下，Redis (<http://www.redis.io>) 是比较合适的开源工具之一。

Redis 也是一种 NoSQL 数据库，它主要提供的是高性能的键/值存储(key/value store)，采用的是内存数据集的方式。Redis 的键值可以包括字符串、哈希、列表、集合和有序集合等数据类型，因此也被称作是一款数据结构服务器(data structure server)。Redis 会周期性地把更新的数据写入磁盘或者把修改操作写入追加的记录文件，并且在此基础上实现了主从同步，具有非常快速的非阻塞首次同步、网络断开自动重连等功能。同时，Redis 还具有其他一些特性，其中包括简单的 check-and-set 机制、pub/sub 和配置设置等，使得它能够表现得更像高速缓存(cache)。Redis 还提供了丰富的客户端，支持现阶段流行的大多数编程语言，使用起来比较方便。

在广告系统中使用 Redis，需要注意的一点是，当以批处理方式更新其中内容时，应避免对线上高并发的读请求产生影响，因此有时需要采用多次写入的方案。

有关 Redis 更详细的介绍和使用方法可以参考参考文献[51]。

9.5.8 流计算平台 Storm



Hadoop 能够处理的数据规模相当可观，但是处理的响应速度却很难保证。因此，在图 9-2 的在线处理部分，需要一种新型的、能够以数据流的方式对线上日志准实时处理的平台作为基础设施，在这类平台的开源解决方案中，工业界比较常用的是 Storm (<http://storm.apache.org>)。

广告中需要用到流计算的问题包括在线反作弊、计费、实时受众定向和实时点击反馈等(参见 13.3 节)。我们希望的解决方案是能够自动地处理各流计算模块间的通信和数据依赖，并能够在数据规模增大时自动进行分布式的负载分配，Storm 这样的流计算平台就可以为我们实现上述的需求。流计算的任务逻辑与 MapReduce 过程有些类似，熟悉 Hadoop 编程的读者也可以比较容易地在 Storm 上开发应用。不过需要注意的是，流计算的任务调度原则和 HDFS 上的 MapReduce 不同，流计算是调度数据，让数据在不同的计算

节点间流动起来，而 MapReduce 是尽可能调度计算以减少数据 I/O。因此，流计算从本质上讲并不是一个可以真正处理海量数据的框架，它的特长仍然在数据处理的响应速度上。

Storm 保证每个消息都会得到处理，而且处理速度很快，每秒可以处理数以百万计的消息，并且可以使用任意编程语言来做开发。另外，Storm 还可以直接部署在新一代的 Hadoop 计算调度引擎 YARN 上，这样可以非常方便地共享一个 Hadoop 集群的存储功能和计算资源。

其他的相关开源工具还有 S4 (<http://incubator.apache.org/s4>) 以及下面要介绍的 Spark 的 Streaming 方式 (<http://Spark.apache.org/streaming>) 等，但它们的系统特点和使用场景还是有一定的差别，读者可以自行了解。有关 Storm 更详细的介绍和使用方法可以参考参考文献[2, 80]。

9.5.9 高效的迭代计算框架 Spark



Spark (<http://spark.apache.org>) 在最近几年崭露头角，作为一种新兴的大数据计算平台受到越来越多的关注，一些计算广告系统也开始广泛使用 Spark 平台解决一些需要迭代计算的问题。用 Hadoop 进行大规模数据处理在 Map 和 Reduce 两个阶段之间需要用硬盘进行数据交换，因此在需要面对多次迭代才能完成的任务时效率相当低。由于这样的迭代计算任务在计算广告中很常见（参见第 10 章），如文本主题模型、点击率预估等，我们非常需要一种更适合于迭代计算的框架。

作为一种新型分布式计算框架，Spark 的最大特点在于内存计算。Spark 的计算模型可以更加精简地描述等价的 MapReduce 模型，另外由于 Spark 的数据共享基于内存，因而相对于基于硬盘的 Hadoop MapReduce 批处理计算，其性能有数量级的提升。此外，Spark 可以在一套软件系统上支持多种计算任务，除了传统的 Hadoop MapReduce 所对应的批处理计算之外，还支持各种机器学习算法为代表的迭代型计算、流式实时计算、社交网络中常用的图计算、SQL 关系查询、交互式即席查询等。这样，使用 Spark 就可以避免同时维护多套针对不同计算需求的系统，还可以避免不同系统之间的数据转储，大大减低了开发和运维成本。

虽然 Spark 可以在很多中等规模的迭代计算问题上表现的性能非常优异，但是由于大量数据的基础存储仍然要依赖于 Hadoop，在两个集群之间调度数据成为高效处理数据的

障碍。不过，与 Storm 一样，现在 Spark 也已经可以直接部署在 YARN 之上，以“Spark on YARN”的方式与 Hadoop 方便地共享集群的存储功能和计算资源。

有关 Spark 更详细的介绍和使用方法可以参考参考文献[21，45]。

9.6 延伸思考

- 1.对于你熟悉的某种广告产品，如何估算其服务成本？如何根据广告系统的特点优化这一成本？
- 2.对一个提供受众定向的效果类广告产品，如何估算其数据处理的规模？

第 10 章 基础知识准备

计算广告并不是一门独立的学科，它更应该被看成是一个工业界的具体问题。在解决此问题的过程中，需要大量用到相关学科的一些基本技术和算法。本书的目的并不是专门介绍这些技术，但是在后续的讨论中不可避免需要用到一些背景知识。因此，我们在进入具体的广告技术和算法之前，先概要性地介绍几个相关领域的技术和算法。这既是为后面的算法章节铺垫，也是为了帮助读者将来在工作中遇到相关问题时可以有目的地找到相关资料。

我们将重点关注三个相关领域的背景知识：信息检索（Information Retrieval, IR）、最优化（Optimization）和机器学习（Machine Learning, ML）。信息检索是所有大规模数据处理系统，特别是搜索和个性化系统的通用技术，而为了了解广告检索、流量预测等相关问题中的一些改进算法，必须对其中的倒排索引等方法有基本认识。对于所有与数据、算法打交道的工程师来说，最优化理论的重要性可以排在首位，因为它是连接问题、模型与最终解决方案的关键桥梁。在面对不同类型的最优化问题时的一般思路和基本方法，将是我们介绍的重点。而机器学习算法对于计算广告的作用不言而喻：广告中的许多问题，如文本主题模型、受众定向、点击率预测等，都需要掌握一些机器学习基础方法，并对机器学习的方法论有清晰认识。我们将主要介绍统计机器学习的框架，并关注其在分布式计算环境下的实现思路。

从本章开始，我们会用 C++ 或 Matlab 语言给出一些关键性算法或过程的示例性代码。我们会尽量将这些代码的具体逻辑实现得清晰完整，不过由于对整个系统的依赖性，大多数情况下并不能将这个代码视为可实际执行的代码。但是，在参考这些示例代码的基础上，相信读者可以比较方便地在实际系统中实现相应的功能。

10.1 信息检索

从第 8 章介绍的广告系统架构可以看出，为了达到面向大量中小广告主时良好的扩展性，计算广告采用的是类搜索的技术框架，即检索加排序两段的决策过程。因此，我们有必要对搜索引擎信息检索的基本方法有所了解，这里主要介绍倒排索引和向量空间模型。

10.1.1 倒排索引

倒排索引 (inverted index) [83] 是现代搜索引擎的核心技术之一，其核心目的是将从大量文档中查找包含某些词的文档集合这一任务用 $O(1)$ 或 $O(\log n)$ 的时间复杂度 [2] 完成，其中 n 为索引中的文档数目。也就是说，利用倒排索引技术，可以实现与文档集大小基本无关的检索复杂度，这一点对于海量内容的检索来说至关重要。正是有了倒排索引技术的支撑，互联网才在实时检索大规模数据方面取得了质的飞跃。我们用例子来说明倒排索引的基本概念，假设我们有如下的几篇文档：

D_0 = “谷歌地图之父跳槽 Facebook”

D_1 = “谷歌地图之父加盟 Facebook”

D_2 = “谷歌地图创始人拉斯离开谷歌加盟 Facebook”

D_3 = “谷歌地图创始人跳槽 Facebook 与 Wave 项目取消有关”

D_4 = “谷歌地图创始人拉斯加盟社交网站 Facebook”

对每篇文档都进行分词以后，可知这些文档中包含的关键词 (term) 有：{谷歌，地图，之父，跳槽，Facebook，加盟，创始人，拉斯，离开，与，Wave，项目，取消，有关，社交，网站}。首先，去掉“与”这样的没有实际表意作用的停止词 (stop word)，我们对每一个词建立一个链表，表中的每个元素都是包含该词的某篇文档的标识。于是，与上面的文档集对应的倒排索引，也就是所有关键词的倒排链集合可以表示如下：

谷歌 $\rightarrow \{D_1, D_2, D_3, D_4, D_5\}$ ，地图 $\rightarrow \{D_1, D_2, D_3, D_4, D_5\}$ ，之父 $\rightarrow \{D_1, D_2, D_4, D_5\}$ ，
跳槽 $\rightarrow \{D_1, D_4\}$ ，Facebook $\rightarrow \{D_1, D_2, D_3, D_4, D_5\}$ ，创始人 $\rightarrow \{D_3\}$ ，
加盟 $\rightarrow \{D_2, D_3, D_5\}$ ，拉斯 $\rightarrow \{D_3, D_5\}$ ，离开 $\rightarrow \{D_3\}$ ，Wave $\rightarrow \{D_4\}$ ，
取消 $\rightarrow \{D_4\}$ ，项目 $\rightarrow \{D_4\}$ ，有关 $\rightarrow \{D_4\}$ ，社交 $\rightarrow \{D_4\}$ ，网站 $\rightarrow \{D_4\}$ 。

为了后文一些实例的方便，我们用下面一段代码中的类结构来描述一个倒排索引。这个类结构派生于 hash map，其中的键为关键词，即 term，典型情况下，该键是 string 类型，但是在后文介绍的布尔表达式检索等场景中，其键的类型可能会发生变化。因此，为了逻辑统一，我们引入了模板参数来泛化此处的数据类型。而 hash map 的值就是倒排链，是一个由索引条目组成的链表。每个索引条目有两个域，第一个是该条目对应的文档的 ID，第二个是一个辅助变量，比如可以用于表示目前关键词在此文档的 TD-IDF（参见 10.1.2 节），在后面提到的其他索引类型中也会有独特的应用。当然，这种结构只是一个概念上

的表达，实际的倒排索引还要存储很多其他信息，为了便于突出主要概念，在本书中采用这样简单的概念性描述。

倒排索引最基本的操作有两项：一是向索引中加入一个新文档，二是给定一个由多个关键词组成的查询时，返回对应的文档集合。我们也在下面的代码中对这两项基本功能的实现做了描述。需要注意的是：在倒排索引中，由于文档 ID 是在加入倒排索引时被在线分配的，因此每个倒排链都可以确保是有序的，这会在后面的应用中得到具体利用。


```

1  template <class TKey>
2  class InvIndex : public map<TKey, list<int>> {
3  public:
4      vector<vector<TKey> > docs; // 文档正排表
5
6  public:
7      // 向索引中加入一个文档
8      void add(vector<TKey> & doc) {
9          // 在正排表里记录该文档
10         docs.push_back(doc);
11         int curDocID = docs.size() - 1;
12
13         // 遍历document里所有的term
14         for (int w = 0; w < doc.size(); w++) {
15             map<TKey, list<int> >::iterator it;
16             it = this -> find(doc[w]);
17
18             // 如果该term的倒排链不存在，新建倒排链
19             if (it == this -> end()) {
20                 list<int> newList;
21                 (*this)[doc[w]] = newList;
22                 it = this -> find(doc[w]);
23             }
24
25             // 在倒排链末尾插入新的文档
26             it -> second.push_back(curDocID);
27         }
28     }
29
30     // 在索引中进行一次查询
31     void retrieve(vector<TKey> & query, set<int> & docIDs) {
32         int termNum = query.size();
33
34         // 合并所有term的倒排链
35         docIDs.clear();
36         for (int t = 0; t < termNum; t++) {
37             map<TKey, list<int> >::iterator it;
38             // 该term倒排链不存在则跳过
39             if ((it = this -> find(query[t])) != this -> end())
40                 docIDs.insert(it->second.begin(), it->second.end());
41         }
42     }
43 };

```

需要说明，这段代码仅仅是帮助大家了解问题的示例性代码，而实际的倒排索引远比此复杂。其工程难点有很多，比如如何设计精简的数据结构以节省对内存的使用以及如何比较实时地将新的文档加入倒排索引等。这些问题由于是信息检索领域专门的研究课题，并非广告的特殊需求，我们不再深入介绍。需要自行实现广告检索部分的读者可以参考这方面专门的技术文献或者深入学习 9.5.3 节中介绍的开源的倒排索引工具 Lucene。

10.1.2 向量空间模型

如果说倒排索引技术是大规模信息检索的基石，那么向量空间模型（Vector Space Model, VSM）^[71]则是信息检索中最基础且最重要的文档相似度度量方法之一。VSM 的核心有两点：文档的表示方法和相似度计算方法。

首先，我们对每个文档采用词袋（Bag of Words, BoW）假设，即用各个关键词在文档中的强度组成的矢量来表示该文档：

$$\mathbf{d} = (x_1, x_2, \dots, x_M)^\top \quad (10.1)$$

其中 x_m 一般采用词表中第 m 个词在 $\mathbf{d}$ 中对应的 TF-IDF（Term Frequency-Inverse Document Frequency, 词频-倒数文档频率）值，这是一种信息检索中最常见的词强度度量，可以分解为两个量的乘积：一个量是词频（Term Frequency, TF），即某文档中该词出现的次数；另一个量是倒数文档频率（Inverse Document Frequency, IDF），即该词在所有文档中出现的频繁程度的倒数。IDF 的引入是考虑到那些广泛出现在各个文档中的常用词对主题的鉴别力并不强，因而需要降低其权重。IDF 的计算方法有若干种，最常用的形式为：

$$\text{IDF}(m) = \log(N/\text{DF}(m)) \quad (10.2)$$

其中 $\text{DF}(m)$ 为词 m 在其中出现的文档的总数目， N 为总文档数目。在广告应用中如何计算 IDF 值，在某些情形下需要不同的处理。例如，在处理对广告主有价值的竞价标的词时，可以采用所有广告描述，而不是互联网上的网页作为文档集合。相应地，在根据关键词进行广告检索时，也应该使用这种方法得到的 TF-IDF。

这样的 BoW 文档表示方法是对自然语言最简单粗略的一种近似表示。它完全忽略了词的前后接续关系以及更高阶的语法因素的影响，因而并不太可能具有精细的文档描述能力。不过，这种方法在信息检索中的作用无疑是巨大的，因为它通过极为简单经济的操作对文档进行了简化，同时又比较好地保留了文档的概貌，这对于海量文档数据的处理和索引非常有利。时至今日，虽然学者们在自然语言处理方面取得了许多进展，但这种简单的方法仍然是工程实践中信息检索和文档主题挖掘的最常用文档表示。如果我们考虑更精细

的文档描述，可以进一步加入文档的 **n-gram** 信息，但是也会带来数据的爆炸式增长和模型估计稳健性上极大的挑战。

采用 BoW 的文档表示方法，在计算两个文档的相似度时，一般是用其对应矢量的余弦距离：

$$\cos(\mathbf{d}_1, \mathbf{d}_2) = \frac{\mathbf{d}_1^\top \mathbf{d}_2}{\|\mathbf{d}_1\| \cdot \|\mathbf{d}_2\|} \quad (10.3)$$

余弦距离的最显著好处是当两个矢量在尺度上没有归一化时，仍然可以得到比较稳健的结果。比如有两篇一样的文档，将其中的一篇内容重复一遍，再去计算余弦距离仍然是 0，而如果采用其他方式，如欧氏距离，结果就不再是 0 了。再比如两个人对各种电影打分，甲倾向于给较高的分数，乙倾向于给较低的分数，那么在一组 3 部电影上，甲给出的分数 {3.6, 3.6, 4.8} 和乙给出的分数 {3.0, 3.0, 4.0} 实际上一致程度相当高，这也可以被余弦距离比较公允地度量出来。

了解了上面的这些内容，读者可以建立对海量文档进行检索的基本方案。在离线索引阶段，需要对文档集合分词，并按照 BoW 模型表示得到每个文档的 TF-IDF 矢量，对分词后的文档集合建立倒排索引。当在线的查询到来时，也进行分词，从倒排索引中查出所有符合要求的文档候选，并对其中的每个候选评价其与查询的余弦距离，按距离由小到大进行排序。这样的一个基本框架也适用于广告这一大规模数据挖掘问题，也是图 9-2 的基本原理。

虽然 VSM 不是实际系统中对检索候选进行排序的常见方法，不过要提醒大家注意，这是一种简单、无需训练的基线方法。因此，在探索各种数据驱动的精细模型时，要先将它们与 VSM 方法做比较。

10.2 最优化方法

为了探索比上面的向量空间模型更加有效的计算广告方案，必然会碰到大量的与数据挖掘和机器学习相关的算法问题。在这些与数据相关的问题中，最重要的基础技能是最优化理论和方法。最优化讨论的是在给定一个数学上明确表达的优化目标后，如何用系统性的方法和思路找到该目标的最优解。这方面的书籍和文章很多，我们从工程的角度出发，简要整理一下在面临各类目标函数时的一般性思路，并希望大家能够认清“模型”和“优化”这两个概念的联系与区别。

最优化问题讨论的是，给定某个确定的目标函数以及该函数自变量的一些约束条件，求解该函数的最大或最小值的问题。这样的问题可以表示为下面的一般形式：

$$\begin{aligned} \min f(\mathbf{x}) \\ \text{s.t. } \mathbf{g}(\mathbf{x}) \preceq 0, \quad \mathbf{h}(\mathbf{x}) = 0 \end{aligned} \quad (10.4)$$

这里 $f(x)$ 是一个关于自变量 x 的目标函数，而 $g(x)$ 和 $h(x)$ 为 x 的矢量函数，对应着一组不等式和等式约束条件，其中 $g(x) \leq 0$ 表示矢量 $g(x)$ 的每一个元素都小于或等于 0。根据约束条件以及目标函数的性质不同，最优化问题求解的思路也有很大的不同。其中无约束优化问题的方法是基础，而带约束优化问题则在一定条件下可以转化为无约束优化问题来求解，这涉及下面将要谈到的拉格朗日法和凸优化问题。

10.2.1 拉格朗日法与凸优化

我们先来看看解带约束优化问题的一般框架思路。在实际工程中，带约束优化非常常见，如后面将提到的广告合约量约束下的优化问题。有关带约束优化最重要的方法就是拉格朗日法。具体来说，对公式 10.4 那样的带约束优化问题，可以引入一个拉格朗日对偶函数（Lagrange dual function）^[13]或简称对偶函数：

$$L(\lambda, \nu) = \inf_x \left[f(x) + \lambda^\top g(x) + \nu^\top h(x) \right] \quad (10.5)$$

这里引入的矢量变量 λ 和 ν 称为拉格朗日乘子，对偶函数是一个关于拉格朗日乘子的函数，对应地，有下面的拉格朗日对偶问题（Lagrange dual problem）：

$$\max L(\lambda, \nu) \quad \text{s.t.} \quad \lambda \succeq 0 \quad (10.6)$$

可以证明，对偶问题的最优值是原问题最优值的下界，而当这两者完全一致时，称为强对偶（strong duality）得到满足。可以证明，当原问题是凸优化问题，即目标函数为凸函数，并且由各项约束得到的可行解域（feasible region）也是凸的话，强对偶总是被满足的。但需要特别说明，并不是只有凸优化问题才是强对偶的^[13]，如后面将要提到的 Trust-Region 法中的子问题，虽然其目标函数不能保证为凸，但是强对偶也是可以保证的。由于凸优化的这一性质，它在带约束优化中具有非常重要的核心地位——因为我们可以通过转而优化对偶问题求得同样的解，这为优化过程提供了极大的方便性。另外有趣的是，不论原问题是否为凸优化，这一对偶问题都是一个凸优化问题，因此往往在求解上有一定的便利性。

进一步，当原目标函数和所有的约束函数都可导时，强对偶问题最重要的性质是使得 KKT（Karush-Kuhn-Tucker）^[13]条件成立的点可以同时满足原问题和对偶问题最优化的要求。KKT 条件是一组关于 x , λ , ν 的等式和不等式方程，它为很多带约束优化问题提供了求得解析解的思路，这里我们略去其具体形式，有兴趣的读者请进一步参考参考文献[13]中详细的

说明。

拉格朗日乘子法和 KKT 条件为带约束优化问题提供了标准思路。而当我们遇到的带约束优化问题为凸优化时，完全可以沿着这一标准思路来解决；当问题不是凸优化时，需要具体分析强对偶是否成立，再决定求解的思路。

通过拉格朗日方法，我们可以将一个带约束优化问题转化为不带约束的基本优化问题来解决。在下面的讨论中，我们将根据优化问题的特点介绍无约束优化的一些基本算法。

10.2.2 下降单纯形法

在有些问题中， f 不可导或者工程上求导代价极大^[4]这种情形下，假设函数值是连续的，我们有一种自然的思路，那就是采用不断试探的方法：在自变量为一维的情况下，给定一个初始区间，假设区间内有唯一的最小值，可以按照黄金分割的方法不断缩小区间以得到最小值。

上面的方法也可以推广到自变量是高维的情形，对应的算法称为下降单纯形法（downhill simplex method）。这一方法有一个更直观的称呼，即阿米巴变形虫法。简单地讲，将一维空间上用两个点限制的区间不断变形的思路加以推广，在 D 维空间中可以选择一个 $D+1$ 个点张成的超多面体或称为单纯形（simplex），然后对这一单纯形不断变形以收敛到函数值的最小点。

有关下降单纯形法的细节和代码实现可以参考参考文献[66]。

10.2.3 梯度下降法

当 f 可以比较容易地求导时，基于梯度的方法是首要选择。我们先来看一下梯度的定义。假设有 D 维空间中的自变量 $\mathbf{x} = (x_1, x_2, \dots, x_D) \in \mathbb{R}^D$ ，那么函数 $f(\mathbf{x})$ 在 $\mathbf{x}$ 点的梯度可以写成：

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_D} \right)^\top \quad (10.7)$$

梯度的几何意义是 f 在 $\mathbf{x}$ 点函数值上升最快的方向，因此它是一个与 $\mathbf{x}$ 维数相等的矢量。利用梯度的优化方法概念上就是每次都沿着梯度的相反方向按某步长前进一小步，这样的方法称为梯度下降法（gradient descent），其更新公式为：

$$\mathbf{x} \leftarrow \mathbf{x} - \epsilon \nabla f(\mathbf{x}) \quad (10.8)$$

其中 ϵ 控制着沿梯度负方向下降的速度，称为学习率（learning rate）。

很多工程中的目标函数都具有可分解的特性，即整个训练集上的梯度可以表示为各个训练样本梯度的和。在这种情况下，一个可行但效率并不高的并行实现就是将计算梯度的

过程分解到各个数据划分上分别完成，然后将各部分的梯度相加并更新参数。显然这样的计算过程非常容易在 MapReduce 框架下实现，然而每迭代一步，都要用到训练集所有的数据，可想而知，在数据规模较大时，这种方法的迭计算效率是比较低的。

在在线学习中，梯度下降的方法还有另外一种变形，也就是随机梯度下降（Stochastic Gradient Descent, SGD）^[12]的方法。在普通梯度方法中，计算一次下降方向需要很大的计算量，而 SGD 的每一次迭代并不是精确地计算梯度，而是基于随机选取的一个样例来计算梯度。这是一个重要的简化，在实际大数据的情况下，这比普通的梯度法效果更好。从计算角度来看，SGD 并不容易并行实现，为了实现其并行计算，产生了一系列并行 SGD 算法和相应的机器学习框架，如 Parallelized SGD^[82]等，有兴趣的读者可以深入了解。

10.2.4 拟牛顿法

在实际的工程问题中，简单地采用批处理模式的梯度下降法有时会遇到一个麻烦：当函数值对各个自变量归一化不够好时，优化过程会陷入 Zig-Zag 折线更新的困境，这一现象可以用图 10-1 中的例子来形象地说明。在自变量维数很高时，这一问题尤为严重，因为我们无法一一检查各个自变量的意义，因此在某些维度上缩放尺度不一样是无法避免的。如何避免这一问题呢？我们假设函数值呈现像图 10-1 中那样呈近似的二次曲面状，那么很自然的思路就是引入二阶导数信息，以迅速探索到函数值的谷底。




图 10-1 梯度下降法优化过程陷入 Zig-Zag 折线示意

$f(\mathbf{x})$ 的二阶导数是一个 $D \times D$ 的矩阵，其定义为：

$$\nabla^2 f(\mathbf{x}) = \left\{ \frac{\partial^2 f}{\partial x_i \partial x_j} \right\}_{D \times D} \quad (10.9)$$

这是一个 $D \times D$ 的矩阵，我们称之为赫斯矩阵（Hessian matrix）。同时利用梯度和二阶导数做优化，相当于在当前点处进行二阶的泰勒展开，并找到此二次曲面的极小值点，这样的方法称为牛顿法，其更新公式为：

$$\mathbf{x} \leftarrow \mathbf{x} + \epsilon [\nabla^2 f(\mathbf{x})]^{-1} \nabla f(\mathbf{x}) \quad (10.10)$$

当 $\epsilon=1$ 时，牛顿法的每一步都是在求一个二次曲面的极小值。显然，只有当赫斯矩阵正定时，极小值才存在。不过在实际的优化问题中，即使目标函数存在唯一的极小值，也不能保证每一点的赫斯矩阵都正定，因此一般来说，牛顿法并不是想象中那样可行。

解决上面的问题其实也不难：我们可以构造一个不太精确，但是可以保证正定的伪赫斯矩阵，用它来代替实际的赫斯矩阵更新参数，这样的方法就是工程上真正使用的拟牛顿法。直观上来看，利用前面几次迭代的函数值和梯度可以近似地拟合出赫斯矩阵，而随着拟合公式的不同，也就产生了不同的拟牛顿方法。拟牛顿的一种常见方法是由 Broyden、Fletcher、Goldfarb 和 Shanno 四位学者创造的，称为 BFGS 方法^[62]。在 BFGS 方法中，赫斯矩阵的逆是迭代更新的，其更新公式如下：

$$\mathbf{B}_{k+1} = \mathbf{B}_k + \frac{\mathbf{s}_k \mathbf{s}_k^\top}{\mathbf{y}_k^\top \mathbf{s}_k} \left[\frac{\mathbf{y}_k^\top \mathbf{B}_k \mathbf{y}_k}{\mathbf{y}_k^\top \mathbf{s}_k} + 1 \right] - \frac{1}{\mathbf{y}_k^\top \mathbf{s}_k} [\mathbf{s}_k \mathbf{y}_k^\top \mathbf{B}_k + \mathbf{B}_k \mathbf{y}_k \mathbf{s}_k^\top] \quad (10.11)$$

其中 $\mathbf{y}_k = \nabla_{k+1} - \nabla_k$ 为前后两次的梯度差，而 $\mathbf{s}_k = \mathbf{x}_{k+1} - \mathbf{x}_k$ 为前后两次的自变量差。这里之所以要直接操作赫斯矩阵的逆是因为在牛顿法的更新中，给定赫斯矩阵的逆和梯度矢量，可以通过简单的矩阵乘法得到更新方向，从而避免了复杂的求逆过程。

再来看看如何确定公式 10.10 中的步长 ϵ 。牛顿法是在当前自变量点进行泰勒展开，因此拟合出来的二次曲面严格来说只在很小的邻域内是有效的，因此我们完全无法保证按公式 10.10 或得到更好的函数值。但是，当 ϵ 足够小时，一定可以找到一个比现有函数值更优的点。要找到这样一个合适的 ϵ ，需要根据 Wolfe 条件^[62]，即要求 ϵ 满足如下的不等式：

$$\begin{aligned} f(\mathbf{x}_k + \epsilon \mathbf{p}_k) &\leq f(\mathbf{x}_k) + c_1 \epsilon \nabla f_k^\top \mathbf{p}_k \\ \nabla f(\mathbf{x}_k + \epsilon \mathbf{p}_k)^\top \mathbf{p}_k &\geq c_2 \nabla f_k^\top \mathbf{p}_k \end{aligned} \quad (10.12)$$

其中 $\mathbf{p}_k$ 为迭代第 k 步时找到的下降方向，在拟牛顿法中即为 $\mathbf{B}_k \nabla f_k(\mathbf{x})$ ，而 $0 \leq c_1 \leq c_2 \leq 1$ 为两个常数^[5]。因此，在实际的拟牛顿法中，在得到下降方向后，需要在下降方向上进行线搜索（line search），以找到满足 Wolfe 条件的 ϵ 用以更新参数。

需要强调，拟牛顿法是连续优化问题中最为基础的优化方法，它作为原子操作大量地被用在其他更为复杂的优化方法当中。因此，对拟牛顿方法熟练地掌握和应用是工程中非常重要的基本技能。我们在下面附上 BFGS 迭代求解的代码片段。

```

1 // 用于计算目标函数的值和梯度的函数指针类型
2 typedef vector<double> Vec;
3 typedef void (*FP_EVAL)(const Vec & x, double & f_x, Vec & df_x, ...);
4
5 // 以x0为种子, 用BFGS方法求目标函数f的局部极小值
6 void BFGS(FP_EVAL f, Vec & x0) {
7     double f_x0, f_xt; // 初始和更新后目标函数值
8     Vec df_x0, df_xt; // 初始和更新后梯度
9     Vec xt, s, y;
10
11     f(x0, f_x0, df_x0);
12
13     // B初始化成对称正定对角阵
14     int dim = x0.size();
15     vector<Vec> B; B.resize(dim);
16     for(int i = 0; i < dim; i++) {
17         B[i].resize(dim, 0.0);
18         B[i][i] = 1.0;
19     }
20
21     int iter = 0;
22     while(iter < MAX_ITER_NUM && dot(df_x0, df_x0) > TOL) { // 判断收敛
23
24         // 求下降方向 $-B\nabla f(x)$ 
25         d = scale(multiply(B, df_x0), -1.0);
26
27         // 线搜索
28         WolfeSearch(f, x0, d, xt);
29         f(xt, f_xt, df_xt);
30
31         s = minus(xt, x0);
32         y = minus(df_xt, df_x0);
33
34         // 迭代更新赫斯矩阵的逆
35         Vec t = multiply(B, y);
36         double rho = 1.0 / dot(y, s);
37         double l = dot(t, y) * rho * rho + rho;
38         for (int i = 0; i < B.size(); ++ i)
39             for (int j = 0; j <= i; ++ j) {
40                 B[i][j] -= rho * (s[i] * t[j] + s[j] * t[i]) + l * s[i] * s[j];
41                 B[j][i] = B[i][j];
42             }
43
44         // 进入下一轮迭代
45         x0 = xt; f_x0 = f_xt; df_x0 = df_xt;
46         iter ++;
47     }
48 }

```

这段代码仍然是示例性的，并且为了表述简洁，其中用到了未预先定义但意义很清楚的简单的运算函数，例如用 `dot` 函数计算两个适量的点积等。本书后面的一些代码也会有这样的情况，我们就不一一说明了。在上述代码中用到了一维线搜索求解步长，即其中的 `WolfeSearch` 函数调用。比较常见的方案是基于 Wolfe 条件的方法，下面给出其示例性代码。

```

1 // In:
2 // f      : 目标函数
3 // x0     : 初始自变量
4 // d      : 搜索方向
5 // Out:
6 // xt     : 更新后自变量
7 int WolfeSearch(FP_EVAL f, const Vec & x0, const Vec & d, Vec & xt) {
8     double f_x0, f_xt;
9     Vec df_x0, df_xt;
10
11     f(x0, f_x0, df_x0);
12
13     double leftBound = 0.0, rightBound = MAX; // 初始搜索区间[0, MAX]
14     double alpha = 1; // 初始步长
15     double C1 = 0.1, C2 = 0.9;
16     double ddt, dd0 = dot(d, df_x0);
17
18     int iter = 0;
19     while (iter < MAX_ITER_NUM) {
20         xt = x0;
21         plusAssign(xt, alpha, d); // xt = x0 + alpha * d, 检查下一个点
22
23         f(xt, f_xt, df_xt);
24         ddt = dot(d, df_xt);
25
26         if (f_xt > f_x0 + C1 * alpha * dd0) { // 检查函数是否充分下降
27             rightBound = alpha;
28             alpha = (leftBound + rightBound) / 2;
29         }
30         else if (ddt < C2 * dd0) { // 检查Wolfe条件是否满足
31             leftBound = alpha;
32             alpha = (leftBound + rightBound) / 2;
33         }
34         else return 0; // 找到了满足条件的点
35         iter ++;
36     }
37     return -1;
38 }

```

10.2.5 Trust-Region 法

梯度下降法、牛顿法和拟牛顿法都属于线搜索方法，它们的共同特点是，在当前迭代点 $\mathbf{x}^k$ 处寻找下一个迭代点 $\mathbf{x}^{k+1}$ 时，首先确定一个下降方向，然后沿着这个下降方向进行一维线搜索。这种搜索策略可以概括为“先方向，后步长”。Trust-Region 法采用的是一种不同的搜索策略：每次迭代时，将搜索范围限制在 $\mathbf{x}_k$ 的一个置信域内，然后同时决定下次迭代的方向和步长；如果当前置信域内找不到可行解，则缩小置信域范围。在每个迭代中，我们要求自变量的差 $\mathbf{s}_k$ 满足 $\|\mathbf{s}_k\|_2 \leq \delta_k$ 。另外为了单次迭代求解的效率，用函数在 $\mathbf{x}_k$ 附近的泰勒展开 $m_k(\mathbf{s}) = f(\mathbf{x}_k) + \nabla^\top f(\mathbf{x}_k)\mathbf{s} + \frac{1}{2}\mathbf{s}^\top \nabla^2 f(\mathbf{x}_k)\mathbf{s}$ 来近似原来的目标函数 $f(\mathbf{x}_k + \mathbf{s})$ 。具体来说，每一次迭代需要解下面形式的子问题：

$$\begin{aligned} \min_{\mathbf{s}} \quad & f(\mathbf{x}_k) + \nabla^\top f(\mathbf{x}_k)\mathbf{s} + \frac{1}{2}\mathbf{s}^\top \nabla^2 f(\mathbf{x}_k)\mathbf{s} \\ \text{s.t.} \quad & \|\mathbf{s}\|_2 \leq \delta_k \end{aligned} \tag{10.13}$$

通过解得的 $\mathbf{s}$ 就可以同时获得本次迭代的方向和步长。由于此过程没有对目标函数的一阶导和二阶导做近似，往往能够更准确地把握下降方向，因此有时能表现出比拟牛顿法更好的收敛性能。

在公式 10.13 的基础上，为了实现 Trust-Region 优化策略，还需要确定置信半径 δ_k 的选取。一般来说，可以通过比较模型函数和目标函数的下降量来指导置信半径的选择：

$$\rho_k = \frac{f(\mathbf{x}_k) - f(\mathbf{x}_k + \mathbf{s})}{m_k(\mathbf{0}) - m_k(\mathbf{s})}$$

如果 $\rho_k \leq 0$ ，说明目标函数值没有改进；若模型函数较真实地逼近了目标函数，我们期望 ρ_k 的值接近于 1；如果 ρ_k 的值较小，说明在当前置信域内，模型函数和目标函数差别较大，需要缩小当前的置信域；如果 ρ_k 的值较大，可以在下次迭代时适当伸长收敛半径。在这一思路的基础上，我们附上 Trust-Region 算法主流程的代码片段。

```

1 // 用Trust-Region方法求目标函数 $f$ 的局部极小值, 迭代初始点 $\mathbf{x}_0$ 
2 void TrustRegion(FP_EVAL f, Vec & x0) {
3     double delta, snorm, prered, actred, f_x0, f_xt, rho;
4     int iter = 0;
5     Vec x0, xt, df_x0, df_xt, s, r;
6
7     f(x0, f_x0, df_x0);
8     delta = dot(df_x0, df_x0);
9     double gnorm1 = delta;
10
11     while (iter < MAX_ITER_NUM) {
12         // 求解子问题10.13 得到位移 $\mathbf{s}$ 
13         tr_cg(delta, df_x0, s, r);
14
15         //  $\mathbf{x}_t = \mathbf{x}_0 + \mathbf{s}$ ,
16         // 计算在 $\mathbf{x}_t$ 点的梯度 $\nabla f(\mathbf{x}_t)$  和目标函数值 $f(\mathbf{x}_t)$ 
17         xt = x0;
18         plusAssign(xt, 1, s);
19         f(xt, f_xt, df_xt);
20
21         //  $\rho_k \leftarrow \frac{f(\mathbf{x}_k) - f(\mathbf{x}_k + \mathbf{s})}{m_k(\mathbf{0}) - m_k(\mathbf{s})}$ 
22         actred = f_x0 - f_xt;
23         prered = -0.5 * (dot(df_x0, s) - dot(s, r));
24         rho = actred / prered;
25
26         // 初始化首轮迭代的置信域大小
27         snorm = dot(s, s);
28         if (iter == 0) delta = min(delta, snorm);
29
30         // 根据目标函数、模型函数的逼近程度和一定的规则, 更新置信域的半径
31         double delta_old = delta;
32         delta = updateDelta(actred, prered, delta_old);
33
34         // 如果 $\rho_k > \eta$ , 则 $\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{s}_k$ , 否则 $\mathbf{x}_{k+1} = \mathbf{x}_k$ 
35         if (rho > ETA0) {
36             x0 = xt; f_x0 = f_xt; df_x0 = df_xt;
37             double gnorm = dot(df_x0, df_x0);
38             // 判断收敛
39             if (gnorm <= eps * gnorm1)
40                 break;
41         }
42         iter ++;
43     }
44 }

```


每个迭代中需要解子问题 10.13，即代码中 `tr_cg` 的函数调用。显然，这是一个带约束优化问题，由于 $\nabla^2 f(\mathbf{x}_k)$ 未必是正定的，因此这并不是一个凸优化问题。不过，在这个特殊的非凸优化中，读者可以自行验证，KKT 条件是可以满足的，因此仍然可以用拉格朗日法来求解。我们略去求解的过程，直接给出下面的解。 $\hat{\mathbf{s}}$ 为问题 10.13 的全局最优解，当且仅当 $\hat{\mathbf{s}}$ 本身是一个可行解，并且存在 $\lambda \geq 0$ 满足下面的条件：

$$\begin{cases} (\mathbf{H}_k + \lambda \mathbf{I}) \hat{\mathbf{s}} = -\nabla f(\mathbf{x}_k) \\ \lambda(\delta_k - \|\hat{\mathbf{s}}\|) = 0 \\ (\mathbf{H}_k + \lambda \mathbf{I}) \succeq 0 \end{cases} \quad (10.14)$$

最后一个不等式表示矩阵 $(\mathbf{H}_k + \lambda \mathbf{I})$ 是半正定的。当 $\hat{\mathbf{s}}$ 位于置信域内部时， $\lambda=0$ ，有显式解 $\hat{\mathbf{s}} = -\mathbf{H}_k^{-1} \nabla f(\mathbf{x}_k)$ ；当 $\hat{\mathbf{s}}$ 位于置信域边界上时， $\lambda>0$ ，问题变为寻找充分大的 $\lambda>0$ ，使得 $\mathbf{H}_k + \lambda \mathbf{I}$ 半正定，并且为 $\| -(\mathbf{H}_k + \lambda \mathbf{I})^{-1} \nabla f(\mathbf{x}_k) \| = \delta_k$ 这一方程的根，此时虽然不存在显式解，但由于这是一个单变量的优化问题，可以比较方便地用线搜索的方法得到解。根据公式 10.14，读者容易写出 `tr_cg` 函数的具体实现。

10.3 统计机器学习

机器学习是近年来得到快速发展和广泛应用的研究领域，它研究的是用数据或先验知识优化计算机算法的效果。从机器学习的方法可以分为统计方法和非统计方法。非统计的方法种类很多，并且往往最后都归结于一个具体的优化问题，可以通过深入掌握优化理论和算法，比较有效地把握各种非统计类方法。而统计类机器学习方法，虽然也用到最优化方法，但是还有一些在概率框架下系统性的思路。下面我们把统计方法的脉络稍加整理，供大家参考。

10.3.1 最大熵与指数族分布

统计机器学习中，指数族形式^[9]的分布由于求解的方便性，有非常重要的工程地位，我们先来看一下这一族分布形式产生的原因。要了解指数族形式产生的原因，需要先了解最大熵（Maximum Entropy, ME）原理^[6]。最大熵原理告诉我们，当在某些约束条件下选择统计模型时，需要尽可能选择满足这些条件的模型中不确定性最大的那个。如果采用熵作为统计不确定性的度量，这个问题就变成一个在这些约束下优化熵的问题。在最大熵的准则下，估计一个概率的优化问题可以表示成：

$$\begin{aligned} p^*(\mathbf{x}) &= \arg \max_{p(\mathbf{x})} H(\mathbf{x}) \\ \text{s.t. } E_p[f_d(\mathbf{x})] &= E_{\tilde{p}}[f_d(\mathbf{x})], \quad d = 1, \dots, D \end{aligned} \quad (10.15)$$

其中 $H(\mathbf{x}) = -\mathbf{p}(\mathbf{x}) \ln \mathbf{p}(\mathbf{x})$ 为概率分布 $\mathbf{p}(\mathbf{x})$ 的熵， $\mathbf{f}_i(\mathbf{x})$ 为一组特征函数，而优化中约束的意义是这一组特征函数在模型 $\mathbf{p}(\mathbf{x})$ 下的均值等于其数据上的均值 ($\tilde{\mathbf{p}}(\mathbf{x})$ 为数据分布)。有时是用最大熵准则来优化一个条件分布 $\mathbf{p}(\mathbf{x}|\mathbf{y})$ ，在这种情形下，可以很方便地构造一个相应的根据特征 $\mathbf{x}$ 对标签 $\mathbf{y}$ 进行分类的模型，本书后面将谈到的点击率预测的逻辑回归模型也属于此最大熵模型的特例。

上面的最大熵问题的另一项产出就是指数族分布。将拉格朗日方法应用于问题 10.15，有一项重要的结论，就是求其最大熵解等价于求一个对应指数形式分布的最大似然解。这样的结果带来了指数族分布这一工程中非常常用的分布形式。指数族分布的归一化形式 (canonical form) 可以表示为：

$$p(\mathbf{x}|\boldsymbol{\theta}) = h(\mathbf{x})g(\boldsymbol{\theta}) \exp\{\boldsymbol{\theta}^\top \mathbf{u}(\mathbf{x})\} \quad (10.16)$$




在这一形式中， $\mathbf{u}(\mathbf{x})$ 为上面 $\mathbf{f}_i(\mathbf{x})$ 聚合在一起的矢量形式； $\boldsymbol{\theta}$ 为指数族分布的参数，而 $g(\boldsymbol{\theta})$ 为使得概率密度曲线下面积为 1 的归一化项。指数族分布在建模上被广泛采用是因为一个重要的特性：指数族分布参数的最大似然估可以完全由其充分统计量 (sufficient statistics)

得到。这里的充分统计量指的是训练集上变换函数 $\mathbf{u}(\mathbf{x})$ 的统计量，即 $\sum_{i=1}^N \mathbf{u}(\mathbf{x}_i)$ 。在给定了充分统计量以后， $\boldsymbol{\theta}$ 的最大似然解可以通过解下式求得：

$$-\nabla \ln g(\boldsymbol{\theta}_{\text{ML}}) = \frac{1}{N} \sum_{i=1}^N \mathbf{u}(\mathbf{x}_i) \quad (10.17)$$

这一概念强调的是，在给定充分统计量以后，最大似然估计过程与数据无关。根据充分统计量的形式，我们很容易得出，无论什么样的指数族分布，都只需要遍历一遍数据就可以得到最大似然解，这一点实际上对应了一个非常简便的 MapReduce 实现。这也是指数族分布在大数据运算上带给我们的最大便利性。由于指数族的分布形式与最大熵原理的本质联系，这一族的许多重要分布都可以从最大熵的角度加以解释。表 10-1 总结了几种重要的指数族分布形式以及其主要用于描述的变量类型。

表 10-1 若干重要指数族分布形式

分布	$\mathbf{u}(\mathbf{x})$	解释	使用场景	示例
高斯分布	$\begin{bmatrix} x \\ x^2 \end{bmatrix}$	给定均值方差时熵最大的分布	一般实变量	
γ 分布	$\begin{bmatrix} x \\ \ln x \end{bmatrix}$	给定均值方差, 且 $x > 0$ 时熵最大的分布	非负实变量	
β 分布	$\begin{bmatrix} \ln x \\ \ln(1-x) \end{bmatrix}$	给定均值方差, 且 $x \in (0, 1)$ 时熵最大的分布	某区间内的实变量	
多项式分布	$\mathbf{x}$	给定均值方差, 且 $\mathbf{x} \in \{0, 1\}^D$ 时熵最大的分布	离散变量	

从表 10-1 给出的示例中可以发现指数族分布的另一个重要特点——分布都是单模态（uni-modal）的。所谓单模态，可以理解为分布从几何形态上看只有一个峰或者一个谷，这说明指数族分布虽然数学上使用方便，但其实际的描述能力是有限的，并不适合于表达多种因素并存的随机变量。

10.3.2 混合模型和 EM 算法

由于指数族分布是单模态的，因而不适用于分布比较复杂的数据建模。为了解决这个问题，同时又能充分利用到指数族分布的一些方便的性质，工程领域产生了采用多个指数族分布叠加的部分来建模的实用方法，即混合模型（mixture model）。指数族分布形式的混合模型可以表示为：

$$p(\mathbf{x}|\boldsymbol{\omega}, \boldsymbol{\Theta}) = \sum_{k=1}^K \omega_k h(\mathbf{x}) g(\boldsymbol{\theta}_k) \exp\{\boldsymbol{\theta}_k^\top \mathbf{u}(\mathbf{x})\} \quad (10.18)$$

其中 $\boldsymbol{\omega} = (\omega_1, \dots, \omega_K)$ 为各个组成分布先验概率，而 $\boldsymbol{\Theta} = \{\boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_K\}$ 表示各个组成分布的参数。这一分布的图模型如图 10-2 所示。




图 10-2 混合分布的概率图模型表示

在许多常见的机器学习模型当中，根据多个变量的条件依赖关系，图 10-2 的有向图模型可以比较清晰地表达整体的联合分布。有向图模型的每一个节点代表一个随机变量，而给定了该变量所有入边对应的起始节点后，该变量的分布与其他所有变量都条件无关。需要指出，有向图模型本身只给出了条件依赖关系，并没有明确各条件分布的形式。一般来说，我们在工程中的思路是，用图模型表达先验的变量结构关系，然后对每个条件分布选取合适的指数族分布来建模，而混合分布模型就是了解这种工程思路的最典型例子。按照上面的有向图模型表示，我们引入了多项式变量 $\mathbf{z} = (z_1, \dots, z_K)$ 来明确表示状态，可以把混合分布改写成结构更清晰的表达式：

$$p(\mathbf{x}|\boldsymbol{\omega}, \boldsymbol{\Theta}) = \sum_{\mathbf{z}} \prod_k \omega_k^{z_k} \left\{ h(\mathbf{x}) g(\boldsymbol{\theta}_k) \exp\{\boldsymbol{\theta}_k^\top \mathbf{u}(\mathbf{x})\} \right\}^{z_k} \quad (10.19)$$

在混合模型的最大似然求解过程中，最大期望（Expectation-Maximization, EM）算法起着非常重要的作用。从上面的概率图模型例子可以看出，除了要求解的参数 $\boldsymbol{\omega}$ 、 $\boldsymbol{\Theta}$ 和观测到的变量 $\mathbf{x}$ ，还存在一个变量 $\mathbf{z}$ ，我们把这样的变量称为隐变量（hidden variable）。EM 算法就是为了解决有隐变量存在时的最大似然估计问题的。这是一种迭代的算法，每个迭代又可以分为 E-step 和 M-step。在 E-step 阶段，将参数变量和观测变量都固定，得到隐变量的后验分布；在 M-step 阶段，用得到的隐变量的后验分布和观测变量再去更新参数变量。以上面的混合分布问题为例，在 EM 算法的每一步迭代当中，都转而求解以下辅助函数优化问题：

$$\max_{\boldsymbol{\omega}, \boldsymbol{\Theta}} Q(\boldsymbol{\omega}, \boldsymbol{\Theta}; \boldsymbol{\omega}^{\text{old}}, \boldsymbol{\Theta}^{\text{old}}) = \max_{\boldsymbol{\omega}, \boldsymbol{\Theta}} \sum_{\mathbf{z}} p(\mathbf{z}|\mathbf{X}, \boldsymbol{\omega}^{\text{old}}, \boldsymbol{\Theta}^{\text{old}}) \ln p(\mathbf{X}, \boldsymbol{\omega}, \boldsymbol{\Theta}|\mathbf{z}) \quad (10.20)$$

由于此时的隐变量 $\mathbf{z}$ 是离散的，因此等式右边为求和的形式，如果在其他问题中遇到的隐变量是连续的，那么只需要将求和号换成积分号即可。

对应于公式 10.20，指数族混合分布 EM 算法的 E-step 和 M-step 可以很容易求出，其结果如下式：

$$\text{E-step: } \gamma_i(k) \triangleq p(z_k = 1 | \boldsymbol{\Theta}^{\text{old}}, \boldsymbol{\omega}^{\text{old}}, \mathbf{x}_i) = \frac{\omega_k^{\text{old}} g(\boldsymbol{\theta}_k^{\text{old}}) \exp\{\mathbf{u}^\top(\mathbf{x}_i) \boldsymbol{\theta}_k^{\text{old}}\}}{\sum_l \omega_l^{\text{old}} g(\boldsymbol{\theta}_l^{\text{old}}) \exp\{\mathbf{u}^\top(\mathbf{x}_i) \boldsymbol{\theta}_l^{\text{old}}\}} \quad (10.21)$$

$$\begin{aligned} \text{M-step: } -\nabla \ln g(\boldsymbol{\theta}_k^{\text{new}}) &= \frac{1}{N} \sum_{i=1}^N \gamma_i(k) \mathbf{u}(\mathbf{x}_i) \\ \omega_k^{\text{new}} &= \frac{1}{N} \sum_{i=1}^N \gamma_i(k) \end{aligned} \quad (10.22)$$

在混合分布的情形下,这种分解使得许多非指数族分布的模型在进行最大似然估计时,其 **M-step** 形式上与简单的指数族分布是一致的,这也使得指数族分布工程上的便利性得以继续发挥。虽然 **M-step** 的形式与指数族最大似然估计的形式公式 10.17 非常相近,我们却不宜将等式右边的部分也称为充分统计量,因为这一过程是迭代进行的,需要多次访问数据才能完成最大似然估计,因此,简单地称其为统计量更为准确。

指数族分布的混合模型在工程中的应用同样很广泛,只要是单模态分布不易刻画的数据分布都可以考虑用某种指数族分布叠加的方式更精确地建模。常见的混合模型,如高斯混合模型 (Mixture of Gaussians, MoG) 和概率潜在语义索引 (Probabilistic Latent Semantic Index, PLSI), 可以认为后者是建立在多项式分布基础上的混合模型,在文本主题分析中有着广泛的应用。

需要注意的是,指数族混合分布的 EM 算法只是 EM 算法的一种较简单的特殊情况,这一算法广泛应用于各种隐变量存在的统计模型训练中,有关这方面更详细的理论和应用介绍可以参考参考文献[9, 28]。

10.3.3 贝叶斯学习

以上讨论的模型参数估计方法都是在最大似然准则下进行的。最大似然准则是把模型的参数看成固定的,然后找到使得训练数据上似然值最大的参数,这是一种参数点估计 (point estimation) 的方法。这样的点估计方法在实际中如果遇到数据样本不足的情形,往往会产生比较大的估计偏差。对此,工程上常常用到贝叶斯学习的方法论。为了介绍贝叶斯学习的基本概念,我们先从下面的贝叶斯公式入手了解其中的关键概念。

$$\underbrace{p(\theta|X)}_{\text{后验分布}} = \frac{\overbrace{p(X|\theta)}^{\text{似然值}} \overbrace{p(\theta)}^{\text{先验分布}}}{\underbrace{p(X)}_{\text{evidence}}} \quad (10.23)$$

在贝叶斯体系下,模型参数 θ 不再被认为是固定不变的量,而是服从一定分布的随机变量。在没有数据支持的情况下,我们对其有一个假设性的分布 $p(\theta)$, 这称为先验分布 (prior),而在观测到数据集 $X=\{x_1, \dots, x_n\}$ 以后,根据数据集上表现出来的似然值(likelihood) $p(X|\theta)$, 可以得到调整后的后验分布 $p(\theta|X)$ 。先验分布、后验分布和似然值之间的变换关系就通过上面的贝叶斯公式表达出来。等式右侧的分母项也是贝叶斯学习中的一个重要概念,称为 **evidence**, 它可以展开表示为 $p(X) = \int p(X|\theta) p(\theta) d\theta$ 。由贝叶斯公式和这些重要概念出发,表 10-2 对比了三种常见的模型估计方法。

表 10-2 若干常见模型估计方法

模型估计方法	参数估计	预测
最大似然方法	$\hat{\theta}_{\mathbf{X}}^{\text{ML}} = \arg \max_{\theta} p(\mathbf{X} \theta)$	$p(\mathbf{o} \mathbf{X}) = p(\mathbf{o} \hat{\theta}_{\mathbf{X}}^{\text{ML}})$
贝叶斯方法	$p(\theta \mathbf{X}) = p(\mathbf{X} \theta)p(\theta)$	$p(\mathbf{o} \mathbf{X}) = \int p(\mathbf{o} \theta)p(\theta \mathbf{X})d\theta$
最大后验概率方法	$\hat{\theta}_{\mathbf{X}}^{\text{MAP}} = \arg \max_{\theta} p(\theta \mathbf{X})$	$p(\mathbf{o} \mathbf{X}) = p(\mathbf{o} \hat{\theta}_{\mathbf{X}}^{\text{MAP}})$

概率统计模型有两个常见任务：一是参数估计（parameter estimation），二是预测（prediction）。其中第二项任务指的是给定一组训练数据 $\mathbf{X}$ ，评估某新的观测数据 $\mathbf{o}$ 的概率。在最大似然体系中，参数估计是根据似然值最大化得到的点估计，而预测过程就利用估计出来的参数计算似然值 $p(\mathbf{o}|\theta)$ 即可。在贝叶斯体系下，参数的点估计为其后验分布所代替，也就意味着参数在估计结果中具有不确定性，于是，在预测过程中，需要用积分的方式将参数的不同可能性都加以考虑，这是两者非常本质的区别。还有一种常见的参数估计方法，即最大后验概率（Maximum A Posterior, MAP）方法，它本质上仍然是点估计方法，只不过同样引入了先验部分对参数作规范化，因此，其参数估计形式上是对贝叶斯后验概率求极值，而预测过程则与最大似然情形一样。

1.共轭先验

贝叶斯方法的关键问题之一是如何选择公式 10.23 中的先验分布 $p(\theta)$ 。这一点有两层含义：一是如何选择先验分布的形式，二是如何确定先验分布中的参数。之所以要讨论这个问题，是因为虽然先验分布的形式是我们选择的，但后验分布 $p(\theta|\mathbf{X})$ 的形式却无法选择，而后验分布才是在使用中最关键的，其形式如果过于复杂，会给实际应用带来很大困难。如果我们能够找到一种先验分布，使得相应的后验分布也具有同样的形式，无疑是方便的。满足这种条件的先验分布就称为共轭先验（conjugate prior）。

对于指数族分布的似然函数，容易发现共轭先验总是存在的，这又一次说明了指数族分布在工程上的便捷性。对于公式 10.16 的指数族分布形式，其共轭先验可以一般性地写成：

$$p(\theta|\eta) = \exp \{ \chi^{\top} \theta - \nu g(\theta) - b(\chi, \nu) \} \quad (10.24)$$

值得注意，这一指数族分布的共轭先验分布仍然是指数族的形式，其用到的数学工具也就与前面的讨论一致。这一先验分布的参数 $\eta = \{\chi, \nu\}$ 称为超参数（hyper-parameter）， η 控制着先验分布的具体形状。

将前面介绍的几种典型指数族分布与公式 10.24 相对照,可以得到以下相应的共轭先验。

(1) 对于高斯分布, 如果仅仅考虑其均值的不确定性, 对应的共轭先验仍然是高斯分布。

(2) 对于 γ 分布, 其对应的共轭先验称为维希特分布 (Wishart distribution) 。

(3) 对于多项式分布, 其对应的共轭先验是狄利克雷分布 (Dirichlet distribution) 。

多项式-狄利克雷这一共轭对是后面介绍的文本主题分析中非常重要的分布形式。

当模型为指数族分布并选择共轭先验的情形下, 对应的后验分布 $p(\theta|X)$ 可以很简单地写成下面的形式:

$$\tilde{\chi} = \chi + \sum_{i=1}^N \mathbf{u}(\mathbf{x}_i) \quad (10.25)$$

$$\tilde{\nu} = \nu + N \quad (10.26)$$

这里用变量上的波浪线代表后验。我们又一次看到, 指数族分布的充分统计量在这里仍然发挥了核心作用, 其结果使得贝叶斯学习中后验概率分布的计算非常简便。需要特别指出, 选择共轭的先验形式, 从贝叶斯体系来看并没有太多理论上的必然性, 这主要是为了满足工程上的方便性。

同样是从工程上来说, 采用贝叶斯方案的目的是为了对模型参数进行约束, 以提高估计的稳健型。因此, 超参数的选择同样十分关键, 因为超参数的取值决定了模型参数的自由程度。在实际应用中, 可以根据一些领域知识和经验来设定超参数值, 但是这样的方法有两个问题。

(1) 当模型过于复杂, 超参数数目太多时, 不太可能都根据经验相对合理地设定超参数。

(2) 采用这种主观的方式设定超参数, 必然导致在一个固定的数据集上参数估计的结果会随着主观超参数的不同而变化, 这有些背离数据建模的客观性。因此, 有必要探索一种数据驱动的超参数设定方法。

2.经验贝叶斯

数据驱动的超参数决定方法中, 经验贝叶斯的方法值得大家注意。在公式 10.23 中, 右边的分母, 即 **evidence**, 是将模型参数积分后的似然值的期望。可以注意到, 在似然值和先验部分的形式确定的前提下, **evidence** 仅仅是先验部分的函数。从概念上来看, 如果把 **evidence** 认为是超参数对应的似然值, 那么也可以用优化 **evidence** 的方式找到最优的超参数。这种根据数据来确定超参数的方法就称为经验贝叶斯, 其优化问题可以表示为:

$$\hat{\eta} = \arg \max_{\eta} \int \prod_{i=1}^K p(\mathbf{X}_i|\theta_i) p(\theta_i|\eta) d\theta_i$$

由于是根据 **evidence** 来确定超参数，这一方法框架又称为 **evidence** 框架。需要说明，**evidence** 框架除了能够用于确定超参数，同样可以用于在若干种先验部分形式中作选择，选择标准仍然是判断各种分布的 **evidence** 的大小。上式中还有一点需要特别注意，那就是我们是假设 $i=1, \dots, K$ 个模型共享同一个先验分布。从后面的讨论可知，只有当 $K>1$ 的时候，上面的经验贝叶斯问题才会有非退化的解。

在公式 10.27 中， X 为观测量， η 为参数，而 θ 实际上是隐变量。因此，最直接的思路仍然是使用 EM 算法^[9]来求解。当 $p(x|\theta)$ 为指数族分布，而 $p(\theta|\eta)$ 为其共轭先验分布时，对应的 EM 辅助函数可以写成下面的表达形式：

$$\begin{aligned} Q(\eta, \eta^{\text{old}}) &= \sum_{i=1}^K \int_{\theta_i} p(\theta_i | X_i, \eta^{\text{old}}) \ln p(X_i, \theta_i | \eta) d\theta_i \\ &= \sum_{i=1}^K \int_{\theta_i} p(\theta_i | X_i, \eta^{\text{old}}) \ln p(\theta_i | \eta) d\theta_i + C \\ &= \sum_{i=1}^K \int_{\theta_i} p(\theta_i | \tilde{\eta}_i^{\text{old}}) \ln p(\theta_i | \eta) d\theta_i + C \end{aligned} \quad (10.27)$$

请注意，在这里用到了共轭先验的性质，即后验分布有着与先验分布一样的行为，并且将第 i 个模型的后验超参数记为 $\tilde{\eta}_i^{\text{old}}$ 。仔细观察这一结果，如果把 θ 当成数据， η 当成参数，那么已知的后验分布 $\frac{1}{K} \sum_{i=1}^K p(\theta_i | \tilde{\eta}_i^{\text{old}})$ 可以看成是数据的分布，而 $\ln p(\theta_i | \eta)$ 则相当于参数 η 在此数据集上对应的似然值。于是，对此辅助函数的优化相当于是在此数据分布上对 η 进行最大似然估计。又由于 $p(\theta | \eta)$ 也是指数族分布，其最大似然估计可以通过充分统计量得到。该经验贝叶斯问题的 E-step 和 M-step 可以表示成下面的形式：

$$\begin{aligned} \text{E-step: } \tilde{\chi}^{\text{old}} &= \chi^{\text{old}} + \sum_{i=1}^N \ln p(\chi_i | \eta^{\text{old}}) \quad \tilde{\eta}^{\text{old}} = \eta^{\text{old}} + N \\ \text{M-step: } \langle \theta, g(\theta) \rangle_{p(\theta | \eta^{\text{new}})} &= \frac{1}{K} \sum_{k=1}^K \langle \theta, g(\theta) \rangle_{p(\theta | \tilde{\eta}_k^{\text{old}})} \end{aligned} \quad (10.28)$$

其中的 E-step 就是采用共轭先验的情形下后验的计算公式，而 M-step 是一个关于 η^{new} 的方程，此方程是否有闭式解与具体的指数族分布形式有关。

10.4 统计模型分布式优化框架

在上面介绍的一些统计机器学习模型中可以发现，指数族分布及其充分统计量在计算流程中起着非常关键的枢纽作用。不论是指数族分布的最大似然解、指数族混合分布的最大似然解，还是指数族分布的贝叶斯学习，如果采用 MapReduce 的计算框架，都可以用图 10-3 来描述。




图 10-3 指数族分布 MapReduce 学习框架

从这一计算流程可以看出，对于大规模数据上的许多机器学习计算问题，MapReduce 是一个可行的选择：因为在机器之间交换的数据只是统计量或者充分统计量，其空间复杂度仅仅与模型的参数数目有关，与数据的多少并无直接关系。不过，MapReduce 的方案却并不是一个高效的方案，当算法需要多次迭代才能完成的时候，由于需要在每次 Map 过程中重新加载数据，使得整个过程的 I/O 负担变得较重，从而降低整个计算过程的效率。这里的分析主要是针对上面指数族分布相关的概率估计问题，但是对于前面提到的迭代式优化问题也同样成立。

由于 MapReduce 方案在面对迭代求解问题时效率不高，我们应该考虑其他替代方案。当数据的规模可以承受时，采用 Spark 之类的计算框架会更加高效，可以参考 9.5.9 一节中的介绍。而在 Hadoop 新一代的调度器 YARN 的基础上，Spark 可以直接架设在 Hadoop 底层的分布式存储 HDFS 上，这使得数据可以直接在 Spark 的计算过程中复用，并没有在不同集群之间大量传递数据的开销。

第 11 章 合约广告核心技术

合约广告的关键特征是广告投放的价格和量由双方协商约定。合约广告的最初形式是按广告位售卖的 CPT 广告，而这样的 CPT 广告排期系统并不是一个个性化系统，技术实现上相对简单。不过，在实际的媒体广告投放中，经常会遇到 CPT 广告与其他服务器决策的动态广告混合的情形，并需要处理动态广告返回失败时的防天窗问题。本章将会介绍这样一个混合排期系统的决策框架。

合约广告的重点形式是按指定受众购买的、按 CPM 计费的展示量合约广告。展示量合约广告的投送系统称为担保式投送系统。它依赖于受众定向、流量预测、点击率预测这三项基本技术，并采用在线分配的方式完成实时决策。由于受众定向和点击率预测的重要程度已经超出了合约广告的范畴，我们会在后续的章节中陆续介绍。而在线分配问题，即在一组合约量的约束条件下，对每个在线到达的展示作投放决策，以优化某效果目标这一问题，将是本章介绍的重点技术。

担保式投送的决策逻辑比较复杂，而且在目前竞价广告为主的市场环境中显得有些过时。然而，此问题的研究却对广告中广泛存在的“量的约束下优化效果”这一根本诉求给出了重要的框架，而这一框架在各种市场形态中都有具体的表现形式，比如后面章节中将介绍的 ADX 中的询价优化问题等。因此，我们希望能从两个方面介绍此问题的一般性思路：一是在未来流量分布未知的情形下，如何估计在线分配算法的极限性能；二是在根据历史数据能进行相对合理的流量预测的情形下，如何利用这些预测搭建一个实用的在线分配系统。

按 CPM 售卖的合约广告除了上述的核心算法，还有两项广泛应用的支持技术，即流量预测和频次控制。其中流量预测是在线分配的基础，也是后面竞价广告系统中广泛使用的功能。有多种流量预测的方法，本章将介绍一种基于信息检索技术的方案。而频次控制则是广告主为了展示的有效性提出的控制性要求。关于这两项技术的业务背景和常用的技术方案也将在本章中介绍。

11.1 广告排期系统

对于按 CPT 结算的广告位合约，媒体一般采用广告排期系统来管理和执行。广告排期系统与我们后面要讨论的各种广告系统都不同，因为它并不是一个个性化系统，也不太需要服务器端的动态决策。广告排期系统的一般技术方案是将广告素材按照预先确定的排期

直接插入媒体页面，并通过内容分发网络（Content Delivery Network，CDN）加速访问。这样可以使得广告投放延迟很小，也没有服务端的压力和开销。

广告排期系统需要注意的技术环节是在与其他动态广告相混合投放时的调度策略。由于广告位合约的方式不需要在服务器端计算，因此在混合投放时，要充分考虑这一特点，尽可能地减少服务器的负载。另外一个相关的问题就是当一些横幅广告位上没有广告位合约，需要用其他服务器动态决策的广告补足时，由于服务器可能出现超时或其他错误导致广告未能返回，那么也需要在页面上展示一个默认广告防止出现广告位的空白，这样的广告称为防天窗广告。防天窗广告由于需要在服务器不工作的情形下补位，因此也应该放在 CDN 上实现。下面详细介绍这类混合投放时的决策逻辑。

排期与动态广告混合系统

对一个广告位合约与动态广告混合投放的系统来说，需要同时考虑 CPT 广告和防天窗广告的投放逻辑。我们以 Web 页面上的广告投放为例来描述这一调度过程，此过程的示意图如图 11-1 所示。




图 11-1 排期与动态广告混合投放决策逻辑

（1）首先，前端的广告位代码从 CDN 上获取一个默认广告素材以及标示此广告是优先的 CPT 广告还是防天窗广告的参数。

（2）根据上述参数，如果 CDN 上获得的是一个 CPT 广告，那么直接将素材渲染在页面上即可。

（3）如果 CDN 上获得的是一个防天窗广告，则优先向广告投放机发送请求，如果在指定延迟时间内有广告返回，则将其渲染在页面上。

（4）如果服务器在指定延迟时间内没有广告返回或发生其他错误，则将从 CDN 里得到的防天窗广告渲染在页面上。

可以很容易地验证，只要 CDN 不发生错误，这样的系统可以保证不会出现广告位上的天窗。同时，由于我们对广告位合约直接透过前端投放，在这部分流量上避免了访问服务

器带来的延迟，因此 CPT 广告的效果可以得到较好的保证。实际的排期和动态广告混合系统，由于有轮播模式的存在和地域定向^[4]的需求，会比上述的逻辑更加复杂一些，不过没有原理上的差异。

虽然本书的重点是讨论各种基于受众定向的动态广告系统，但是读者需要了解，往往上面这样的排期调度系统是媒体投放展示广告的基础系统，而各种动态广告产品的接入则统一在步骤 2 中进行。

11.2 担保式投送系统

与展示量合约对应的广告系统称为担保式投送（Guaranteed Delivery, GD）系统。在展示量合约这样的交易结构中，只要合约都被满足，系统的收益就是一定的，于是公式 2.2 中的优化目标变成了常数。不过，这一系统多了合约带来的一组量的约束条件，因此变成了一个带约束优化问题。关于此问题的具体描述和解法将放在后面的在线分配部分中介绍。有时，展示量合约还会约定投放量未达到时的惩罚，在这种情况下，目标不再是一个常数，不过这仍然可以用在线分配的一般框架来解决。

担保式投送系统的整体架构如图 11-2 所示。在此系统中，在线投放引擎接收用户触发的广告请求，根据用户标签和上下文标签找到可以匹配的广告合约，然后由在线分配模块决定本次展示投放哪个广告。完成决策后，将展示和点击日志送入数据高速公路。这些日志一方面进入离线分布式计算平台以后，通过日志的整理，完成合约的计划，即确定在线分配算法的参数，再将分配方案送给线上投放机使用；另一方面，日志也送到流计算平台，在反作弊和计价的基础上，再对索引进行快速调整。可以看出，这一系统的核心技术是在线分配的算法策略与执行过程。

由于担保式投送需要用到人群标签或上下文标签，因此在广告检索的过程中也需要用到用户标签（user attribute）和页面标签（page attribute）这两个标签库，由于标签的生成过程与担保式投送本身的关系不大，我们将放在后面受众定向技术部分集中讨论。

担保式投送需要用到的核心技术，最重要的就是在线分配。关于在线分配，我们将在下面用专门的章节介绍。除了在线分配以外，担保式投送还有另外两项主要的支持技术：流量预测和频次控制。




图 11-2 担保式投送广告系统架构示意

11.2.1 流量预测

在展示量合约广告中，流量预测^[75]是一项支持技术，它对于在线分配的效果至关重要。除此以外，在广告网络中，一般来说也需要根据定向条件和出价估计广告展示量，以辅助广告主进行决策。因此，流量预测是一项在计算广告中广泛使用的技术。

流量预测的问题可以描述为：给定一组受众标签组合以及一个 $eCPM$ 的阈值，估算在将来某个时间段内符合这些受众标签组合的条件、并且市场价在该 $eCPM$ 阈值以下的广告展示量。这里的 $eCPM$ 阈值主要是用于竞价广告系统中，目的是了解在某出价水平下的流量情形。对于展示量合约式广告来说，这个阈值是不需要的，或者为了工程上一致，将该阈值设为一个很大的常数。

流量预测一般的方法其实并不是预测，而是根据历史数据的统计来拟合未来的流量。当然，也可以引入时间序列分析的方法，从流量在时间轴上的规律预测未来某个时间段的流量，这主要适用于需要短时预测的场景，对广告业务来说并不十分必要。因此，此节将主要介绍根据历史数据统计的方法。用统计的方法解决流量预测问题，工程上的主要挑战在于，给定的受众标签组合可能性非常多，不可能将所有这些组合都预先做好统计。可行的思路是将其视为一个反向检索的问题：在一般的广告检索问题中，索引的文档是广告 a ，而查询是 (u, c) 上的标签；而在流量预测问题中，索引的文档由广告 a 变成了每次展示，而文档的内容即是这次展示上的 (u, c) 上的标签，而查询由 (u, c) 上的标签变成了广告设置的受众条件。可以看出，这两个问题是对偶的，可以用类似的技术方案来解决。

对比广告检索问题，流量预测的检索问题要简单一些：首先， (u, c) 供给节点不存在布尔表达式描述，而是简单的特征集合；另外，流量预测的大多数应用场景对实时性的要求都不算高，例如，在竞价系统辅助决策时，秒级的响应完全可以满足要求，这比起线

上广告检索毫秒级的要求显然要低得多。用反向检索的方案来进行流量预测，主要包括以下几个步骤。

(1) 准备文档。将历史流量中， (u, c) 上的所有标签的展示合并为一个供给节点 i ，并统计其总流量 s_i 以及这部分流量上 $eCPM$ 的直方图 $hist_i$ 。这样的每个供给节点作为流量预测反向索引的一篇文档。

(2) 建立索引。对上一步生成的每个供给节点建立倒排索引，文档的 **terms** 即为此供给节点 (u, c) 上的所有标签。同时，在索引的正排表部分记录 s_i 和 $hist_i$ 。

(3) 查询结果。对一条输入的广告 a ，将其限定的标签条件作为查询，得到所有符合条件的供给节点的集合。

(4) 估算流量。遍历上一步得到的每个供给节点，对于某个供给节点 i ，首先计算其与该广告 a 的 $eCPM$ 即 $r(a, u_i, c_i) = \mu(a, u_i, c_i) bid_a$ ，然后根据相应的 $eCPM$ 直方图 $hist_i$ 计算 a 能获得的流量。这样，就可以估算出 a 在出价 bid_a 情形下近似能获得的流量。

基于反向索引的流量预测方法如图 11-3 所示。实际操作过程中，由于历史广告投放日志可能流量非常大，将所有的供给节点都建立索引规模上是无法承受的。当然，实际上我们也并不需要这样做，在流量预测误差允许的范围内，我们可以在上面的第 1 步和第 2 步之间加一个采样的过程，将索引中的供给节点的数量控制在合理的规模。




图 11-3 基于反向索引的流量预测示意

11.2.2 频次控制

频次，指的是某个用户在一段时间内看到某个或某组广告的曝光次数。关于频次对广告效果的影响，Herbert E.Krugman 博士在 1972 年提出了著名的“三打理论”（three hit theory）^[48]：第一次，刺激消费者试着了解信息，去问“这个广告是什么？”；第二次，刺激消费者去评量，去问“广告内容是什么？”“我曾经看过这个广告吗？”；第三次，消费者接触

到广告时会回忆并开始逃离广告。三次足以对消费者产生作用。这个理论对广告投放的效果有重要的指导意义，但是主要适用于传统广告，并且是假设用户已经顺利通过了关注阶段。对于互联网广告，技术手段能够记录到的展示，在广告位置差异的影响下，离有效展示有相当大的距离，因此无法直接套用三打理论。不过，一般来说，随着某个用户看到同一个创意频次的上升，点击率呈下降的趋势这一点是可以被验证的。因此，在按照 CPM 采买流量时，广告主有时会要求根据频次控制某个用户接触到某创意的次数，以达到提高性价比的目的。特别是在视频广告这样有效曝光程度较高的广告产品中，频次控制(frequency capping)的意义和重要性尤为显著。

图 11-4 给出了某广告产品中实际的频次与广告效果 (eCPM) 的关系曲线。将这一量化结果与传统广告的频次理论相对比，会有一些新的发现：首先，广告效果随着频次的上升呈单调的下降趋势，而并非在三次时达到最佳；其次，频次较高的广告展示效果很差，因此，没有足够的广告主数量，整体的广告效果会受到相当大的限制。而这些特点在竞价广告产品中更加容易利用，我们将在第 13 章中再讨论。




图 11-4 频次与广告效果的关系示例

从计算的角度来看，频次是使得公式 2.2 中的可分性假设不成立的最主要影响因素。而将频次作为一个可控制的定向条件引入广告系统后，这个问题虽不能被彻底解决，却是大大地缓解了。频次控制的需求可以描述成，控制各 (a, u) 组合在一定的时间周期内

的展示量。应该说，频次的明确要求主要存在于展示量合约广告中，而在 CPC 结算的竞价广告中，可以将频次作为 CTR 预估的特征之一，从而隐式地对广告的重复展示进行控制。

频次控制有客户端和服务端两种解决方案。客户端的方案就是把某个用户对某个广告创意的频次值记录在浏览器 cookie 中，投放决策时再把这个值传给服务器来决策创意。这一方案的好处是简单易行，而且服务成本低。缺点是扩展性不好，当同时跟踪多个广告的频次时，cookie 可能会变得很重，从而影响广告响应时间。当然，在移动应用广告中利用 SDK 做前端投放控制的场景，客户端的方案是非常好的选择。服务器端的方案是在后台设置一个专门用于频次记录和更新的缓存，当广告请求到来时，在缓存中查询候选广告的频次，并根据最后实际投放的广告更新频次。

频次控制用到的缓存，同时存在高并发读和高并发写的要求。而且随着频次控制粒度要求的不同，需要记录的频次变量数目也可能很大。比如在创意级别控制频次就比在广告主级别控制频次需要更多的缓存容量。不过考虑到问题的实际情况，这一缓存实际上可以有很轻量级的方案。对我们有利的问题特性主要有以下两点。

(1) 频次存储的规模是有上界的。如果我们在某个时间周期内控制频次，那么上述的频次变量总数一定不会超过这个时间周期内的展示总数，这会远远小于所有可能的 (a, u) 的组合数量。因此，缓存实际的存储规模没有我们想象的那么大。

(2) 当用 (a, u) 的组合生成缓存中对应的键时，实际上并不需要处理冲突，因为从业务角度来说，对极少比例的冲突组合上的频次控制不准是可以接受的。因此，我们用简单的 MD5 之类的散列方法生成键就可以，这会比哈希表的方案要简便高效一些。这实际上也反映了广告系统投放过程弱一致的设计原则。

由于频次控制有上述这些特点，并且存在高并发读写的要求，大多数通用型的 NoSQL 存储方案并不能很好地用于频次控制的缓存服务，因此很可能需要自行实现一个非常轻量级的内存 $(key, value)$ 方案来满足需求。而且，就大多数广告产品的流量规模来看，此缓存完全可以放在广告投放机本机的内存中。

11.3 在线分配

本章中我们讨论的重点是展示量合约广告以及相应的担保式投送系统。展示量合约广告优化问题与公式 2.2 表达的一般问题，主要区别在于合约量的要求引入了一些约束条件，这引出了在线分配问题。

在线分配问题指的是在通过对每一次广告展示进行实时在线决策，从而达到在满足某些量的约束的前提下，优化广告产品整体收益的过程。很容易理解，此问题计算上最困难

的地方在于“在线”，也就是在信息尚不全面的时候作出决策；而系统上最困难的地方在于分配策略需要是弱状态的，同时各广告投放机之间耦合程度也要尽量低。

在线分配是计算广告中比较关键的算法框架之一，它适用于许多量约束下的效果优化问题，而这实际上是广告业务非常本质的需求。由于在线分配问题的重要性超越了担保式投送本身，我们先来介绍此问题的应用场景与算法。

11.3.1 在线分配问题

我们的出发点仍然是公式 2.2 的计算广告核心问题。此问题优化的是一组广告展示上的利润，而在线分配问题进一步引入了量的约束。为了讨论方便，需要先对公式 2.2 做一些变化，得到适合于描述在线分配问题的带约束优化问题。

1. 供给与需求二部图

以担保式投送为代表，可以看出在线分配问题有两个主要的挑战：一是要在量的约束下优化效果；二是要实时对每一次展示作出决策。直接在这两个要求下优化，会使得求解过程相当困难。因此，在在线分配问题中，一般将此问题简化为一个二部图(bipartite graph)匹配的问题。这里的“二部”指的是代表广告库存的供给节点（集合记为 I ，其中某个节点代表的是所有标签都相同的流量库存）和代表广告合约的需求节点（集合记为 A ）。

供给节点、需求节点和在线分配二部图的示例如图 11-5 所示。在这个示例中，下方的 6 个节点为供给节点，而上面的三个节点为需求节点。如果某个供给节点的受众标签能够满足某个需求节点的要求，就在相应的两个节点间建立一条连接边。我们把这个二部图记为 $G=(I \cup A, E)$ ，其中 E 为 I 与 A 之间边的集合，并用 $\Gamma(a)$ 表示所有与需求节点 $a \in A$ 相邻的供给节点的集合，而 $\Gamma(i)$ 表示所有与供给节点 $i \in I$ 相邻的需求节点的集合。我们的任务就是求解由 $i \in I$ 到 $a \in A$ 的分配比例，使得满足供给方和需求方的约束的同时，某个与广告效果相关的目标函数达到最优。




图 11-5 在线分配中的二部图匹配问题示意

二部图中的供给节点有时为一组标签约束下的流量集合，在这种情况下，用 s_i 表示供给节点 i 的总流量；有时也会用一个节点代表一次展示，这适用于不假设对流量有预测能力的场景或者需要精细区分每次展示的场景下。

请大家注意，与 2.2 的计算广告一般问题相比，这样的二部图结构实际上假设了在同样一组供给节点和需求节点之间发生的广告展示，其目标函数或回报 r 是没有差别的。这虽然不够准确，但却是更直接地研究在线分配算法的一种合理近似。在这一近似下， r 由 (a, u, c) 组合的函数变成了供给节点 i 和需求节点 a 的函数，将其记为 r_{ia} 。为了方便起见，从分配问题的物理意义出发，往往还假设整体的收益或目标函数是可分的^[73]，这一目标函数表示为如下的形式：

$$F(\mathbf{s}, \mathbf{x}) = \sum_{i,a} s_i x_{ia} r_{ia} \quad (11.1)$$

其中 s_i 为供给节点 i 的总供给量，而 $\mathbf{x}=\{x_{ia}\}_{|I|\times|A|}$ 中的每个元素表示 s_i 分配给合约 a 的比例，这就是在线分配问题求解的变量。

这一在线分配问题的目标函数，直观上看与 2.2 的一般广告问题目标大有不同，不过这实际上是通过二部图假设简化后得到的表示。另外，在这种表达中，供给节点的数目会随着定向条件的增加而呈几何级数上升，也就会使得对应的分配问题变得过于复杂而无法有效求解。下面我们来看此优化问题有哪些约束。

2.需求约束与供给约束

在线分配问题的第一个约束条件是分配给某广告合约 a 的收益要至少等于其约定的量 d_a ，这个约束称为需求约束（demand constraint）：

$$\sum_{i \in \Gamma(a)} q_{ia} s_i x_{ia} \leq d_a, \forall a \in A \quad (11.2)$$

其中 q_{ia} 为将供给节点 i 连接到需求节点 a 的单位流量惩罚，其具体意义将在后面举例说明。简单起见，一般都假设这一需求约束是线性的，实际上这也已经能满足所有常见场景中的需求。

实际产品中常见的需求约束有两类：一类是预算、服务成本等的上限要求；另一类是合约量的下限要求。在后一种情形下， q_{ia} 为负数，需求约束实际上描述的是一个收益项的下界。

在线分配问题的另一个约束条件是每个供给节点被分配出去的量不能多于其总流量，这个约束称为供给约束（supply constraint），其意义很容易理解。供给约束可以表示成下面的形式：

$$\sum_{a \in \Gamma(i)} x_{ia} \leq 1, \forall i \in I \quad (11.3)$$

3.问题框架

根据上面的讨论，从公式 2.2 定义的计算广告目标出发，引入供给约束与需求约束，得到下面的在线分配优化问题框架表示：

$$\begin{aligned}
& \max \quad \sum_{(i,a) \in E} s_i x_{ia} r_{ia} \\
& \text{s.t.} \quad \sum_{a \in \Gamma(i)} x_{ia} \leq 1, \quad \forall i \in I \\
& \quad \sum_{i \in \Gamma(a)} s_i x_{ia} q_{ia} \leq d_a, \quad \forall a \in A \\
& \quad x_{ia} \geq 0, \quad \forall (i, a) \in E
\end{aligned} \tag{11.4}$$

除了供给约束和需求约束，上式中还有第三个约束，它用以保证分配变量非负。公式 11.4 是一个比较一般性的数学表达，不仅仅适用于 GD 问题，也适用于其他量约束下的在线分配问题。有关它的一些算法和结论也不仅仅用于合约式广告系统，在后面介绍的竞价广告系统或广告交易市场中也有着广泛的应用。

如果可以离线对公式 11.4 进行决策，那么这是一个一般的带线性约束的优化问题。然而在广告投放实际环境中，不可能达到全局最优，而是必须对每次广告展示马上作出决策，这就要求设计一种比较聪明的策略，使得整体流量情况尚不明朗时，仍然可以相对合理地作出决策，而最终目的是全部流量上的分配结果与离线最优化的结果尽量接近。

11.3.2 在线分配问题举例

在线分配技术并不仅仅适用于 GD 问题，其他典型的问题还有 AdWords 问题、展示广告问题、最大代表性分配（Maximal Representative Allocation, MRA）^[35]问题以及广告交易平台中的询价优化问题等。在此举例介绍 GD 问题和 AdWords 问题的具体表达，其他问题还会在本书的后面遇到。

1. GD 问题

在线分配的最典型应用就是 GD（担保式投送）问题。在此主要考虑按 CPM 结算的市场。在 GD 合约的情形下，由于按 CPM 售卖广告在所有合约都满足时，如果不考虑合约 a 未完成的惩罚，收益是一定的常数。那么 GD 的优化问题可以写成：

$$\begin{aligned}
& \max \quad C \\
& \text{s.t.} \quad \sum_{a \in \Gamma(i)} x_{ia} \leq 1, \quad \forall i \in I \\
& \quad \sum_{i \in \Gamma(a)} s_i x_{ia} \geq d_a, \quad \forall a \in A \\
& \quad x_{ia} \geq 0, \quad \forall (i, a) \in E
\end{aligned} \tag{11.5}$$

可以看出，GD 问题的优化目标主要在于更好地满足所有合约的要求，而不是优化 eCPM。有时，GD 合约在未达到（under delivery）时会有相应的惩罚，在这种情形下，目标函数就不是常数了，可以引入惩罚项来改写上面的问题，使其仍然在线分配的框架内，在此不详细描述。

GD 问题的两个约束都非常容易理解：供给约束的含义是每个供给节点分配给所有需求节点的流量比例之和不超过 1；需求约束的含义是每个需求节点被分配到的流量总和应该大于等于对应合约的展示量要求。

2.AdWords 问题

AdWords 问题，也被称为有预算约束的出价（budgeted bidder）问题，讨论的是在 CPC 结算的竞价广告环境下，给定各个广告主的预算，整体化市场营收的问题。在这种情形下，公式 11.5 中的目标函数和需求约束都有所变化，其对应的在线分配问题体现为如下的形式：

$$\begin{aligned}
 \max \quad & \sum_{(i,a) \in E} q_{ia} s_i x_{ia} \\
 \text{s.t.} \quad & \sum_{a \in \Gamma(i)} x_{ia} \leq 1, \quad \forall i \in I \\
 & \sum_{i \in \Gamma(a)} q_{ia} s_i x_{ia} \leq d_a, \quad \forall a \in A \\
 & x_{ia} \geq 0, \quad \forall (i,a) \in E
 \end{aligned} \tag{11.6}$$

为了便于理解，可以把这里的供给节点 i 具体想象成搜索广告中的一个关键词。于是， q_{ia} 代表的是将关键词 i 的一次点击分配给广告 a 的期望收益，即广告 a 对关键词 i 的出价^[2]； s_i 为关键词 i 的总点击量；而 x_{ia} 为关键词 i 分配给广告 a 的流量比例。AdWords 问题的优化目标是整个市场的收入最大化；而需求约束的含义是每个广告主的花费应该小于该广告主的预算。

研究 AdWords 问题的目的是为了探讨在广告主有预算上限的情形下，是否可以通过全局的分配调整影响整个市场的收入。虽然对这一问题的实际意义和效果，工业界存在着不同的看法：在自助式投放中，广告主有时会先预设较少的预算，并在预算将花完时判断是否要追加。因此，在系统中看到的预算并不是一个强约束。但是，这样的思考方式以及在线分配对于各种量约束下优化问题的框架意义是值得体会的。

11.3.3 极限性能研究

如果不对未来的流量分布做假设和预测，那么在线分配的效率上限如何，什么样的策略更加合理呢？虽然这样极端情形的讨论对实用系统的帮助有限，但这一极限情形的研究却对我们理解问题的本质特点和算法方向有指导意义。

极限性能研究的指标主要是某一在线分配策略的有效性。所谓有效性可以描述如下：如果能够完全确知所有的流量分布情况，那么可以根据全局的信息求得一个分配的最优解；但是由于分配是在线执行，最优解并不一定能达到，如果某种在线分配策略在最差情形下能够达到上述最优解目标函数的 $\dagger$ 倍，那么我们就说这一分配方案是 $\dagger$ -competitive 的。显然，这里的 $\dagger$ 是一个 $[0, 1]$ 内的数，也就是该分配方案有效性的度量。

公式 11.4 是一个典型的带约束优化问题，根据第 10 章介绍的最优化知识，可以应用拉格朗日乘子法来分析这一问题。公式 11.4 的拉格朗日算符可以表达为：

$$\sum_{(i,a)} r_{ia} s_i x_{ia} + \sum_i \alpha_i \left[\sum_{a \in \Gamma(i)} s_i x_{ia} - s_i \right] + \sum_a \beta_a \left[\sum_{i \in \Gamma(a)} q_{ia} s_i x_{ia} - d_a \right] - \sum_{(i,a)} \gamma_{ia} s_i x_{ia} \quad (11.7)$$

不进行预测，把每次展示当作一个供给节点，则有 $s_i=1$ ，于是上式的对偶问题为：

$$\begin{aligned} \min \quad & \sum_{a \in A} d_a \beta_a + \sum_{i \in I} \alpha_i \\ \text{s.t.} \quad & \beta_a + \alpha_i \geq r_{ia} \\ & [x_{ia}, \beta_a, \alpha_i \geq 0] \end{aligned} \quad (11.8)$$

原问题的每个约束条件对应着一个对偶变量。在参考文献[31]中，利用这些对偶变量，作者给出了在 Free Disposal^[4]前提下，在线分配的一种优化方案框架。该方案有如下的几个步骤。

(1) 初始化每个需求约束的对偶变量 $\beta_a \leftarrow 0$ 。

(2) 当一次展示 i 到达时，令 $a^0 \leftarrow \arg \max_a r_{ia} - \beta_a$ 取得最大值的广告合约 a （即分配给收益最大的合约，如果该值对所有的广告都为负，则所有合约都不需要分配）。

(3) 令 $x_{ia^0} = 1$ ，如果 a^0 已经被分配了 d_{a^0} 次展示，令 i^0 为其中最小的，并将 $x_{i^0 a^0}$ 设置为 0。

(4) 在对偶问题中，令 $\alpha_i = r_{ia^0} - \beta_{a^0}$ ，并通过一定的更新规则来更新 β_{a^0} 。不同的更新规则对应了不同的分配算法，也相应地会导致不同的分配性能。

这个过程的关键在于两点：一是第 2 步实际上是把展示分配给最难满足的一个合约；二是第 4 步如何更新 β_{a^0} ，即如何重新估计需求合约的满足难度。参考文献 [31] 中对几种典型的 β_{a^0} 的更新策略进行了讨论，并且给出了一种有效性为 $(1-1/e)$ -competitive 的分配方案，实际上，可以证明这是在线分配问题可以达到的有效性的上界。表 11-1 对

比了参考文献[31]中讨论的几种在线分配策略。在几种 β_a 更新策略中，指数加权的极限性能最佳，而且 $1-1/e$ 被证明是所有分配算法理论上能达到的最好的极限性能。

表 11-1 若干在线分配策略的对比

策略	描述	有效性
贪心	β_a 是分配给 a 的前 d_a 个高权重展示中最低的权重，也即 a 接受一个新的展示需要抛弃的权重	$\frac{1}{2}$ -competitive
平均加权	β_a 是分配给 a 的前 d_a 个高权重展示的权重的算术平均如果分配给 a 的展示少于 d_a 个， β_a 是这些展示总权重与 d_a 的比	$\frac{1}{2}$ -competitive
指数加权	β_a 是分配给 a 的前 d_a 个高权重展示的权重的指数加权，即： 设 $r_1 \leq r_2 \leq \dots \leq r_{d_a}$ ，则： $\beta_a = d_a \left\{ \left[(1 + d_a^{-1})^{d_a} \right] \sum_{j=1}^{d_a} r_j (1 + d_a^{-1})^{j-1} \right\}$	$\left(1 - \frac{1}{e}\right)$ -competitive

直观地理解， β_a 可以对应于将一个新的展示替换原有已分配给 a 的展示时，被替换掉的收益部分。显然，当合约 a 被分配展示少于 d_a 时， β_a 应该为 0，而上面的研究告诉我们，按照已分配的权重进行指数加权会有比较好的极限性能。在实际的工程系统中，不可能不利用历史流量数据来进行在线分配。然而，上面的研究对于深入理解在线分配的合理策略会有很大的帮助。

11.3.4 实用优化算法

假定未来一段时间内需要投放的合约是已知的，如果广告流量的分布在各个循环周期内是近似一致的，那么在线分配的问题就可以在流量预测的指导下进行，这是大多数在线分配实用工程方法的基本出发点。

1.直接求解的原始分配方案

在实际的工程系统中，假定流量的分布是平稳的，我们会利用历史流量数据来拟合未来流量 s_i ，把在线分配转化成离线问题，离线对公式 11.4 进行决策。这是一个一般的带线性约束的优化问题，当优化目标为线性函数或二次函数时，是一个标准的线性规划(linear programming)或二次规划(quadratic programming)问题，可以采用相应的优化工具直接求解该问题。当所求解的问题规模较小时，比如定向标签很少、广告主也较少时，求解过程也很简单。直接求解的 Matlab 代码如下所示。

```

1 % In:
2 %   supplies      : 供给节点列表
3 %   demands       : 需求节点列表
4 %   demandLinks   : 满足各个需求节点的供给节点列表
5 % Out:
6 %   theta         : 需求节点的需求/供给比
7 function theta = get_theta(supplies, demands, demandLinks)
8 % 生成各需求节点对应总供给
9   eligibles = zeros(size(demands));
10  for d = 1 : length(demands)
11    eligibles(d) = sum(supplies(demandLinks{d}));
12  end
13
14 % 各个需求节点的需求-供给比
15  theta = demands ./ eligibles;
16 end
17
18 % In:
19 %   supplies      : 供给节点列表
20 %   demands       : 需求节点列表
21 %   supplyLinks    : 满足各个供给节点的需求节点列表
22 %   demandLinks   : 满足各个需求节点的供给节点列表
23 % Out:
24 %   allocation_plan : 求解得到的分配方案
25 function allocation_plan = get_primal_solution(supplies, demands,
26   supplyLinks, demandLinks)
27
28   theta = get_theta(supplies, demands, demandLinks);
29
30   numSupply = length(supplies);
31   numDemand = length(demands);
32
33 % 原始问题的约束条件
34   begIdx1 = 1;          endIdx1 = begIdx1 + numDemand - 1;
35   begIdx2 = endIdx1 + 1; endIdx2 = begIdx2 + numSupply - 1;
36   begIdx3 = endIdx2 + 1; endIdx3 = begIdx3 + numDemand*numSupply - 1;
37   numConstraint = endIdx3;
38   numX = numDemand * numSupply;
39
40 % Ax <= b
41   A = zeros(numConstraint, numX);
42   b = zeros(numX, 1);
43
44 % 需求约束
45   for j = 1 : numDemand
46     for i = demandLinks{j}
47       id = (i - 1) * numDemand + j;
48       A(j, id) = -supplies(i);
49     end
50   end
51   b(begIdx1 : endIdx1) = -demands';
52
53 % 供给约束
54   idx = numDemand;
55   for i = 1 : numSupply
56     for j = supplyLinks{i}
57       id = (i - 1) * numDemand + j;
58       A(idx + i, id) = 1;
59     end
60   end
61   b(begIdx2 : endIdx2) = ones(numSupply, 1);
62
63 % 非负约束
64   A(begIdx3 : endIdx3, :) = -eye(endIdx3 - begIdx3 + 1);
65   b(begIdx3 : endIdx3) = zeros(numX, 1);
66
67   x0 = rand(numX, 1); % 初始值
68   option = optimoptions('fmincon', 'Algorithm', 'active-set')
69   f = @(x)f_origin(x, supplies, demands, supplyLinks, demandLinks,
70     theta);
71   [x, ~] = fmincon(f, x0, A, b, [], [], [], [], [], option);
72
73   allocation_plan = zeros(numSupply, numDemand);
74   for i = 1 : numSupply

```

```

75     for j = supplyLinks{i}
76         allocation_plan(i, j) = x((i - 1)* numDemand + j);
77     end
78 end
79 end

```

在大型的合约广告系统中，由于定向条件的复杂性，供给节点的数目会随着定向条件的增加而呈几何级数上升，需求节点数也会达到数千个，边 $|E|$ 的数目会在百万级以上，这就使得对应的分配问题变得过于复杂而无法直接有效求解。我们令 n 为变量的个数（正比于供需二部图中边的数目 $|E|$ ），求解线性规划问题的经典算法如内点法（时间复杂度为 n 的多项式级别）和单纯形法（时间复杂度为 $O(n^{1.5}-n^2)$ ）在小时级延迟的定期更新求解是几乎不可能的。另外，这样直接求得的解参数正比于 $|E|$ 的数量，规模有可能过于庞大，在线上投放时使用很不方便。因此，我们有必要探索更新效率更高、空间复杂度更低的在线分配方案。

2.基于对偶算法的紧凑分配方案

在实际的广告系统中，不仅要考虑离线分配方案规划时的复杂度，还要考虑线上的快速响应。模型的分配策略不能给服务器带来内存和计算上的很大负担，而前述原始分配方案中求解出来的原问题的方案过于庞大（变量数正比于 $|E|$ ）。因此，往往需要一个更紧凑的分配方案。

除了紧凑性的要求，如果分配策略能做到一定程度上无状态，即投放策略与前面的投放历史无关，这对于广告投放机的实现非常有利：如果与投放历史无关，多台广告投放机之间就不需要频繁进行同步以完成状态更新，而是根据预先计算好的策略进行投放即可，这对于系统的稳健性和扩展性非常有益。

在线分配对偶问题的解不是紧凑解，其变量数目正比于约束的数目，包括供给约束和需求约束，前者变量的量级数为十万甚至百万千万，但后者的量级在数千级别。为了分配方案的紧凑性，可否只保留需求约束对应的对偶变量，通过数学变换恢复出供给约束的对偶变量和分配率 x 呢？在参考文献 [73] 中，作者就给出了这样的方案，通过对相应对偶问题的 K.K.T 条件的分析，推导得到了一个由 β 恢复 α 和 x 最优解的计算方法：

$$\sum_{a \in \Gamma(i)} r_{ia}^{-1} (\beta_a - \alpha_i) = 1 \quad (11.9)$$

$$x_{ia}^* = \max \left\{ 0, r_{ia}^{-1} (-q_{ia} \sum_k \beta_k - \alpha_i) \right\} \quad (11.10)$$

由于 β 的维数正比于合约数目 $|A|$ ，远远小于 x 的维数（正比于 $|E|$ ），我们把这样的方案称为紧凑分配方案（compact allocation plan）。利用这一方法，只需要在一部分历史数据上求解对偶问题得到 α ，就可以很高效地进行在线分配。

下面的 Matlab 模拟实验代码描述了这一过程。

```
1 % In:
2 %   alpha      : 需求节点的对偶变量
3 %   supplies   : 供给节点列表
4 %   demands    : 需求节点列表
5 %   supplyLinks : 满足各个供给节点的需求节点列表
6 %   demandLinks : 满足各个需求节点的供给节点列表
7 % Out:
8 %   beta       : 供给约束的对偶变量
9 function beta = get_supply_dual(alpha, supplies, demands, supplyLinks,
10    demandLinks)
11
12     theta = get_theta(supplies, demands, demandLinks);
13
14     % 计算供给节点的对偶变量
15     beta = zeros(size(supplies));
16     for i = 1:length(supplies)
17         tmp2 = sum(theta(supplyLinks{i}));
18         tmp1 = tmp2 + sum(theta(supplyLinks{i}).*alpha(supplyLinks{i}))-1;
19
20         if(abs(tmp2)) < 1e-20
21             beta(i) = 0;
22         else
23             beta(i) = tmp1 / tmp2;
24         end
25
26         if beta(i) < 0
27             beta(i) = 0;
28         end
29     end
30 end
```

还原原问题的原始解 x_{ij} :

```

1  % In:
2  %   alpha       : 需求约束的对偶变量
3  %   beta        : 供给约束的对偶变量
4  %   supplies    : 需求节点列表
5  %   demands     : 供给节点列表
6  %   supplyLinks : 满足各供给节点的需求节点列表
7  %   demandLinks : 满足各需求节点的供给节点列表
8  % Out:
9  %   x           : 分配方案
10 function x = dual2primal(alpha, beta, supplies, demands, supplyLinks,
11    demandLinks)
12
13     theta = get_theta(supplies, demands, demandLinks);
14
15     numSupply = length(supplies);
16     numDemand = length(demands);
17     x = zeros(numSupply, numDemand);
18     for i = 1 : numSupply
19         for j = supplyLinks{i}
20             x(i, j) = max(0, theta(j) * (1 + alpha(j) - beta(i)));
21         end
22     end
23 end

```

在实际应用中，由于使用所有历史数据求解上述问题规模太大，需要对数据作一些采样以便更高效地得到分配方案。关于采样的方法以及采样以后该问题求解的稳定性分析，参考文献[73]中也都进行了详细讨论，有兴趣的读者可以进一步探索。

3.综合分配方案 SHALE

前述的基于对偶算法的紧凑分配方案，虽然在线分配时确实达到了紧凑和无状态的特性，但是求解的代价仍然较高。在 SHALE 算法^[8]中，作者对求解对偶变量的步骤进行了优化，采用原始对偶方法迭代进行求解，每次迭代的过程中改善对偶解。这样的方法，可以比较高效地求解。这一方法的 Matlab 代码如下所示。

```

1 % In:
2 %   supplies      : 需求节点列表
3 %   demands       : 供给节点列表
4 %   supplyLinks   : 满足各供给节点的需求节点列表
5 %   demandLinks   : 满足各需求节点的供给节点列表
6 %   N             : 迭代次数
7 % Out:
8 %   alpha         : 需求约束的对偶变量
9 %   beta          : 供给约束的对偶变量
10 function [alpha, beta] = shale(supplies, demands, supplyLinks,
11     demandLinks, N)
12
13     theta = get_theta(supplies, demands, demandLinks);
14
15     alpha = zeros(size(demands));
16     for i = 1:N
17         beta = get_supply_dual(alpha, supplies, demands, supplyLinks,
18             demandLinks);
19         alpha = get_contract_dual(beta, supplies, demands, supplyLinks,
20             demandLinks);
21     end
22 end
23
24 % 已知供给约束的对偶变量, 求需求约束的对偶变量
25 % In:
26 %   beta          : 供给约束的对偶变量
27 %   supplyLinks   : 满足各个供给节点的需求节点列表
28 %   demandLinks   : 满足各个需求节点的供给节点列表
29 %   supplies      : 供给节点列表
30 %   demands       : 需求节点列表
31 % Out:
32 %   alpha         : 需求约束的对偶变量
33 function alpha = get_contract_dual(beta, supplies, demands,
34     supplyLinks, demandLinks)
35
36     theta = get_theta(supplies, demands, demandLinks);
37
38     alpha = zeros(size(demands));
39     for j = 1:length(demands)
40         a = sum(supplies(demandLinks{j}));
41         b = sum(supplies(demandLinks{j}) .* beta(demandLinks{j}));
42         tmp1 = demands(j) + theta(j) * b - theta(j) * a;
43         tmp2 = theta(j) * a;
44
45         if abs(tmp2) < 1e-20
46             alpha(j) = 0;
47         else
48             alpha(j) = tmp1 / tmp2;
49         end
50     end
51 end

```

读者可以自行验证，通过原始对偶方法得到的 α 和前述直接求解的 α 一致。在得到了合同的对偶解后，之后的算法和参考文献[73]中的就一样了。基于迭代的对偶问题求解方法节省了线下的计算时间，同时也能更好地支持插入新合同时的增量求解。

4.启发式的分配方案 HWM

上述根据历史流量数据来求解紧凑分配方案的方法原理上可行，但在实际的工程应用中仍然显得有些复杂，比如离线仍要耗费大量时间求解对偶解。我们希望实现一种快速算法，保持前述方法紧凑分配、无状态的特性，效果上也能近似最优。前述方案中通过合同节点的对偶变量（是否容易满足约束）即可恢复最优解，受其讨论启发，我们可以发现，只要大体确定好每个合同在分配中的相对优先级以及分配时得到某次展示的概率，就可以构造出一种直觉上可行的在线分配方案。高水位（High Water Mark, HWM）算法^[23]就是这样一种方案，虽然其数学上不是完全严谨，但是由于根据历史数据来制定分配方案本身就具有相当程度的近似，因此其实际效果也相当不错，又加上工程上的便利性，可以考虑在在线分配方案中采用这种算法。

HWM 分配规划算法的关键有两点，一是根据历史流量确定每个广告合约资源的紧缺程度，进而得到分配优先级；二是根据优先级确定各个广告合约的分配比例。优先级可以通过可满足各合约的供给节点总流量的升序排列得到，而在确定了合约的优先级之后，按照优先级依次确定各合约的分配率以满足其流量要求。下面的 Matlab 代码描述了 HWM 离线制定分配计划的算法。

```

1  % In:
2  %   supplies      : 供给节点列表
3  %   demands       : 需求节点列表
4  %   demandLinks   : 满足各需求节点的所有供给节点号列表
5  % Out:
6  %   orders        : 需求节点的分配顺序
7  %   rates          : 需求节点分到流量的比例
8  function [orders, rates] = hwm_plan(supplies, demands, demandLinks)
9      demandNum = length(demands);
10
11     % 生成各个需求节点总供给
12     eligibles = zeros(size(demands));
13     for i = 1:demandNum
14         eligibles(i) = sum(supplies(demandLinks{i}));
15     end
16
17     % 把需求节点按照紧急程度（需求-供给比）降序排序
18     [~, orders] = sort(demands ./ eligibles, 'descend');
19
20     % 按分配顺序依次处理各需求节点
21     rates = zeros(size(demands));
22     remains = supplies;
23     for d = orders
24         for s = demandLinks{d}
25             total_remain = sum(remains(demandLinks(d)));
26             if total_remain < demands(d)
27                 rates(d) = 1.0;
28             else
29                 rates(d) = demand(d) / total_remain;
30             end
31             remains(s) = remains(s) * (1 - rates(d));
32         end
33     end
34 end

```

根据上面离线生成的分配方案，也即对每个需求节点计算出来的分配优先级（order）和分配率（rate），可以很方便地在线上服务中对每次展示作出简单的决策，这一决策的过程如图 11-6 所示。




图 11-6 HWM 算法在线分配方案示意

HWM 算法在线分配的基本逻辑是：根据优先级依次检查各个符合条件的候选，直至它们的累积分配比例超过 1，然后，按照这些合约对应的分配比例随机选择一个合约投放（如图 11-6 的上图所示）；如果所有的候选合约总的分配比例不足 1，那么以 1 减去其总分配比例的概率请求其他剩余流量变现的广告产品（如图 11-6 的下图所示）。此分配过程的关键思想在于以概率和优先级相配合的方式进行投放决策。下面的 Matlab 代码描述了 HWM 在线分配的算法。


```

1 % In:
2 %   candidates: 满足本次请求的所有需求节点列表
3 %   orders     : 所有需求节点的分配优先级
4 %   rates      : 分配方案
5 % Out:
6 %   candId     : 选中的广告, 如果返回-1, 则将此次展示交还Server, 再从其他渠道查询广告
7 function candId = hwm_serve(candidates, orders, rates)
8     %将所有候选按照分配优先级排序
9     candNum = length(candidates);
10    [~, sortedIndex] = sort(orders(candidates));
11    candidates = candidates(sortedIndex);
12
13    % 对此次展示产生分配随机数
14    randValue = rand();
15
16    % 计算累积Serving Rate的截断位置
17    accuRate = cumsum(rates(candidates));
18    candId = -1;
19    for i = 1:candNum
20        if randValue < accuRate(i)
21            candId = i;
22            break;
23        end
24    end
25 end

```

11.4 延伸思考

合约与竞价混合的广告产品在供给方很常见, 除了本章 HWM 算法中给出的启发式方案外, 是否还有更加系统的方案来优化这样的混合产品的收入?

第 12 章 受众定向核心技术

要提高在线广告的效果，受众定向是最重要的核心技术之一。从计算广告的核心问题，即优化一组流量上的利润这一挑战来看，受众定向技术是对广告（a）、用户（u）、上下文（c）这三个维度提取有意义的特征（这些特征也称为标签）的过程。由于上下文标签也可以认为是即时的用户兴趣，因此我们把它们统称为受众定向。受众定向虽然不见得是计算广告中最困难的技术，但是确实是在线广告、特别是展示广告最核心的驱动力之一，也是计算广告成为大数据典型应用的关键。

关于各种受众定向技术的原理，应该在第 2 章广告有效性模型的基础上进行理解。一般来说，对于某种特定的定向技术，需要同时关注其效果和规模两方面的指标，同时提供覆盖率较高但精准程度有限的标签和那些非常精准但量相对较小的标签，这有利于市场形成竞争的环境，也为竞价广告形成充分竞争提供了基础。

从技术框架来看，受众定向标签可以分成用户标签、上下文标签和广告主定制化标签 3 种类型，其实现方案也有较大的不同。本章重点介绍前两种定向技术的做法，而广告主定制化标签属于需求方定义的标签，第 14 章讲述 DSP 技术时再介绍。

上下文定向需要对广告所在的页面进行分析，然而这一分析过程与搜索引擎的爬虫有很大的不同。结合广告对上下文信息的需求特点，一般可以采用一种半在线的方式抓取和分析页面，这种方式避免了无效的页面分析计算，又能够快速响应需要分析的页面。

行为定向是根据用户历史上的网络访问行为对用户打标签的过程。哪些网络行为有价值是挖掘行为数据来源时需要考虑的问题。本章将列举一些业界公认的有价值的行为数据类型，并给出使用多种数据类型进行行为定向的基本框架。由于海量用户的原始网络行为的数据量一般来说特别巨大，如何设计非常高效的数据组织方式以及合理的访问流程对于行为定向的实用化是非常关键的。行为定向一般采用 reach/CTR 曲线进行半定量的评价，而此曲线的解读方法也将在本章中提及。

实际上，受众定向除了服务于广告产品外，也成为广告市场中相关数据产品的关键技术。而这些数据产品的地位，也随着实效广告的发展变得越来越重要，因此，对于受众定向技术的探讨，除了考虑广告产品中的需求之外，也必须考虑数据产品带来的需求。与受众定向直接相关的数据产品主要是数据交易平台和数据管理平台。这两种产品从第一方数据和第三方数据的角度出发，专门提供数据加工和交易功能，实际上它们是受众定向技术直接产品化的结果。本章也会简单介绍这类数据加工产品的技术架构。

12.1 受众定向技术分类

先来回顾一下第 4 章中介绍的受众定向常见方法（参见图 12-1）。总体上看，按照计算框架的不同，这些受众定向技术可以分为以下三种类型。

（1）用户标签，即可以表示成 $t(u)$ 形式的标签，这是以用户历史行为数据为依据，为用户打上的标签。

（2）上下文标签，即可以表示成 $t(c)$ 形式的标签，这是根据用户当前的访问行为得到的即时标签。

（3）定制化标签，即可以表示成 $t(a, u)$ 形式的标签，这也是一种用户标签，不同之处在于是针对某一特定广告主而言的，因而必须根据广告主的某些属性或数据来加工。




图 12-1 常见受众定向方法一览

以上各种定向中，地域定向、频道定向和上下文定向属于 $t(c)$ 的定向方式；人口属性定向、行为定向属于 $t(u)$ 的定向方式；而重定向和新客推荐（look-alike）则是 $t(a, u)$ 的定向方式。各种定向的标签被应用于根据用户和环境信息选取广告候选的过程，因而对广告投送的结果有比较显著的影响。 $t(c)$ 和 $t(u)$ 两种定向方式，一个是根据当前环境信息，一个是根据历史日志数据，因而在技术方案上有比较大的区别。下面将对这两种方式的典型代表，即上下文定向和行为定向的实现进行讨论。而定制化标签，即 $t(a, u)$ 形式的标签，变成了完全开放的标签体系，其标签数量不再是常数，而是有可能与广告主数目成正比，因此最适合于在程序化交易的环境中由需求方直接提供，这种标签将在第 14 章讨论 DSP 时再介绍。实际上，我们还需要对每个广告也打上标签 $t(a)$ ，以便与上下文或用户的标签做匹配，广告标签一般有两种常用选择：一是直接将广告投放中的广告主、广告计划、广告组、关键词等直接用作标签，二是用人工的方式归类。可以用一个 (a, u, c) 上的三维坐标来示意以上的几种标签类型，参见图 12-2。




图 12-2 (a, u, c) 空间中的标签示意

值得注意，受众定向技术并非按照上述的分类严格区分或者一成不变的。各个广告网络或定向技术提供商能够接触到的数据类型和规模都各不相同，基于这些数据本身进行深入挖掘，并找到对广告投放有意义的信号，才是受众定向在使用中的重点。另外，上面的分类主要是为了方便技术方案的讨论，从产品角度来看，以上几种受众定向标签对于广告主而言并没有本质区别。

12.2 上下文定向

我们先来看那些归类为 $t(c)$ 的受众定向方式。这样的定向中有一些根据广告请求中的参数信息经过简单运算就可以得到，如地域定向、频道/URL 定向、操作系统定向等；另外一类则是根据上下文页面的一些特征标签，如关键词、主题、分类等进行定向，我们重点讨论这样的上下文定向技术。

抛开标签体系不谈，仅从打标签的方法上来看，上下文定向主要有以下几种思路。

(1) 用规则将页面归类到一些频道或主题分类。例如，将 `auto.sohu.com` 下的网页归在“汽车”这个分类中。这种方法相对简单。

(2) 提取页面中的关键词。这是在将搜索引擎的关键词匹配技术推广到媒体广告上时自然产生的，也是上下文定向的基本方法。

(3) 提取页面入链锚文本中的关键词。这需要一个全网的爬虫作支持，因此已经超出了一般意义下广告系统的范畴，有兴趣的读者可以参考搜索引擎方面的有关文献。

(4) 提取页面流量来源中的搜索关键词。这种方法除了页面内容，也需要页面访问的日志数据作支持，从技术方案上看更接近后面介绍的行为定向。

(5) 用主题模型将页面内容映射到语义空间的一组主题上，这样做的目的是为了泛化广告主的需求，提高市场的流动性和竞价水平。

在以上各种思路中，关键词提取是一项基础技术。上下文定向中的关键词提取可以按照信息检索中的一般方法，即选取页面内容中 **TF-IDF** 较高的词作为关键词（见 10.1.2 节中的具体介绍）；也可以采用需求方驱动的思路，从广告商相关描述中得到商业价值高的关键词表和 **IDF**，再与页面内容中关键词的 **TF** 一起计算 **TF-IDF** 来选取关键词。当能够得到比较丰富的广告信息时，如运营搜索引擎的文本广告，或者可以拿到广告主 **SEM** 词表时，后一种方法往往更加有效。

确定了对上下文页面打标签的方法以后，在在线广告投放时，页面标签系统需要对广告投放机查询的某一个 **URL** 快速返回其对应的标签。复杂的打标签计算是不可能马上完成的，不过在广告的问题中，某一次展示时标签的缺失并不是致命性的。根据广告的这一特点，可以用一种半在线的方式实现页面抓取和打标签的逻辑。

12.2.1 半在线抓取系统

上下文页面的有关信息显然不可能在广告请求发生时实时分析得到，那么是否需要一个类似于搜索引擎爬虫的系统来预先抓取呢？对于广告系统来说，是没有这个必要的。因为页面信息对搜索引擎而言是服务的主体内容，而对广告系统而言，只是锦上添花的补充信息，完全可以设计一个更轻量级、效率更高的页面抓取系统。这一系统的设计关键是不作任何离线抓取，而在在线服务产生实际需求后才尽快抓取，我们把它叫作半在线（near-line）的抓取系统。



图 12-3 上下文定向半在线抓取系统示意

半在线抓取系统的工作原理如图 12-3 所示，系统用一个缓存（如 9.5.7 节中介绍的 Redis）来保存每个 URL 对应的标签，当在线的广告请求到来时进行如下操作。

（1）如果该请求的上下文 URL 在缓存中存在，那么直接返回其对应的标签。

（2）如果该 URL 在服务中不存在，为了广告请求能及时得到处理，当时返回空的标签集合，同时立刻向后台的抓取队列中加入此 URL，这样在较短的一段时间（通常为秒至分钟量级）之后该 URL 就被抓取下来并打上标签存入缓存中。

（3）考虑到页面内容可能会不定期更新，可以设置缓存合适的 TTL（Time to Live）以做到自动更新标签。

这样的方案有以下两点好处。首先是在线缓存的使用效率非常高，仅仅那些最近有广告请求发生的 URL 才会被抓取，这样不需要耗费大量的爬虫资源去抓取可能根本用不到的 URL。其次，因为只抓取需要的页面，并且可以在该页面第一次广告请求后很快得到页面标签，页面的信息覆盖率就会很高。

半在线的上下文抓取系统非常典型地揭示了在线广告系统弱一致的业务需求：只要保证大多数的广告决策最优正常，很少量的次优决策甚至随机决策都是可以接受的。充分把握这一特点，对于设计高效率、低成本的广告系统至关重要。

12.2.2 文本主题挖掘

根据上下文内容进行受众定向的粒度可以精细到关键词，也可以粗略到页面的类型。除了这两种极端情况，我们也可以考虑将页面内容直接映射到一组有概括性意义的主题上，比如将一个讲编程语言的博客页面映射到“IT 技术”这样的主题上。如果把页面视为一个文档，这就对应于文本主题模型（topic model）的研究问题。文本主题模型有两大类别：一种是预先定义好主题的集合，用监督学习的方法将文档映射到这一集合的元素上；一种是不预先定义主题集合，而是控制主题的总个数或聚类程度，用非监督学习的方法自动学习出主题集合以及文档到这些主题的映射函数。

广告中的主题挖掘有两种用途：如果仅仅用于广告效果优化的特征提取，那么监督或非监督的方法都可以；如果是用于对广告主售卖的标签体系，那么应该优先考虑采用监督学习的方法，因为这样可以预先定义好对广告主有意义且可解释的标签体系，对售卖会有很大帮助。

我们从非监督方法说起。假设有一个由 M 个词组成的词表以及一组文档 $\{d_1, d_2, \dots, d_N\}$ ，采用 BoW 表示，文档 d_n 表示为 $\{x_{n1}, x_{n2}, \dots, x_{nM}\} (1 \leq n \leq N)$ 的形式，其中 x_{nm} 为词表中第 m 个词 w_m 在 d_n 中对应的词频或 TF-IDF 值。显然，一般情况下，矩阵 $X = \{x_{nm}\}_{N \times M}$ 是

非常稀疏的。假设这一文档集合主题模型对应着 $\{1, 2, \dots, T\}$ 这一组主题，我们的目的就是每个文档得到其在这组主题上的强度 $\{z_{n1}, z_{n2}, \dots, z_{nT}\}$ ($1 \leq n \leq N$)。

1.LSA 模型

文本主题模型最初的解决思路是对上面文档和词组成的矩阵 X 进行奇异值分解 (Singular Value Decomposition, SVD)，找到这一矩阵的主要模式，这一方法称为潜在语义分析 (Latent Semantic Analysis, LSA) [27]。LSA 的分解过程可以表示如下：

$$\mathbf{X} = (\alpha_1 \cdots \alpha_K)^\top \cdot \text{diag}(s_1, \cdots, s_K) \cdot (\beta_1 \cdots \beta_K) \quad (12.1)$$

其中 K 为矩阵 X 的秩， $s_1 \geq s_2 \geq \dots \geq s_K$ 为 X 的 K 个奇异值。左侧的矩阵就是将潜在语义空间中的主题映射到某个文档的变换矩阵，而右侧的矩阵则是主题映射到某个文档词表中某个词的变换矩阵。最多可以得到的主题数目等于矩阵 X 的秩 K ，不过一般情况下，都会选择一个远小于 K 的主题数目用来建模。当选择的主题数目为 K 时，实际上是用下式的 X^0 对 X 进行了近似：

$$\mathbf{X}' = (\alpha_1 \cdots \alpha_T)^\top \cdot \text{diag}(s_1, \cdots, s_T) \cdot (\beta_1 \cdots \beta_T) \quad (12.2)$$

这等价于令所有的 s_t ($T < t \leq K$) 都等于 0，换句话说，通过这种方式去掉了大多数非主要因素的影响，从而得到了整个语义空间比较平滑的描述。实际上，从上述的 SVD 分解结果可以很容易得到每个文档的相应主题，请参见参考文献[39]。

根据奇异值的性质，我们知道所有的奇异值都是非负的，但是 LSA 得到的两个变换矩阵不能保证每个元素都为非负值。这一点对应的直觉意义是：如果一篇文档有某个主题的话，可能该文档中出现某些词的频次的期望值为负。这一点，直观上并不十分容易理解，也是 LSA 模型与后面几种概率文档主题模型不太一样的地方。

2.PLSI 模型和 GaP 模型

LSA 方法的物理意义清楚，也有成熟的数学工具可以利用，因而在信息检索中得到了比较早的应用。类似的思想也可以用概率建模的方式来表达，这就是概率潜在语义索引 (Probabilistic Latent Semantic Indexing, PLSI) 方法[39]。PLSI 方法是通过对文档生成的过程进行概率建模来进行主题分析。这一模型下的文档生成过程可以表述为以下两个步骤。

(1) 根据每个文档 d_n 生成对应的一个主题 z 。

(2) 给定主题，对应一个词的多项式分布 $p(w_n|z, \beta)$ ，据此生成一个词 w_i ；其中的参数 $\beta = (\beta_1, \dots, \beta_K)$ ，而 β_k 即为当 $z_k=1$ 时对应的多项式分布参数。

PLSI 的图模型如图 12-4 所示。




图 12-4 PLSI 概率图模型表示

对应于上面的生成过程，文档集 $\mathbf{X}$ 的生成似然值可以表达为：

$$\begin{aligned}\ln P(\mathbf{X}) &= \sum_{n,m} P(d_n)P(w_m|d_n) = \sum_{n,m} x_{nm} \ln \left\{ P(d_n) \sum_z P(w_m|z)P(z|d_n) \right\} \\ &= \sum_{n,m} x_{nm} \ln \left\{ \sum_z P(w_m|z)P(d_n|z)P(z) \right\}\end{aligned}\quad (12.3)$$

其中 $P(z)$ 为多项式分布 $\text{Multi}(z; \omega)$ ，显然，这也是一个混合模型的形式，如果 $P(d_n|z)$ 和 $P(w_m|z)$ 也都采用多项式分布形式，就是 PLSI 模型。PLSI 是概率化了的 LSA 模型，可以将 $P(d_n|z)$ 和 $P(w_m|z)$ 的参数分别对应于 LSA 中的两个变换矩阵。这两个模型的形式很相似，不过物理意义有所不同：在 PLSI 中，变换矩阵即两个条件分布的元素都大于 0，即在给定一个主题的情况下，某个词频的期望值不会为负，这一点与直觉更为吻合，也更加合理。在 PLSI 模型下，给定一个新文档，求得相应主题分布的过程，请参见参考文献[39]。

概率模型的另一个好处是可以较容易地实现分布式求解。可以看出，PLSI 模型是 10.3.2 节中介绍的指数族混合分布的特例，其中的基本分布为多项式分布。因此，可以直接套用 EM 算法以及对应的 MapReduce 或 MPI 迭代解法来求解。而 LSA 模型用到的 SVD 分解，需要一定的技巧才能变成分布式版本。因此，PLSI 比 LSA 在实际海量数据上的文档主题模型更具有实用优势。

PLSI 模型用多项式分布来描述主题分布和主题中的词分布，而如果采用 γ 泊松过程来建模，即假设每个主题生成的概率用独立的 γ 分布来描述，而主题中某词的产生服从泊松分布，就构成了 γ 泊松 (GaP) 模型^[18]。从变量的依赖关系上看，GaP 与 PLSI 很相似，只不过两者中条件分布的指数族形式不同。GaP 与 PLSI 相比，由于没有将每个文档中各个主题变量的强度进行归一化^[9]，因此对内容相似的长文本和短文本的概率描述是不同的，而泊松词产生概率也更加适合离散到达事件的描述，因而 GaP 模型在主题建模上有一定的合理性。不过，GaP 模型的 EM 最大似然解不像 PLSI 那样有简单的闭式更新公式，在参考文献[18]中，作者也是采用一种近似的方法来优化，因此，这一模型在工程中的实用性受到了一定的限制。

3.LDA 模型

10.3.3 节中介绍的贝叶斯方法也可以应用于 PLSI 模型，这样做的目的是在文档信息不足或者噪声较大时能够利用贝叶斯的框架对结果进行有效的平滑。这一思路也就产生了潜在狄利克雷分配 (Latent Dirichlet Allocation, LDA) 方法^[10]。在 LDA 方法中，我们视 PLSI 模型的参数为随机变量，对于某一篇文章，其生成过程可以描述如下。

(1) 根据一个泊松分布选择文档的长度 M 。

(2) 根据 ω 的先验分布 $\text{Dir}(\alpha)$ 生成 ω 。

(3) 对每个文档中的词 $m \in \{1, \dots, M\}$, 根据 $\text{Multi}(\omega)$ 分布选择一个主题 z ; 给定主题, 对应一个词的多项式分布 $p(w_m|z, \beta)$, 据此生成一个词 w_m 。

其对应的图模型如图 12-5 所示。




图 12-5 LDA 概率图模型表示

把这一生成过程与 PLSI 对比可以知道, 这相当于 PLSI 的贝叶斯版本, 即给 Topic 的分布 w 加上了先验分布, 而先验分布采用的是共轭形式, 即狄利克雷分布。当然也可以对主题的词频分布 β 用贝叶斯的方法加以平滑, 这实际上对应了参考文献 [10] 中的 LDA Smoothing 方法。从 10.3.3 节中的介绍可知, 可以采用经验贝叶斯的方案来确定这两个超参数 α 。由 PLSI 模型到 LDA 模型对文档生成过程的描述更为清晰, 而根据贝叶斯学习的作用可知, LDA 模型在数据噪声较大或者每个文档内容较少时可以达到比较稳健估计的效果。

如果采用经验贝叶斯的方法来确定超参数 α , 那么此时原来的参数 ω 就变成了隐变量, 优化的参数除了 α , 还包括参数 β , 优化的目标函数可以写成:

$$p(w|\alpha, \beta) = \int p(\omega|\alpha) \left(\prod_{m=1}^M \sum_z p(z|\omega) p(w_m|z, \beta) \right) d\omega \quad (12.4)$$

由于 PLSI 模型不是指数族分布, 因而其对应经验贝叶斯模型的解不能通过 EM 方法得到闭式解, 而是需要采用变分法^[43]近似求解。在参考文献[10]中, 对这一模型的变分解法进行了详细的介绍。不过在实际的工程实践中, LDA 模型更为常用的更新方法是吉布斯采样 (Gibbs sampling) 法, 而且这种方法更容易实现分布式更新求解。关于分布式吉布斯采样方法可以参考参考文献[61]。

4. 有监督主题模型

无监督的主题模型技术上发展比较充分, 但结合广告的业务来看, 其得到的主题有时会出现混淆、不易解释等问题。因此, 其结果主要适用于非直接售卖的场景, 如用作点击率预测的特征。

当标签直接用于售卖时, 它们往往是预先定义好的。因此, 有监督的主题模型对于这种场景更加适用。根据前面的讨论, 它可以是一组非结构化的标签集合, 也可以是一个结构化的层次标签体系。有两种思路来解决此问题: 一是采用多标签分类 (multi-label

classification) 的方法, 二是沿用上面的主题模型方法, 将其变成有监督主题模型。关于有监督主题模型, 以上述的 LDA 为出发点, 研究者也提出了若干种相关的方法。

结合广告定向的情景, 可以关注两种有监督主题模型。

(1) 有监督的 LDA (supervised LDA, sLDA) [11], 这是在某种标签监督下进行主题挖掘的通用模型, 适用于标签为各种分布的情形。当标签为离散值时, 就对应于根据某种分类进行主题挖掘。

(2) 层次化的有监督的 LDA (Hierarchically Supervised LDA, HSLDA) [65]。在此模型中, 标注的类型是一个 Hierarchy 上的层次标签, 这非常契合于广告中的需求。关于这方面的具体技术可以参考上面提到的文献。

值得注意的是, 在文档主题挖掘领域, 还有一类方法也与 Hierarchy 有关, 如 HLDA 或 HDP, 但是其问题定义是在某个数据集上学习得到一个 Hierarchy 结构, 而不是根据一个给定的 Hierarchy 上的标准挖掘潜在主题。因此, 这类工作不属于有监督主题模型的范畴。

将有监督的文本主题模型应用于上下文定向, 虽然在标签体系的设计上可以做到更加合理, 更有针对性, 但也给训练过程带来了麻烦: 除了准备文档集合, 还需要准备对应的标签标注, 这么一来训练集能够覆盖到的文档规模就受到很大限制。因此, 在有监督文本主题模型的实用过程中, 最关键的一点是找到系统性地批量标注的方法。

12.3 行为定向

归类为 $t(u)$ 的受众定向方式包括从用户网上浏览记录加工得到的兴趣定向以及根据用户历史所在的地域得到的用户主要居住地的“Where on Earth”定向等。由于这些都是根据用户的历史行为进行挖掘的问题, 因此把它们统称为行为定向 (Behavioral Targeting, BT)。

行为定向需要进行大规模的数据挖掘, 是在线广告中数据利用和变现最重要的计算问题之一。这一问题可以描述为, 根据某用户一段时期内的各种网络行为, 将该用户映射到某个定向标签上。关于行为定向可能用到的有价值的数据来源可以参考 6.6.1 节。而行为定向的用到的标签体系、建模方法、特征生成和评测指标等问题将在下面分别讨论。

12.3.1 行为定向建模问题

行为定向问题的目标是找出在某个类型的广告上 eCPM 相对较高的人群。如果假设在该类型的广告上点击价值近似一致, 那么问题就转化为找出在该类型广告上点击率较高的

人群。虽然对品牌广告而言，点击率未必总是合理的评价指标，然而如果认为在该类型上各种目的的广告均衡存在时，点击率仍然具有相对的衡量意义。因此，可以把某个用户在某类广告上的点击量作为建模的对象。

由于点击行为是离散到达的随机变量，对其数量最自然的概率描述是泊松分布。泊松分布的形式如下：

$$p_t(h) = \frac{\lambda_t^h \exp(-\lambda_t)}{h!} \quad (12.5)$$

其中 h 为某个用户在某个定向类别广告上的点击量^[10]， t 代表某个受众标签，而 λ_t 为相应的控制点击行为到达频繁性的参数。当然，直接比较单位时间内的点击量并没有太大的意义，这里的点击量是单位有效展示对应的点击数，关于如何计算单位有效展示，可以参考 13.5.4 节。行为定向模型要做的就是将用户的行为与频繁性参数 λ_t 联系起来。如果利用线性模型联系用户行为和 λ_t ，则有：

$$\lambda_t = \sum_{n=1}^N w_{tn} x_{tn}(\mathbf{b}) \quad (12.6)$$

这里的 $\mathbf{w}_t = (\mathbf{w}_{t1}, \dots, \mathbf{w}_{tN})$ 即为标签 t 对应的行为定向模型需要优化的参数， n 表示不同的行为类型，如搜索、网页浏览、购买等。此处将原始行为 $\mathbf{b}$ 先经过特征选择函数 $x_{tn}(\mathbf{b})$ ，再将结果作为特征用在模型中。将公式 12.6 代入公式 12.5，就得到行为定向的整体模型。

这是工程上一种非常典型的建模思路：当面对一个多自变量的回归问题时，可以先根据目标值的特性选择合适的指数族分布来描述，并用线性模型将多个自变量和指数族分布的参数联系起来。这样做，可以利用线性模型更新简单和可解释性强的特点，同时又对目标变量的类型有较强的适应性。这种建模方法称为广义线性模型 (Generalized Linear Model, GLM)。有关广义线性模型的一般性讨论可以参考参考文献[36]。

公式 12.5 的行为定向模型有两点需要特别说明。

(1) $\mathbf{w}$ 可以是与标签 t 相关的，即对不同的定向标签训练不同的线性函数。这样做的优点是可以更准确地对每个类别进行建模，但缺点是当有些类别数据不足时估计偏差较大。一般来说，当 $\mathbf{w}$ 与标签相关时，原始行为也可以考虑经过一个与标签无关的选择函数，因为类的本质特征已经反映在了模型参数矢量上。

(2) 这种建模方法主要适用于有明确需求方意义的标签体系：只有广告 $\mathbf{a}$ 上也有这些标签才能根据其点击行为来建模。

有关公式 12.6 中的模型参数 $\mathbf{w}_t$ 的最大似然解，需要多次访问数据迭代求解。具体的求解方法并不复杂，读者可以自行推导，也可以进一步参考参考文献[22]。下面重点讨论的内容是如何选择合适的行为定向特征以及优化相关的计算过程。

12.3.2 行为定向特征生成

行为定向特征的生成过程有两点需要讨论：一是特征选择函数 x_m 的确定，二是公式 12.5 对应模型的训练集的组织 and 生成方式。行为定向的特征生成过程，由于样本量比较大，处理的高效性是在工程中主要考虑的问题。

最常用的特征选择函数 $x_m(b)$ 是将一段时间内的原始用户行为映射到确定的标签体系上，同时计算出各行为在对应标签上的累积强度作为模型的特征输入。例如，对于页面浏览行为，我们用上下文定向的方法将 URL 转换为标签，作为此次行为的标签，而一次浏览的强度置为 1；而对于搜索行为，可以根据查询词将其映射为标签，而一次搜索的强度置为 1。关于搜索、广告点击、网页浏览等各类行为的标签化方法还将在后面专门讨论。模型中 w_m 的作用实际上就是在调整搜索、浏览等不同行为类型的重要程度。这一特征生成过程如图 12-6 所示。




图 12-6 行为定向特征生成过程示意

这里要注意，我们考虑的是“一段时间内的行为”，因为过于久远的行为对于用户兴趣的贡献是很小的。如何将行为累计控制在一段时间以内，工程上有两种常用的方法，分别是滑动窗口法和时间衰减法，如图 12-7 所示。

在滑动窗口法中，设定一个窗口长度 D ，然后将从当前时间倒推再此窗口长度内所有属于 t 的行为强度累加起来。用 $\tilde{x}$ 代表累积特征以区别于单时间片特征 x ，实际上在公式 12.6 中，应该使用 $\tilde{x}$ 而不是 x 。在滑动窗口法中， $\tilde{x}$ 的计算公式为：

$$\tilde{x}(d) = \sum_{\delta=0}^D x(d - \delta) \quad (12.7)$$




图 12-7 用户行为累计方法示意：滑动窗口法（上），时间衰减法（下）

而在时间衰减法中，并不明确设定窗口长度，而是设定一个衰减因子 α ，用上一个时间片的累积特征 $\tilde{x}(d-1)$ 与本时间片的行为强度 $x(d)$ 递归地得到今天的累积特征 $\tilde{x}(d)$ ，其更新公式为：

$$\tilde{x}(d) = \alpha \tilde{x}(d-1) + x(d) \quad (12.8)$$

在实际的行为定向建模中，会用累积特征 $\tilde{x}$ 替代单时间片特征 x 。上面的两种累积特征计算方法并无本质区别，它们对原始行为过滤的窗型，前者为矩形，后者为指数形，并且形状都由唯一的参数来控制。但是从工程角度看，我们更推荐使用第二种方案，因为在这种方法中，只需要保存累积到前一个时间片的特征和当前时间片的行为强度，空间和时间复杂度都比较低。

行为定向的训练过程实际上就是调整各个标签类别上各种特征权重的过程。影响训练结果和效率的因素主要有两个。

（1）训练集的长度。一般来说，为了消除工作日的周期性影响，训练集的天数一般选择为 7 的整数倍。对于一个用户来说，他累积到前一个时间片的行为特征 $\tilde{x}_t(d)$ 和本时间片的该标签广告点击次数 $h_t(d)$ 对应于公式 12.5 的一个训练样本。因此，每个用户会对应多个训练样本。

（2）时间片的大小。这反映了对定向的时效性的要求，如果希望更快地利用行为数据对标签做出调整，必然要缩小这一时间片大小^[44]。

可以想见，训练集的样本数目正比于训练集长度且反比于时间片长度。当用户数目较多、训练集长度较长，而时间片又较短时，总的训练样本数目是非常大的。为了避免计算冗余，使训练时的空间代价尽可能小，在参考文献 [22] 中作者给出了一个复杂度为 $O(1n)$ 的训练样本生成算法，该算法的关键点是在预处理过程中生成每个用户 u 各个时间片的 x_{ut} 和 h_t ，将它们按时间顺序排列成一个事件流。通过在此事件流上向前滑动，依次在训练过程中得到各个时间片的累积特征 x_{ut} ，并得到相应的训练样本。

这一方法看起来普通，却是在大规模用户行为分析时必须要注意的，也是计算广告架构（图 9-2）中提到要将用户行为与用户标识作为键组织在一起的原因。以时间衰减法为例，我们将累积行为定向特征生成的过程用下面的代码示意。

```

1 // In:
2 //   events : 各时间片的原始特征
3 //   alpha  : 衰减因子
4 // Out:
5 //   features : 各时间片的累积特征
6 int btSampleGen(vector<Vec> & events, int T, vector<Vec> & features) {
7     int numSlice = events.size();
8     int dim = events[0].size();
9
10    features.resize(numSlice);
11    features[0] = events[0];
12    for (int s = 1; s < numSlice; s ++) {
13        features[s] = features[s - 1];
14        for (int d = 0; d < dim; d ++) {
15            features[s][d] *= alpha;
16            features[s][d] += events[s][d];
17        }
18    }
19 }

```

各类行为的标签化方法

上面关于行为定向特征生成的讨论还缺少一个环节：特征选择函数 $x_m(b)$ 的计算方法，即搜索、广告点击、网页浏览等行为映射到一个或多个定向标签上。这是行为定向计算过程中最关键的环节，下面介绍工程中的实用方案。

(1) 网页浏览、分享等与内容相关的行为可以通过 12.2.2 节中提到的有监督文本主题模型的方法，将其映射到预先定义好的标签体系上，也可以直接提取内容中的关键词作为标签。

(2) 广告点击等与广告活动相关的行为可以转化为对广告落地页内容的分析，因此可以使用与网页浏览相同的方法。不过，实践中经常会碰到广告落地页内容为图片、Flash 或者内容很少的情形。因此，根据创意形式的不同，还有其他两种方法：当创意为文字链时，可以将其题目或描述作为内容；当创意为图片时，往往需要人工标注其标签，但由于工作量较大且正确性不宜评估，建议只在必要时进行。

(3) 最值得重视的是搜索、搜索点击等与查询相关的行为。由于查询的信息量较少，很难直接提取标签。可行的方案有两种，都要用到搜索引擎：第一种方案是利用搜索引擎做内容扩展，即将查询送入搜索引擎，用返回的若干结果描述或者链接页的内容作为该查询对应的内容，这种方案借助通用搜索引擎即可；第二种方案是对查询进行某垂直领域分类时，直接利用相应垂直媒体的标签体系和搜索引擎。下面以电商行业为例来说明此方案。

如果要给查询标注电商行业标签，可以采用与某综合电商，如淘宝，相一致的分类标签体系。在此基础上，任给一个查询，将其送入淘宝的搜索引擎，然后查看返回商品结果对应的分类，将此分类作为标签即可。如果返回结果很少或结果中的分类很分散，可以认为此查询没有合适的电商行业标签。这实际上是借鉴了电商搜索引擎成熟的分类能力，往往可以较快地做到比较准确的查询分类。此方法的限制是必须采用与某电商一致的标签体系，不过一般来说这不是大问题。这个例子虽然针对电商行业，但对于其他垂直行业，如汽车、房产等，也完全适用，只要借助于该行业网站比较成熟的垂直搜索引擎即可。

(4) 转化、预转化等需求方行为往往可以对应到一个单品。同样，利用该单品的分类信息可以将其映射到某个标签上，而对于预转化中的站内搜索行为，可以按照上面的一般搜索行为来处理。

这几类典型行为的标签化过程如图 12-8 所示。对于其他的行为，往往也可以归结到这几种类型之一，或者根据其行为数据的特点具体讨论。




图 12-8 各类行为标签化方法示意

12.3.3 行为定向决策过程

虽然公式 12.5 的行为定向模型看起来比较复杂，不过其核心目的无非是为了通过数据得到公式 12.6 中的行为系数 w_m 。在行为定向的决策过程中，不需要 λ 到 h 的泊松分布，只需要计算线性函数 λ 的值，然后根据预先确定的阈值来确定某个用户是否应该被打上某个定向标签。

行为定向计算过程比训练过程的数据准备要简单，因为不再需要准备目标值，只需要按照滑动窗口法或者时间衰减法得到累积特征 $\tilde{x}_{tn}$ ，再根据 w_n 加权求和得到得分 λ 。由于这一计算过程也是线性的，当特征累积采用时间衰减法时，得分 λ 也可以通过昨天的得分衰减后累积上今天得分的方式得到，即：

$$\begin{aligned}\lambda_t(d) &= \sum_n w_n \alpha \tilde{x}_{tn}(d-1) + \sum_n w_n x_{tn}(d) \\ &= \alpha \lambda_t(d-1) + \sum_n w_n x_{tn}(d)\end{aligned}\tag{12.9}$$

上面的公式揭示了受众定向系统工程实现的一个关键点：在线上存储各用户的定向标签得分 λ 的缓存中，在每个新的时间周期，在缓存中得分乘以 α 进行衰减，再将上一个时间周期收集到的原始行为 $\mathbf{x}_m$ 加权求和后累加上即可。这比起在每个时间周期重新计算所有 λ 并更新整个线上缓存显然要轻量级许多。这一线上计算过程更加体现了时间衰减法的优势，特别是当需要对用户的短时行为进行快速反馈时，这样简便的递归式计算方法非常有效。

12.3.4 行为定向的评测

对于上面讨论的行为定向模型，因为可以通过调整线性函数输出 λ 的阈值来控制某个标签人群的量，相应的标签人群在广告投放中的效果也会相应变化。当然，在量扩大的情况下一般来说精准性也会降低。其他形式的行为定向模型也都具有类似的特点。因此，行为定向模型的评测需要考虑到量的影响。

一般来说，行为定向可以通过 reach/CTR 曲线来进行半定量的评测。在正常情况下，较小的人群规模应该较为精准，也即对该类型广告的 CTR 较高；而随着人群规模的扩大，该 CTR 也会逐渐走低。我们把标签接触到的人群规模称为 reach，而这一 reach 和 CTR 构成的曲线是评价该标签上的定向是否合理、以及效果如何的重要依据。

图 12-9 给出了一个实际的 reach/CTR 曲线示例，我们来了解一下解读此曲线的几个关键之处。首先，该曲线应该大体呈下降的趋势，如果数据质量或定向建模有一些问题，有时会出现非下降的趋势或者头部较低的情况，这意味着调低用户规模反而使得点击率下降，显然是不正常的。如果出现这种情形，需要认真检查定向流程或者判断是否已有的数据无法支持该定向标签。其次，reach/CTR 曲线最右端一个点的 CTR 水平是固定的，即无法通过改善数据和模型来提高，因此这是 reach 达到 100%，也即全部用户的情形下的 CTR 水平。该曲线的斜率越大，往往表示定向模型的鉴别力越强。由于实际中一般会将阈值设定得较高，从而达到较好的定向效果，因此往往只需要关注该曲线头部的部分即可。




图 12-9 reach/CTR 曲线示意

工程中需要注意的是，生成 reach/CTR 曲线的过程需要仅仅访问一遍数据就能完成。因此，在前面受众定向的过程中，需要保留的是每个用户在各个标签上的得分值，而不是最后二元的判断结果。给定一批测试用户在所有标签上的定向得分值，生成 reach/CTR 曲线的过程如下面的代码所示。

```

1 struct Imp {int click; int userId; double score;};
2
3 // In:
4 //   imps   : 各次展示的数据集
5 //   binNum : reach/CTR曲线的点数
6 // Out:
7 //   reaches : 各点的reach
8 //   ctrs    : 各点的CTR
9 void reach_ctr(vector<Imp> &imps, int binNum, Vec&reaches, Vec&ctrs){
10     int sampleNum = (int)imps.size();
11
12     // 遍历所有的样本以得到分数的最小值和最大值
13     double minScore = INF, maxScore = -INF;
14     for (int s = 0; s < sampleNum; s++) {
15         if (imps[s].score < minScore) minScore = imps[s].score;
16         if (imps[s].score > maxScore) maxScore = imps[s].score;
17     }
18
19     // 得到各个bin的阈值
20     Vec bins;
21     double step = (maxScore - minScore) / binNum;
22     bins.assign(binNum + 1, minScore);
23     for (int b = 0; b < binNum; b++)
24         bins[b + 1] = bins[b] + step;
25
26     // 再次遍历样本以得到各个bin上的reach和点击数目
27     Vec reachClicks;
28     reachClicks.assign(binNum, 0);
29     reaches.assign(binNum, 0);
30     ctrs.assign(binNum, 0);
31     for (int s = 0; s < sampleNum; s++) {
32         for (int b = 0; b < binNum; b++) {
33             if (imps[s].score < bins[b]) break;
34             if (imps[s].click) reachClicks[b]++;
35             reaches[b]++;
36         }
37     }
38
39     // 计算reach和CTR
40     for (int b = 0; b < binNum; b++) {
41         ctrs[b] = reachClicks[b] / reaches[b];
42         reaches[b] /= sampleNum;
43     }
44 }

```

12.4 人口属性预测

严格来说，年龄、性别、教育程度、收入水平等人口属性并不属于用户的兴趣，而是用户确定的特点描述。不过在实际定向广告系统中，除了一些实名的社交网络以外，规模化地获得人口属性比较困难，因此往往还是需要数据驱动模型，以用户的行为为基础自动预测其人口属性。

这种基于预测的方法直觉上很容易理解，以性别属性为例：经常访问军事网站或汽车网站的用户绝大部分都是男性；经常浏览娱乐八卦的用户则以女性居多。性别属性预测的问题可以描述成一个典型的二分类问题，其输入特征就是用户的原始行为 $\mathbf{b}$ （或者提取后的行为特征 $\mathbf{x}^0$ ），而输出就是 $\{M（男），F（女）\}$ 两个分类。有很多机器学习模型都可以用于性别预测问题，比如采用最大后验概率的框架，则预测问题可以表示成：

$$\hat{g} = \arg \max_{g \in \{M, F\}} p(g|\mathbf{b}) \quad (12.10)$$

其他的模型，如支持向量机（Support Vector Machine, SVM）^[16]、AdaBoost^[32]等，都可以考虑，需要根据自己的数据特点具体判断哪种模型更合理。

建模中有两个问题需要注意：首先，不论用什么样的模型来预测人口属性，必须要有一定的拒识门槛，也就是说对那些行为不够丰富或不够有代表性的用户应该输出“未知”的判断，而不是简单地用模型算出一个结果；其次，模型训练集的获得非常重要，往往算法的有效性不如更准确、规模更大的训练集对结果的提升明显。较大训练集的获得往往是要依赖社交网络，比如可以将广告系统的用户身份与微博用户对应，再从微博公开的用户属性获得标注。

除了性别以外的其他人口属性用简单的分类模型并不太准确。以年龄为例，假设我们把标签设定成五个年龄段，那么将第一个年龄段的认错分到第二个年龄段与错分到第三个年龄段的代价应该是不同的，而如果采用简单的 5 个类的分类模型，这一差别就被忽略了。因此，需要在分类模型中明确考虑不同类之间的错分代价，其他的属性如教育程度、收入水平也类似。不过总体上说，从用户行为上预测非性别的人口属性是比较困难的任务，除非有非常相关的数据来源以及充分多的准确的训练样本，否则不太建议用这种方法获得这些标签。

12.5 数据管理平台

第 6 章介绍了数据交易平台和数据管理平台这两种与广告相关的数据产品。虽然这些数据产品主要是在程序化交易市场中发挥作用，不过就其技术架构来说，不过是将本章介绍的数据收集和受众定向功能独立出来，形成专门的产品，因此，我们在本章中一起介绍。另外，数据管理平台和数据交易平台虽然分别从第一方和第三方的视角来收集和加工数据，不过其技术架构却很类似，而且在实际产品中分界也没有那么鲜明，因此我们在此统一以数据管理平台来代表。

数据管理平台的系统架构如图 12-10 所示。通过部署在媒体上的代码或 SDK 收集第一方访问日志，送入数据高速公路。同时通过数据高速公路收集自有的第二方数据，然后把这些日志原始行为映射到结构化或非结构化的受众标签体系上。另外，还会有一些第三方提供的加工好的标签数据直接进入用户标签集。最后通过统一的接口对外提供标签。在这一架构中，DMP 同时对接了第一方、第二方和第三方的数据，并根据这些数据对受众群体进行灵活的、自定义的划分。虽然这些功能并不直接体现在广告交易环节中，却是数据驱动的在线广告中越来越重要的一环。

除了需要用到上面讨论的受众定向技术，DMP 还有一个技术问题，即如何将用户标签传送给购买方，比如某 DSP。这包括两个环节，一是用户身份对应，比如将在第 14 章中介绍的 cookie 映射；二是数据的传递方式。图 12-10 中的数据传递是直接通过在线缓存的形式访问，实际上更常见的方式是在广告交易的过程中，附着在询价请求上直接提供。

12.6 延伸思考

1. 移动互联潜在的受众定向能力会高于 PC，利用移动互联网的哪些数据可以加工出哪些与 PC 不同的定向标签？

2. 本章中给出的行为定向建模方法比较适合于那些对应于广告主分类的、规模较大的兴趣标签，对于其他无法明确对应广告主分类或规模不大的兴趣标签应该如何处理？




图 12-10 数据管理平台（DMP）系统架构示意

第 13 章 竞价广告核心技术

竞价交易是整个在线广告市场最关键的一次产品进化，同时也带来了广告技术的迅速发展。应该说，竞价广告使得当今计算广告中最关键的几项通用技术挑战找到了适用的场景，并很快成熟起来。本章将首先给出实际系统中各种机制设计共同作用时的竞价逻辑，然后介绍搜索广告和广告网络这两种典型产品的技术架构和优化目标以及其中的一些计算问题。在此基础上，将重点介绍竞价广告最关键的几项通用技术，特别是广告检索和 eCPM 估计技术。

在竞价广告中，大量中小广告主的检索规模使得计算的效率要求很高，如何根据广告的业务要求设计更高效的索引和检索技术是竞价广告系统要解决的关键问题。我们将结合广告检索的具体需求，重点讨论布尔表达式检索与相关性检索这两个场景下的算法思路。

另外，竞价广告系统还需要对给定 (a, u, c) 组合上的 eCPM 做尽可能准确的估计，由于大量中小广告主的参与，广告系统对 eCPM 的估计往往面临样本不足的情形。与此相关的点击率预测和探索与利用两个问题所涉及的技术也是竞价广告系统通用的关键技术。点击率预测是广告系统中最重要机器学习问题之一，由于面对的数据量巨大，如何高效地设计算法以减少迭代是优化中要考虑的关键。另外，结合广告业务的特点设计有效的特征，让点击率模型快速捕捉用户兴趣的动态信号是提高点击率预测效果的关键。

在搜索广告中，竞价标的即关键词的粒度很细。因此，在 5.1 节中介绍的查询扩展问题至关重要。查询扩展可以看成是一个关键词推荐问题，但也需要考虑一些与广告领域相关的特点。另外，搜索广告的北区广告条数在策略上存在非常大个性化调整空间，这可以描述成一个用户体验约束下的收入优化问题。

广告网络中的反作弊、计价等模块，需要将系统日志快速加工处理并反馈给线上决策系统。另外，对用户行为和点击的快速反馈对广告效果的提高帮助很大。这些准实时数据处理需求催生了流计算平台。流计算技术与 Hadoop 等离线分布式计算技术相配合可以更有效地完成计算广告中的数据处理任务。

13.1 竞价广告计价算法

第 5 章介绍了搜索广告和广告网络这两种最典型的竞价广告产品。在进入这些具体产品的技术之前，我们先来了解“竞价”这一核心逻辑具体的实现，顺便引出此核心逻辑的几项主要支持技术。

5.2 节介绍了位置拍卖市场中一些常用的定价策略，包括 GSP、MRP、价格挤压等，单独理解这些策略都不困难。在实际的系统中，需要将这几种策略综合起来执行。以按 CPC 计价的竞价广告产品中一次广告展示为例，我们将实际的计价算法用下面的代码描述，可以对照表 5-2 进一步直观地理解此完整的定价过程。

```

1 // In:
2 //   cands   : 候选广告ID
3 //   ctrs    : 候选广告预估的点击率
4 //   bids    : 候选广告的出价
5 //   MRP     : 市场保留价
6 //   squash  : 价格挤压因子
7 //   slotNum : 要求的广告条目数
8 // Out:
9 //   results : 排序结果
10 //   prices  : 计价结果
11 void auction(vector<int> & cands, Vec & ctrs, Vec & bids, float MRP,
12             float squash, int slotNum, vector<int> & results, Vec & prices) {
13     int candNum = cands.size();
14
15     // 按照给定的squashing因子调整预估CTR
16     for (int c = 0; c < candNum; c++)
17         ctrs[c] = ctrs[c] ^ squash;
18
19     // 计算调整后的eCPM
20     Vec eCPMs;
21     eCPMs.resize(candNum, 1e-10f);
22     for (int c = 0; c < candNum; c++)
23         if (bids[c] >= MRP) // 跳过那些出价小于市场保留价的候选
24             eCPMs[c] = ctrs[c] * bids[c];
25
26     // 将所有候选按照eCPM排序
27     for (int c1 = 0; c1 < candNum; c1++)
28         for (int c2 = c1 + 1; c2 < candNum; c2++)
29             if (eCPMs[c1] < eCPMs[c2]) {
30                 SWAP(cands[c1], cands[c2]);
31                 SWAP(eCPMs[c1], eCPMs[c2]);
32                 SWAP(ctrs[c1], ctrs[c2]);
33             }
34
35     // 得到各竞价结果并计算定价
36     results.clear(); prices.clear();
37     for (int c = 0; c < candNum - 1; r++) {
38         if (eCPMs[c] <= 1e-10f)
39             break;
40
41         // 按照GSP计算定价
42         float price = eCPMs[c + 1] / ctrs[c];
43         if (price < MRP) price = MRP;
44
45         results.push_back(cands[c]);
46         prices.push_back(price);
47     }
48 }

```

在实际的广告产品中，还有可能同时存在若干种计费方式，其 eCPM 估算过程也不同，我们用下面的一小段代码来说明在各种计费方式并存的情况下完整的 eCPM 计算逻辑。当然，这里的逻辑比较简单直观，有关 CPM 和 CPC 混合竞价的拍卖过程与定价机制的探讨可以进一步参考参考文献[81]。

```

1  enum BidMode{CPM, CPC, CPS};
2
3  float calcuECPM(float bid, BidMode mode) {
4      switch (mode) {
5          case CPM:
6              return bid;
7          case CPC:
8              return predictCtr() * bid;
9          case CPS:
10             return predictCtr() * predictClickValue();
11     }
12 }

```

从定价过程的输入可以看出，对于一个 CPC 结算的竞价广告系统，需要先得到广告候选集合，并计算每个候选的点击率，这对应了竞价广告两个最关键的计算问题：广告检索和广告排序，这也是本章要讨论的重点技术问题。

竞价广告中根据 eCPM 对广告进行排序，而根据 2.3.1 节的介绍，按照点击和转化两个发生在不同阶段的行为，eCPM 可以分解成点击率和点击价值的乘积，eCPM 的估计主要就是点击率预测和点击价值估计两个任务：

$$r(a, u, c) = \mu(a, u, c) \cdot \nu(a, u) \quad (13.1)$$

点击率 μ 是广告三个行为主体的函数，而点击价值则是用户 u 和广告商 a 的函数。在 CPC 计算的竞价广告中，点击价值是广告主的出价，不需要估计。在分别介绍搜索广告和广告网络的架构和技术点之后，我们将把主要篇幅放在广告检索和点击率预测这两项核心技术上。

13.2 搜索广告系统

搜索广告是最早产生的，也是最为重要的竞价广告系统。搜索广告的优化目标在公式 2.2 的基础上加以调整，可以用下式来表达：

$$\max_{a_1, \dots, a_T} \sum_{i=1}^T \{\mu(a_i, c_i) \cdot \text{bid}_{\text{CPC}}(a_i)\} \quad (13.2)$$

这个目标相对简单清晰：对每次展示的各个候选，根据查询估计其点击率 μ ，并乘以广告主出的点击单价得到 eCPM，再按此排序即可。而在 eCPM 的估计过程中，根据上下文即用户输入的查询来决策。

搜索广告是竞价广告中最典型的系统之一，它与一般广告网络最主要的区别是上下文信息非常强，用户标签的作用受到很大的限制。搜索广告的检索过程一般都不考虑用户 u 的影响，而上下文信息 c ，即查询，又是实时通过用户输入获得，因而离线受众定向的过程基本可以被省略。在这样的应用场景下，搜索广告的系统架构如图 13-1 所示，它与一般的竞价广告系统架构的主要区别是没有上下文和用户标签的缓存，但是其检索模块由于查询扩展的需求，会比一般的竞价广告系统要复杂，并且在排序后的收益优化阶段还需要进行北区和东区的广告放置决策。

搜索广告算法上最关键的技术是点击率预测，这一点会在后面专门讨论。除此之外，搜索广告还有一个技术上的重点，那就是查询词的扩展，即如何对简短的上下文信息进行有效的拓展，由于搜索广告的变现水平高，这样的精细加工是值得而且有效的。

13.2.1 查询扩展

搜索广告中查询的重要性极高，粒度又非常细，如何根据广告主需求对关键词进行合理的拓展对于需求方和供给方来说都有很大意义。需求方需要通过扩展关键词获得更多流量；供给方则需要借此来变现更多流量和提高竞价的激烈程度。因此，查询扩展是搜索广告的重要技术，它主要用于 5.1.3 节中介绍的广泛匹配情形下。搜索广告的查询扩展与搜索中的查询扩展既有相通之处，又有一些显著的区别。相关的方法很多，在此只介绍 3 种主要的思路。




图 13-1 搜索广告系统架构示意

1. 基于推荐的方法

如果把用户一个会话（session）内的查询（query）视为目的相同的一组活动，可以在{session, query}矩阵上通过推荐技术产生相关的关键词。这种方法利用的是搜索的日志数据，而基本上个性化推荐领域的各种思路和方法都可以适用。以查询扩展的问题为例介绍一下推荐技术的基本问题。

给定一组用户会话 $s=\{1, \dots, M\}$ 和一组关键词 $w=\{1, \dots, N\}$ ，可以产生一个对应的交互强度矩阵 $\{x_{mn}\}_{M \times N}$ 。如果其中某个用户搜索过某个关键词，则矩阵相应的元素就置为一个相应的交互值，比如该用户在一段时间内搜索过该词的次数。

显然，这个矩阵中大多数单元都是空白，但这并不意味着用户搜索该词的可能性为零。而推荐的基本任务就是根据这个矩阵中已知的元素值去尽可能预测性地填充那些历史上没有观测到的单元。类似的场景除了搜索，还广泛出现在各种互联网应用当中，比如商品的浏览或购买记录以及在线电影的打分记录都可以抽象出类似的交互强度矩阵以及相应的推荐问题。这样根据群体用户的选择关联性进行推荐的问题也被称为协同过滤（Collaborative Flittering, CF）问题。

基于协同过滤的推荐问题有非常多的算法，它们可以分为基于内存的非参数化的方法和基于模型的参数化方法。后者是用维数较低的空间概要性地刻画交互矩阵，然后根据该空间的生成参数恢复矩阵里未知的值。这种将空间降维的思路与文档主题模型乍看起来很相似，不过问题本身还是有明确的区别：在推荐问题中，应该把那些未观测到的交互单元视为未知，而在文档主题模型中，合理的方法是认为未在某文档中出现的词交互强度为 0。关于推荐算法的综述可以参考[58, 68]等文献。

各种推荐方法的本质都是对 $\{x_{mn}\}_{M \times N}$ 矩阵进行平滑，从而将 x_{mn} 变成平滑后的值 x'_{mn} 。为什么可以利用推荐的方法进行关键词扩展呢？对某一个关键词 w_n 来说，其原始的交互强度矢量 $(x_{1n}, \dots, x_{Mn})^T$ ，虽然我们也可以根据两个关键词对应矢量的相似度来找到近似的关键词，不过由于其元素过于稀疏，这一方法在实用中往往不可行。在经过了推荐算法的平滑以后，这一矢量变成 $(x'_{1n}, \dots, x'_{Mn})^T$ ，矢量中的未知元素也都被填充上相对合理的值，于是就可以稳健地比较关键词的相似度。

2. 基于主题模型的方法

除了利用搜索的日志数据，也可以利用一般的文档数据进行查询扩展。这类方法实质上就是利用文档主题模型对某个查询拓展出主题相似的其他查询。关于文档主题模型的介绍可以参考 12.2.2 节。

在主题模型的描述下，每个词 w_n 都可以对应于一个文本主题组成的矢量 $\{z_{n1}, z_{n2}, \dots, z_{nk}\}$ 。于是，也可以用两个词对应的主题矢量来计算它们相似度。这种方法与上一种方法相比，主要考虑的是语意上的相关性，而非用户意图上的相关性，因此效果会差一些，只能作为用户搜索行为数据不足时的补充方法。

3.基于历史效果的方法

对搜索广告而言，还有一类查询扩展方法很重要，那就是利用广告本身的历史 eCPM 数据来挖掘变现效果较好的相关查询。由于在广告主选择竞价的关键词时，一般来说都会选择多组，如果从历史数据中发现，某些关键词对某些特定广告主的 eCPM 较高，那么应该将这些效果较好的查询组记录下来，以后当另一个广告主也选择了其中的某个关键词时，可以根据这些历史记录，自动地扩展出其他效果较好的查询。

虽然这种方法得到的扩展结果经常会与前两种方法得到的结果相重合，不过由于这种方法直接使用广告的优化目标，即 eCPM 来指导查询扩展，往往能够成为前两种方法非常重要的补充手段，而且对提高营收起到的效果往往还要好于前面的两种方法。

13.2.2 广告放置

如 5.1.3 节中讨论的，广告放置指的是搜索引擎广告中确定北区和东区广告条数的问题。考虑到用户体验，需要对北区广告的数量进行限制，因此，这是一个典型的带约束优化的问题：约束是系统在一段时间内整体的北区广告条数，而优化的目标则是搜索广告系统的整体营收。在进行广告放置之前的排序过程中，比较的都是单条广告的 eCPM，不过此处的优化需要处理一组广告，并且需要考虑位置因素，此问题可以表达如下：

$$\begin{aligned} \max \quad & \sum_{i=1}^T \left\{ \sum_{s=1}^{n_i} r(a_{is}, c_i, N_s) + \sum_{s=n_i+1}^{n_i+e_i} r(a_{is}, c_i, E_{s-n_i}) \right\} \\ \sum_{i=1}^T n_i \leq & TC \end{aligned}$$

其中 n_i 和 e_i 分别表示第 i 次展示的北区和东区广告条数。在 eCPM 的表达 r 中，多了一个表示位置的参数^[12]，例如， N_s 表示北区的第 s 个位置， E_s 表示东区的第 s 个位置。 C 为北区的平均广告条数上限。显然，调整北区广告准入的一些指标，如 MRP、相关性、质量度等，都会影响此问题的解。为了不使表达过于复杂，这些参数在公式 13.3 中没有显式出现，但读者可以很容易地在实际系统中找到它们的作用并模拟其影响。显然，这个问题形式上不是可导的，而且要调整的参数也不太多，可以采用 10.2.2 节中介绍的下降单纯形法求解。

搜索广告虽然不宜进行深入的个性化，但在广告放置问题上存在着很大的个性化空间。不同用户对于广告接受和容忍的程度有着很大的不同，实际上，即使在北美这样的用户教育水平较高的市场上，也至少有 30%~40% 的用户不能完全分辨搜索结果和广告。因此，对不同的用户动态调整北区的条目数可以使得在北区平均广告数目相同的约束下，整体系

统的营收有显著的提高。在考虑单个用户的广告接受程度后，我们可以对公式 13.3 中的收入作个性化的调整。例如，对于北区的一个广告展示，改成下面的形式：

$$r'(a_{is}, u_i, c_i, N_s) = r(a_{is}, c_i, N_s) \cdot \overline{\mu(u_i)} / \bar{\mu} \quad (13.3)$$

这里的 $\overline{\mu(u_i)}$ 和 $\bar{\mu}$ 分别表示用户 u_i 对北区广告的平均点击率和所有用户对北区广告的平均点击率。在计算点击率的过程中需要对北区不同位置的点击做归一化，并且需要做平滑，参考 13.5.4 节。用 r' 替换公式 13.3 中的 r 后，可以用同样的框架求解。

13.3 广告网络

广告网络是除了搜索广告以外最重要的非实时竞价类广告产品。由于没有了明确的用户意图以及展示位置的固定性，像查询扩展、广告放置等问题在广告网络中并不存在。下面看一下广告网络的优化目标、系统架构以及短时行为反馈等问题。

广告网络的优化目标在公式 2.2 的基础上有所调整，可以用下式来表达：

$$\max_{a_1, \dots, a_T} \sum_{i=1}^T \{\mu(a_i, u_i, c_i) \cdot \text{bid}_{\text{CPC}}(a_i)\} \quad (13.4)$$

由于广告网络的成本是分成或包断媒体资源，因此公式 2.2 中的成本项被去掉了；而收入部分是比较典型的根据“a given user in a given context”，求“suitable ad”的过程，即根据给定的用户和上下文求合适的广告的过程，这也反映了计算广告决策的核心逻辑。

广告网络的典型系统架构如图 13-2 所示，其中广告投放的决策流程为：服务器接收前端用户访问触发的广告请求，首先根据上下文信息和用户身份标识从页面标签和用户标签中查出相应的上下文标签和用户标签；然后用这些标签以及其他一些广告请求条件从广告索引中找到符合要求的广告候选集合；最后，利用 CTR 预估模型计算所有的广告候选的 eCPM，再根据 eCPM 排序选出赢得竞价的广告，并返回给前端完成投放。

从离线计算的流程来看，广告网络需要根据广告投放的历史展示和点击数据对点击率预测进行建模。当然，实际的广告网络也往往需要同时提供受众定向的功能，因此这部分离线计算也需要进行。不过由于我们只给出最核心的功能块，因此没有强调这一部分。

由于广告网络广泛采用 CPC 计费，准实时的计费和点击反作弊功能是必不可少的；另外，将用户行为尽快反馈到广告决策中对于点击率预估和受众定向的效果提升也非常关键。这些需求共同催生了流计算技术，这一技术被广泛应用于短时受众定向和短时用户行为反馈。

短时行为反馈与流计算

虽然用户行为定向不适用于搜索广告，但是用户在一个会话内的一系列查询如果能够快速处理，还是会对准确理解用户意图有帮助。除了这样的短时用户行为反馈，在广告业务中还有以下一些需要快速对在线日志进行处理的场景。

图 13-2 广告网络系统架构示意

(1) 实时反作弊。反作弊是所有广告系统都需要的模块，关于反作弊具体的技术将在第 15 章中介绍。在 ADN、DSP 这类依赖于站外流量的广告产品中，爬虫流量、突发的作弊流量都会对广告主预算产生巨大的影响。因此，在所有需要实时数据处理的模块之前，需要一个实时反作弊的模块，对系统产生的日志进行过滤。

(2) 实时计费。广告产品需要一个实时计费的模块，以便将那些预算消耗完的广告及时下线，避免系统损失。

（4）短时动态特征。CTR 预测中的动态特征（见 13.5.4 节）也可以根据分钟级的数据补充调整。

这些场景对数据处理系统提出了新的挑战：简单的基于 Hadoop 的离线挖掘模式不再适用了，需要一个灵活的计算框架，能够实时流式地接受线上日志，并用预先组织好的一组处理过程来加工这些数据，得到随时可以被使用的结果。这样的需求催生了流计算平台。以上面的几个广告系统中实时处理的任务为例，它们组成的处理流程可以用图 13-3 来示意。




图 13-3 广告系统中的流计算任务流程示意

图 13-3 的流程非常类似于一组有依赖关系的 MapReduce 任务，但是由于数据实时处理的需求，它需要的计算架构与 MapReduce 是不同的。一个流计算的基础平台应该能够自动完成数据在不同任务间的调度以及任务内部的分布计算。流计算平台有若干开源工具可供选择，其中 Storm 的编程接口与 Hadoop 很相似，使用起来相当方便，可以参考 9.5.8 节中的介绍。

虽然计算逻辑上接近，流计算与 MapReduce 有着本质的不同：MapReduce 是通过分布式文件系统尽可能对计算进行调度，而流计算则是在各台服务器之间调度数据来完成计算。这使得它们的适用场景也有着很大的区别：流计算适用于准实时、快速的数据统计和反馈，但是由于是在调度数据，所以并不适合于海量数据的批量计算；而 MapReduce 更适用于数据量非常大，但是计算实时性要求并不太高的情形。实践中，往往需要两者结合来达到数据量和实时性两方面的要求。

13.4 广告检索

大量中小广告主参与的竞价广告市场中，复杂的定向条件对检索技术提出了新的要求。倒排索引是搜索引擎的关键技术，而广告的检索上也采用这样的框架。但是广告的检索问题也有一些自身的特点和需求，基本的倒排索引技术在广告检索中遇到了两个新问题。

(1) 广告的定向条件组合可以看成是一个由与或关系连接的布尔表达式，这样的文档显然与搜索引擎面对的 BoW 文档不太一样，这里存在着有针对性的检索性能优化空间。

(2) 在上下文关键词或和用户标签比较丰富时，广告检索中的查询可能相当长，甚至会由上百个关键词组成，这种情况下的检索也与搜索引擎中主要由 1~4 个关键词组成的查询有很大区别。试想，如果将 100 个关键词同时输入搜索框中，返回的结果会是你想要的吗？

这些差异使得广告中使用的检索技术在基本的倒排索引之上有所发展，下面将具体讨论上面两个问题。

13.4.1 布尔表达式的检索

广告检索与普通搜索引擎检索的第一个不同是布尔表达式的检索问题。在受众定向的售卖方式下，一条广告文档不能再被看成是 BoW，而是应该被看成一些定向条件组合成的布尔表达式，如下面的几个例子。

$a_1 = (\text{age} \in \{3\} \cap \text{geo} \in \{\text{北京}\}) \cup (\text{geo} \in \{\text{广东}\} \cap \text{gender} \in \{\text{男}\})$

$a_2 = (\text{age} \in \{3\} \cap \text{gender} \in \{\text{女}\}) \cup (\text{geo} \notin \{\text{北京}, \text{广东}\})$

$a_3 = (\text{age} \in \{3\} \cap \text{gender} \in \{\text{男}\} \cap \text{geo} \notin \{\text{广东}\}) \cup (\text{state} \in \{\text{广东}\} \cap \text{gender} \in \{\text{女}\})$

$a_4 = (\text{age} \in \{3, 4\}) \cup (\text{geo} \in \{\text{广东}\} \cap \text{gender} \in \{\text{男}\})$

$a_5 = (\text{state} \notin \{\text{北京}, \text{广东}\}) \cup (\text{age} \in \{3, 4\})$

$a_6 = (\text{state} \notin \{\text{北京}, \text{广东}\}) \cup (\text{age} \in \{3\} \cap \text{state} \in \{\text{北京}\}) \cup (\text{state} \in \{\text{广东}\} \cap \text{gender} \in \{\text{男}\})$

$a_7 = (\text{age} \in \{3\} \cap \text{state} \in \{\text{北京}\}) \cup (\text{state} \in \{\text{广东}\} \cap \text{gender} \in \{\text{女}\})$

这些例子用布尔表达式表示广告的定向人群，并且写成析取范式（Disjunctive Normal Form, DNF）的形式。在这样的表达形式中，先要解释以下两个概念。

（1）每个 DNF 都可以分解成一个或多个交集（conjunction）的并，如 a_1 可以分解成 $j_1 = (\text{age} \in \{3\} \cap \text{geo} \in \{\text{北京}\})$ 和 $k_2 = (\text{geo} \in \{\text{广东}\} \cap \text{gender} \in \{\text{男}\})$ 这两个交集。

（2）每个交集又可以进一步分解为一个或多个赋值集（assignment）的交，以 j_1 为例，可以分解为 $\text{age} \in \{3\}$ 和 $\text{geo} \in \{\text{北京}\}$ 这样两个赋值集。为了后面算法描述方便，我们定义 Assignment、Conjunction 和 DNF 的数据结构如下。

```
1 class Assignment {
2     public:
3         int    attribute; // 该Assignment指定的标签类型
4         bool   belong;    // 表示该Assignment是属于还是不属于
5         int    value;     // 该Assignment指定的标签取值
6 };
7
8 // 一个或多个Assignment的交
9 typedef vector<Assignment> Conjunction;
10
11 // 一个或多个Conjunction的并
12 typedef vector<Conjunction> DNF;
```

布尔表达式检索的问题有两个特点，这两个特点是设计算法的重要依据。首先，当某次广告请求的定向标签满足某个 Conjunction 时，一定满足包含该 Conjunction 的所有广告，这说明只要对 Conjunction 建立倒排索引，并加上一层 Conjunction→AD 的辅助索引即可。其次，在 Conjunction 的倒排索引中，有一项直觉可以帮助我们减少计算：令 sizeof

(query) 表示广告请求中的定向标签个数，而 sizeof (Conjunction) 表示某 Conjunction 中的含有“ ϵ ”的 Assignment 数目，当 sizeof(query)<sizeof(Conjunction) 时，该 Conjunction 一定不满足该次请求。

根据上述两个重要特点，可以设计出为布尔表达式检索定制的算法。我们以参考文献 [76] 中的算法为例介绍这种思路。该算法维护一个两层的倒排索引，即上面所说的 Conjunction 和 AD 两层索引，后一个索引按照“或”的关系进行检索，而前一个索引有不太一样的结构：在 Conjunction 的索引中，把每个 Conjunction 分解成一组（键，值）对，例如，将 $\text{age} \in \{3, 4\}$ 分解成 $\text{age} \in \{3\}$ 和 $\text{age} \in \{4\}$ 两个 Term，这些 Term 即是倒排索引的键，而“ ϵ ”和“/ ϵ ”操作符放在倒排链表的具体元素上。利用上文所说的 Assignment 个数的约束，我们可以做的优化是将这一倒排索引按照 sizeof (Conjunction) 分成若干部分，以提高检索效率。仍然以上文的一组广告为例，这组广告的 DNF 可以按如下的方式分解成一些 Conjunctions:

$$a_1=j_1Uj_4, \quad a_2=j_2Uj_6, \quad a_3=j_3Uj_7, \quad a_4=j_5Uj_4, \quad a_5=j_6Uj_5, \quad a_6=j_6Uj_1Uj_7, \quad a_7=j_1Uj_7$$

其对应的倒排索引也可以很容易地写成下面的形式：

$$j_1 \rightarrow \{a_1, a_6, a_7\}, \quad j_2 \rightarrow \{a_2\}, \quad j_3 \rightarrow \{a_3\}, \quad j_4 \rightarrow \{a_1, a_4, a_7\}, \quad j_5 \rightarrow \{a_4, a_5\}, \quad j_6 \rightarrow \{a_2, a_5, a_7\}, \\ j_7 \rightarrow \{a_3, a_6\}$$

可以注意到，所有 Conjunction 中最大的 size 为 2，可以将倒排索引分成 3 部分，每部分中所有的 Conjunction 其 size 都一样，按照这样的准则，最终形成的 Conjunction 倒排索引应为下面的形式：

$$\begin{aligned} \text{size}=0: & (\text{geo}, \text{北京}) \rightarrow \{(j_6, / \epsilon)\}, \quad (\text{geo}, \text{广东}) \rightarrow \{(j_6, / \epsilon)\}, \quad Z \rightarrow \{(j_6, \epsilon)\} \\ \text{size}=1: & (\text{age}, 3) \rightarrow \{(j_5, \epsilon)\}, \quad (\text{age}, 4) \rightarrow \{(j_5, \epsilon)\} \\ \text{size}=2: & (\text{age}, 3) \rightarrow \{(j_1, \epsilon), (j_2, \epsilon), (j_3, \epsilon)\}, \quad (\text{geo}, \text{北京}) \rightarrow \{(j_1, \epsilon)\}, \\ & (\text{gender}, \text{女}) \rightarrow \{(j_2, \epsilon), (j_7, \epsilon)\}, \quad (\text{gender}, \text{男}) \rightarrow \{(j_3, \epsilon), (j_4, \epsilon)\}, \\ & (\text{geo}, \text{广东}) \rightarrow \{(j_3, / \epsilon), (j_4, \epsilon), (j_7, \epsilon)\} \end{aligned}$$

其中 size 为 0 的部分包含哪些所有只有“/ ϵ ”操作符的 Conjunction。为了保证给定一个 Assignment，size 为 0 的 Conjunction 至少出现在一个倒排表中，算法引入 Z 为一个特殊的 Term，并且将所有 size 为零的 Conjunction 都放在其倒排表中，并赋以一个“ ϵ ”操作符。

在第 10 章的标准倒排索引类基础上加以改进，将 DNF 索引类的代码列在下面，方便大家参考。在这段代码中，IndexDNF 对应上面提到的 DNF 的倒排索引，而 IndexConj 对应于 Conjunction 的一组倒排索引，其中每一个倒排索引中所有的 Conjunction 都具有相同的 size。

```

1 // IndexConj内部的一组倒排索引的数据结构
2 typedef Map<int, Map<pair<int, int>, vector<pair<Conjunction, bool>>>> ConjInner;
3
4 class IndexConj {
5 public:
6     ConjInner index;
7     vector<pair<Conjunction, bool>> zeroConjList;
8
9     void add(Conjunction & conj) {
10         // 含有 "<" 的Assignment数目
11         int K = getSize(conj);
12         if (K == 0) zeroConjList.push_back(make_pair(conj, true));
13         for (int i = 0; i != conj.size(); ++ i) {
14             // 建立Conjunction size 为K的倒排索引
15             index[K][make_pair(conj[i].attribute, conj[i].value)].push_back
16                 (make_pair(conj, conj[i].belong));
17         }
18     }
19
20     // 给定多个Assignment的交,返回符合条件的Conjunction集合
21     void retrieve(vector<Assignment>& assigns, set<Conjunction>& conjs) {
22         ConjInner::iterator it = index.begin();
23         for (; it != index.end(); ++ it) {
24             vector<vector<pair<Conjunction, bool>>> lists;
25             vector<int> positions, lists_size;
26
27             // 根据Assignment的条件数目对查询剪枝
28             int K = it->first;
29             if (K > assigns.size()) break;
30
31             // 初始化匹配该assigns的倒排链表lists, 各列表游标positions, 各列表长度
32             lists_size
33             initPostingLists(lists, positions, lists_size, assigns, it->second);
34
35             // K=0时和K=1时的处理逻辑是一致的
36             if (K == 0)
37                 {lists.push_back(zeroConjList); positions.push_back(0); K = 1;}
38
39             // lists的size太小, 以至于没有Conjunction能满足条件
40             if (lists.size() < K)
41                 continue;
42
43             while (positions[K - 1] < lists_size[K - 1]) {
44                 // 按照首个conjID的升序对lists进行排序, g的Conjunction在前
45                 SortByCurrentEntries(lists, positions, lists_size);
46                 if ((*lists)[positions[0]].first == (*lists)[positions[K
47                     - 1]].first) {
48                     // 跳过包含g操作符的Conjunction
49                     if ((*lists)[positions[0]].second == false) {
50                         for(int L = K; L < assigns.size(); L++) {
51                             if (positions[L] != positions[0]) break;
52                             (*lists)[L].skipto(positions[0] + 1);
53                         }
54                     }
55                     else {
56                         // 找到满足条件的Conjunction并跳过它
57                         conjs.insert((*lists)[positions[K - 1]].first);
58
59                         for (int i = 0; i < K; i++)
60                             (*lists)[i].skipto(positions[K - 1] + 1);
61                     }
62                 }
63                 else { // 跳过前K-1个posting list
64                     for (int i = 0; i < K; i++)
65                         (*lists)[i].skipto(positions[K - 1]);
66                 }
67             }
68         }
69     };
70
71     class IndexDNF : public InvIndex<Conjunction> {
72     public:
73         IndexConj conjIndex ;
74
75         void add(vector<Conjunction> & conjs) {
76             Map<Conjunction, list<int>>::iterator it;
77             for (int i = 0; i < conjs.size(); i++) {
78                 it = this->find(conjs[i]);
79                 // 对新加入的Conjunction建立二级索引
80                 if (it == this->end()) {
81                     conjIndex.add(conjs[i]);
82                 }
83             }
84             // 调用父类的add方法
85             InvIndex<Conjunction>::add(conjunctions);
86         }
87
88         // 查询DNF表达式, 返回对应的广告ID
89         void retrieve(const vector<vector<Assignment>>& query, set<int>& dnfIDs) {
90             set<Conjunction> conj_set;
91             set<Conjunction>::iterator it;
92             // 对每个Assignment的交, 返回符合条件的Conjunction集合
93             for (int i = 0; i < query.size(); i++)

```

```
92     conjIndex.retrieve(query[i], conj_set);
93     // 求Conjunction对应的广告ID的并集
94     for(it=conj_set.begin();it!=conj_set.end();it++)
95         InvIndex<Conjunction>::retrieve(*it, dnfIDs);
96     }
97 }
```


13.4.2 相关性检索

竞价广告与搜索的检索问题还有一点不同，有时，竞价广告系统需要处理很多个标签组成的查询。让我们考虑上下文定向的情形：当通过网页内容的关键词来匹配广告候选时，往往需要用十多个甚至几十个关键词去查询广告，再进行 eCPM 排序。在这一情形下，如果仍然采用一般搜索引擎对查询的处理办法，则会陷入两难的境地。如果假设各个关键词之间是“与”的关系，基本上不可能得到任何匹配的结果；如果假设各个关键词之间是“或”的关系，那么在检索阶段就会返回大量相关性很差的候选，给后续排序的效率带来很大的挑战。

同样地，当用户的兴趣标签较丰富时，也存在类似的挑战。简单地比较一下搜索与搜索重定向广告就可以理解为什么展示广告的查询信号会丰富很多：在搜索中，仅仅需要根据用户当前输入的关键词进行检索；而在搜索重定向广告中，虽然用的也是搜索信号，但是需要将用户一段时间内的搜索关键词全部考虑，显然这样的查询要长了很多。在此也可以看出，搜索广告完全可以采用一般的检索技术，但是展示广告需要有新的方案。

考察上面问题产生的原因会发现，在长查询的检索情形下，我们实际上希望的是查询与广告候选间的相似程度尽可能高，但任何一个关键词是否出现在文档中其实都不关键。这样以查询和文档间的相似程度为目标的检索问题称为相关性检索。

解决相关性检索的基本思路是在检索阶段就引入某种评价函数，并以此函数的评价结果决定返回哪些候选。评价函数的设计有两个要求：一是合理性，即与最终排序时使用的评价函数近似；二是高效性，即需要在检索阶段实现快速评价算法，否则就与在排序阶段对每个候选分别计算没有差别了。研究表明，当选用线性评价函数（变量为各标签或关键词）且各权重为正时，是可以构造出这样的快速检索算法的。假设线性评价函数的形式如下式所示：

$$\text{score}(a, c) = \sum_{t \in F(a) \cap F(c)} \alpha_t v_t(a) \quad (13.5)$$

其中 $F(a)$ 和 $F(c)$ 分别表示广告文档 a 和上下文特征 c 上不为零的特征集合，比如查询中的关键词，而 $v_t(a)$ 表示 t 这一特征在 a 广告上的贡献值。常用的 VSM 模型不符合这一要求，但是如果不考虑余弦距离中的归一化分母，可以用这一线性函数在检索阶段做近似的预评估。这种情况下， α_t 即为关键词 t 在上下文中的 TF-IDF，而 $v_t(a)$ 即为 t 在某广告 a 中的 TF-IDF。虽然 α_t 在不同的查询中取值不同，但在同一次查询中是一组常数。

将线性函数评价过程加速的关键在于使用两个上界：一是某个关键词 t 在所有文档上贡献值的上界，记为 u_t ；二是某个文档中所有关键词的上界的和，这实际上是该文档对当前查询评价函数的上界，记为 U_a 。巧妙地利用这两个上界可以在检索过程中排除掉大量不

可能胜出的候选，从而达到快速评价的目的。这一方法即为 Andrei Broder 等人提出的 WAND (Weak AND) 算法^[15]，也是上下文定向广告和内容推荐产品中非常实用的快速检索算法，我们以此算法为例，介绍一下相关性检索的算法过程。

WAND 的检索过程如图 13-4 所示，图中每个关键词 (Term) 带有一条倒排链，链表中的每一项是包含此关键词的文档 ID，用阴影表示。WAND 算法用到一个小顶的排序堆结构：该堆维护着到目前为止的 top-K 结果，当新的候选产生时，如果堆尚未装满或相关度大于堆顶文档的相关度，则采用堆排序的方法将其插入堆，否则就可以直接抛弃此候选。检索过程迭代地执行下面两个步骤。

(1) 将各关键词对应的倒排链按照其最小的文档 ID 升序排列。

(2) 按前面的升序依次访问各关键词 t ，并累加其对应的 u_t 至 U ，直至 U 大于堆顶。设此时到达第 $n-1$ 个关键词 (图 13-4 中 $n=3$)，如果此时第 0 个关键词倒排链和第 $n-1$ 个关键词倒排链的最小文档 ID 一致，则计算该文档准确的相关性，如果仍然大于堆顶，则将该文档推入堆；如果最小文档 ID 不一致，说明该候选无胜出的可能，于是在前 n 个关键词倒排链中挑选一个，将链表头跳到第 $n-1$ 个关键词倒排链的最小文档 ID，然后流程跳转至第 1 步。




图 13-4 WAND 相关性检索过程示意

读者可以自行验证，WAND 算法的执行过程能够利用两个上界在检索过程中快速地排除大部分候选。此算法执行过程的伪代码如下。

```

1 class WANDIndex : public InvIndex<string> {
2     public:
3         vector<list<int> > posting;
4         Map<string, double> term_ub;
5         vector<string> terms;

```

```

6 int doc_num = 0;
7
8 void add(vector<string> & doc) {
9     // 构造传统倒排
10    InvIndex<string>::add(doc);
11    doc_num ++;
12    for (int t = 0; t < doc.size(); t ++){
13        // 更新  $u_t \geq \alpha_t \max(w(t, d1), w(t, d2), \dots)$ 
14        update_term_ub(term_ub, doc[t]);
15    }
16
17 void retrieve(vector<string> & query, set<int> & docIDs) {
18     terms = query;
19     int curDoc = 0;
20     double minScore = 0;    // 初始化剪枝阈值  $\theta$ 
21     MinHeap<pair<double, int> > heap;    // 维护相关性得分最高的top-K doc
22
23     // 初始化posting列表, 每个元素指向对应Term的倒排链的第一篇doc
24     Map<TKey, list<int> >::iterator it;
25     for (int t = 0; t < terms.size(); t ++){
26         it = this -> find(terms[t]);
27         // skipto(id):跳跃倒排链至第一个使得docID >= id的元素
28         posting[t] = it->second->skipto(0);
29     }
30
31     while(curDoc < doc_num) {
32         bool flag = do_next(curDoc, minScore);
33         if (flag == false) break;
34         //  $\text{score}(\text{doc}, \text{query}) = \sum_{t \in q \cap d} \alpha_t w(t, d)$ 
35         score = full_evaluate(curDoc, query);
36         // 如果score>topn堆中最小值则将doc入堆
37         heap.insert(make_pair(score, curDoc));
38         // 更新堆阈值
39         minScore = heap.topScore();
40     }
41
42     // 将top-K doc填充到结果集合中
43     docIDs.insert(heap);
44 }
45
46 private:
47 bool do_next(int & curDoc, float minScore) {
48     int numTerm = terms.size();
49
50     // 按照首个docID的升序对terms进行排序
51     for (int t1 = 0; t1 < numTerm - 1; t1 ++){
52         for (int t2 = t1 + 1; t2 < numTerm; t2 ++){
53             if (posting[t1] > posting[t2]) {
54                 SWAP(terms[t1], terms[t2]);
55                 SWAP(posting[t1], posting[t2]);
56             }
57         }
58     }
59     // 找到使得累计的UB大于阈值的Pivot term
60     float accUB = 0.0f;
61     int pivot = 0;
62     for (pivot = 0; pivot < numTerm; pivot ++){
63         accUB += term_ub[terms[pivot]];
64         if (accUB > minScore) break;
65     }
66
67     // 已经没有可以胜出的候选
68     if ((accUB < minScore) || (posting[pivot] == end()))
69         return false;
70
71     // 候选doc已被考虑过, 滑动倒排链寻找候选doc
72     if (pivot <= curDoc) {
73         // 选一个[0..pivot]间的term
74         int pos = pickTerm(terms, pivot);
75         posting[pos] = (*this)[terms[pos]].skipto(curDoc + 1);
76     }
77     else {
78         // 找到候选doc, 向后滑动倒排链跳过它
79         if (posting[0] -> second == posting[pivot] -> second) {
80             curDoc = pivot;
81             while((pivot+1<doc_num)&&(posting[pivot]==posting[curDoc]))
82                 pivot ++;
83             for (int i = 0; i <= pivot; i ++){
84                 (*this)[terms[i]].skipTo(curDoc + 1);
85             }
86             return true;
87         }
88         else {
89             // pivot没有胜出, 滑动倒排链寻找候选doc
90             int pos = pickTerm(terms, pivot);
91             posting[pos] = (*this)[terms[pos]].skipto(pivot);
92         }
93     }
94 }
95 }
96 }
97 }

```

这里讨论的相关性检索技术仅仅考虑了相关性评价函数为线性的情况。虽然这一条件严格限制了评价函数的适用范围，然而，如果考虑到广告的排序模型经常采用广义线性模型的建模方法的话，线性评价函数的适用范围就会大大扩展。我们采用后面提到的基于广义线性模型的 CTR 预测模型也可以套用此框架。

13.5 点击率预测

广告点击率预测的目的是广告排序，但不能套用搜索里的排序问题：点击率预测不能像搜索那样只要求结果排序的正确性，因为点击率需要乘以点击单价才得到最后的排序。另外，在 DSP 中，需要尽可能准确地预测 eCPM 用于出价。因此，作为各种广告系统中通用的一项技术，点击率预测更适合被建模成回归问题而不是排序问题。

关于点击率预测的方法，很自然的可以想到基于统计的估计：

$$p = \sum_{i=1}^N h_i / N \quad (13.6)$$

其中 h_i 是表示第 i 次展示被点击的次数，一般情形下为 0 或者 1。但是，如果某种 (u, c) 组合的情形下，广告 a 没有被展示过或点击量很稀疏，就无法通过历史数据来统计点击率了。容易想到的解决方案是将要展示的广告 a 和一个展示过的广告 a^0 类似，则可以预估 a 的点击率与 a^0 接近。如果将 (a, u, c) 投影到特征空间比较，则演化为即将介绍的点击率模型。

13.5.1 点击率预测模型

我们把点击事件 h 看成一个二元取值的随机变量，那么其取值为真 ($h=1$) 的概率就是点击率。因此，点击事件的分布可以写成以点击率 μ 为参数的二项分布 (binomial distribution)：

$$p(h) = \mu^h (1 - \mu)^{1-h} \quad (13.7)$$

而点击率预测模型的作用是在 (a, u, c) 组合与点击的概率 μ 之间建立函数关系，这可以表示成对 $\mu(a, u, c) = p(h=1|a, u, c)$ 的概率建模问题，可以很自然地想到的基础模型是逻辑回归 (Logistic Regression, LR)：

$$p(h|a, u, c) = \sigma((2h - 1)\mathbf{w}^\top \mathbf{x}(a, u, c)) = \left\{ 1 + e^{-(2h-1)\mathbf{w}^\top \mathbf{x}(a, u, c)} \right\}^{-1} \quad (13.8)$$

其中 $\mathbf{x}$ 表示 $(\mathbf{a}, \mathbf{u}, \mathbf{c})$ 组合上的特征矢量，即前面介绍过的受众定向的输出及其派生的其他特征； $\mathbf{w}$ 为各特征的加权系数，也就是此模型需要优化的参数； $(2h-1) \mathbf{w}^\top \mathbf{x}$ 这一线性函数的输出经过逻辑 S 型 Sigmoid 函数 $\sigma(z) = \{1 + e^{-z}\}^{-1}$ 映射到 $(0, 1)$ 区间内，其中 $(2h-1)$ 是为了将 $\{0, 1\}$ 的点击变量变换到集合 $\{-1, 1\}$ 上。从方法上看，LR 是利用线性函数来解决非线性目标，也属于广义线性模型^[36]。可以推导得到，逻辑回归正是当目

标值的分布服从伯努利分布时广义线性模型的一个特例，映射函数为 $\text{logit}(p) = \log\left(\frac{p}{1-p}\right)$ 。因此，有关广义线性模型的性质和结论也适用于 LR 模型。

实践中，由于 LR 模型使用的特征较多，并且有相当多的特征在训练集中出现的次数并不多，为了避免过拟合，还需要在最大似然估计时加入正则化项。如果采用 L_2 -norm^[52]，则此优化问题可以表达成：

$$\min \left\{ C \sum_{i=1}^T \ln(1 + e^{-(2h_i-1)\mathbf{w}^\top \mathbf{x}(a_i, u_i, c_i)}) + \frac{1}{2} \mathbf{w}^\top \mathbf{w} \right\} \quad (13.9)$$

13.5.2 优化算法

对于 LR 模型，我们通常采用最大似然估计来求解加权系数 $\mathbf{w}$ 。LR 模型的最大似然解有很多计算方法，而我们在实践中重点关注其收敛速度以及在面对海量数据时分布式计算的便捷性。比如，如将其视为最大熵模型的特例，那么最大熵模型的典型优化方法——改进的迭代缩放（Improved Iterative Scaling, IIS）算法^[7]也可以用于 LR 的更新。这种方法虽然物理意义明确、计算简单，却有着收敛速度慢的致命弱点，因此并不适用。

由于 LR 模型不存在闭式解，其优化方法必然需要迭代进行。典型的 MapReduce 分布式计算框架下，由于磁盘被用作迭代之间的数据交换手段，迭代的次数直接决定着训练算法的效率。因此，在每个迭代中尽可能完成更复杂深入的运算、减少迭代次数是此处的关键。这样的思路适用于 LR 模型训练，也适用于许多 MapReduce 下的需要迭代求解的机器学习算法。

1.L-BFGS

在目标函数可导的一般优化问题中，拟牛顿法是一族最常用的方法，因此也可以直接应用于 LR 问题的求解。不过，从 10.2.4 节中的 BFGS 的代码可以看出，它需要存储赫斯矩阵的逆矩阵的近似 $\mathbf{B}_k$ ，因此空间复杂度为 $O(D^2)$ 。在点击率预测这样的变量维数很高的优化问题中，赫斯矩阵的尺寸过大，根本无法在内存中存放。

解决这一问题的思路是仅仅保留最近几次更新的一些状态矢量，然后利用这些状态矢量和当前的梯度，直接计算出更新方向，这种方法称为有限内存 BFGS（Limited-memory BFGS, L-BFGS）。L-BFGS 的核心思想是根据前几次的函数值变化和梯度变化近似地拟合

赫斯矩阵的逆。先来回顾一下，在 BFGS 的迭代过程中，赫斯矩阵逆的更新公式可以表示为：

$$\mathbf{B}_{k+1} = \left(\mathbf{I} - \frac{\mathbf{s}_k \mathbf{y}_k^\top}{\mathbf{y}_k^\top \mathbf{s}_k} \right) \mathbf{B}_k \left(\mathbf{I} - \frac{\mathbf{y}_k \mathbf{s}_k^\top}{\mathbf{y}_k^\top \mathbf{s}_k} \right) + \frac{\mathbf{s}_k \mathbf{s}_k^\top}{\mathbf{y}_k^\top \mathbf{s}_k} = \mathbf{V}_k^\top \mathbf{B}_k \mathbf{V}_k + \rho_k \mathbf{s}_k \mathbf{s}_k^\top \quad (13.10)$$

其中 $\rho_k = 1/\mathbf{y}_k^\top \mathbf{s}_k$ ， $\mathbf{V}_k = (\mathbf{I} - \rho_k \mathbf{s}_k \mathbf{y}_k^\top)$ ， $\mathbf{y}_k$ 和 $\mathbf{s}_k$ 的定义请参见 10.2.4 节。如果对此迭代公式展开并做截断，只保留前 m 次的状态量，则 $\mathbf{B}_{k+1}$ 可近似地表示为：

$$\begin{aligned} \mathbf{B}_{k+1} = & (\mathbf{V}_k^\top \cdots \mathbf{V}_{k-m+1}^\top) \mathbf{B}_k^0 (\mathbf{V}_{k-m+1} \cdots \mathbf{V}_k) \\ & + \rho_{k-m+1} (\mathbf{V}_k^\top \cdots \mathbf{V}_{k-m+2}^\top) \mathbf{s}_{k-m+1} \mathbf{s}_{k-m+1}^\top (\mathbf{V}_{k-m+2} \cdots \mathbf{V}_k) \\ & + \rho_{k-m+2} (\mathbf{V}_k^\top \cdots \mathbf{V}_{k-m+3}^\top) \mathbf{s}_{k-m+1} \mathbf{s}_{k-m+1}^\top (\mathbf{V}_{k-m+3} \cdots \mathbf{V}_{k-1}) + \cdots + \rho_k \mathbf{s}_k \mathbf{s}_k^\top \end{aligned} \quad (13.11)$$

其中 $\mathbf{V}_k = \mathbf{I} - \rho_k \mathbf{y}_k \mathbf{s}_k^\top$ ，而 $\mathbf{B}_k^0$ 是设定的赫斯逆的初值。为降低计算复杂度，实际中比较有效

的选择是令 $\mathbf{B}_k^0$ 为一个对角阵： $\mathbf{B}_k^0 = \gamma_k \mathbf{I} = (\mathbf{s}_{k-1}^\top \mathbf{y}_{k-1} / \|\mathbf{y}_{k-1}\|^2) \mathbf{I}$ 。在这样的表示下， $\mathbf{B}_k$ 可以在每次迭代中高效地计算出来的。参考文献[54]中进行的实验研究表明，这类有限内存的二阶方法是可行而且有效的。下面附上 L-BFGS 迭代求解的代码片段。

```

1 // In:
2 //   q      : 当前梯度
3 //   s      : 最近M轮迭代的前后自变量差
4 //   y      : 最近M轮迭代的前后梯度差
5 //   rho    : ρ, 最近M轮迭代的1/y⊤s

```

```

6 // Return : 本次迭代的线搜索方向
7 Vec LBFGSStep(Vec & q, list<Vec> & s, list<Vec> & y, list<double> & rho){
8     if(s.empty()) return q;
9
10    list<Vec>::reverse_iterator iter1 = s.rbegin();
11    list<Vec>::reverse_iterator iter2 = y.rbegin();
12    list<double>::reverse_iterator iter3 = rho.rbegin();
13    list<Vec>::iterator it1 = s.begin();
14    list<Vec>::iterator it2 = y.begin();
15    list<double>::iterator it3 = rho.begin();
16    list<double> alphas;
17
18    // 逆序遍历, 第一个循环
19    while(iter1 != s.rend()) {
20        //  $\alpha_i \leftarrow \rho_i s_i^T q$ 
21        double alpha = (*iter3) * dot(q, *iter1);
22        //  $q \leftarrow q - \alpha_i y_i$ 
23        plusAssign(q, -alpha, *iter2);
24        alphas.push_front(alpha);
25        iter1 ++; iter2 ++; iter3 ++;
26    }
27
28    //  $r \leftarrow B_k^0 q$ 
29    list<Vec>::reverse_iterator s_tail = s.rbegin();
30    list<Vec>::reverse_iterator y_tail = y.rbegin();
31    double gamma = dot(*s_tail, *y_tail) / dot(*y_tail, *y_tail);
32    Vec r = scale(q, gamma);
33
34    // 顺序遍历, 第二个循环
35    while (it1 != s.end()) {
36        //  $\beta \leftarrow \rho_i y_i^T r$ 
37        double beta = (*it3) * dot(r, *it2);
38        //  $r \leftarrow r + s_i(\alpha_i - \beta)$ 
39        plusAssign(r, alphas.front() - beta, *it1);
40        alphas.pop_front();
41        it1 ++; it2 ++; it3 ++;
42    }
43    return r;
44 }
45
46 // 用L-BFGS方法求目标函数f的局部极小值, 迭代初始点x0
47 double LBFGS(FP_EVAL f, Vec & x0) {
48     list<Vec> s, y;
49     list<double> rho;
50     double f_x0, f_xt;
51     Vec df_x0, df_xt, xt, q, d;
52     int iter = 0;
53     int M = 10;
54
55     f(x0, f_x0, df_x0);
56
57     while(iter < MAX_ITER_NUM && dot(df_x0, df_x0) > TOL) {
58         q = df_x0;
59         d = scale(LBFGSStep(df_x0, s, y, rho), -1.0); // L-BFGS计算搜索方向
60         WolfeSearch(f, x0, d, xt); // 线搜索
61         f(xt, f_xt, df_xt);
62
63         // 利用最近M轮的曲率信息校正Hessian矩阵
64         if (m >= M)
65             {s.pop_front(); y.pop_front(); rho.pop_front();}
66         m ++;
67         s.push_back(minus(xt, x0));
68         y.push_back(minus(df_xt, df_x0));
69         rho.push_back(1.0 / dot(*y.rbegin(), *s.rbegin()));
70
71         // 进入下一轮迭代
72         x0 = xt; df_x0 = df_xt; f_x0 = f_xt;
73
74         iter ++;
75     }
76     return f_x0;
77 }

```


容易验证，上面每一步迭代的空间和时间复杂度都降到了 $m \times D$ ，如果选择一个较小的 m ，就可以认为其复杂度接近线性，这在大多数较高维度特征空间上建模的应用中就可以达到实用水平了。注意，在迭代的前 $m-1$ 步，L-BFGS 和 BFGS 是没有区别的。

2.Trust-Region 法

除了 L-BFGS，Trust-Region 法也被证明对求解 LR 问题很有效，而且往往可以更快地收敛^[52]。不过，在点击率预测的问题中，同样因为模型的维数可能很高，直接用公式 10.14 来解 Trust-Region 的子问题仍然是不现实的。

对于这样高维的问题，可以采用共轭梯度法（conjugate gradient method）^[62]来求解 Trust-Region 的子问题。当目标函数为二次正定函数 $f(\mathbf{x}) + \nabla f(\mathbf{x})^\top \mathbf{s} + \frac{1}{2} \mathbf{s}^\top \mathbf{H} \mathbf{s}$ 时，共轭梯度法可以在 n （特征维数）次迭代后达到收敛，避免了存储和计算赫斯矩阵。与无约束优化中的共轭梯度法略有不同的是，这里需要满足 $\|\mathbf{s}\| \leq \delta_k$ 的约束条件，考虑到子算法中位移量是递增的^[52]，当发现某次的位移跳出置信球之外时，将其沿着原来的搜索方向退回到置信球边界即可。

具体来说，在共轭梯度法的每次迭代中的，主要的操作是 $\mathbf{H}$ 矩阵与向量 $\mathbf{s}$ 的乘积，由于 $\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_N)$ 是稀疏的，不需要直接求赫斯矩阵也可以得到该乘积，对于公式 13.9 的目标函数，计算公式如下：

$$\mathbf{H} \cdot \mathbf{s} = (\mathbf{I} + \mathbf{C}\mathbf{X}^\top \mathbf{D}\mathbf{X})\mathbf{s} = \mathbf{s} + \mathbf{C}\mathbf{X}^\top (\mathbf{D}(\mathbf{X}\mathbf{s})) \quad (13.12)$$

其中 $\mathbf{D} = \text{diag}\{\mathbf{D}_i\}$ ， $\mathbf{D}_i = \sigma((2h_i - 1) \mathbf{w}^\top \mathbf{x}_i) \{1 - \sigma((2h_i - 1) \mathbf{w}^\top \mathbf{x}_i)\}$ 。

采用上述的共轭梯度法求解 Trust-Region 子问题的代码片段如下。

```

1 // In:
2 //   delta : 当前迭代置信域半径 $\delta_k > 0$ 
3 //   g      : 当前的导数
4 // Out:
5 //   s      : 求得的位移矢量, 初始位移 $s_k = 0$ ,
6 //   r      : 共轭梯度法的中间变量, 外迭代中会引用其计算模型函数的下降量
7 void tr_cg(double delta, const Vec & g, Vec & s, Vec & r) {
8     Vec d, Hd;
9     double r2, rnew2;
10
11     //  $r = -\nabla f(x)$ 
12     r = scale(g, -1.0);
13     r2 = dot(r, r);
14
15     // 初始化搜索方向
16     d = r;
17
18     while (true) {
19         // 当 $\|r^i\| < \varepsilon \|\nabla f(x)\|$  时, 跳出内层迭代
20         if (dot(r, r)) <= 0.1 * dot(g, g))
21             break;
22
23         // 位移 $s_{i+1} = s_i + \alpha_i d_i$  步长 $\alpha_i = \|r_i\|^2 / d_i^\top \nabla^2 f(x) d_i$ 
24         Hd = HvProduct(d); // 计算赫斯向量的乘积
25         double alpha = r2 / dot(d, Hd);
26         plusAssign(s, alpha, d);
27
28         // 如果cg到达置信域外, 重新计算步长使得 $\|s + \alpha d_i\|^2 = \delta_k$ 跳出内层迭代
29         if (dot(s, s) > dot(delta, delta))
30             {reCalS(alpha, d, s, r); break;}
31
32         //  $r_{i+1} = r_i - \alpha_i \nabla^2 f(x) d_i$ 
33         alpha = -alpha;
34         plusAssign(r, alpha, Hd);
35         rnew2 = dot(r, r);
36
37         // 更新下轮迭代方向 $d_{i+1} = r_{i+1} + \beta_i d_i$ ,  $d_{i+1}$ 和 $d_i$ 是共轭方向
38         double beta = rnew2 / r2; //  $\beta_i = \|r_{i+1}\|^2 / \|r_i\|^2$ 
39         scale(d, beta);
40         plusAssign(d, 1, r);
41         r2 = rnew2;
42     }
43 }

```

3.ADMM 计算框架

从上节中 Trust-Region 法与 L-BFGS 法的比较中可以看到，随着每轮迭代的代价增加，迭代次数也随之降低了，因此有可能会带来收敛速度的提升。是否存在一种普适性的思路，使得我们可以对一般的迭代求解问题减少其迭代次数呢？学术界对这个问题也进行了深入的研究，产生了一些颇具启发意义的方法。这里我们介绍一种称为交替方向乘子法（Alternative Directional Method of Multipliers, ADMM）^[14]的计算框架。

从方法论上说，要降低迭代数目，必然要求在一个迭代内完成更复杂的计算。要了解 ADMM，需要先介绍一下扩展拉格朗日方法。10.2.1 节介绍了带约束优化的拉格朗日法，如果只考虑等式约束为一个线形约束（ $Ax=b$ ）的形式，可以构造如下的扩展拉格朗日：

$$L_\rho(x, y) = f(x) + y^\top (Ax - b) + \frac{\rho}{2} \|Ax - b\|_2^2 \quad (13.13)$$

容易验证，这一形式可以得到与标准拉格朗日一样的解。引入一个二阶惩罚项，往往会使得问题求解的过程更好地收敛。根据参考文献[14]中的介绍，这一问题可以用 Dual Ascent 方法求解。而问题得以分布式求解的关键是当目标函数可以分解成下面的形式时，就可以发现存在有效的分解迭代求解方案：

$$\min f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c \quad (13.14)$$

对应的迭代求解方案是一个 x, z, y 依次迭代更新的过程：

$$\begin{aligned} x_{k+1} &\leftarrow \arg \min_x (f(x) + (\rho/2) \|Ax + Bz_k - c + s_k\|_2^2) \\ z_{k+1} &\leftarrow \arg \min_z (g(z) + (\rho/2) \|Ax_{k+1} + Bz - c + s_k\|_2^2) \\ s_{k+1} &\leftarrow s_k + Ax_{k+1} + Bz_{k+1} - c \end{aligned} \quad (13.15)$$

为了表达上的整洁，我们将 y 换成了归一化的形式 $s = (1/\rho) y$ 。在典型的利用 ADMM 分布式求解的问题中，上面的第一个公式用于各部分数据的局部参数更新，第二个公式用于将各部分得到的局部优化参数综合成全局的参数；而第三个公式中对偶变量的更新则是使得整个过程稳定和高效的关键。

按照公式 13.14 的结构，可以将 LR 的优化问题 13.8 改写成下式：

$$\begin{aligned} \min \quad & \sum_{l=1}^L \sigma(D^{(l)} w^{(l)}) + r(v) \\ \text{s.t.} \quad & w^{(l)} - v = 0, \quad l = 1, \dots, L \end{aligned} \quad (13.16)$$

这里的 $l=\{1, \dots, L\}$ 表示数据集分裂后的各个部分， $w^{(l)}$ 对应于某一部分数据上得到的 LR 参数（对应于公式 13.16 中的 x ），而 v 为整体决策后的参数（对应于公式 13.16 中的 z ）。 $D^{(l)}$ 表示由第 l 块数据样本的特征拼成的矩阵。问题的约束条件是表明求解收敛

时各部分的参数应该等于整体参数，这是非常自然需要满足的。目标函数中的 $r(\mathbf{w})$ 代表的是求解过程的对参数的某种正则化项，比如公式 13.9 中的 L_2 -norm 项。于是，可以得到用 ADMM 方法迭代求解此问题的方法：

$$\begin{aligned} \mathbf{w}_{k+1}^{(l)} &\leftarrow \arg \min_{\mathbf{w}} \left(\sigma(\mathbf{D}^{(l)} \mathbf{w}) + (\rho/2) \|\mathbf{w} - \mathbf{v}_k + \mathbf{s}_k^{(l)}\|_2^2 \right) \\ \mathbf{v}_{k+1} &\leftarrow \arg \min_{\mathbf{v}} \left(r(\mathbf{v}) + (L\rho/2) \|\mathbf{v} - \overline{\mathbf{w}}_{k+1} - \overline{\mathbf{s}}_k\|_2^2 \right) \\ \mathbf{s}_{k+1}^{(l)} &\leftarrow \mathbf{s}_k^{(l)} + \mathbf{w}_{k+1}^{(l)} - \mathbf{v}_{k+1} \end{aligned} \quad (13.17)$$

我们来分析一下这一更新过程。

(1) 首先，在每个数据分块上，分别执行第一个公式中的对应更新，得到该数据分块上更新后的参数，这一步是可以分布式进行的，而且各个数据块之间不需要通信。

(2) 然后，根据各部分更新得到的参数，执行第二个公式得到综合以后的整体参数 $\mathbf{v}$ 。

(3) 根据第三个公式更新对偶变量 $\mathbf{s}$ ，并将更新后的 $\mathbf{v}$ 和 $\mathbf{s}$ 分发至各个数据块的处理单元。

这一过程可以非常自然地用 MapReduce 方式来实现，其中步骤 1 对应着各个 Mapper，而步骤 2 和步骤 3 对应着一个唯一的 Reducer。

我们可以将此过程与 L-BFGS 的迭代的更新过程比较一下：在 L-BFGS 当中，每个 Mapper，即分布式部分计算过程非常简单，只需要在每个样本上对参数求导数，再将导数累加即可；而在 ADMM 方法中，Mapper 计算的过程变得复杂了很多，由简单的导数计算变成了一个 LR 的求解问题，也就是说 Mapper 的计算本身就需要迭代才可以完成。但正由于在每个 Mapper 中作了更多的计算工作，使得整体求解过程的收敛更快。同时需要注意的是，实际上在每个 Mapper 中复杂的更新过程并不会带来计算代价的显著增加，这是由于每个 Mapper 所需要处理的数据量有限，因此可以放在内存中，于是在分布式计算中最主要的开销即 I/O 开销并没有增加。可以认为 ADMM 的方法是用对局部内存的更多访问换得了全局 MapReduce 过程的迭代次数减少，从而提高了效率。该方法的具体 MapReduce 编码实现并不困难，读者可以自行实现。

虽然是以 LR 模型为例来介绍 ADMM 方法的应用，实际上这种方法可以应用于许多常见的机器学习模型，而且大都在 MapReduce 的计算框架下可以达到减少总迭代次数，从而提高效率的目的。

4. Spark 上的模型优化

大多数机器学习问题往往需要进行迭代求解，而 Hadoop 上 MapReduce 的编程范式约束了每次迭代需要由一个 MapReduce 的 Hadoop Job 来完成。如图 10-3 所示，Map 读入训练数据和模型，并在分块数据集上计算统计量；Reduce 聚合统计量并更新模型。由于 Map 将训练数据从磁盘读入时产生大量 I/O，所以在 Hadoop 平台上进行一次迭代的代价

非常昂贵。单轮迭代时间无法优化，想降低模型训练的时间只能减少模型训练的迭代数，这就产生了以上所说的工业界常用的模型训练思路。

- (1) 降低模型训练次数，通过特征侧的方法来捕捉信号的快速变化。
- (2) 增量求解，降低模型收敛所需的迭代轮数。
- (3) 精心设计最优化算法如 **ADMM**^[14]，降低模型收敛所需的迭代轮数等。

如果能降低每轮迭代的开销，模型训练的总时间也能得到大幅的优化，于是便出现了 **Spark** 这样的平台。**Spark** 是将数据集缓存在分布式内存中的计算平台，如果数据集的规模能够控制在内存中，那么即使仍然采用 **MapReduce** 范式求解，由于每轮迭代不需要通过磁盘 I/O 读取数据，从而大幅降低了单轮迭代时间。应该说，**Spark** 的出现使得像点击率预测这种迭代求解的模型有了更好的计算平台，也逐渐在这些中等数据规模的应用上有替代 **MapReduce** 的趋势。

Spark 最方便的编程语言是 **Scala**，下面给出 LR 模型训练在 **Spark** 平台下的参考 **Scala** 代码。

```
1 import breeze.linalg.{Norm => brzNorm}
2 import breeze.linalg.{DenseVector => BDV, SparseVector => BSV}
3 import breeze.optimize.{CachedDiffFunction, DiffFunction, LBFGS}
4 import org.apache.spark.storage.StorageLevel
5
6 // In:
7 // l2RegParam      : 惩罚项的参数
8 // memParam        : 内存配置
9 // maxNumIterations : 迭代次数
10 // tolerance       : 停止迭代阈值
11
12 // 定义一个用LBFGS求解LR优化问题的类
13 class LRWithLBFGS(val l2RegParam: Double,
14                  val memParam: Int,
15                  val maxNumIterations: Int,
16                  val tolerance: Double) extends Serializable {
17   // ...
18 }
```

```

18 // In:
19 // trainSet : 训练数据集
20 // initialWeights : 初始权重
21 // Out:
22 // 返回最优解
23 def train(trainSet: RDD[ClkImpInstance], initialWeights: BDV[Double]) = {
24 // 将训练数据缓存存在内存中
25 if (trainSet.getStorageLevel == StorageLevel.NONE) {
26 trainSet.cache
27 }
28 // 定义优化目标, 传入数据集
29 val costFun = new CostFun(trainSet, l2RegParam)
30 // 定义最优化方法, 采用lbfgs求解
31 val lbfgs = new LBFGS[BDV[Double]](maxNumIterations, memParam,
32 tolerance)
33 // CachedDiffFunction 是计算梯度的抽象接口, 迭代求解
34 val states = lbfgs.iterations(new CachedDiffFunction(costFun,
35 initialWeights)
36 var state = states.next()
37 while (states.hasNext) {
38 state = states.next()
39 }
40 // 返回最优解
41 state.x
42 }
43 // 定义优化目标的类
44 // In:
45 // data : 数据集
46 // l2RegParam : 惩罚项的参数
47 private class CostFun(data: RDD[ClkImpInstance], l2RegParam: Double)
48 extends DiffFunction[BDV[Double]] with Serializable {
49 // 计算梯度和loss的函数
50 // In:
51 // labeledInstance : 单条训练样本
52 // weightsBC : 模型的权重向量, 广播变量
53 // Out:
54 // 返回单条样本的梯度和loss值, 类型为稀疏向量BSV[Double]和Double 类型
55 def calGradientLossInstance(labeledInstance: ClkImpInstance,
56 weightsBC: Broadcast[BDV[Double]]): (BSV[Double], Double) = {
57 // 计算prob, 并对可能溢出的情况进行了处理
58 def score2LossProb(score: Double) = {
59 if (score < -30) {
60 (-score, 0.0)
61 } else if (score > 30) {
62 (0.0, 1.0)
63 } else {
64 val tmp = 1 + math.exp(-score)
65 (math.log(tmp), 1.0 / tmp)
66 }
67 }
68 val weights = weightsBC.value
69 // 对相同特征的样本做了聚合, 获取该样本的点击和展示数
70 val (clicks, imps) = (labeledInstance.click, labeledInstance.
71 impression)
72 val nonclicks = imps - clicks
73 // 稀疏存储的样本特征
74 val x = labeledInstance.features
75 val score = x dot weights
76 var totalMult = 0.0
77 var totalLoss = 0.0
78 if (clicks > 0) {
79 val (loss, prob) = score2LossProb(score)
80 val mult = (prob - 1.0) * clicks
81 totalMult = mult
82 totalLoss = loss * clicks
83 }
84 if (nonclicks > 0) {
85 val (loss, prob) = score2LossProb(-1 * score)
86 val mult = (1.0 - prob) * nonclicks
87 totalMult += mult
88 totalLoss += loss * nonclicks
89 }
90 val gradient = x * totalMult
91 (gradient, totalLoss)
92 }
93 // 更新权重的接口
94 // In:
95 // z : 初始权重向量
96 // Out:
97 // 返回loss和更新后权重
98 override def calculate(x: BDV[Double]): (Double, BDV[Double]) = {
99 // 利用Spark的broadcast特性, 广播weight到每个节点, 以便权重更新计算
100 val wb = data.sparkContext.broadcast(x)
101 // Reduce聚合每条样本的梯度和loss
102 val kvs = data.flatMap(inst => {
103 val (grad, loss) = calGradientLossInstance(inst, wb)
104 grad.activeIterator.toSeq :+ (-1, loss)
105 }).ReduceByKeyLocally(_ + _)
106 val gradient = new Array[Double](x.length)
107 // L2-norm
108 for (index <- kvs.filterKeys(_ >= 0).keys) {
109 gradient(index) = kvs.getOrElse(index, 0.0) + l2RegParam *
110 x(index)
111 }
112 val norm = brzNorm(x, 2)
113 val loss = kvs(-1) + 0.5 * l2RegParam * norm * norm
114 (loss, new BDV(gradient))
115 }
116 }

```

5.基于 MPI 的模型优化

MPI (Message Passing Interface) 是基于消息传递函数库的标准规范, MPICH2 是 MPI 编程规范的常用实现, 允许各节点的进程之间在任何时刻互相通信^[79]。对分布式机器学习来说, MPI 平台的核心在于提供了 Allreduce/Broadcast 范式, Allreduce 范式可以实现大部分批处理迭代的机器学习算法, 同时避免了 MapReduce 编程范式下每次迭代之间磁盘读写数据的开销。在 MPI 编程方式下, 机器学习程序可以在每个节点的内存中保持模型, 每轮迭代中各个节点计算好需要的统计量后, 各个节点通过 Allreduce 通信得到全局统计量, 之后进行下一轮迭代, 迭代之间不需要资源的重新分配。

在 Spark 的最新版本中, Allreduce 的 Spark 实现 treeAggregate 已经在逐渐成熟。这里为了开拓思路, 以在 YARN 上实现了 Allreduce 范式并可容错的开源库 Rabbit 为例来介绍 MPI 程序的开发思路。事实上, YARN 的出现就是鼓励大家基于不同的算法抽象开发自己的计算框架。MapReduce、Storm 和 Spark 等计算框架均可运行在 YARN 之上。

尽管对于机器学习来说 Allreduce 范式是一个更好的选择, 但是 MPICH2 没有提供容错的功能, 一旦集群中一个节点宕机后, 整个程序必须从头开始计算。Rabbit 为了解决容错的问题, 只实现 MPI 的一个包含 Allreduce 的子集, 容错难度降低了很多。另外, 大多数公司数据存储都依赖于 Hadoop, 在 MPI 集群和 Hadoop 之间调度数据成了高效处理数据的障碍。而 Rabbit 兼容 YARN 平台, 可以直接读取 HDFS 上的数据, 解决了存储的问题。下面给出基于 Rabbit 的 LR 代码片段, 可以看到, 相对于 MapReduce 来说, 分布式的 MPI 代码可以很容易从单机代码上迁移。


```

1 void lr_eval(const Vec& x, double & f_x, Vec & df_x, ...)
2 {
3     // 伪代码处理数据
4     vector<Instance> dataset = get_dataset();
5     int instance_num = dataset.size();
6     double loss = 0.0;
7
8     for(Instance instance : dataset)
9     {
10         loss += calLoss(instance, x);
11         Vec df_x_instance = calGrad(instance, x);
12         plusAssign(df_x, 1, df_x_instance);
13     }
14     // 全局各个节点梯度求和，并通信返回给各个节点
15     rabit::AllReduce<rabit::op::Sum>(df_x, df_x.size());
16
17     // 增加正则项
18     if(rabit::GetRank == 0){
19         double regular = lambda * square(norm_2(x));
20         f_x = loss/m + regular ;
21     }else{
22         f_x = loss/m;
23     }
24     // 全局各个节点loss求和，并通信返回给各个节点
25     rabit::AllReduce<rabit::op::Sum>(&f_x, 1);
26 }

```

13.5.3 点击率模型的校正

点击率预测问题有一个数据上的挑战，就是正例和负例样本严重不均衡，特别是在展示广告点击率只有千分之几的情况下。在很多建模方法中，这样严重的不均衡会带来模型估计上的问题，我们仍然以 LR 模型为例，讨论一下模型存在偏差的原因以及相应的校正方法。

点击率模型可能存在偏差的原因如图 13-5 所示。假设分别用两个高斯分布来描述 $h=0$ 和 $h=1$ 情形下的特征分布。熟悉统计的读者都知道，高斯分布方差的最大似然估计是有偏的（为了得到方差的无偏估计，需要将样本数目减去 1 来计算方差），而这一偏差的方向是对方差有所低估，并且样本数目越少，低估越严重。由于 $h=1$ 时的数据量远远小于 $h=0$ 时的数据量，对前者的方差低估就会更严重，对应图 13-5 所示，前者的分布（右侧的高

斯分布) 会变得更窄一些。加入用这两个最大似然估计的高斯分布来决定 $h=0$ 和 $h=1$ 两个类的边界点, 就会出现比实际边界点向右偏移的情况。这也就意味着更多的样本被分到了 $h=0$ 这个类中, 或者说意味着点击率将会被系统性地低估一些。这里的解释虽然只是示意性的, 却与 LR 模型中点击率估计有偏的原因基本一致。




图 13-5 正负例样本不均衡时点击率模型存在偏差的原因示意

所幸消除这一点击率估计的偏差并不十分困难, 实际上对此偏差的系统性分析可以上升到广义线性模型的层次来研究。在 LR 模型情况下, 有关这一系统偏差的量化计算和校正方法可以参见参考文献[47]中的详细介绍。

13.5.4 点击率模型的特征

上一节主要讨论的是点击率预测模型侧的问题, 这一节我们来看特征侧的问题。从受众定向得到的所有 $t(a, u, c)$ 以及这些特征的运算, 可以组合出大量的特征供模型选择, 这是大多数机器学习问题共同的方法。这样的特征生成方法是点击率特征的基础方法, 不过在广告这样的问题中也遇到一些挑战: 一是组合特征数量可能巨大, 使得模型的参数数目也非常大多, 工程上参数更新和在线计算都需要比较高效的设计; 二是模型动态性的本质要求参数快速更新, 而在多台广告投放机之间协同进行在线学习并非易事。

点击率预测问题的主要挑战在于如何使模型能捕捉高度动态的市场信号, 以达到更准确预测的目的。这一挑战可以用在线的模型学习算法, 或者用快速更新的动态特征来解决, 从方法论上说, 这两种思路是对偶的, 但我们将重点放在第二种思路, 因为其工程扩展上更方便一些。

1. 静态特征

为什么广告展示的决策可以提取出大量的特征呢? 这是因为在 (a, u, c) 三个维度上, 都存在着人为指定或机器生成的多种标签, 这些标签有的相互独立, 也有的存在一定的层级关系。比如以 a 上的标签为例, 我们介绍过, 在广告运营当中, 广告会被组织成广告主、广告计划、广告组、广告创意这几个层次。在预测的过程中, 这样的层级结构对于更稳健地估计某个广告, 特别是新广告的点击率有非常大的帮助。如图 12-2 所示, 将 $t(a)$ 、 t

(u)、t(c) 以及 t(a, u) 等各种标签任取一个或两个，都可以都造出一个点击率模型的特征，例如下面的一些例子：

```
{cookie(u)=*};{creative(a)=*};{gender(u)=*};  
{gender(u)=*&&topic(a)=*};{location(c)=*&&advertiser(a)=*};  
{category(a)=category(a)=*}
```

这些例子中的前三个是某个单个标签的取值生成的，其对应的特征总量等于这些标签的取值实例总量；中间的两个，是将上下文或用户的某个标签与广告的某个标签组合生成的，其对应的特征总量等于这两侧标签的取值可能性总量的乘积；最后一个，是常用的特征，它表示的是广告和用户的某个标签相匹配。显然，由于组合特征的存在，可选的特征总量巨大，对应的模型维度也非常高。直接生成所有可能的单维度特征和组合特征，选取出现频次在一定阈值以上的，将其作为 LR 模型的特征集合。这样的特征，我们称为静态特征，这是广告点击率模型特征生成的基本方法。显然，静态特征都是取值为 0 或 1 的特征。

2. 动态特征

在机器学习问题中，有一项很重要的方法论，即某项模型侧的技术，一般都可以找到特征侧的对偶方案。那么如何设计特征方案达到与模型快速演进类似的效果呢？当然就是让特征变成快速演进的。如何才能让特征“动”起来呢？办法也很简单：当某个组合特征被触发时，我们不再用 1，而是采用这个组合历史上一段时期的点击率作为其特征取值。这样一来，即使是同一个 t(a, u, c)，在不同的时间点，其所对应的特征取值也是不同的，这样的特征就是动态特征。

可以这样理解采用历史点击率作为动态特征：我们最终预测的是某个特定 (a, u, c) 上的点击率，而某个组合特征 t(a, u, c) 上的点击率可以认为是关于最终目标的一个弱决策器。通过对这些对应特征组合的弱决策器的融合，可以更容易地预测该 (a, u, c) 上的点击率。这样的方案有个最大的好处，那就是这些弱决策本身只需要简单的数据统计就可以得到，而不需要复杂的训练过程。因此，通过这些简单的弱决策器来捕捉模型的动态部分，整体的融合模型就可以不必那么快速地更新了。

使用动态特征的另一个好处是可以大大减少模型的参数数目：对于 {geo(c)=北京 &&category(a)=电商} 和 {geo(c)=北京 &&category(a)=日化} 这两个特征组合的具体实例而言，如果采用静态特征方案，需要对这两个实例分配不同的特征号；而采用动态特征方案时，由于它们等号前的部分都相同，因此可以在模型中共享同一个特征参数，而通过不同实例的不同特征取值来分辨它们。这样一来，整体模型的参数个数就由各种维度组合总的实例数目降到了维度组合的种类数目，其离线估计和在线计算都会大为简化。

3. 位置偏差与 CoEC

使用动态特征在实际操作中还会碰到一些困难，特别是当广告主数量不充分的时候。假设某广告网络有两个广告位，一个是某网站首页首屏，另一个是某网站内容页最下端。很显然，如果用点击率作为直接的反馈，前几天更多地投在第一个广告位的广告会表现出更好的效果，而这主要是由于位置带来的偏差。

除了广告位位置，还会有其他一些非定向因素对点击率有比较大的影响，主要的有广告位尺寸、广告位类型（如门户首页、频道首页、内容页、客户端）、创意类型（如图片、Flash、富媒体）、操作系统、浏览器、日期和时间等。所有这些因素，都与广告决策没有关系，但是对点击率的影响要远远超过定向技术带来的影响。因此，在这些因素上占据优势的广告，其点击率会被严重高估，如果直接用点击率作为反馈，也会造成强者愈强的马太效应。

如何去除位置等因素的影响呢？如果我们有财力和人力，可以采用眼球跟踪的设备来评估用户对页面上广告位的关注程度，在后续的统计中据此做归一化。对于一些极关键的页面，如搜索广告结果页，这样做是值得和可行的。但对于大量展示广告的广告位来说，这样做显然不切实际。工程上一种合理的办法是将某广告位相当长一段时期内的平均点击数作为其关注程度的近似评估，我们把这一指标称为期望点击（expected click）。

期望点击要求评估的是在广告质量完全随机的情况下，广告位或其他属性对应的平均点击率。要严格达到此目的，需要采用随机出广告的策略进行小流量测试，而这也只能用于搜索广告等因素简单且非常重要的页面。在多个因素共同作用或广告环境比较复杂的情况下，可以采用从数据中近似地学习出期望点击的方法。该方法概念上很简单，只用那些偏差因素作为特征，训练一个点击率模型，这个模型称为偏差模型（bias model）。这里的偏差因素指的是那些与广告决策无关的特征，这些特征一般来说与广告 a 无关。偏差模型可以概念性地表示为

$$\mu_{\text{bias}}(u, c) = p_{\text{bias}}(h = 1|u, c) \quad (13.18)$$

偏差模型的形式和训练方法都可以与前面介绍的整体点击率模型一致。需要注意的是，偏差模型需要用比一般点击率模型更长时间的数据来训练，这样做的目的是希望消除某段时期广告质量带来的影响。

得到了偏差模型以后，可以定义下面的归一化的点击率指标：

$$\text{CoEC} = \frac{\sum_i h_i}{\sum_i \mu_{\text{bias}}(u_i, c_i)} \quad (13.19)$$

这一指标是点击与期望点击的比值，因此称为 CoEC（Click on Expected Click）。由于在分母上考虑了位置以及其他因素的偏差对点击率的影响，这一指标可以更准确地表征某部分流量上广告投放的实际点击率水平，也比较适用于点击反馈这样的动态特征。

采用动态特征和偏差模型的工程方案，点击率预测模型训练的流程分三步完成：首先，用较长一段时间的训练数据，只提取偏差特征并训练偏差模型；然后，利用得到的偏差模型计算所需维度组合上的 CoEC 作为动态特征；最后，用所有非偏差的动态特征训练整体点击率模型，其中用偏差模型的输出作为点击率的先验。利用 CoEC 特征的点击率模型训练流程如图 13-6 所示。




图 13-6 利用 CoEC 特征的点击率模型训练流程

4. 常见的偏差特征

前面说到，除了位置，在线广告中还有一些重要的偏差特征是建模时应该考虑的。

(1) 广告位位置。位置的影响在搜索广告和展示广告环境下有一定的区别。对于搜索而言，页面布局简单，位置相对稳定，相应地统计也比较充分，因此可以将位置视为离散的变量，分别计算各个位置的 EC。而对于展示广告，特别是在广告网络环境下的展示广告而言，位置的可能性非常多，因此不可能对每种不同的位置都作为独立的变量来考虑。比较合理的方法是找出重要影响因素，比如广告位中心相对于页面左上角的坐标，用这样的连续变量作为特征来训练偏差模型。

(2) 广告位尺寸。尺寸与上面说的位置因素很类似：在创意尺寸选择比较少的情况下，可以作为离散变量来处理；而在尺寸选择很多的情况下，也可以用长宽等连续变量来代替。对于搜索广告，由于各创意尺寸一致，这一因素的影响不存在。

(3) 广告投放延迟。广告完成决策逻辑，并将最终结果返回给用户的整体时间长短对点击率有着非常大的影响。如果在前端将广告请求发生的时间和最终展示时间都记录下来，可以为点击率预测模型提供一个重要的偏差特征。

(4) 日期和时间。工作日还是周末，对不同类型的广告（如游戏）点击率有着明确的影响，这主要是由于在不同时间用户任务的集中程度不同，对广告的关注也有所区别。时间的因素，即是工作时间还是休闲时间，也有着类似的特性。因此，日期和时间一般来说也是必须要考虑的偏差特征。除了在模型中显式利用，往往还要求所有的训练过程都覆盖 7 天的整数倍的数据，其目的也是为了避免日期带来的偏差。

(5) 浏览器。浏览器本身并不对广告效果有明确的影响，不过由于各个浏览器上 AD Blocker 的覆盖程度有较大区别，因此在实际建模中其影响也相当大。

上面列举的几项都是在通用的广告系统中最常见的偏差特征，也是建模时需要首先考虑的，读者需要结合具体的广告产品，按照“去除与广告决策无关的影响因素”这一原则来确定和使用偏差特征。

5. 点击反馈的平滑

用 CTR 或 CoEC 这样的点击反馈作为动态特征，大量的长尾组合特征对于准确地预测点击率有很大帮助。但是要利用好这些长尾组合特征，还需要解决一个问题，就是在统计不足的维度组合上如何稳健地统计 CTR 或 CoEC。

以 CTR 为例，公式 13.7 给出了点击的生成模型，点击率就是这一模型的参数。在知道每次展示点击与否的情况下，可以得到参数 μ 的最大似然估计为：

$$\hat{\mu} = \sum_i h_i / N \quad (13.20)$$

其中 N 为总的展示数。当估计某些数据不足的维度组合上的点击率时，一般的思路是在分子分母上各加一个常量，以起到平滑的作用：

$$\hat{\mu}' = \left(\alpha + \sum_i h_i \right) / (\gamma + N) \quad (13.21)$$

很显然， α/γ 应该等于某更大流量范围内的平均点击率。可是 α 和 γ 的绝对数值就没有太直观的方法可以设置。根据 10.3.3 节的介绍，也可以采用经验贝叶斯的方法来解决这个问题。

在贝叶斯的框架下，可以把 μ 看成随机变量，由于公式 13.7 是一个二项分布，其参数 μ 对应的共轭先验是 Beta 分布，即：

$$p(\mu|\alpha, \beta) = \text{Beta}(\mu|\alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \mu^{\alpha-1} (1 - \mu)^{\beta-1} \quad (13.22)$$

超参数 α 和 β 其实就对应于公式 13.21 中的 α 和 $\gamma - \alpha$ 。可以采用经验贝叶斯的方法来估计 α 和 β 。将公式 13.7 和公式 13.22 代入公式 10.28 给出的一般指数族分布经验贝叶斯解，可以得到解 α 和 β 的具体 EM 算法：

E-step

$$\tilde{\alpha}_k^{\text{old}} = \alpha^{\text{old}} + \sum_{i=1}^{N_k} h_{k,i}, \quad \tilde{\beta}_k^{\text{old}} = \beta^{\text{old}} + \left(N_k - \sum_{i=1}^{N_k} h_{k,i} \right) \quad (13.23)$$

M-step

$$\psi(\alpha^{\text{new}}) - \psi(\alpha^{\text{new}} + \beta^{\text{new}}) = \frac{1}{K} \sum_{k=1}^K \psi(\tilde{\alpha}_k^{\text{old}}) - \psi(\tilde{\alpha}_k^{\text{old}} + \tilde{\beta}_k^{\text{old}}) \quad (13.24)$$

$$\psi(\beta^{\text{new}}) - \psi(\alpha^{\text{new}} + \beta^{\text{new}}) = \frac{1}{K} \sum_{k=1}^K \psi(\tilde{\beta}_k^{\text{old}}) - \psi(\tilde{\alpha}_k^{\text{old}} + \tilde{\beta}_k^{\text{old}}) \quad (13.25)$$

其中 M-step 需要解关于 α^{new} 和 β^{new} 的方程组，因而并不是闭式解，不过这一方程组用数值方法求解并不难。

13.5.5 点击率模型评测

点击率模型预测的是点击事件出现的概率，因此可以采用准确率/召回率（Precision/Recall, PR）曲线或接收机操作特性（Receive Operating Characteristic, ROC）曲线来评测。这两个曲线实际上是对同样一组统计数据不同侧面的表现：点击率模型是一个对点击事件进行预测的模型，因此，对任何一个样本实例，存在下面四种情况。

- （1）点击行为被预测为点击行为，其数目计为 n_1 。
- （2）点击行为被预测为非点击行为，其数目计为 n_2 。
- （3）非点击行为被预测为点击行为，其数目计为 n_3 。
- （4）非点击行为被预测为非点击行为，其数目计为 n_4 。

对于这四个数值，有两种常见的视角：一是观察 $\text{Recall}=n_1/(n_1+n_2)$ 和 $\text{Precision}=n_1/(n_1+n_3)$ 的关系，二是观察 $\text{True Positive Rate}=n_1/(n_1+n_2)$ （实际上 $\text{True Positive Rate}$ 和 Recall 是一样的）和 $\text{False Positive Rate}=n_3/(n_3+n_4)$ 的关系。当然，是否被预测为点击是针对某个点击概率的阈值而言的，因此，通过取不同的阈值，就可以得到一条 Precision/Recall 曲线或者是 True Positive Rate/False Positive Rate 的曲线，前者即为 PR 曲线，而后者就是 ROC 曲线。为了方便理解，我们把上述的几个基本量直观地表示在图 13-7 中。

		标注	
		P	N
决策	P	True Positives(n_1)	False Positives(n_3)
	N	False Negatives(n_2)	True Negatives(n_4)

图 13-7 点击率模型评测若干统计量

实际的 PR 曲线可以参见图 13-8（左）。一般来说，PR 曲线呈下降的趋势，不过这并没有理论上的保证，实际数据上局部呈上升趋势的 PR 曲线也很常见。对广告而言，应该更加关注 PR 曲线的头部，因为尾部是 Recall 比较高，也就是很多广告候选都被考虑时的情形，而实际的投放环境中，只选择排名最好的一个或几个候选。另外一点需要注意的是，PR 曲线下方的面积是没有明确的物理意义，因此不能作为有价值的指标来衡量。

实际的 ROC 曲线可以参见图 13-8（右）。一般来说，ROC 曲线呈上升的趋势，不过这一点同样没有理论上的保证。与 PR 曲线不同，ROC 曲线下方的面积有明确的物理意义，

它在一定程度上表征了对 $h=0$ 和 $h=1$ 事件估计值排序的正确性。我们把 ROC 曲线下的面积称为曲线下面积（Area Under Curve, AUC），这是评价点击率模型时常用的量化指标。AUC 虽然经常被用作点击率模型的质量代表，却有一个问题要引起注意，那就是即使只用偏差模型，即对广告排序无直接贡献的模型来预测点击率，AUC 往往也处于比随机猜测高得多的水平上，如图 13-8 中所示。因此，模型对广告排序的作用需要对这两个 AUC 的差值做评估才能比较公允地加以衡量。




图 13-8 PR 曲线（左）与 ROC 曲线（右）示例

无论是计算 ROC 曲线还是 PR 曲线，都是要统计上述的 $n_{1..4}$ 这组值。严格的统计方法需要对整个测试集按照模型估算的点击率排序，不过这样的计算复杂度为 $O(n \log n)$ （ n 为测试集的样本数目），显然在测试样本量较大时无法实用。因此，可以采用近似但对实用来说足够精确的方法，即将整个点击率的取值范围划分成一组区间，并在每个区间上得到一个曲线点。此方法的原理与 12.3.4 节中 reach/CTR 曲线的生成方法是一致的，可以参考该节的介绍。

13.5.6 智能频次控制

第 4 章介绍过频次控制的问题。在竞价广告环境下，这一问题有些变化。合约式广告中，由于广告主对于位置可以由合约控制，因而可以在某个特定的位置上设定展示频次，这一点在按 GD 方式售卖的视频前贴片广告中应用最为广泛。但是在广告网络情形下，由于广告主的创意可能出现在各种媒体的各种位置上，不同位置的有效展示有相当大的差别。因此，简单设定一个展示数目上的频次来控制用户的接触次数是不太合理的。

在这种情况下，需要一个更智能的频次控制方案。最直接的思路是利用 13.5.4 节中介绍的 EC 概念。由于 EC 从某种程度上更接近于有效展示数目，可以采用 EC 上的累积计数代替频次来控制用户接触次数。我们把这种方案叫作智能频次控制。

在品牌广告和效果广告两种情况下，智能频次控制的做法也有所不同：在效果广告中，可以将 EC 的计数或者频次的计数作为点击率预测模型的特征直接加入训练，靠点击率模型的作用降低出现频次过高的创意的竞争力；在品牌广告中，可以通过 EC 计数上的直接控制达到一定用户接触程度的目的，由广告主来直接设定^[14]。

竞价广告精细的效果要求让我们认清了频次的本质：它与其他影响点击率的特征是平等的，并且应该放在统一的、数据驱动的计算框架下加以利用。而究竟对某个创意应该将频次控制在多少，也不应该是根据经验设定，而是应该放在竞价的环境中自行决定。

13.6 探索与利用

在点击率预测中，我们需要采取或是模型、或是特征上的手段来捕获动态信息。这也就意味着，对某种类型的 (a, u, c) 组合，如果没有相关历史数据的支持，很难对其合理地估计点击率。由于线上我们总是使用统计上最优的策略来投放广告，那些非最优的组合出现机会很少，因而对这部分的估计也就不准确。实际上，无法对特征空间均匀采样构造训练集，是互联网问题区别于其他机器学习问题的重要特点。

此问题属于强化学习的范畴。直觉的想法是牺牲一部分流量上 eCPM 最优的策略，采用相对随机的策略采样那些效果未知的特征空间，这称为探索 (exploration) 过程；再根据探索和正常决策的总体流量更有效地预测点击率，这称为利用 (exploitation) 过程。这样的整体策略称为探索与利用，即 E&E。E&E 可以形象地类比成玩老虎机时的决策问题：玩家面对老虎机上 A 个有不同期望收益的手柄，需要用尽可能少的筹码探索出收益最高的那个手柄，然后利用这个结果去获取回报。这种简单的 A 中选 1 的研究问题也称为多臂老虎机 (Multi-Arm Bandit, MAB)^[37] 问题。我们来看看 MAB 问题的数学描述。

假设有 A 个手柄 $a \in \{1, 2, \dots, A\}$ (这里的手柄是广告)，在每个决策时刻 i (对应于广告展示)，必须从 A 个手柄中选择一个，而目标是优化许多次决策后的整体收益。每个广告 a 在第 i 次展示的收益计为 $r_i(a)$ ，对于不同的 i，这些收益是独立同分布的。在 i 时刻，用下面的两个量来分别表示该分布的均值 $\overline{r_i(a)}$ 与方差的经验估计 (此处先不考虑 u 和 c 的影响)：

$$\overline{r_i(a)} \triangleq \frac{1}{i} \sum_{j=1}^i r_j(a), \quad V_i(a) \triangleq \frac{1}{i} \sum_{j=1}^i [r_j(a) - \overline{r_i(a)}]^2 \quad (13.26)$$

最优的手柄或广告定义为期望收益最高的那个：

$$a^* = \arg \max_a \langle r(a) \rangle \quad (13.27)$$

MAB 问题有一个简单的基础方法，即总是用比例为 ϵ 的一小部分流量来做探索，在探索流量上随机选择 A 个广告中的一个；在剩余的 $1-\epsilon$ 比例的流量上，总是选择经验收益最高的那个广告。这样的基础方法称为 ϵ 贪婪法。很显然，只要经过足够多次的尝试， ϵ 贪婪法是一定可以找到最优的那个手柄的。既然如此，还有什么深入研究的必要呢？我们当然是希望能够以更小的代价找到最优手柄。这里的代价定义为整个过程的回报与一开始就总是选择最优手柄这一策略的回报差值，即探索所付出的代价。对于一次选择广告 a 的展示，这一代价数学上的表达为：

$$\Delta_a \triangleq \langle r(a^*) \rangle - \langle r(a) \rangle \quad (13.28)$$

而 E&E 过程的目标就是使得整体的代价（Regret）最低。以 $n_i(a)$ 表示到 i 时刻为止分配给 a 的展示数，则整体代价可以写成：

$$R_i = \sum_{a=1}^A n_i(a) \Delta_a \quad (13.29)$$

假设总共需要进行 T 次展示决策，探索一些系统性的方法，使得我们在对最优广告 a^* 没有先验了解的情形下，以比较低的代价完成这一过程，是这个问题研究的目标。这需要借鉴类似于贝叶斯学习的思想，即将估计的不确定性引入解决方案中，下面介绍一些典型的方法。

13.6.1 UCB 方法

MAB 问题经典的思路是置信上界（Upper Confidence Bound, UCB）方法。此方法在每次投放时不是简单地选择经验上最优的广告，而且考虑到经验估计的不确定性，进而选择估计值有可能达到的上界最大的那个广告。

根据这一思路，在每个决策点，UCB 的过程主要分成两个步骤：首先根据过去的观测值，利用某种概率模型计算出每个 a 的期望回报的 UCB；然后，选择 UCB 最大的 a 。可以看出，这一算法的关键在于如何计算 UCB。参考文献 [4] 中给出了一种称为 β -UCB 的策略，是按照下式计算上界：

$$B_{k,s} = \left(\overline{r_s(a)} + \sqrt{\frac{2V_s(a) \log(\beta_s^{-1})}{s}} + \frac{16 \log(\beta_s^{-1})}{3s} \right) \wedge 1 \quad (13.30)$$

其中 $\beta_s \triangleq \frac{\beta}{4As(s+1)}$ 。相应地，在任意一个时刻 i ，只需要选择令 $B_{k, n_k(i-1)}$ 最大的 a 即可。

β -UCB 的策略并不对回报的具体参数化模型表达有所假设，而是仅通过一阶和二阶的一些统计量来完成策略，因而具有比较好的普适性。这一策略直觉的好处是我们不可能长时间地选择错误的 a ，参考文献[4]中对这一点做了理论上的探讨。遗憾的是，由于 E&E 问题的复杂性，实践中这些比较复杂的策略并未体现出比贪婪法明显的优势，不过这样的思路和方法还是值得学习的。

13.6.2 考虑上下文的 bandit

MAB 问题和 UCB 实际的广告问题还有一定差距。实际广告系统中的主要挑战有两点：首先，需要探索的是 (a, u, c) 这一组合空间，而不是简单的一组广告，这使得探索的复杂程度大大上升。以展示广告为例，我们要面临的实际情况是数十万的广告主、数百万的上下文页面以及数以亿计的用户，即使将这些信息按某种层级结构聚合起来，其组合可能性仍然相当庞大，对探索是个挑战。其次，对 (a, u, c) 的某一具体组合，并不像前文假设的那样有一个确定的期望收益，这是由广告问题的高度动态性决定的。

对于需要探索的空间过大的问题，工程上比较常用的思路是将此空间参数化，在一个维数较低的连续空间中进行探索。这样的 E&E 问题可以称为考虑上下文的 bandit（contextual bandit）问题。注意这里说的“上下文”不同于上下文定向中提到的“上下文”，此处是指根据 (a, u, c) 组合参数化后的上下文空间位置。

考虑上下文的 bandit 的问题，代表性的思路有 LinUCB 方法^[50]。从名字就可以了解到，这一方法是将公式 13.26 中表达的回报分布由 a 决定，变成由一些环境特征的线性组合决定，也就是说，在某个时刻 t ，我们将某个 a 的期望回报表达成：

$$E(r_{t,a} | \mathbf{x}_{t,a}) = \mathbf{f}^\top(a, u_t, c_t) \boldsymbol{\theta}_a^* \quad (13.31)$$

可以看出，这样的表达达到了两个目的：首先，将 (a, u, c) 的组合空间，而不仅仅是 a 都纳入了探索的范围以内；其次，用线性组合的连续输出代替了离散的 ID 值，使得 E&E 过程可以在如此巨大的空间上实施。在参考文献[50]中，这一变换模型被称为不相交的线性模型（disjoint linear model），这里“不相交”的含义指的是对于每一个广告 a 适用独立的线性变换参数 $\boldsymbol{\theta}_a^*$ 。细心的读者一定会发现，这样的假设在 a 数量巨大时也会成为障碍，因此，在实际中，也可以在广告主类型或其他聚合粒度上使用不同的变换参数。

13.7 延伸思考

1.在搜索广告中，广泛匹配的引入会给位置拍卖会带来什么样的影响？与此对应，可能在机制设计上采取什么策略？

2.在一个 CPC/CPM 混合竞价的广告市场中，CTR 预估的系统偏差和模型误差会对市场产生什么影响？

第 14 章 程序化交易核心技术

程序化交易的发展使得广告市场发生了深刻的变化：供给方的功能简化成了简单的比价平台，而需求方开始承担广告决策的主要职责。在这样的变化下，第一方数据、第二方数据和第三方数据可以同时为广告优化服务，于是广告精准化、实效化的趋势与越来越显著。在技术层面，这样的变化也带来了一些新的技术挑战。

广告交易平台是技术挑战相对较少的产品，架构也相对简单。其主要技术难点在于如何用可行的成本处理大流量的广告请求，不过这并不是一个独特的技术问题，因此在此不做过多讨论。本章主要介绍两点相关技术：一是各广告或数据产品在进行用户身份对应时的 cookie 映射方法；二是如何优化询价的服务成本，即尽可能只向那些可能赢得拍卖的 DSP 询价，这也是第 11 章介绍的在线分配框架下的具体问题。

在所有在线广告产品中，需求方平台（DSP）是算法挑战相对较大的。首先，在实时竞价环境下，DSP 需要提供重定向、新客推荐等定制化用户标签，而这既需要与第一方数据和商品库打通等繁杂的工程接口，又产生了一些新的建模问题，特别是像 look-alike（新客推荐）这种第一方数据和第三方数据兼用的受众定向问题。其次，需求方平台需要像广告网络那样估计点击率，并且会遇到比广告网络更高的准确性要求，另外还需要在面向效果类广告主时同时估计点击价值。另外，实时竞价中的出价是存在优化空间的，这是 DSP 特有的出价策略问题，也对 DSP 的收益影响很大。总之，实时竞价的开放市场环境为定向技术和效果优化拓展了巨大的空间，未来需求方的技术也还有很大的提高余地。本章将重点介绍这些在实时竞价环境下产生的需求方技术问题。

程序化交易市场还有供给方平台（SSP）这一产品，其核心优化问题是面向多个广告网络时的收入优化问题，可以看成是与广告交易市场中的询价优化相类似的问题，本章也将分析这两项技术之间的关系。

14.1 广告交易平台

我们先来看广告交易平台的优化目标，在公式 2.2 的基础上，这一目标可以调整为：

$$\max_{a_1, \dots, T} \sum_{i=1}^T \text{bid}_{\text{CPM}}(a_i) \quad (14.1)$$

这里的 a 代表的是某 DSP 而非具体广告。与公式 2.2 相比，这一优化目标显然大大简化了：首先是成本项没有了，这是由在广告交易平台中分成或包断媒体资源的方式决定的；

其次，收入项不再与用户或上下文相关，因为这部分因素都由 DSP 来考虑，并体现在最终的报价中。显然，此优化简单地通过比较 DSP 报价，取价高者即可。因此，广告交易平台在各种广告产品中是算法方面挑战最小的。

虽然广告交易平台中的计算问题不多，我们还是要介绍以下两个问题。

(1) 由于实时竞价的功能需求，广告交易市场解决供给方和需求方用户身份对应的问题，在 Web 广告环境下，这需要用到 cookie 映射的技术。

(2) 实践中当考虑到带宽和服务成本带来的约束时，希望用更少的询价请求完成尽可能高效的变现，在这种情况下，公式 14.1 的优化问题会有所变化，这一问题称为询价优化。

由于主要功能是提供公开或私有的实时竞价市场，广告交易平台是架构上相对简单的广告产品，其架构如图 14-1 所示。

这一架构主要涉及的是在线广告请求时的系统过程，而离线的 cookie 映射过程将在下面专门介绍。当用户访问媒体页面，广告请求发至 ADX 后，ADX 向各个接入的 DSP 发起询价并完成比价决策，然后将胜出的 DSP 返回给媒体页面进行广告投放。从核心概念上看，ADX 既不需要自己的广告索引，也不需要 eCPM 估计，因而可以用非常简单的架构实现。但是这仅仅是理论上的概念，实际产品中，ADX 与 ADN 的界限并不是泾渭分明，往往为了支持小规模广告主在更方便的图形界面采买，也需要广告检索和排序；而为了实现询价优化，简单的 eCPM 估计也是不可少的。

[14.1.1 cookie 映射](#)

我们先来了解在线广告中是如何对用户身份进行跟踪的。在不同的广告形式中，采用的用户身份标识也不尽相同。

在 Web 环境下投送的广告，用户身份标识可以用 HTTP 协议提供的 cookie 机制来完成。cookie 机制在安全性方面有很多好处，比如每个域名下的服务只能访问本域名下的 cookie，这实际上是由浏览器保证了不同 Web 应用之间用户数据的隔离。不过 cookie 在用户跟踪的有效性方面受到一些限制：首先，用户可以主动清除 cookie，于是广告系统对该用户的跟踪就中断了；另外，由于广告网络往往是在其他域名的网站上跟踪用户和投放广告，其种植的 cookie 是第三方 cookie。而对于第三方 cookie，浏览器一般有更为严格的限制，有的浏览器甚至会在默认情况下禁止第三方 cookie，这也成为行为定向的障碍。随着市场对用户隐私问题越来越关注，W3C 还进一步制定了“Do Not Track”（DNT）的标准，用于用户主动向网站要求不要被跟踪，或者不要被网站上的第三方应用所跟踪。cookie

的跟踪方式还有一个问题，那就是当某台电脑的用户使用多个浏览器时，其 cookie 无法直接统一起来。




图 14-1 广告交易平台系统架构

在有用户登录信息的广告产品中，用户登录的身份往往是比浏览器 cookie 更强的身份标识，而最典型的情形出现在社交广告中。用户登录信息不仅在接续性上远远好于普通的浏览器 cookie，还具有能够打通不同的桌面和移动设备的功能。因此，创造网站功能以鼓励用户登录是很多从事广告业务的互联网公司都在努力的方向。当然，也不能认为用户登录身份的准确性一定好于浏览器 cookie。例如，在某些游戏性质较强的产品中，由于一个用户可能创建多个“马甲”参与，会导致其用户标识相当不准确。

与其他身份标识不同，cookie 由于具有域名之间的隔离性，在 RTB 这种服务器间的广告请求中，DSP 无法直接得到自己域名下的 cookie。因此，必须要通过某种技术手段来完成身份对应，这称为 cookie 映射。cookie 映射应用的范围很广，除了上面提到的 ADX 与 DSP 之间的身份对应，典型的应用还例如媒体与 DMP 之间的身份对应以及某具有永久用户标识的服务向其他域名提供 cookie 找回的服务等。

cookie 映射的场景比较多样，我们可以重点关注三个问题：由谁发起？在哪里发起？谁保存映射表？最典型的场景有两种：一是涉及两个域名，即在一个域名的服务上向另一个域名发动的 cookie 映射；二是涉及三个域名，即在一个第三方域名页面上发动的其他两个域名间的 cookie 映射。我们分别来讨论这两种情况。

涉及两个域名的 cookie 映射，典型的例子是媒体与 DMP 之间的身份对应问题。如图 14-2 所示，这一过程有 5 个步骤。

- (1) 用户到达媒体页面。
- (2) 向媒体的 cookie 映射服务请求一段负责此功能的 JavaScript 代码。
- (3) 媒体的 cookie 映射服务返回该段 JavaScript 代码。

(4) 该 JavaScript 代码判断需要映射的话(如果最近已经做过则可以不),向 DMP 发起 cookie 映射请求,并传送两个参数:媒体的标识(mid)以及媒体方的 cookie(mck)。

(5) DMP 返回一个 1×1 的 beacon,并记录下媒体方 cookie(mck)与己方 cookie(dck)的对应关系。




图 14-2 媒体与 DMP 间 cookie 映射示例

考察一下关注的三个问题可以发现,这一 cookie 映射过程是由媒体方在媒体的页面上发动,并由 DMP 方保存映射关系。这样做有其合理性:媒体需要从 DMP 获得标签的人群是自己的访问人群,因此从媒体页面发动;而 DMP 保存映射,可以比较方便地将自己的用户标签与媒体 cookie 对应,并传回给媒体。

涉及三个域名的 cookie 映射,典型的例子是 DSP 与 ADX 之间的用户标识对应问题。如图 14-3 所示,这一过程有 6 个步骤。

(1) 用户访问广告主页面。

(2) 选择性加载一个 DSP 域名下的 iframe。

(3) DSP 判断需要映射的话,返回包括多个 beacon 的动态 HTML,此处多个 beacon 的目的是为了同时与多个 ADX 交换 cookie。

(4) 通过其中的某个 beacon 向对应的 ADX 发送 cookie 映射请求,并带有 ADX 标识(xid)、DSP 标识(did)和 DSP cookie(dck)三个参数。

(5) ADX 通过 302 重定向向 DSP 返回 ADX 标识(xid)及其域名下的 cookie(xck)。

(6) DSP 返回一个 1×1 的 beacon,并记录下 ADX 方 cookie(xid)与己方 cookie(dck)的对应关系。



图 14-3 DSP 与 Ad Exchange 间 cookie 映射示例

这个过程与上一个过程相比,由于是在第三方的网站上发动映射,因而较为复杂,需要用到 302 重定向,不过熟悉前端技术的朋友应该不难理解。仍然考察我们关注的三个问

题，这次是由 DSP 在广告主页面上发动映射，并由 DSP 保存映射关系。这样做也是符合业务逻辑的：DSP 主要需要广告主的人群做深入加工并对这部分人群在 ADX 中出价，因此从广告主页面发动；而 RTB 是 cookie 的对应，由各 DSP 分别自行完成比在 ADX 中集中时完成显然更加合理，因此这一映射表保存在 DSP 方。

除了上面两个典型的例子，cookie 映射可能遇到的需求还很多，但大家只要分析清楚关键的三个问题，并透彻理解上面两种方式，就很容易举一反三，根据实际需求设计合理方案。

14.1.2 询价优化

ADX 中有一个重要的问题需要考虑，那就是如何在带宽和服务成本的约束下获得更高的 eCPM。如果不考虑成本，ADX 的询价策略非常简单，每次展示都向所有接入的 DSP 询价即可。可是当 DSP 数以十计时，服务成本就会上升一个数量级，这显然是无法接受的。因此，广告交易平台需要在带宽或服务成本的约束下，优化整体市场的 eCPM 水平。要考虑带宽或服务成本的约束，显然就需要对每次展示中询价的 DSP 数目做精简，这个问题称为询价优化。

询价优化有两种典型的思路，一种是工程规则的思路，另一种是将其视为一个带约束优化问题的思路。先介绍一下工程规则的思路：考虑到 DSP 方有相当一部分是按照广告主定制标签来采买流量，因此，这种 DSP 一般来说只会在自己感兴趣的人群，也就是 cookie 映射过的用户群上出价。显然，ADX 是可以先验地知道这一用户群的，因此，对这类 DSP 中的某一个，如果当前广告请求到达的用户 cookie 没有与其映射过，那么就不需要向该 DSP 询价。一般来说，这样的规则可以显著降低带宽需求。不过，也有很多的 DSP 并不是仅仅在广告主用户集合上出价，或者当这样做仍然不能满足带宽成本的要求时，就需要进一步的优化了。

询价优化的问题，由于也需要在每个广告请求到来时做决策，因此从框架上非常类似于第 11 章的在线分配问题。只不过这里的约束变成了带宽或服务的成本。由于从商业规则上说，我们不能完全依赖 eCPM 水平来决定向哪个 DSP 发起询价，因为这样有可能造成某些 DSP 完全得不到流量，从而退出市场。因此，实际的询价优化问题的约束往往设置成各个 DSP 获得流量比例的一个上限，而这一上限是根据该 DSP 一段时间的花费来决定的。在这样的约束下，参考文献[19]中将询价优化描述为下面的优化问题：

$$\begin{aligned}
 & \max \sum_{(i,a)} \sum_k k y_{iak} \\
 & \text{s.t.} \sum_i x_{ia} \leq \rho_a \\
 & x_{ia} \leq 1; y_{iak} \leq p_{iak} x_{ia} \\
 & \sum_{(i,a)} y_{iak} \leq 1; x_{ia}, y_{iak} \geq 0
 \end{aligned} \tag{14.2}$$

这里的 a 代表的不再是一条具体的广告，而是某一个 DSP； i 可以是一个供给节点或一次展示（在没有流量预测的情形下）； k 是某个出价（此处进行了离散化以方便问题描述）。与第 11 章的在线分配问题对比， p_{iak} 与 y_{iak} 是新引入的变量，分别表示 DSP a 为供给 i 的一次展示出价 k 的概率以及以此出价赢得此次拍卖的概率。与在线分配框架问题对比，可以发现它们在数学本质上是一样的。询价优化问题的关键就是上式中的第一个约束，它表示的是总体分配给每个 DSP a 的流量不超过其上限 p_a 。有关询价优化问题更详细的研究参见参考文献[19]。

注意一下公式 14.3 中所有 $\sum_{(i,a)}$ 的式子。在供需二部图中， (i, a) 是所有的供给节点与需求节点之间边的集合。对于开放竞价的 ADX 来说，所有的流量向所有的 DSP 开放，因此任意的 (i, a) 组合都要考虑；而在 PMP 中，可行的 (i, a) 组合是由每个私有市场向哪些 DSP 开放决定的。

除了在线分配的框架，询价优化的关键基础实际上是对 p_{iak} 与 y_{iak} 两组变量的预估。也就是说，对于某个供给节点，也即特定的人群，要对各 DSP 在此人群上的出价以及此人群整体的市场价水平有一定的估计能力，这实际上就是要预估各个 DSP 在特定人群上对 ADX 来说的 eCPM。因此，在询价优化的需求下，ADX 也需要 eCPM 估计。

14.2 需求方平台

DSP 的优化目标与大多数广告产品有所不同。从利润的角度出发，除了尽量提高广告的 eCPM，还需要尽量降低每次广告展示的费用，而后者在广告网络这类的产品中是无需优化的。因此，DSP 的优化问题可以用下式来表达：

$$\max_{a_1, \dots, T} \sum_{i=1}^T \{ \mu(a_i, u_i, c_i) \cdot \nu(a_i, u_i) - p(u_i, c_i) \} \quad (14.3)$$

公式 14.3 中的减号前的部分，即收益，可以通过 eCPM 估计来计算，其技术与广告网络中的 eCPM 估计相类似；而减号后的部分则通过出价策略来优化，这是 DSP 特有的优化需求。

DSP 的系统架构如图 14-4 所示，其中广告投放的决策流程为：DSP 服务器通过 RTBS 接口收到广告询价请求，然后经过与广告网络类似的决策步骤，包括检索和 eCPM 排序，找到价值最高的广告，并将报价返回给 ADX。这样的决策流程，适用于按 CPC 或效果付费、以套利为目标的 DSP，这类 DSP 通过优化算法提升广告主的 ROI 来赚取更多的利润。也有一类 DSP 产品，其服务接近于透明采买的方式，即广告主按照自己的用户划分和策略完成 RTB 购买，而 DSP 收取固定的手续费，这种情况下，对优化的需求就没有那么高。我们重点讨论的是前一种 DSP。

与广告网络相比，DSP 的广告决策过程更加复杂，我们会重点讨论下面的几个技术点。

(1) DSP 往往需要支持定制化的用户划分能力。在实际产品中，定制化用户划分有时由专门的 DMP 来提供，但更常见的情形是 DSP 提供的标准接口来实现。

(2) 由于 DSP 是完全面向广告主的产品，需要在量的约束下投放。因此，还存在类似在线分配的问题，这产生了对于出价策略的需求。

(3) 在按 CPC 结算的 DSP 中，进行 eCPM 估计时，需要估计 CTR；而在按 CPS 等效果结算的 DSP 中，还需要同时估计点击价值。并且，由于实时出价的要求，这两项的估计都要尽可能准确。关于点击率和点击价值估计的方法在前一章已经介绍过，本章会简要介绍一下在 DSP 当中的挑战。




图 14-4 需求方平台（DSP）系统架构示意

14.2.1 定制化用户标签

DSP 与其他广告产品相比，多了定制化用户划分功能（customized audience segmentation）部分，这是收集第一方数据的接口，这部分数据将用于加工第一方专用的用户标签，用于指导广告投放。

对于定制化用户标签中最常用的重定向，需要将访问广告主网站的某特定用户集合传送给 DSP。这个接口也有两种主要的实现方式。

(1) 直接在广告主的网站上布设 DSP 域名的 JavaScript 代码或者外链图片（也可以是不可见的 beacon），这样 DSP 就可以直接收集到访客的记录，再自行加工分析即可。

(2) 采用线下数据接口的方式，定期将广告主或者其委托的 DMP 收集到的访客集合批处理式地传送给 DSP。当然，前提是 DSP 与广告主或其 DMP 之间建立起了 cookie 映射的机制。

这两种方式各有优缺点：前者能够实时地获取访客信息，但是需要一段时间的数据积累才能覆盖广告主用户集合的大部分，而且在多个 DSP 同时服务于一家广告主时需要加多段跟踪代码，这样会降低页面响应速度；后者虽然可以迅速得到访客集合，并且避免页面因多组跟踪代码而变得太重，却在数据更新时有一定的延迟，并且对广告主方的技术要求较高。

除了获取第一方用户行为数据的接口以外，当需要提供个性化重定向功能时，DSP 还需要向广告主提供用于商品库同步的接口，由于不同广告主的商品库存储和管理区别很大，往往需要多套接口才能满足业务的需要。在实际的个性化重定向技术中，商品库的接口是最为复杂的功能之一。

在定制化用户标签中，要特别提到 look-alike（新客推荐）这类方法，因为它要同时用到第一方数据和第三方数据，有比较独特的算法建模需求。

look-alike 建模

关于 look-alike 的具体建模方法，目前市场上还没有大家公认的通用方案。不过，如果从这种定向方式的本质，即 $t(a, u)$ 的特点出发，并且以优化效果为主要目的话，也可以以前文讨论的点击率模型为基础，得到 look-alike 的一般可行思路。

任意给定一组 (a, u, c) 的组合，点击率模型按照训练好的模型计算其预估的点击率。如果变换一下思路，筛选出一个特定广告主的历史投放数据，并且只使用那些与用户或广告主相关的组合特征 $x(a, u)$ 训练下面的模型。

$$p(y = 1|x(a, u)) \quad (14.4)$$

虽然此模型的形式与点击率模型类似，但是其意义已经发生了本质的变化：首先，这里的一条样本是一个用户，而不是一次展示；其次，这里的输出信号 y 不再是点击行为，而是标示一个用户是否为广告主用户的二元变量。显然，此模型是一个针对广告主 a ，评价某个 u 成为其用户可能性的评估函数。由于此模型评估的是用户的属性，因此与上下文信息 c 无关。

对于训练集中每一个用户 u ，确定其对应的 y ，有两种方法：第一种方法根据广告主提供的种子用户集，将出现在该种子用户集中的 u 对应的 y 标为 1，否则标为 0；第二种

方法根据广告投放的记录，将点击过该广告主广告一定次数（一般设为 1）以上的用户对应的 y 标为 1，否则标为 0。比较这两种方法，第一种需要用到广告主提供的第一方数据，能够高质量且比较精确地圈定目标人群；第二种方法不需要第一方数据，但是靠广告点击收集的种子用户集合往往质量较差，而且量会受到限制，也会有比较严重的冷启动问题。至于 look-alike 模型的具体形式和训练方法与点击率模型有类似的选择。由于 look-alike 问题的训练集正比于用户规模而不是展示量规模，因此求解的过程比点击率模型会简单一些，往往不需要用分布式计算方案就可以解决。

对任意一个给定的用户 u ，上述 look-alike 模型给出的是其成为广告主 a 用户的可能性。此可能性是 $(0, 1)$ 之间的一个概率值，对其设定一个阈值，就可以将用户分成两类，一类我们认为是该广告主的潜在新客，一类认为不是。这样就得到了该广告主的潜在新客这一标签，显然，这样的标签是一种定制化用户标签。

在很多情况下，为特定广告主发现新客，既可以采用这样的 look-alike 标签，也可以采用普通的受众定向标签。比如，为招商银行的信用卡寻找新客，既可以由招商银行提供种子用户，加工其专用的 look-alike 标签，也可以简单地选择普通受众定向体系中的“财经/信用卡”这样的人群。显然，由于第一方数据的使用，我们希望 look-alike 标签在同样的 reach 水平下，其 CTR 应该高于普通受众定向标签，也就是前者的 reach/CTR 曲线在后者的曲线上方（如图 14-5 所示）。否则，look-alike 技术就没有价值了。

14.2.2 DSP 中的点击率预测

DSP 中的点击率预测与广告网络中的点击率预测原理一致，方法也可以通用。不过，由于 RTB 环节的存在，点击率预测准确性的要求是更高的，而且离线测试与线上测试存在一个系统性的偏差，下面探讨这两个问题。

对点击率预测准确程度要求高这一点很容易理解：在广告网络中，估计 eCPM 是为了对候选进行排序，因此相对一致的点击率高估或者低估，对结果的影响是有限的；而在 DSP 中，估计 eCPM 是为了做出价的依据，任何高估或低估都会对最后的利润产生直接的影响。而前面介绍的 PR 曲线和 ROC 曲线主要对排序比较敏感，在精细地反映预测准确程度上还不够。例如，我们把某一个模型计算出来的点击率 μ 作如下的变换：

$$\lg \mu^0 = 12 (\lg \mu - \lg 0.01) + \lg 0.01 \quad (14.5)$$

可以验证， μ^0 与 μ 得到的 PR 曲线和 ROC 曲线都是一样的。但是，显然它们的预估准确程度不相同。因此，除了关注 AUC 等指标以外，还需要在各种流量细分上关注预测点击与真实点击的比，看它是否在 1 附近。某部分流量上真实点击总数与各展示预估 CTR 之和

的比例称为 CoPC（Click on Predicted Click），在实际系统中，CoPC 也是需要重点关注的指标之一，它表征着某部分流量上是否存在明显的点击率高估或低估。




图 14-5 look-alike 标签与一般受众定向标签效果区别示意

表 14-1 说明了 DSP 点击率模型离线测试与线上测试的系统性偏差。假设有三个广告位 A、B、C，在探索得到的训练集上获得的流量都是 10 千次，并且点击率也都是 0.2%，但是模型估计的点击率有的高估，有的低估。于是，在离线测试时，模型估计的平均点击率与真实点击率是一致的。然而，在线上按照此模型参与竞价时，点击率高估的部分获得的流量比例会上升，如表中所示，A、B、C 三个广告位实测时获得的流量分别为 70 千次、100 千次、130 千次，于是，在线上实测集上观察，模型预估的平均点击率变成了 0.21%，比真实点击率高估了 5%。由于模型总是会在部分流量上高估或低估，因此，这样的系统偏差总是存在的，有时还会相当严重。

	离线测试集			线上实测集		
广告位	展示量（千次）	实际点击率（%）	预测点击率（%）	展示量（千次）	实际点击率（%）	预测点击率（%）
A	10	0.20	0.18	70	0.20	0.15
B	10	0.20	0.20	100	0.20	0.20
C	10	0.20	0.22	130	0.20	0.25
平均		0.20	0.20		0.20	0.21

特别提及此系统偏差的目的是要告诉大家，在实时竞价的动态博弈环境下，由于模型本身会影响流量的分布，对点击率预测和其他算法问题效果的理解要有新的思考方式，并且应该更多地根据线上实测的结果来判断一个模型的好坏与取舍。

14.2.3 点击价值估计

由于 DSP 代表的是广告主的利益，往往可以通过在广告主网站布设代码等方式获得转化数据^[15]，按 CPS/CPA/ROI 等转化效果方式与广告主结算。在这种结算方式下，除了要按广告网络那样估计点击率，还需要估计点击价值。我们来看点击价值估计的问题。

$$\nu(a, u, c) = h(a, c) \cdot c(a, u) \cdot t(a) \quad (14.6)$$

如公式 14.6 所示，点击价值可以分解为到达率（reach） h 、转化率 c 和转化单价 t 三个量的乘积。到达率指的是实际打开广告落地页次数与点击次数的比例，这与广告主网站的页面打开延迟关系最大，与媒体的属性、特别是误点情况也有一定关系，因此可以认为它与广告主 a 和媒体 c 有关；转化率指的是到达落地页以后，有多少比例产生了广告主定义的转化行为，这主要与用户对广告主产品的兴趣有关，因此是广告主 a 和用户 u 的函数；转化单价在 CPA/CPS 类的广告中是广告主指定的转化费用，而在 ROI 类广告中是广告主客单价与分成比例的乘积，因此我们认为转化单价主要与广告主 a 相关。当然，上面的讨论非常近似，实际上 a 、 u 、 c 三个变量都对到达率、转化率和转化单价有一定的影响，而公式 14.6 只考虑了其影响因素。

上面的几个量中，到达率与转化单价都不难统计，而转化率的估计是一个比较困难的问题。这首先是因为转化比起点击还要稀疏得多，用机器学习的方法建模存在较大困难；其次，转化的定义和性质与广告的具体业务类型、甚至不同广告主的目标紧密相关。例如，电商广告主会将购买定义为转化，而游戏广告主在开服的需求下会将注册定义为转化，在一般运营状态下会将充值定义为转化。显然，不同类型的转化无法用同一模型来描述，这进一步加剧了数据的稀疏性。

特别要注意的是，在没有充足的行业数据支持的情形下，广告产品千万不能贸然将点击价值估计全部交由机器完成。实践中比较可行的办法基本上都是简单统计与运营经验相结合来估算转化率。不过，当某 DSP 的广告主类型和转化流程相对一致，比如专门服务于游戏客户的 DSP 或者像淘宝这样的平台电商自建的 DSP，那么在转化数据比较充分的前提下，可以采用机器学习建模的方法预测转化率。转化率预测用到的数学工具和优化方法在此不再展开介绍。

14.2.4 出价策略

如果 DSP 投放的广告活动没有预算的限制，那么出价策略非常简单：只要按照 eCPM 水平出价，就可以保证在第二高价的情况下每次展示都有利润。但是在有预算约束的情况下，显然希望每次展示的利润率尽可能高，而利润率除了需要知道 eCPM，还需要对当前展示的市场价格有所估计，并在全局水平上尽可能将出价集中在那些利润率较高的展示上，这就是 DSP 出价策略的直观理解。

显然，出价策略也是一个量约束下的效果优化问题，可以很自然地想到用在线分配的问题框架来解决。根据上面的问题描述，可以把出价策略描述成如下的优化问题：

$$\begin{aligned} \max \quad & \sum_{(i,a) \in E} s_i x_{ia} (r_{ia} - m_i) \\ \text{s.t.} \quad & \sum_{a \in \Gamma(i)} x_{ia} \leq 1, \quad \forall i \in I \\ & \sum_{i \in \Gamma(a)} s_i x_{ia} m_i \leq d_a, \quad \forall a \in A \\ & x_{ia} \geq 0, \quad \forall (i,a) \in E \end{aligned} \tag{14.7}$$

在这个问题中，仍然把流量分解成一组供给节点 $i \in I$ ，并用 r_{ia} 表示供给节点 i 分配给广告 a 的单位流量收益，用 m_i 表示供给节点 i 上的市场价格。由于第二高价的存在，市场价格就是成本，而 $r_{ia} - m_i$ 就是单位流量产生的利润。公式里的需求约束表示的是每个广告主的花费不能超过其预算。因此，这个优化问题的物理意义是，在广告主预算的约束下最大化 DSP 的收益。注意到在供给约束中，所有的 x_{ia} 分配比率加起来可以小于 1，也就是说，对在线到来的询价请求可以有一定不参与竞价的概率，这也反映了出价策略的本质。

我们注意到，在这个问题中， r_{ia} 和 m_i 是需要估计的量，也是策略优化的关键。在估计 r_{ia} 和 m_i 时，比较重要的一点是如何将流量划分到合适的供给节点上，在最彻底的情形下，还是可以将每次展示作为一个供给节点，直接利用 eCPM 估计的模型来计算 r_{ia} ，并建立一个专门的市价预测模型来估计 m_i 。不过，由于对市价 m_i 的估计远远没有对 eCPM 的估计那样可靠，不宜使用过于复杂的模型和算法，一般来说，主要使用时间、地域、媒体属性等影响明确的因素来进行预估。

14.3 供给方平台

供给方平台是与广告交易平台比较接近的产品，一般会实现私有的 RTB 交易以及网络优化等功能，并且用动态分配的逻辑决定当前展示分配给哪种广告渠道。动态分配的整体

产品策略已经在 6.5.1 节中有所介绍，这个过程涉及的技术与其他产品多是相通的，唯有其中第 3 步，即网络优化的问题，需要特别说明。

网络优化

网络优化问题是指 SSP 在接入多个广告网络以后，在线动态决定将广告请求发给哪个广告网络，从而优化整体收入的问题。

将网络优化与 14.1.2 节的询价优化问题对比可以发现，这两个问题有一些相似之处：前者需要预估若干广告网络在当前 (u, c) 条件下的 eCPM，而后者则需要预估若干 DSP 在当前 (u, c) 条件下的 eCPM。当然它们也有很大的不同：首先是在网络优化时，只需要找到 eCPM 最高的广告网络，而在询价优化中，要根据带宽约束在线决定向哪几个 DSP 询价；另外，询价优化中 DSP 的 eCPM 可以根据历史数据比较精细地建模计算，但是在网络优化中，由于广告网络一般没有向媒体报价的功能，往往只能采用粗略的数据分析和建模手段来估计其 eCPM。

概念上说，在网络优化中，估计某个 (a, u, c) 组合上的 eCPM 时，这里的 a 由具体的一个广告变成了某个广告网络，由于没有了具体的广告信息，因此预测的准确程度也会大打折扣。有关网络优化的 eCPM 估计问题，由于其在实践中的重要程度有限，并且并不是多数广告系统会遇到的计算问题，在此不讨论其细节。

14.4 延伸思考

- 1.在移动互联网环境下，如果采用 IMEI 这种比较稳定的用户身份标识进行程序化交易，会对供给方、需求方和数据方带来哪些正面和负面的影响？
- 2.对于同样流量规模的 ADX 与 ADN，请定量估算其服务成本的差距，并据此估算询价优化中合理的服务成本约束。
- 3.优选 (preferred deals) 和 RTB 中需求方的出价策略有何不同？哪一种效率更充分？

第 15 章 其他广告相关技术

在本书的前面章节中，我们以在线广告市场上产品形态发展的过程为主线，对按合约售卖的广告系统、非实时竞价的广告网络和实时竞价的程序化交易市场作了介绍，并对其关键计算技术进行了深入讨论。除了这些骨干性的技术以外，在线广告中还有一些非常重要的外围问题，本章将对这些问题展开讨论，目的是为了让读者对实际广告系统的各个环节都有实际的认识。

在前面的章节中讨论的所有技术和算法，其核心都是为了优化广告效果。不过前面谈到的广告效果优化思路，基本上集中在受众的选择的角度，而在实际的在线广告中，还有一项对广告效果影响巨大的技术，那就是创意优化。创意优化与受众优化性质有所不同，因为创意的改变实际上也改变了广告要表达的诉求。如何在基本的宣传诉求可比的前提下，结合受众定向对创意做调整，这是广告系统不能不考虑的重要问题。

广告系统运营中另一个必须考虑的问题是建立一个灵活的实验框架（**experimentation framework**）。由于各种策略、算法、架构的调整，通过线下评测和模拟都很难完全反映线上的变化，因此，需要有一个线上的实验系统来确定其有效性。线上实验系统的原理很简单，无非是从实际流量中分出一定比例用于实验方案。不过，由于同时测试的方案个数可能比较多，如何在一个框架中进行更多的测试是工程中提高广告系统进化效率的关键。

还有两个与广告效果的度量相关的问题。一是如何在流量中去除那些恶意的和非主动的流量，这部分称为流量保护（**Traffic Protection, TP**）。其中去除恶意流量的反作弊问题，由于是一个“道高一尺、魔高一丈”的动态博弈过程，因此并无确定不变的技术和算法，不过也有一些原则和基础方法可以遵循。二是需求方站在自己的利益角度对广告效果的核实性度量，这称为广告监测。这两个问题其实有着相当深入的联系，在今天程序交易和受众定向大量被使用的在线广告市场中，这两个问题在一定程度上可以结合起来考虑，并催生了所谓广告安全的问题和相应技术。

受众定向和程序交易广告的另一个重要影响是用户的行为数据存在在不同的广告产品之间泄露的可能。因此，隐私保护技术与其对立面，即去匿名化技术，从正面或者负面的角度都与在线广告有着密切的联系。关于隐私保护相关问题及其在广告中的可能应用，也将是本章涉及的内容。

15.1 创意优化

创意对于广告效果的影响无疑是巨大的，然而我们不能把调整创意带来的效果等同于受众定向产生的效果。因为随着创意的改变，广告表达的诉求已经发生了变化，其点击行为也就不再与其他创意完全可比。可以通过一个例子来理解这个问题：假如有一个保险类型的广告主，将一个宣传公司品牌和实力的品牌型创意变成一个用户填写车险申请的表单式创意，如图 15-1 所示。毫无疑问，后者的点击率会大幅度上升。但是实际上，这两个创意向用户传达的诉求有着相当大的区别：前者的目的是向潜在用户渗透性地宣传品牌的定位，以利于将来长期的用户转化和利润空间；而后者的目的则是短期内的转化效果，但对品牌特质的宣传有所不足。




图 15-1 品牌型创意（左）和效果型创意（右）

因此，我们重点讨论在广告的基本诉求保持相对稳定的前提下，如何调整创意以提高效果。

15.1.1 程序化创意

创意优化的一个重要原理是我们在第 2 章广告有效性模型中介绍过的原则：为了提高用户的关注程度，需要将向用户推送此广告的关键原因在创意中明确表达出来。由于推荐原因众多，这样的创意优化往往需要用程序自动进行，而不是预先做好大量的素材。类比于程序化交易，我们把这类思路称为程序化创意。下面就程序化创意的思路给出一些示例性建议。

（1）地域型创意。地域定向是根据用户的地域信息投送相应的广告，如果能将明确地域指示性的内容体现在创意上，往往会对效果有非常直接的帮助。例如，如图 15-2 所示，对同样一个汽车广告，对北京和上海地域的受众，分别加上当地经销商的联系电话。显然，对每个城市制作一版独立的素材是不经济的，应该在投放时动态加入与地域相关的信息。



图 15-2 同一汽车广告在北京（左）和上海（右）的地域型创意

（2）搜索重定向创意。根据用户的搜索行为提供的重定向图片广告，如果能明确标示搜索词，往往更容易唤起用户的注意力和兴趣。因此，可以采用图 15-3 所示的创意形式，将用户曾经的搜索词放在图片下方的搜索框中，现在这也需要投放系统在线自动完成。



图 15-3 搜索重定向创意示例

（3）个性化重定向创意。这种产品在 6.4.3 节已经做过具体介绍，其中展示的单品都是在线动态决定的（参见图 6-7），而创意也是在线合成的，这也是一种程序化的创意。

在线广告的服务对象由传统的品牌广告向效果广告发生了倾斜，传统的由设计人员主导的、品牌形象驱动的创意生产模式也一定会越来越多地加入机器决策的、效果导向的内容。因此，程序化的创意优化模式应该得到足够的重视。

15.1.2 点击热力图

在找出创意设计的问题、优化效果等方面，点击热力图是一个非常重要的工具。点击热力图是将某一个创意各位置被点击的密度用热力图的方式呈现出来，帮助创意优化者直观地发现和解决其中的问题。一般来说，创意中的若干主要信息聚焦点应该会比较集中地吸引用户点击。如图 15-4 所示^[16]，在创意中人物的眼神发生变化时，用户关注和点击的热点也有很大的区别。显然，在这样的点击热力图指导下，创意的迭代优化可以半定量地进行，并且更加有目的性。



图 15-4 创意中人物的眼神对点击热力图的影响

不过，在程序化创意的影响下，点击热力图的使用有一些障碍：由于在线时会对创意的部分内容作修改，这种情况下叠加在一起的热力图有时无法反映细节问题。不过对于创意中一些固定元素的优化或动态模块整体的效果评估，热力图还是很有帮助。

15.2 实验框架

无论是广告系统调整算法、架构，还是投放时调整创意、定向策略，都需要依赖线上的实际流量测试来确定其真实效果如何。切分部分流量用于测试并非难事，但是一个实用的实验框架需要尽可能多地同时容纳多组实验，以提高流量利用效率和产品进化速度。

设计这样一个实验系统的关键，是利用系统模块之间的相对独立性，用分层的结构来扩展实验容量。在参考文献 [69] 中，作者给出了比较典型的一种分层实验框架的架构，如图 15-5 所示。在这一架构中，不同的实验参数被分置于不同的实验层中，一般来说，可以按模块划分这些实验层，例如在广告系统中，按检索、排序和展现将相应的参数划分成三层，每层都可以将流量切分成不同的测试子集或域。显然，在这种分层结构下，不同层上的实验是可以共享流量的，这样就大大提升了同时进行的实验数目。另外，系统还预留了一个非重叠测试域（domain），目的是方便有时需要进行的、联合调整各层参数的一些特殊实验。除了实验层以外，此实验框架还涉及了专门的发布层，用于将实验通过的参数逐渐灰度发布到全流量上。同一个参数，只能出现在一个实验层和一个发布层中，而优先级关系是优先采用实验层参数，其次是发布层参数，最后是默认参数。这样的一个兼顾流量实验和灰度发布的实验框架在实践中能够满足大部分情形下的需求。




图 15-5 分层实验框架架构示意

那么在每一层中，流量是如何随机被分到各个域中的呢？对于广告系统而言，按照每次展示做随机分配是不合适的，这是因为多次广告展示之间的相关性会对测试的结果产生影响。正确的做法是按用户划分，即每个用户的广告展示请求都被固定地发送到同一个域中。这样做的目的是使得一个广告策略的高阶或长期影响能够真实地表现出来。

15.3 流量保护和效果监测

流量保护包括两方面的内容：一是对非主动用户访问行为，主要是爬虫行为的去除；二是反作弊，即对于恶意展示或流量来源的去除。从技术难度上看，我们主要关注的是后一个问题。反作弊的检测方案，在在线投放和离线统计中都有需求，并且是广告计价和其他数据统计的基础步骤。另一个在线完成的辅助任务是为广告主服务的广告监测服务，它为了完成广告的展示和点击计数，当然也需要一定的反作弊处理，因此这两个问题有着密切的联系。

15.3.1 反作弊

由于广告有很多的相关利益方，因此除了那些无恶意的、机器产生的流量，也会经常遇到欺骗性的展示或点击行为，即作弊。作弊的具体手段五花八门，无法一一列举，并且随着反作弊手段的进步而不断进步。要在面对广告作弊时快速找到思路，需要先搞清作弊者的目的。我们知道，广告活动是广告主、媒体与用户之间三方交互的行为，因此广告中的作弊行为主要有以下三种情况。

（1）媒体作弊。媒体是广告活动的主要受益者，因而作弊的动力也最强。由于大多数广告网络与媒体之间是按照点击的价格来结算，因此点击作弊是最为常见的，当然也存在为了满足 CPM 订单量的需求而对展示进行作弊的情形。这种作弊的花样繁多，既有将广

告展示和点击代码放在非约定位置上或非用户自然行为产生的流量上的方式，也有通过将广告位与内容靠得很近甚至相互重叠来骗取点击的方式。

(2) 广告平台作弊。广告网络或广告交易市场这样的广告平台也有制造虚假点击，以获取更多分成的目的。而 DSP 这样的需求方广告产品，除了混入劣质流量的广告展示、制造虚假点击以外，还会通过一些作弊手段为广告主带来虚假转化，以满足效果考核的要求。

(3) 广告主竞争对手作弊。某些广告主的竞争对手，会通过技术手段大量消耗该广告主的预算，达到降低其广告效果的非正常竞争目的。与媒体作弊不同，广告主的竞争对手很难通过控制广告展示的方式来作弊，而是通过多次重复点击广告的形式来作弊。由于通过单一 IP 或 cookie 大量点击广告很容易被发现，作弊方往往会通过频繁清除 cookie，改变 IP，甚至通过木马控制多台用户电脑来达到作弊的目的，当然，这样的作弊手段也被媒体或广告平台所采用。

单一 IP 或 cookie 在大量展示或点击的作弊方式是最容易去除的，只需要一定时间段内的展示或点击设定合理的上限，进而发现那些显著超过上限的 IP 或 cookie 并加入黑名单即可。

对于更复杂的，通过控制多台电脑来产生假点击的作弊方式，上面提到的点击热力图也是一个很有用的反作弊工具：正常的用户点击，在创意上的位置分布往往呈现与创意关键区域相关的比较自然的分布；而机器产生的用户点击，其分布要么过于均匀，要么过于集中，很容易与自然点击分布相区别。图 15-6 中给出了一个广告创意正常的点击热点分布与作弊的点击热点分布的示例，左侧是自然点击的热力图，右侧是有作弊行为的点击热力图。可以看出，除了自然点击区域外，还多了一些集中且均匀的点击分布，这些明显不符合正常用户的行为特征，可以认定为作弊行为。需要说明，认清作弊者的身份和动机对于用好点击热力图反作弊很有帮助，因为这关系到如何分解某个创意上的流量来绘制点击热力图，以发现明确的作弊信号。



图 15-6 自然点击热点图（左）与机器作弊点击热点图（右）对比

除了 cookie、IP 级别的统计以及点击热点图这些思路以外，如果广告系统能在 JavaScript 代码或 SDK 中收集到更多其他的物理信息，如展示时间、点击时间等，也会对于甄别作弊流量很有帮助。一般来说，在收集到比较充足的特征以后，可以建立一个反作弊的判断模型，用以过滤作弊行为。这样的模型需要有一个在线的实时计算版本，为在线计费和其他实时反馈模块做过滤；也需要有一个更加精细的离线版本，用于每天处理广告日志，得到最终确认的财务结算数据。由于反作弊特征和模型是广告系统高度保密的模块，在此不展开讨论其细节。

流量劫持

除了制造虚假展示和点击的作弊行为，在广告市场上还存在着通过非法手段获得广告展示或点击的准作弊行为，而其中最典型的情形就是流量劫持。

所谓流量劫持，就是在无权投放广告的地方强行投放，或者改变广告创意甚至落地页的内容。一般来说，只有一些网络底层服务的提供商，如 DNS、CDN、电信运营商等，才有能力进行这种劫持。流量劫持并非互联网广告的新问题，在电视广告中也存在这种现象，如图 15-7 中强行加入的滚动字幕广告。尽管流量劫持不是合法的商业产品，但在中国及东南亚等地区，这确是一个不能忽视的广告渠道，在服务于效果类广告主时，必须要了解其客观存在并加以应对。



图 15-7 电视广告流量劫持示例

下面通过几个例子了解流量劫持的具体手段。

(1) 信道弹窗。通过电信运营商对信道的控制能力，在用户上网时强行向下行内容中插入弹窗广告创意。这种形式在 PC 和移动设备上都存在，虽然 CCTV 在 2013 年“3·15”晚会对这种灰色广告渠道进行了曝光，但是至今仍然广泛存在，并且在移动设备上大有愈演愈烈之势。

(2) 创意替换。创意替换仍然是通过电信运营商的信道，将某些网站上的广告创意直接替换为其他创意，显然，这是一种比信道弹窗更加粗暴的劫持行为。

(3) 搜索结果重定向。由于搜索是高商业价值的流量，将搜索流量导向某些搜索引擎，可以获得其收入分成。因此，存在一种流量劫持手段，当用户在搜索引擎 A 输入某关键词以后，搜索的结果页会变成搜索引擎 B 提供的。或者在淘宝这类电商垂直搜索中，改变结果商品的排序或落地店铺。这虽然不是直接的广告劫持，但本质也是一样的。

(4) 落地页来源劫持。这是最为简单粗暴的一种劫持方式，它并不投放广告，而是在用户访问广告主落地页时，直接在 URL 上加上广告来源代码。比如，当用户访问 <http://mkt.mbaobao.com/a-hotalfshell1219> 这个广告主页面时，将其修改成 http://mkt.mbaobao.com/ahotalfshell1219?utm_source=*，这样广告主就会将其统计成某广告渠道带来的访问。

这些流量劫持手段中，前三种手段主要损害的是媒体利益，而对广告主来说，流量本身则是真实存在的。而第四种就是一种彻底的作弊行为了，损害的是广告主的利益。由于有这种非法劫持流量的存在，严重扰乱了正常的效果广告和程序化交易市场，客观上在中国形成了一个劣币驱逐良币的环境——毕竟努力提高技术和算法水平远不如去买低成本的非法流量效果来得快。因此，我们在这里呼吁大家，一起来抵制这种劫持流量，真正从产品技术方面扎扎实实地做一些有利于行业进步的事。

15.3.2 广告监测

在线广告区别于线下广告的重要特征就是可监测性。从需求方来看，存在切实的需要，委托某家第三方监测公司对实际发生的展示或点击数目进行核对，以确保自己的利益。不过监测的主要需求存在于按 CPT 或 CPM 结算的合约广告中。这是因为在竞价广告系统中，广告主与媒体之间并没有约定的价格，可以根据后续的效果来调整自己的出价，因此对展示或点击的监测并不是强需求。从这里我们可以看出，效果检测主要的服务对象是那些品牌广告主，一般会占有在线品牌广告投放 1% 左右的预算。

借助监测代码或者 SDK 实现广告展示或点击的计数并不困难。但是当广告投放基于受众进行时，监测就要困难多了。例如，某广告计划要求在男性用户流量上投放 1 000 千次的展示，那么如何才能确定投放的结果满足这一条件呢？一般采用的方案是广告监测提供商采用采样加付费的方式收集一个小比例人群上的真实用户属性，然后通过验证这个人群上性别的准确率来反推整体的投放数据。这一方法看起来十分简单，不过由于采样集一般规模不大，在人群分布上与投放人群相比可能存在较大的偏差，因此此方法的关键在于如何对数据进行有效的纠偏。另外，即便采用这样的方案，也只有部分基于人口属性信息的投放是可以验证的，而对于基于兴趣标签的投放，由于对同一个用户并不存在确定的标准答案，这样的监测意义不大。

由于实名社交网络的人口属性信息相对比较准确，又有很大的规模，因此现在的趋势是直接采用社交网络的数据作为标准来进行定向广告的监测。例如，尼尔森就与 Facebook 合作，推出了基于 Facebook 人口属性信息的广告监测服务。

当然，广告监测与反作弊有着密不可分的联系，所有展示或点击的计量都必须在去除了作弊流量的基础上进行。由于广告监测是代表需求方利益的服务，一般来说其反作弊规则比媒体方或广告平台更加有严格的动力。

15.3.3 广告安全

在越来越复杂的广告投放和交易逻辑当中，广告主已经很难像合约广告中那样非常明确地管理自己的投放媒体了。但是，实践中很多广告主又存在切实的需求，希望自己的广告不要出现在一些特定内容的媒体上。我们在第 2 章中曾经提及，广告预算除了被浪费的那部分，还存在一部分是会产生负面效果的，我们显然希望去掉这些有负面影响的展示。例如，汽车广告主不希望自己的广告出现在有关车祸内容的页面上，也不希望出现在一些低级庸俗内容的网站上。这样的需求，不是简单的广告可以完成的，而是需要专门的服务

来保证广告主的品牌安全，这样的问题称为广告安全问题。与广告安全相关的关键技术是广告投放验证（ad verification）和可视性（viewability）验证。

广告投放验证

广告投放验证的作用是确认品牌的安全性，并保证展示的质量。其工作模式是当广告投放到页面以后，如果发现页面的内容不符合品牌安全的诉求，则停止展示广告主的创意，转而展示一个与品牌无关的创意。与广告监测不同，这里的重点不在于计量效果，而在于阻止不恰当展示的发生。

读者可能会疑惑，既然是在不安全的页面上禁投广告，在广告请求到来时直接根据 URL 过滤不就可以了吗？在实际的广告交易中，由于多层 `iframe` 的嵌套，有时媒体会伪装自己的 URL 以达到流量以次充好的目的。比如，某些高质量媒体会将自己域名的 `iframe` 嵌套在其他小网站上以冒充自己的流量，从而获得高的溢价。因此，必须要在广告投放时，进行 `iframe` 穿透，实时判断投放页面的顶层 URL，才能进行广告投放验证。而页面的内容则可以采用第 12 章中的半在线抓取系统来获得。

当有了一些历史经验以后，也可以采用投放前的验证方案，也就是对那些历史上发现不符合品牌安全策略的 URL 或广告位直接不参与广告交易，这样可以进一步节约服务成本。

可视性验证

品牌广告主的另一个常见诉求是广告展示的曝光程度。显然，出现在第二屏的广告位比第一屏的广告位曝光程度要差很多。这个问题也属于广告安全的范畴。

可视性验证的技术方案一般是判断浏览器是否对广告创意发生了渲染过程，如果没有，那么这次展示实际上不是可视的。解决可视性验证，需要对各种浏览器做充分的针对性测试，目前的技术水平已经可以做到对 95% 以上的浏览器内广告流量进行可视性验证；但是在移动应用内广告中，目前还没有很好的检测办法。

可视性验证同样有投放前的方案，也就是对那些可视比例很低的广告位直接不参与广告交易。

15.4 隐私保护和数据安全

广告是一个典型的个性化系统，它需要大量使用用户的行为数据进行受众定向，同时，在广告市场中还存在着数据交易的产品。无论是受众定向还是数据交易，都需要谨慎地考虑对行为数据的使用是否会泄露用户的隐私；同时也要考虑拥有数据的利益方，特别是广告主，是否在广告市场中被平台或竞争对手获得和利用了自己的关键商业数据。

15.4.1 隐私保护问题

隐私问题讨论的是用户个人信息的安全性，不过对这个问题，市场上存在着一定的认识误区。实际上，隐私保护除了关心那些成批的用户资料泄露意外，更大的挑战是针对熟人的隐私窥探，即窥探者在了解被窥探者一些背景信息的基础上，即用这些背景信息进一步试图获取其更多的隐私信息。后面一种挑战由于可能是人工与机器相结合，而且对成本往往不敏感，给隐私带来的风险也最大。一个最生动的例子，可以参见“清华学生用自拍照推理出王珞丹住址”（<http://news.cntv.cn/ent/20110819/105071.shtml>）这篇报道，在这个例子里，一名清华学生通过分析王珞丹的微博发帖和照片，准确地得到了其住址这一隐私信息。下面我们来具体看一下隐私保护的问题和原则。

1. 隐私保护基本原则

隐私保护在互联网个性化服务发展的很早阶段就得到了大家的重视，欧盟的 A29 委员会也对此问题做过深入的研究和规范。目前，工业界有以下一些共识性的隐私保护原则。

(1) 要严格避免使用个人可辨识信息（Personal Identifiable Information, PII）。PII 是最为重要的隐私信息，它指的是那些被获取后可以被方便地定位到具体人的信息，例如身份证号、电话号码、电子邮件地址、家庭住址等。这些信息一旦被恶意获取，会给当事人带来非常大的不便和潜在风险，因此需要无条件地严格保护。需要说明，广告系统中经常使用的用户标识，如 cookie、IMEI 等，由于不具有方便地辨识人的作用，因此不属于 PII。

(2) 用户有权要求系统停止跟踪和使用自己的行为数据。如图 15-8 所示，当向用户提供行为定向广告时，广告提供商应该给出明确的提示，如图中的广告创意右上角的“AdChoices▶”。如果用户对自己的行为被使用感到不满，可以通过此入口得到更多的详细说明，并且可以通过说明页面上的“Opt Out”操作通知系统停止跟踪和使用自己的行为数据。系统得到通知后，必须停止记录该用户的行为信息，也不再向其投放行为定向广告。这样的入口给了用户决定是否接受个性化广告的权利，对特定情形下的隐私保护非常重要。




图 15-8 Ad Choices 示例

(3) 不应长期保留和使用用户行为数据。即使用户同意接受行为定向广告，广告平台在数据的使用和存储上也应该有所节制，长期保留用户行为对受众定向价值有限，同时又加大了数据泄露的风险。因此应该只保存一段时期以内的行为数据，过期的数据如果并非与业务直接相关，物理上不应再存储。

(4) 工程上还需要特别注意权限的严格分配和最小数据访问的原则。工程师在调试程序时，最好是使用采样过的、关键信息被匿名化处理过的数据子集，而在生产系统中通过特别的密钥访问原始数据全集。而不需要开发数据处理程序的人，包括管理层，也不应当有数据访问的权限。

上面的这些原则相当基本，也非常重要，是广告系统、推荐系统在用户行为数据使用中首先要遵循的。不过，这些原则并不能解决一些深层次的数据隐私泄露问题，对此我们还需要更加深入地认识与并给出对策。

2.Quasi-Identifier 与 K-Anonymity

PII 是可以辨识个人身份的隐私信息，那么是不是非 PII 的信息就无法辨识身份了呢？举个例子，假设有这样一条用户信息：“姓名：XXX；手机号：XXX；年龄：36；工作地点：上海市携程大厦；性别：男；职位：测试工程师；爱好：羽毛球；月薪：15000 元”。其中的“姓名”、“手机号”等 PII 已经被隐藏。不过，如果此用户的一个朋友看到这条记录，根据“年龄、工作地点、性别、职位、爱好”这些非 PII 的组合，还是很容易得知是谁的信息，从而也就得到了“月薪”这一隐私信息。

在上面的例子里，“年龄、工作地点、性别、职位、爱好”这组信息虽然单独看来都无法确定一个人，但组合在一起有可能让熟人确定出对应的人，这样的信息称为“Quasi-Identifier”。由于有这样的 Quasi-Identifier 的存在，即使没有提供 PII，仍然存在比较高的隐私泄露风险，这一点希望引起大家的注意。

有没有什么办法能够降低这一挑战带来的风险呢？简单的思路是将 Quasi-Identifier 做一定程度的泛化。例如，将“年龄：36 岁”泛化成“年龄：30~40 岁”；将“工作地点：上海市携程大厦”泛化成“工作地点：上海市”。如果泛化的结果，使得数据集里的每一组 Quasi-Identifier 的实例都能找到 K 条与其相同的，那么我们就说实现了 K-Anonymity。显然，当 K 的值取得比较合理时，隐私泄露的风险也就降低了不少。

Quasi-Identifier 与 K-Anonymity 并不是互联网隐私问题的产物，而是在数据库领域就有的研究。它给了我们很大的启发：当背景信息充分，而这些信息又较为稀疏时，隐私问题的挑战会变得更大。而在以互联网广告、推荐等为代表的个性化系统相关的数据交易中，这样的风险变得空前严峻。

3.稀疏行为数据的挑战

在计算广告这样的个性化互联网应用中，对一个用户的描述不再限于上面例子中的基本信息，而是包括了其大量的行为数据。行为数据的特点是极为稀疏，换句话说，任何两个用户的行为数据都几乎不可能是相同的，也很难通过 K-Anonymity 的方案来解决。那么是否可以通过行为数据来反推用户的隐私呢？答案是肯定的，而且有实际的案例发生。

在著名的 Netflix 百万美元推荐大赛^[5]中，主办方公布了比赛用的数据库，其中的关键用户信息已经去除了 PII，并做了 K-Anonymity 的处理。不过，用户的观影记录和打分由于是推荐使用的主要数据并未做处理。当数据公布后，恰好有一位关注者在数据中发现了一条记录，从其观看的影片和评价分数来看，集合可以确定无疑是自己的另一位朋友，而同样在这个用户观影记录中，还发现了一些同性恋题材的影片。读者显然明白这意味着什么，实际上，他的朋友不想为人所知的同性恋隐私被这样一个推荐大赛无意中泄露了。由于稀疏的行为数据很难通过简单技术处理模糊用户间的区别，再加上其他一些原因，这一大赛就没有继续举办下去。

在参考文献[60]中，作者对上面的隐私安全问题进行了更加系统的研究，发现通过简单的算法就可以将 Netflix 给出的数据与另一个 IMDb 给出的数据库进行用户身份上的对应，而且准确率相当高。抛开具体的方法不谈，这一研究向我们揭示的问题是：通过稀疏的行为数据，可以比较容易地定位自己熟悉的人，并进而获取其相关隐私信息。这一问题的发现使工业界对隐私安全问题的认识大大提高，也提醒我们在数据交易和泄漏过程中，要特别注意这方面巨大的风险。这也催生了与深度个性化系统中隐私安全相关的差分隐私（differential privacy）^[29]问题的研究。

坦率地讲，稀疏行为数据给隐私保护带来的巨大风险还并没有成熟的解决方案，这无疑将是大规模行为数据利用头上的达摩克利斯之剑。我们在实际的工业实践中，需要对此问题有一定程度的认识和理解，并尽可能考虑到自己的业务过程中与此相关的隐私安全风险。

15.4.2 程序化交易中的数据安全

程序化交易的产生使得在线广告市场可以综合利用需求方和供给方的数据来完成更加精准的广告决策。当然，这样的便利性也是一把双刃剑，在数据得到更加充分利用的同时，RTB 中供给方和需求方对于数据安全性的顾虑和诉求也必须加以考虑。

1. 供给方数据安全

我们先来看看供给方的数据安全性问题。由于在 RTB 过程中，ADX 需要向参与竞价的 DSP 广播每次展示的 URL 和 cookie，使得 DSP 理论上存在规模化监听媒体用户行为的可能。假设有某个恶意的 DSP 对于能够参与竞价的所有广告请求都以很低的价格参与竞价，

目的不在于赢得流量，而在于收集媒体上的用户行为，这就产生了媒体数据的安全问题，我们将其称为供给方数据安全，第 6 章介绍 RTB 原理时也曾经提到过这一问题。

供给方的数据安全问题尽管在 RTB 中确实存在，但是并不是想象中那样严重。可以回顾一下 14.1.2 节介绍过的询价优化技术：由于带宽的限制，实际上在每次询价时，ADX 应该尽可能只向那些最可能赢得竞价的 DSP 发送询价请求，而那些以恶意收集数据为目的的 DSP，在理想情况下应该被挡在大部分的询价以外。

2.需求方数据安全

再来看看需求方的数据安全性问题。在 RTB 的环境下，由于定制化标签的引入，广告主的第一方数据也暴露在了广告交易的过程中，而这些数据有的是广告主的核心数据，需要认真考虑其安全性问题。为了表达更加清楚，我们用图 15-9 所示的例子来说明。假设有两个英语教育类广告主“英孚教育”和“华尔街英语”，两者都通过 DSP 进行重定向访客找回，那么他们分别利用 RTB 的方式接触到了自己的访客集合。需要注意的是，这里的顾客集合实际上是广告主的私有数据，也是特别具有商业价值的数据，然而，DSP、ADX 和媒体都有可能在 RTB 过程中得到这些访客集合。如果 DSP 希望制造更加激烈的竞价环境，获得更高的利润，那么它实际上可以将这两个广告主的顾客集合合并在一起，并生产一个相应的用户标签吸引双方来对此标签竞价。这种做法的实质是在竞争对手之间倒卖顾客集合，并且可以通过比较模糊的标签名字（例如为上面两个广告主的访客集合打上“英语教育”的人群标签）非常隐蔽地操作。随着竞价激烈程度的增加，原本属于广告主的利润就向市场其他环节发生了转移，这个问题就是需求方数据安全性问题。




图 15-9 需求方数据安全问题示例

需求方数据安全性在某种意义上比供给方数据安全性更加重要，因为这决定了广告主是否可以放心地通过 RTB 进行广告采购。坦率地讲，当前的广告交易市场，对这个问题的重视程度和解决方案都还很不充分。所以要提醒广告主，在广告交易中使用自己的第一方数据时，特别是面对强势的广告平台时，要特别留意数据安全性的问题。

15.5 延伸思考

- 1.在移动广告中，流量保护可能会遇到哪些新问题？会有哪些新的方法和特征？
- 2.调研一下移动应用下载类广告的转化流程以及相应的监测环节，并比较其与标准展示广告监测的不同之处。
- 3.在一个电商平台上的某家网店中产生的用户行为数据，平台、网店和用户应该对这些数据的记录和使用分别拥有什么权利？

注 释

- [1].关于为什么要这样做，可以参照 12.3 节中的讨论。
- [2].不同的时间复杂度与索引的具体数据结构有关：采用哈希表索引时为 $O(1)$ ，采用树索引时为 $O(\log n)$
- [3].参见参考文献 [13] 中的具体讨论。
- [4].有时我们需要遍历所有数据或者使用很大内存才能得到目标函数的导数，这种情况实际上在工程中比问题不可导要更常遇到。
- [5].关于 Wolfe 条件的几何意义和其他细节，请参阅 [62] 中更详细的讨论。
- [6].地域定向虽然是受众定向的一种，但由于逻辑比较简单，在 CPT 广告中也会售卖，并且可以采用在前端代码中实现逻辑的方式。
- [7].这里没有考虑广义第二高价等定价机制的影响。
- [8].Free Disposal 指的是给某个合约投送的量超过合约要求是无收益也无损失的，这一点符合大多数广告合约的实际情况。
- [9].多维 γ 分布随机变量在归一化以后服从狄利克雷分布，也就是多项式分布的共轭先验形式。
- [10].参考文献[22]用一个通过历史行为决定参数的泊松分布来建模展示数量，我们认为，广告并非用户主动行为，因此不宜用历史行为来预测。
- [11].更快地利用用户行为反馈还有其他系统方面的需求，参见 13.3 节。
- [12].实际上，在排序阶段，我们都是按照这个参数等于 $N1$ 来处理的。
- [13].搜索广告中查询的过分泛化会对相关性有较大负面影响。因此，我们不提倡在搜索广告检索阶段利用短时用户标签，不过在排序阶段可以利用短时动态特征来加权那些用户更倾向于选择的结果。
- [14].不过，由于 EC 计算的不确定性和难以解释，这样的方案在实际品牌广告中可操作性并不强。
- [15].如果 DSP 不能确定代表广告主的利益，这种深度合作有可能会带来广告主高商业价值数据的安全性风险，参见 15.4.2.2 节中的讨论。
- [16].来源：<http://site.douban.com/106407/widget/notes/335509/note/252343905/>。此图是眼球追踪的热点图，不过考虑到其与点击热力图的一致性，我们仍用它来说明问题。

第四部分 附录

附录 A 主要术语及缩写索引

缩写	英文	中文	参考章节
4A	American Association of Advertising Agencies	美国广告代理协会	2.4.2
ADX	AD eXchange	广告交易平台	6.3, 14.1
	ad group	广告组	3.2
ADN	AD Network	广告网络	5.3, 13.3
	ad placement	广告放置	5.1.3, 13.2.2
	ad safety	广告安全	15.3.3
	affiliate	联盟	5.3, 7.1.4
	agreement-based advertising	合约广告	4, 11
AUC	Area Under Curve	曲线下面积	13.5.5
	auction-based advertising	竞价广告	5, 13
	audience targeting	受众定向	4.2, 12
ASN	Average Show Number		5.1.3
BoW	Bag of Words	词袋	10.1.2
	banner ad	横幅广告	1.3
	bayesian learning	贝叶斯学习	10.3.3
BT	Behaviorial Targeting	行为定向	12.3
	bid term	竞价关键词	5.1.1
	brand awareness	品牌广告	1.2
	call out optimization	询价优化	14.1.2
	campaign	广告计划	3.2
CoEC	Click on Expected Click		13.5.4
CoPC	Click on Predicted Click		14.2.2
CTR	Click Through Rate	点击率	2.3.1

续表

缩写	英文	中文	参考章节
	click value	点击价值	2.3.1
CF	Collaborative Filtering	协同过滤	13.2.1
	compact allocation plan	紧凑分配方案	11.3.1
	constrained optimization	带约束优化	10.2.1
	content as ad	内容即广告	7
CDN	Content Delivery Network	内容分发网络	11.1
	contextual advertising	上下文广告	1.4
	contextual targeting	上下文定向	4.2.1, 12.2
CVR	Conversion Rate	转化率	2.3.1
CPA	Cost per Action	按转化付费	2.3.2
CPC	Cost per Click	按点击付费	2.3.2
CPM	Cost per Mille	按千次展示付费	2.3.2
CPS	Cost per Sale	按销售额付费	2.3.2
CPT	Cost per Time	按时间付费	2.3.2
	creative	广告创意	3.2
CRM	Customer Relation Management	客户关系管理	3.1
	customized audience segmentation	定制化用户标签	6.1, 14.2.1
	data exchange	数据交易平台	6.6.4
DMP	Data Management Platform	数据管理平台	3.1, 6.6.3, 12.5
	demand	需求方	1.2
	demand constraint	需求约束	11.3.1
DSP	Demand Side Platform	需求方平台	6.4, 14.2
	demographical targeting	人口属性定向	14.2.1, 12.4
	direct response	直接效果广告	1.2
	display advertising	展示广告	1.4
	downhill simplex method	下降单纯形法	10.2.2
	dynamic allocation	动态分配	6.5
EDM	E-mail Direct Marketing	邮件定向营销广告	1.3
EM	Expectation-Maximization	最大期望	10.3.2
EC	Expected Click	期望点击	13.5.4
eCPM	Expected Cost per Mille	千次展示期望收入	2.3.1

续表

缩写	英文	中文	参考章节
	experimentation framework	实验框架	15.2
E&E	Explore and Exploit	探索与利用	13.6
	frequency capping	频次控制	11.2.2, 13.5.6
GaP	Gamma-Poisson	γ 泊松	12.2.2
GLM	Generalized Linear Model	广义线性模型	12.3
GSP	Generalized Second Price	广义第二高价	5.2.1
	geo-targeting	地域定向	4.2.1
	gradient descent	梯度下降法	10.2.3
GD	Guaranteed Delivery	担保式投送	4.3, 11.2
HWM	High Water Mark	高水位算法	11.3.4
	hyper-local targeting	精确位置定向	4.2.1
IDFA	Identifier for Advertising	广告专用用户标识符	6.6.1
IIS	Improved Iterative Scaling	改进的迭代缩放	13.5.2
IR	Information Retrieval	信息检索	10.1
	integrated marketing	整合营销	1.2
IMEI	International Mobile Equipment Identity		6.6.1
IAB	Interactive Advertising Bureau	交互广告局	2.4.1
	inventory	库存	1.4
IDF	Inverse Document Frequency	倒数文档频率	10.1.2
	landing page	落地页	2.3.1
LDA	Latent Dirichlet Allocation	潜在狄利克雷分配	12.2.2
LSA	Latent Semantic Analysis	潜在语义分析	12.2.2
L-BFGS	Limited-memory BFGS	有限内存 BFGS	13.5.2
LR	Logistic Regression	逻辑回归	13.5.1
	look-alike	新客推荐	4.2.1, 6.4.1, 6.4.4, 14.2.1
ML	Machine Learning	机器学习	10.3
MRP	Market Reserve Price	市场保留价	5.2.2
MRA	Maximal Representative Allocation	最大代表性分配	11.3.2
MAP	Maximum a Posterior	最大后验概率	10.3.3
ME	Maximum Entropy	最大熵	10.3.1

续表

缩写	英文	中文	参考章节
	mechanism design	机制设计	5.2
	media buying platform	媒介采买平台	1.4
ML	Mixture Model	混合模型	10.3.2
MoG	Mixture of Gaussians	高斯混合模型	10.3.2
	mobile ad	移动广告	7.2
MAB	Multi-Arm Bandit	多臂老虎机	13.6
	native ad	原生广告	7.1, 7.3
	network optimization	网络优化	6.5.1, 14.3
NFP	North Foot Print	北区广告平均条数	5.1.3
	off-site recommendation	站外推荐	6.4.3
	online allocation	在线分配	4.3.3, 11.3
PII	Personal Identifiable Information	个人可辨识信息	15.4
	personalized recommendation	个性化推荐	13.2.1
	personalized retargeting	个性化重定向	6.4.3
	position auction	位置拍卖	5.2
PR	Precision/Recall		13.5.5
	preferred deals	优选	6.2
	premium sales	优先销售	6.2
	pricing	定价	5.2.1
PMP	Private Marketplace	私有交易市场	6.2
PLSI	Probabilistic Latent Semantic Indexing		12.2.2
	programmatic trade	程序化交易	6, 14
	query	查询	13.2
	reach	到达率	2.3.1
RTB	Real Time Bidding	实时竞价	6.1
ROC	Receive Operating Characteristic	接收机操作特性	13.5.5
	remnant inventory	剩余流量	5.3
	retargeting	重定向	6.4.3
ROI	Return on Investment	投入产出比	1.2
RPM	Revenue per Mille	千次展示收益	1.4
	rich media ad	富媒体广告	1.3

续表

缩写	英文	中文	参考章节
	search ad	搜索广告	5.1
SEM	Search engine marketing	搜索引擎营销	5.4
	search retargeting	搜索重定向	6.4.3
	second price	第二高价	5.2.1
SVD	Singular Value Decomposition	奇异值分解	12.2.2
	site retargeting	网站重定向	6.4.3
	social ad	社交广告	1.3, 7.1.1
	sponsored search	付费搜索	5.1
SGD	Stochastic Gradient Descent	随机梯度下降	10.2.3
	stream computing	流计算	9.1, 13.3
	sufficient statistics	充分统计量	10.3.1
	supply	供给方	1.2
	supply constraint	供给约束	11.3.1
SSP	Supply Side Platform	供给方平台	6.5, 14.3
	targeted advertising	定向广告	1.4
TD	Trading Desk	交易终端	5.4.2
TF	Term Frequency	词频	10.1.3
	textual ad	文字链广告	1.3
	topic model	文本主题模型	12.2.2
	traffic forecasting	流量预测	4.3.1
TP	Traffic Protection	流量保护	15.3
	traffic shaping	流量塑形	4.3.2
UCB	Upper Confidence Bound	置信上界	13.6.1
VSM	Vector Space Model	向量空间模型	10.1.2
	vertical ad network	垂直广告网络	5.3.3
VCG	Vickrey - Clarke - Groves		5.2.1
	video ad	视频广告	1.3
WA	Web Analytics	网站分析	3.1

参考文献

[1] AKELLA R, BRODER A, JOSIFOVSKI V.Introduction to computational advertising[C].Meet-ing of the Association for Computational Linguistics, 2011.<https://classes.soe.ucsc.edu/ism293/Spring09/material/Lecture%201.pdf>.

- [2] ANDERSON Q.Storm 实时数据处理[M].卢誉声, 译.北京: 机械工业出版社, 2014.
- [3] ARENSW.当代广告学[M].丁俊杰, 程坪, 译.北京: 人民邮电出版社, 2005.
- [4] AUDIBERT J Y, MUNOS R, SZEPESVARI C.Use of variance estimation in the multi-armed bandit problem[C].Proceedings of NIPS'06, 2006.
- [5] BENNETT J, LANNING S.The Netflix Prize[C].Kdd Cup & Workshop in Conjunction with Kdd, 2007.
- [6] BERGER A, PIETRA S AD, PIETRA V JD.A maximum entropy approach to natural language processing[J].Computational Linguistics, 1996, 22 (1) :39-71.
- [7] BERGER A.The Improved Iterative Scaling Algorithm, a Gentle Introduction[M].Pittsburgh:Carnegie MellonUniversity Press, 1997.
- [8] BHARADWAJ V, CHEN P, MA W, et al.SHALE: an efficient algorithm for allocation of guar-anteed display advertising[C].Proceedings of KDD, 2012:1195-1203.
- [9] BISHOP C M.Pattern recognition and machine learning.springer[J].IEEE Transactions on PatternAnalysis and Machine Intelligence (PAMI) , 2006, 16 (4) :049901.
- [10] BLEI D M, NG A Y, JORDAN M I.Latent dirichletallocation[J].Journal of Machine Learning Research, 2003, 3:993-1022.
- [11] BLEI D M, MCAULIFFE J D.Supervised Topic Models[C].Proceedings of NIPS, 2007:993-1022.
- [12] BOTTOU L.Large-scale machine learning with stochastic gradient descent[C].Proceedings ofCOMPSTAT'10.2010.
- [13] BOYD S, VANDENBERGHE L.Convex Optimization[M].Cambridge: Cambridge University Press, 2004.
- [14] BOYD S, PARIKH N, CHU E, et al.Distributed Optimization and Statistical Learning via the Alternating Direction Method of Multipliers[J].Foundations&Trends in Machine Learning, 2010, 3 (1) :883-898 (16) .
- [15] BRODER A Z, CARMEL D, HERSCOVICI M, et al.Efficient Query Evaluation Using a Twolevel-Retrieval Process[C].Proceedings of CIKM'03, 2003: 426-434.
- [16] BURGESS C JC.A Tutorial on Support Vector Machines for Pattern Recognition.Data Mining and Knowledge Discovery[J].Data Mining&Knowledge Discovery, 1998, 2 (2) :121-167.
- [17] BURROWS M.The Chubby lock service for loosely-coupled distributed systems[C].Proceedings ofOSDI'06, 2006.

- [18] CANNY J. GaP: a factor model for discrete data[C]. Proceedings of SIGIR. 2004:122-129.
- [19] CHAKRABORTY T, EVEN-DAR E, GUHA S, et al. Internet and Network Economics[C]. Proceedings of WINE'10, 2010:145-157.
- [20] CHANG F, DEAN J, GHEMAWAT S, et al. Bigtable: A Distributed Storage System For Structured Data[J]. ACM Transactions on Computer Systems, 2008, 26 (2) .
- [21] 陈超. Spark 大数据平台[M]. 北京, 2014. <http://www.chinahadoop.cn/course/7>.
- [22] CHENYE, PAVLOV D, CANNY J F. Large-scale behavioral targeting[C]. Proceedings of KDD, 2009:426-434.
- [23] CHEN PEIJI, MA WENJING, MANDALAPU S, et al. Ad Serving Using a Compact Allocation-Plan[M]. [S.I]:[s.n], 2012.
- [24] CLARKE E H. Multipart pricing of public goods[J]. Public Choice, 1971, 11 (1) :17-33.
- [25] CUI YING, ZHANG RUOFEI, LI WEI, et al. Bid landscape forecasting in online ad exchange marketplace[J]. Proceedings of KDD'11, 2011:265-273.
- [26] DEAN J, GHEMAWAT S. MapReduce: Simplified Data Processing on Large Clusters[C]. Proceedings of OSDI'04, 2004.
- [27] DEERWESTER S, DUMAIS S T, FURNAS G W, et al. Richard Harshman Indexing by Latent Semantic Analysis[J]. Journal of the American Society for Information Science, 1990, 41 (6) :391-407.
- [28] DEMPSTER A. P, LAIRD N. M, RUBIN D. B. Maximum likelihood from incomplete data via the EM algorithm[J]. Journal of the Royal Statistical Society, 1977, 39 (1) :1-38.
- [29] DWORK C. Differential Privacy: A Survey of Results[J]. Theory and Applications of Models of Computation, 2008, 4978:1-19.
- [30] EDELMAN B, OSTROVSKY M, SCHWARZ M, et al. Internet Advertising and the Generalized Second Price Auction: Selling Billions of Dollars Worth of Keywords. Working paper 2005[J]. American Economic Review, 2005, 97 (1) :242-259.
- [31] FELDMAN J, KORULA N, MIRROKNI V, et al. Online Ad Assignment with Free Disposal[C]. Proceedings of WINE, 2009:374-385.
- [32] FREUND Y, SCHAPIRE R E. A Short Introduction to Boosting ("Recent Developments in the Theory and Applications of Machine Learning") [J]. Journal of Japanese Society for Artificial Intelligence, 1999, 14 (5) :771-780.

- [33] GATES A F. Pig: A Structured, High-Level Dataflow System for Hadoop[M].[S.I]:[s.n.].
- [34] GHEMAWAT S, GOBIOFF H, LEUNG S T. The Google File System[C]. Proceedings of SOSP, 2003.
- [35] GHOSH A, MCAFEE P, PAPINENI K, VASSILVITSKII S. Representative Allocations for Guaranteed Display Advertising[J]. Manual script, 2009.
- [36] GILL J. Generalized Linear Model: a Unified Approach[M]. London: SAGE publications, 2000.
- [37] GITTINS J. Bandit processes and dynamic allocation indices[J]. Journal of the Royal Statistical Society. 1979:148-177.
- [38] GROVES T. Incentives in teams[C]. //Econometrica. 1973:617-31.
- [39] HOFMANN T. Probabilistic Latent Semantic Indexing[C]. Proceedings of Proceedings of SIGIR, 2009:0-57.
- [40] IAB. Digital Video Ad Serving Template (VAST) 3.0[EB/OL]. 北京. 2014. <http://www.iab.net/media/file/VASTv3.0.pdf>.
- [41] IAB. OpenRTB API Specification Version 2.2.[EB/OL]. 北京. 2014. <http://www.iab.net/media/file/OpenRTBAPISpecificationVersion2.2.pdf>.
- [42] JANSEN B J, MULLEN T. Sponsored search: an overview of the concept, history, and technology[J]. International Journal of Electronic Business, 2008.
- [43] JORDAN M I., GHAHRAMANI Z, JAAKKOLA T S., et al. An Introduction to Variational Methods for Graphical Models[J]. Machine Learning, 1999, 37 (2) :183-233.
- [44] JUNQUEIRA F, REED B. Zookeeper: Distributed Process Coordination[M]. O'Reilly Media, 2013.
- [45] KARAUH. Spark 快速数据处理[M]. 余璜, 张磊, 译. 北京: 机械工业出版社, 2014.
- [46] KOREN Y. Factorization meets the neighborhood: a multifaceted collaborative filtering model[C]. Proceedings of KDD'08, 2008:426-434.
- [47] KING G, ZENG L. Logistic Regression in Rare Events Data[J]. Political Analysis, 2002, 9 (2) :137-163.
- [48] KRUGMAN H E. The Impact of Television Advertising: Learning Without Involvement [J]. Public Opinion Quarterly, 1965, 29 (3) :349-356.
- [49] LAMPORT L. Paxos Made Simple[N]. SIGACT News. 2001:32 (4) 51-58.
- [50] LIHONG LI, WEI CHU, LANGFORD J, et al. A Contextual-Bandit Approach to Personalized News Article Recommendation[C]. Proceedings of WWW'10. 2010:661-670.

- [51] 李子骅.Redis 入门指南[M].北京: 人民邮电出版社, 2013.
- [52] LIN C J, WENG R C, KEERTHI S S.Trust Region Newton Method for Large-Scale Logistic Regression[J].Journal of Machine Learning Research, 2008, 9 (2) :627-650.
- [53] 刘奕群, 马少平, 洪涛, 等.搜索引擎技术基础[M].北京: 清华大学出版社, 2010.
- [54] MALOUF R.A Comparison Of Algorithms For Maximum Entropy Parameter Estimation[J].Pro-ceedings of 6th Conference on Natural Language Learning, 2002:1-7.
- [55] MARKOWITZ H M.Portfolio Selection: Efficient Diversification of Investment[R].London:John Wiley&Sons, Inc , 1959.
- [56] MAYERS.V, CUKIER K.Big Data: A Revolution That Transforms How we Work, Live, and Think[J].Houghton Mifflin Harcourt, 2012.
- [57] MCCANDLESS M, HATCHER E, GOSPODNETICO.Lucene 实战[M].牛长流, 肖宇, 译.2 版.北京: 人民邮电出版社, 2011.
- [58] MELVILLE P, SINDHWANI V.Recommender Systems.Encyclopedia of Machine Learning[M].Berlin:Springer, 2010.
- [59] MEHTAA, SABERI A, VAZIRANI U, et al.Adwords And Generalized Online Matching[J].Jour-nal of ACM, 2007, 54 (5) :264-273.
- [60] NARAYANAN A, SHMATIKOV V.Robust De-anonymization of Large Sparse Datasets[C].Pro-ceedings of IEEE Symposium on Security and Privacy.IEEE, 2008:111-125.
- [61] NEWMAN D, ASUNCION A, SMYTH P, et al.Distributed Inference for Latent Dirichlet Allo-cation[C].Proceedings of NIPS'08.2008.
- [62] NOCEDAL J, WRIGHT S J.Numerical Optimization[J].Springer.1999.
- [63] OLSTON C, REED B, SRIVASTAVA U, et al.PigLatin: a not-so-foreign language for data processing[C].Proceedings of SIGMOD'08, 2008:1099-1110.
- [64] OSTROVSKY M, SCHWARZ M.Reserve Prices in Internet Advertising Auctions: A Field Ex-periment[J].Stanford University Graduate School of Business Research., 2009, (2054) :59-60.
- [65] PEROTTE A, BARTLETT N, ELHADAD N, et al.Hierarchically Supervised Latent Dirichlet Allocation[C].Proceedings of NIPS'11, 2011.
- [66] PRESS W H.Numerical Recipe [M].3rd ed.Cambridge: Cambridge University Press, 2007.
- [67] SLEE M, AGARWAL A, KWIATKOWSKI M.Thrift: Scalable cross-language services implemen-tation[J].Facebook White Paper, 2007.

- [68] SU XIAOYUAN, KHOSHGOFTAAR T M.A Survey of Collaborative Filtering Techniques[J].Advances in Artificial Intelligence, 2009.
- [69] TANG D, AGARWAL A, BRIEN D O, et al.Meyer M.Overlapping experiment infrastructure:more, better, faster experimentation[C].Proceedings of KDD'10, 2010.
- [70] 陶辉.深入理解 Nginx: 模块开发与架构解析[M].北京: 机械工业出版社, 2013.
- [71] TURNEY P D, PANTEL P.From Frequency to Meaning: Vector Space Models of Semantics[J].Journal of Artificial Intelligence Research, 2010:141-188.
- [72] VARIAN H R.Position auctions[J].International Journal of Industrial Organization, 2007, 25 (6) :1163-1178.
- [73] VEE E, VASSILVITSKII S, SHANMUGASUNDARAM J.Optimal online assignment with fore-casts[C].Proceedings of the ACM Conference on Electronic Commerce, 2010.
- [74] VICKREY W.Counterspeculation, Auctions, and Competitive Sealed Tenders.[J].Journal of Finance.1961:8-37.
- [75] WANG XUERUI, BRODER A, FONTOURA M, et al.A Search-Based Method For Forecasting Ad Impression In Contextual Advertising[C].Proceedings of WWW'09.2009: 491-500.
- [76] WHANG S E, MOLINA H G.Indexing Boolean Expressions.[C].Proceedings of VLDB, 2009, 2 (1) .
- [77] WHITET.Hadoop 权威指南[M].周敏奇, 钱卫宁, 金澈清, 等, 译.2 版.北京: 清华大学出版社, 2011.
- [78] ZAHARIA M, CHOWDHURY M, MA J, et al.Spark: cluster computing with working sets[M].[S.l.]:[s.n.], 2010.
- [79] FORUM M P.MPI:A message-passing interface standard [J].Proc ACM International Conference on Supercompting, 1994, 20 (2) : 179.
- [80] 赵必厦, 程丽明.从零开始学 Storm.[M].北京: 清华大学出版社, 2014.
- [81] YI ZHU, WILBUR K C.Hybrid Advertising Auctions[J].Social Science Electronic Publishing, 2011, 30 (2) :249-273.
- [82] ZINKEVICH M A, SMOLA A, WEIMER M, et al.Parallelized Stochastic Gradient Descent[C].Proceedings of NIPS'10, 2010.
- [83] ZOBEL J, MOFFAT A.Inverted Files For Text Search Engines[J].ACM Computing Surveys Surveys, 2006, 38 (4) .